

Graph Neural Networks e Álgebra Geométrica para Otimização Aero-Stealth de UCAVs

**Modelagem multifidelidade de Maxwell e Euler e aceleração da otimização
multidisciplinar**

Índice

UCAV Aero-Stealth Optimization with Multifidelity Graph Neural Networks	9
Sobre este projeto	9
Objetivo geral	9
Arquitetura da pesquisa	10
Questões metodológicas centrais	10
Organização do eBook	11
1 Contexto e Definição do Problema Aero-Stealth de um UCAV	12
1.1 UCAV: conceito, escopo e terminologia	12
1.2 UCAV como problema de engenharia multidisciplinar	13
1.3 Continuidade em relação à caracterização de RCS	13
1.4 Fidelidade e modelagem multifidelidade	14
1.5 Radar Cross Section como resposta de projeto	15
1.6 Desempenho aerodinâmico no regime subsônico	16
1.7 Estado da arte em otimização aero-stealth de UCAVs	16
1.8 GNNs para análise aerodinâmica e eletromagnética	17
1.9 Lacuna de pesquisa	18
1.10 Justificativa	18
1.11 Formulação inicial do problema multidisciplinar	19
1.12 Papel das GNNs e da multifidelidade na otimização	20
1.13 Quantificação de incerteza e aprendizado ativo como estratégias auxiliares	20
1.14 Questão de pesquisa	21
1.15 Objetivo geral	21
1.16 Objetivos específicos	21
1.17 Hipóteses de pesquisa	22
1.18 Métricas de avaliação	23
1.19 Estudos de ablação	23
1.20 Progressão experimental de 2D para 3D	24
1.21 Delimitação do estudo	24
2 Álgebra Geométrica para representação física, geométrica e computacional	25
2.1 Partindo de objetos familiares: vetores, comprimento, ângulo e orientação	25
2.2 Do espaço vetorial métrico à álgebra de Clifford	26
2.2.1 O espaço vetorial e a métrica	26
2.2.2 A relação fundamental de Clifford	27

2.3	Produto geométrico, produto interno e produto exterior	28
2.3.1	O produto geométrico de dois vetores	28
2.3.2	Casos geométricos importantes	29
2.3.3	O produto exterior como área orientada	30
2.3.4	Associatividade e não comutatividade	30
2.3.5	Produto de um vetor por um elemento de grau definido	31
2.4	Grades, blades e multivetores	31
2.4.1	O que significa grau	31
2.4.2	Blades: objetos simples de grau definido	32
2.4.3	Multivetores: diferentes graus no mesmo elemento	32
2.4.4	Por que aparecem 2^n componentes	33
2.5	Bases, métrica e independência de coordenadas	34
2.5.1	Objeto geométrico e componentes	34
2.5.2	O conceito de base recíproca	34
2.6	Pseudoescalar e dualidade	36
2.6.1	O elemento de grau máximo	36
2.6.2	Dualidade como correspondência entre dimensões complementares	37
2.7	Involuções, reversão, conjugação e inversa	38
2.7.1	Por que são necessárias operações involutivas	38
2.7.2	Involução de grau	38
2.7.3	Reversão	38
2.7.4	Conjugação de Clifford	39
2.7.5	Inversa de vetores e versores	39
2.8	Projeção, rejeição, reflexão e rotação	40
2.8.1	Decompondo um vetor em partes paralela e perpendicular	40
2.8.2	Reflexão	41
2.8.3	De duas reflexões a uma rotação	41
2.9	Aplicações lineares, tensores, dyadics e matrizes	42
2.9.1	Aplicação linear e sua matriz	42
2.9.2	Dyadics como operadores lineares	43
2.9.3	Tensor não é sinônimo de multivetor	43
2.10	Outermorphisms e extensão de transformações	44
2.10.1	Por que uma transformação de vetores precisa ser estendida	44
2.10.2	Exemplo: transformação de área	45
2.11	Derivada geométrica e cálculo de campos	45
2.11.1	Da derivada direcional ao operador vetorial	45
2.11.2	Divergência: expansão ou compressão local	46
2.11.3	Derivada exterior: circulação local orientada	46
2.12	Ponte computacional para geometrias bidimensionais	47
2.13	Representação geométrica de malhas	48
2.13.1	De vértices a arestas	48
2.13.2	A face como bivector de área	48
2.13.3	Da face orientada à normal	49

2.13.4	Relações entre faces vizinhas	49
2.13.5	Estados multivetoriais em nós ou faces	50
2.14	Ponte para o eletromagnetismo	50
2.14.1	Campo eletromagnético como bivector de espaço-tempo	50
2.15	Ponte para a dinâmica dos fluidos	51
2.15.1	Vorticidade como bivector	51
2.15.2	O termo convectivo continua não linear	51
2.16	Ponte para Graph Neural Networks	52
2.16.1	Por que a geometria interessa ao aprendizado em grafos	52
2.16.2	Uma mensagem geometricamente estruturada	52
2.16.3	Estudos de ablação	53
2.17	Crítérios computacionais	53
2.18	Síntese	53
3	Física governante: eletromagnetismo, RCS e aerodinâmica compressível	55
3.1	Parte I — Eletromagnetismo, espalhamento e Radar Cross Section	55
3.2	Do campo eletromagnético às equações de Maxwell	55
3.2.1	Campos, fontes e meio material	55
3.2.2	As quatro equações de Maxwell	57
3.3	Do domínio do tempo ao domínio da frequência	57
3.3.1	Por que usar fasores?	57
3.3.2	Maxwell no domínio da frequência	59
3.4	O problema de espalhamento eletromagnético	60
3.4.1	Campo incidente, campo espalhado e campo total	60
3.4.2	Onda plana incidente	60
3.4.3	Condições de contorno	61
3.5	Do campo próximo ao campo distante	62
3.5.1	Intuição física	62
3.5.2	Radar Cross Section como área equivalente	62
3.5.3	RCS monoestática e biestática	63
3.5.4	Polarização	63
3.6	Mecanismos de espalhamento e geometria da aeronave	64
3.7	Métodos numéricos e níveis de fidelidade eletromagnética	64
3.8	Maxwell em Álgebra Geométrica do espaço-tempo	65
3.8.1	Da separação $\mathbf{E}/\mathbf{B}$ a um único campo geométrico	65
3.8.2	O operador derivada no espaço-tempo	65
3.8.3	O campo de Faraday como bivector	66
3.8.4	O que a formulação compacta faz — e o que não faz	67
3.9	Validação eletromagnética progressiva	67
3.10	Parte II — Aerodinâmica compressível e equações de Euler	67
3.11	Do escoamento contínuo ao sistema de conservação	67
3.11.1	O que o modelo de fluido representa	67
3.11.2	Hipóteses do modelo	68

3.11.3	Variáveis primitivas e significado físico	68
3.11.4	Velocidade do som e número de Mach	69
3.12	Conservação de massa	70
3.12.1	Intuição: o que entra, o que sai e o que se acumula	70
3.13	Conservação de quantidade de movimento	70
3.13.1	Da segunda lei de Newton ao fluxo por uma superfície	70
3.14	Conservação de energia	72
3.15	Por que os solvers usam variáveis conservativas?	72
3.16	Condições de contorno aerodinâmicas	73
3.16.1	Parede invíscida: não penetração	73
3.16.2	Campo distante e condição de voo	73
3.16.3	Simetria	73
3.17	Da pressão superficial a forças, momentos e coeficientes	74
3.17.1	Pressão local	74
3.17.2	Força e momento integrados	74
3.18	A derivada geométrica e a estrutura local do escoamento	75
3.19	O termo convectivo e a não linearidade de Euler	76
3.19.1	Por que um escoamento permanente ainda pode acelerar?	76
3.20	Vorticidade, vetor de Lamb e analogias com Maxwell	77
3.21	O que pode ser representado por multivetores — e o que continua sendo operador	77
3.22	Métodos e níveis de fidelidade aerodinâmica	78
3.23	Validação aerodinâmica progressiva	78
3.24	Problemas bidimensionais e respostas tridimensionais	78
3.25	Ponte entre os dois domínios físicos e as GNNs	79
3.26	Resíduos físicos como informação de treinamento	80
3.27	Síntese do capítulo	81
4	Graph Neural Networks para modelagem substituta baseada em malhas	82
4.1	Da malha numérica ao grafo	82
4.1.1	Por que não tratar a geometria apenas como um vetor?	82
4.1.2	Definição de grafo e atributos	83
4.1.3	Grafo primal, grafo de faces e grafo de células	83
4.1.4	O que a conectividade preserva — e o que ela não preserva	84
4.2	Message Passing Neural Networks	84
4.2.1	Intuição: informação que percorre a conectividade	84
4.2.2	Formalização de uma camada	85
4.2.3	Exemplo mínimo e campo receptivo	86
4.3	Do message passing ao Geometric Deep Learning	86
4.4	Encoder, processador, decoder e readout	87
4.5	Aprender um simulador dinâmico não é o mesmo que aprender um surrogate estacionário	87
4.6	Localidade, longo alcance e escala da malha	88

4.7	Construção dos atributos do grafo	88
4.7.1	Geometria relativa	88
4.7.2	Condições globais e parâmetros físicos	89
4.7.3	Normalização e adimensionalização	90
4.8	Álgebra Geométrica como fonte de estrutura	90
4.9	Invariância, equivariância e simetrias físicas	91
4.9.1	Permutação de nós	91
4.9.2	Translação e rotação	91
4.10	Reparametrização e remalhamento	92
4.11	Campos locais e respostas globais	92
4.11.1	Predição direta de coeficientes	92
4.11.2	Predição de campo seguida de integração	93
4.11.3	Aprendizado multitarefa	93
4.12	Surrogate eletromagnético	94
4.12.1	O problema de entrada e saída	94
4.12.2	Grade angular fixa ou consulta condicionada	95
4.12.3	Prever RCS diretamente ou prever campos intermediários?	95
4.12.4	Escala linear e escala logarítmica	96
4.13	Surrogate aerodinâmico	96
4.13.1	O problema de entrada e saída	96
4.13.2	Perda de campo ponderada por área	97
4.14	Física incorporada ao aprendizado	97
4.14.1	Quando um resíduo de PDE é realmente calculável?	98
4.15	Surrogates separados ou arquitetura multitarefa?	99
4.16	Generalização e prevenção de vazamento de dados	99
4.16.1	Divisão por geometria	99
4.16.2	Interpolação, extrapolação e domínio de aplicabilidade	99
4.17	Métricas de erro para campos e respostas integradas	100
4.18	Precisão não é o mesmo que utilidade para otimização	101
4.19	Incerteza e domínio de aplicabilidade	101
4.20	Ponte para multifidelidade	102
4.21	Estudos de ablação e comparação justa	102
4.22	Posição em relação à literatura recente	102
4.23	Arquitetura conceitual do framework	103
4.24	Progressão experimental dos grafos 2D para 3D	104
4.25	Síntese	104
5	Modelagem multifidelidade, parametrização e representação geométrica do estudo 2D	105
5.1	Escopo do estudo bidimensional	105
5.2	Parametrização geométrica e vetor de projeto	105
5.3	Design of Experiments e construção do banco de dados	106
5.4	Unidade de amostragem e identificação das configurações	107

5.5	Contrato inicial dos dados em CSV	107
5.6	Reconstrução geométrica em $Cl(2,0)$	108
5.7	Do CSV ao grafo	109
5.8	Respostas globais e campos locais	109
5.9	Consistência de L/D	110
5.10	Definição de fidelidade no conjunto 2D	110
5.11	Estratégias multifidelidade a avaliar	111
5.12	Reprodutibilidade da preparação dos dados	111
5.13	Especificação computacional de referência	111
5.13.1	Features geométricas de referência	112
5.13.2	Serialização e rastreabilidade	112
5.14	Limites da primeira etapa computacional	113
5.15	Saídas computacionais deste capítulo	113
6	GNNs, treinamento, validação e otimização no estudo 2D	114
6.1	Pipeline executável	114
6.2	Reprodutibilidade	114
6.3	Jobs configuráveis	115
6.4	Baselines e ablações	115
6.5	Surrogate aerodinâmico 2D	115
6.6	Surrogate eletromagnético 2D	116
6.7	Modelos separados antes do compartilhamento	116
6.8	Treinamento, validação e teste	117
6.9	Métricas preditivas	117
6.10	Métricas de recursos	117
6.11	Artefatos de cada execução	117
6.12	Enriquecimento sequencial e aprendizado ativo	118
6.13	Otimização: pré-condição geométrica	118
6.14	Formulação aero-stealth 2D	119
6.15	Ponte para o estudo 3D	120
7	Modelagem multifidelidade e representação geométrica do estudo 3D	121
7.1	Geometrias UCAV e parametrização 3D	121
7.2	Design of Experiments e banco de dados 3D	121
7.3	Malhas superficiais e grafos	121
7.4	Álgebra Geométrica em $Cl(3,0)$	122
7.5	Aerodinâmica tridimensional	122
7.6	Espalhamento eletromagnético tridimensional	122
7.7	Fidelidades EM e aero	122
7.8	Correspondência entre fidelidades	123
7.9	Dados, manifestos e rastreabilidade	123
7.10	Transferência do pipeline 2D	123
7.11	Critérios de prontidão para o Capítulo 8	123

8	GNNs multifidelidade e otimização aero-stealth no estudo 3D	124
8.1	Baselines tridimensionais	124
8.2	Surrogate aerodinâmico 3D	124
8.3	Surrogate eletromagnético 3D	124
8.4	Multifidelidade tridimensional	125
8.5	Modelos separados e multitarefa	125
8.6	Interações de longo alcance	125
8.7	Variáveis de projeto	125
8.8	Objetivos e restrições	125
8.9	Otimização assistida por surrogate	126
8.10	Enriquecimento sequencial em regiões relevantes	126
8.11	Reavaliação e qualidade de Pareto	126
8.12	Recursos e aceleração end-to-end	126
8.13	Validação final	127

UCAV Aero-Stealth Optimization with Multifidelity Graph Neural Networks

Sobre este projeto

Este eBook documenta o desenvolvimento de um framework de otimização multidisciplinar aero-stealth para **configurações UCAV de baixa observabilidade**. A expressão UCAV (*Unmanned Combat Aerial Vehicle*) designa uma classe funcional de aeronave não tripulada de combate e não uma configuração aerodinâmica específica. Configurações sem cauda, *flying-wing*, *blended-wing-body* e outras famílias geométricas podem ser consideradas conforme o espaço de projeto for formalizado.

A contribuição computacional central é o emprego de **Graph Neural Networks (GNNs) multifidelidade** como modelos substitutos para reduzir a demanda de recursos computacionais e o tempo de processamento das avaliações eletromagnéticas e aerodinâmicas repetidas durante a otimização.

A **Álgebra Geométrica (AG)** é adotada como formalismo matemático estruturante para representar geometria, operações físicas e relações empregadas no aprendizado e na otimização. O projeto buscará formulações multivetoriais mais compactas e, quando matematicamente admissível, representações lineares nos objetos algébricos escolhidos, preservando explicitamente as não linearidades físicas intrínsecas.

Objetivo geral

Desenvolver e validar um framework de otimização multidisciplinar aero-stealth para configurações UCAV, baseado em Álgebra Geométrica e modelos substitutos por Graph Neural Networks multifidelidade, de forma a reduzir a demanda de recursos computacionais das avaliações eletromagnéticas e aerodinâmicas e viabilizar sua integração com métodos determinísticos de otimização matemática.

Arquitetura da pesquisa

A arquitetura metodológica de referência é:

\$ geometria parametrizada 2D/3D → malha/gráfo → representação em AG → modelos em diferentes fidelidades
→ GNN multifidelidade → otimização matemática aero-stealth → reavaliação por modelos de referência.
\$

A validação metodológica será conduzida em duas etapas. Primeiro, o pipeline completo será desenvolvido e testado em problemas bidimensionais de aerofólios e espalhamento eletromagnético, nos quais geometria, conectividade, atributos em Álgebra Geométrica, treinamento e erros podem ser inspecionados diretamente. Depois, a mesma infraestrutura será estendida para geometrias tridimensionais de configurações UCAV, preservando a separação entre o que foi demonstrado em 2D e o que precisa ser novamente validado em 3D.

A motivação para grafos decorre da estrutura natural de malhas triangulares e não estruturadas, amplamente explorada em *geometric deep learning* e simulação baseada em malhas [1], [2]. Trabalhos recentes já demonstram GNNs para modelagem eletromagnética tridimensional [3] e análise aero-eletromagnética multitarefa em malhas de configurações *blended-wing-body* [4].

Do ponto de vista da otimização, o framework pertence à família de **análise e otimização baseadas em modelos substitutos** (*surrogate-based analysis and optimization*, SBAO), na qual aproximações treinadas reduzem o número de consultas aos modelos físicos de referência sem removê-los do processo de validação [5]. A organização multidisciplinar será descrita com a terminologia de arquiteturas de MDO de Martins e Lambe [6], mas a classificação final como MDF, IDF ou outra arquitetura não será imposta antes de identificar o acoplamento efetivo entre as disciplinas. A gestão dos níveis de fidelidade seguirá o princípio de combinar modelos que aproximam grandezas físicas compatíveis, mantendo avaliações de referência no ciclo para controlar precisão e validade [7].

Questões metodológicas centrais

O projeto investiga, entre outras questões:

1. quanto as GNNs reduzem o tempo de processamento e o número de avaliações dos modelos eletromagnéticos e aerodinâmicos de referência;
2. como combinar modelos de diferentes fidelidades para ampliar o espaço de projeto avaliado com a mesma infraestrutura computacional;
3. como incorporar relações físicas de Maxwell e Euler, formuladas em Álgebra Geométrica, à representação e ao treinamento das GNNs;
4. como integrar os modelos substitutos a formulações determinísticas de otimização multi-objetivo, incluindo NLP e, quando houver variáveis discretas, MINLP;

5. quanto o processo completo reduz a demanda de CPU/GPU, memória e tempo de processamento após contabilizar geração de dados, treinamento, otimização e reavaliação;
6. em que medida a fronteira de Pareto prevista preserva sua qualidade após reavaliação pelos modelos físicos de referência.

Quantificação de incerteza e aprendizado ativo poderão ser avaliados como estratégias auxiliares de seleção de novas simulações, caso acrescentem informação relevante ao processo multifidelidade.

Organização do eBook

Os capítulos são organizados em quatro blocos:

- fundamentos do problema aero-stealth, da Álgebra Geométrica, da física governante e das GNNs;
- estudo bidimensional de representação geométrica, fidelidade, dados e construção dos grafos;
- treinamento, validação e uso dos surrogates no problema bidimensional;
- extensão tridimensional da mesma metodologia, culminando na otimização aero-stealth de configurações UCAV e na reavaliação com modelos de referência.

1 Contexto e Definição do Problema

Aero-Stealth de um UCAV

Este capítulo apresenta o contexto de engenharia, a justificativa, a lacuna de pesquisa, os objetivos e a formulação inicial do problema de otimização aero-stealth de um **Unmanned Combat Aerial Vehicle (UCAV)**. A contribuição computacional central consiste no uso de **Graph Neural Networks (GNNs)** multifidelidade como modelos substitutos para reduzir a demanda de recursos computacionais e o tempo de processamento associados às avaliações eletromagnéticas e aerodinâmicas repetidas durante a otimização multidisciplinar.

A **Álgebra Geométrica (AG)** é adotada como formalismo matemático estruturante do trabalho. Ela será empregada na representação da geometria, na reformulação das relações físicas e na construção dos modelos de aprendizado e otimização. O objetivo é obter descrições algébricas mais compactas, reduzir a dependência de representações exclusivamente matriciais e explorar formulações lineares nos objetos multivetoriais sempre que a estrutura matemática do problema permitir. Não linearidades físicas intrínsecas, como os termos convectivos das equações de Euler, permanecem explicitamente representadas.

1.1 UCAV: conceito, escopo e terminologia

A expressão **Unmanned Aerial Vehicle (UAV)** designa, de forma ampla, um veículo aéreo não tripulado. A classe **Unmanned Combat Aerial Vehicle (UCAV)** particulariza esse conceito para plataformas destinadas a missões de combate. A classificação está associada à função, à missão e à integração do sistema, e não a uma configuração aerodinâmica específica [8], [9].

Consequentemente, UCAV e *flying wing* não são termos equivalentes. Configurações sem cauda (*tailless*), *flying-wing*, *lambda-wing*, *blended-wing-body* e outras arquiteturas aparecem na literatura de baixa observabilidade porque determinadas escolhas geométricas podem favorecer integração volumétrica, desempenho aerodinâmico e controle de assinatura radar. Essas configurações representam famílias de projeto possíveis dentro da classe UCAV.

A literatura ilustra essa diversidade. O programa NATO Science and Technology Organization (NATO STO) AVT-251 desenvolveu e avaliou a configuração MULDISCON, derivada do SACCON, como um conceito UCAV multidisciplinar com ênfase em aerodinâmica, controlabilidade e baixa assinatura [10]. Aleisa et al. estudaram especificamente um UCAV de configuração

flywing com enflechamento não constante [11]. Nikbay et al. investigaram uma configuração UCAV não planar derivada de um conceito planar de asa integrada [12].

O objeto desta pesquisa é, portanto, uma **família geometricamente parametrizada de configurações UCAV de baixa observabilidade**. A arquitetura aerodinâmica específica será definida pelo espaço de projeto e pelas restrições de engenharia adotadas, preservando a distinção entre a classe funcional do veículo e sua configuração geométrica.

1.2 UCAV como problema de engenharia multidisciplinar

O projeto de um UCAV integra requisitos aerodinâmicos, eletromagnéticos, estruturais, propulsores, de estabilidade e controle, além de requisitos próprios de sistemas não tripulados, como autonomia, sensores, comunicação e gerenciamento de missão [9]. Essas disciplinas interagem por meio de variáveis de projeto comuns e podem produzir objetivos conflitantes.

A **Otimização Multidisciplinar de Projeto (Multidisciplinary Design Optimization, MDO)** fornece o arcabouço para formular essas interações como um problema integrado de otimização numérica [6]. Revisões recentes continuam a destacar a MDO como elemento central do projeto de aeronaves avançadas, especialmente quando modelos disciplinares de diferentes níveis de detalhe precisam ser combinados sob restrições de desempenho e de recursos computacionais [13].

No recorte desta pesquisa, o acoplamento principal envolve **desempenho aerodinâmico, assinatura radar e geometria**. Hu e Yu formularam um problema MDO aerodinâmico-stealth-estrutural para um UCAV [14]. Nguyen et al. integraram modelos de diferentes fidelidades ao projeto multidisciplinar de UCAVs [15]. Sepulveda, Smith e Sziroczak desenvolveram uma análise multidisciplinar de UCAVs subsônicos de baixa observabilidade [16], enquanto Papageorgiou et al. incorporaram assinatura radar, sensores, aerodinâmica e trajetória em um problema integrado de projeto de aeronave não tripulada [17].

Esses antecedentes mostram que alterações na forma externa do veículo afetam simultaneamente sustentação, arrasto, estabilidade, distribuição de pressão e mecanismos de espalhamento eletromagnético. O problema de engenharia consiste, portanto, em identificar geometrias que produzam compromissos tecnicamente adequados entre respostas aerodinâmicas e eletromagnéticas sob um conjunto explícito de restrições de projeto.

1.3 Continuidade em relação à caracterização de RCS

A pesquisa parte de uma base experimental e computacional previamente desenvolvida para caracterização de **Radar Cross Section (RCS)**, ou seção reta radar. No Trabalho de Conclusão

de Curso de **João Pedro Rocha Silva (2026)**, foram avaliados alvos canônicos e alvos aeroespaciais complexos por meio de diferentes técnicas de **Eletromagnetismo Computacional (Computational Electromagnetics, CEM)** e de medição experimental [18].

Entre os métodos empregados encontram-se a **Óptica Física (Physical Optics, PO)**, a **Large Element Physical Optics (LE-PO)**, a **Ray Launching Geometrical Optics (RL-GO)** e a técnica **Shooting and Bouncing Rays Plus (SBR+)**, implementadas em ferramentas como Altair Feko e Ansys **High Frequency Structure Simulator (HFSS)**. O trabalho também implementou, para geometrias canônicas, o **Método das Diferenças Finitas no Domínio do Tempo (Finite-Difference Time-Domain, FDTD)**, o **Método dos Momentos (Method of Moments, MoM)** e o **Método dos Elementos Finitos (Finite Element Method, FEM)** [18].

A contribuição dessa base para a presente pesquisa está na experiência acumulada com modelagem eletromagnética, comparação entre métodos e validação experimental. A nova etapa desloca a ênfase da caracterização de geometrias previamente definidas para a exploração de **famílias paramétricas de configurações UCAV** dentro de um processo de otimização.

Os resultados de Rocha Silva também evidenciam diferenças relevantes entre modelos eletromagnéticos. Em geometrias canônicas, métodos distintos reproduzem com diferentes níveis de precisão mecanismos como reflexão especular, múltiplas reflexões e difração [18]. Essa observação conduz diretamente ao conceito de fidelidade utilizado no framework.

1.4 Fidelidade e modelagem multifidelidade

Neste trabalho, **fidelidade** representa o grau de detalhamento físico e numérico com que um modelo aproxima o fenômeno e a resposta de referência relevantes ao problema. A fidelidade depende de vários elementos: equações governantes, hipóteses físicas, discretização espacial, resolução da malha, tratamento de condições de contorno, modelos constitutivos e método numérico. Portanto, a classificação de um modelo como de menor ou maior fidelidade é sempre relativa ao regime físico e à resposta de interesse.

Modelos de maior fidelidade tendem a representar mais fenômenos ou a empregar discretizações mais detalhadas, o que geralmente aumenta a demanda de **tempo de CPU/GPU, memória e armazenamento**. Modelos de menor fidelidade utilizam aproximações físicas, discretizações mais simples ou resoluções reduzidas e, por isso, permitem avaliar um número maior de configurações com a mesma infraestrutura computacional.

A **modelagem multifidelidade** combina sistematicamente informações provenientes de dois ou mais níveis de fidelidade. O objetivo é aproveitar a ampla cobertura do espaço de projeto proporcionada por modelos de menor demanda de recursos e utilizar um conjunto menor de avaliações de maior fidelidade para corrigir, calibrar ou enriquecer a aproximação [15], [19], [20], [21]. A relação entre níveis pode ser aprendida, por exemplo, por uma correção de discrepância

$$y_{HF} = y_{LF} + \Delta_{\theta}(G, y_{LF}, c),$$

em que y_{LF} e y_{HF} representam respostas de menor e maior fidelidade, G representa a geometria codificada como grafo, c reúne as condições operacionais e Δ_{θ} é um modelo treinável de correção.

No domínio eletromagnético, uma hierarquia poderá combinar métodos assintóticos de alta frequência e métodos com representação mais detalhada dos mecanismos de espalhamento, sempre mediante validação para o regime de interesse. No domínio aerodinâmico, modelos de painel, equações de Euler e formulações viscosas baseadas nas equações de Navier–Stokes com médias de Reynolds podem ocupar diferentes níveis dessa hierarquia. A classificação final será definida pelas respostas que cada modelo reproduz e pelos recursos necessários para sua execução.

1.5 Radar Cross Section como resposta de projeto

A RCS quantifica a intensidade com que um alvo espalha energia eletromagnética na direção do receptor e pode ser interpretada como uma área efetiva de espalhamento sob condições especificadas [22]. Na equação de alcance radar monoestática idealizada, a distância máxima de detecção varia com a quarta raiz de σ , o que estabelece uma conexão direta entre assinatura radar e detectabilidade [18], [22].

A RCS depende da frequência, da direção de incidência e observação, da polarização, das propriedades materiais e dos mecanismos de espalhamento. Em alvos eletricamente grandes, a geometria local influencia reflexão especular, difração em bordos e pontas, múltiplas reflexões e ondas de superfície [18], [22]. Consequentemente, a resposta eletromagnética relevante para projeto é angular e pode apresentar picos estreitos em determinados setores.

A modelagem proposta preservará essa estrutura por meio de curvas de RCS em função de azimuth, elevação, frequência e polarização. Para condições $c_{EM} = (\phi, \theta, f, p)$,

$$\sigma = \sigma(\phi, \theta, f, p; x),$$

em que x representa a geometria parametrizada. A partir da curva podem ser construídos objetivos escalares, como média setorial, valor máximo, quantis ou outras medidas de risco. Essa separação permite avaliar simultaneamente a fidelidade física da curva e sua utilização em otimização matemática.

1.6 Desempenho aerodinâmico no regime subsônico

O domínio aerodinâmico concentra-se inicialmente em escoamento externo subsônico de ar tratado como gás perfeito. A **Dinâmica dos Fluidos Computacional (Computational Fluid Dynamics, CFD)** será utilizada em níveis de fidelidade compatíveis com a fase do estudo. Modelos potenciais ou de painel podem fornecer respostas de menor demanda de recursos; as equações compressíveis e invíscidas de Euler constituem um nível intermediário relevante; e modelos viscosos baseados nas **Reynolds-Averaged Navier–Stokes (RANS)** podem servir como referência de maior fidelidade para condições selecionadas.

As respostas aerodinâmicas de interesse incluem o coeficiente de sustentação C_L , o coeficiente de arrasto C_D , o coeficiente de momento C_m , a razão L/D e, quando necessário, campos de pressão e outras grandezas locais. GNNs já foram aplicadas a malhas não estruturadas e *body-fitted* para aproximar campos de escoamento em geometrias variáveis [23], [24], e operadores neurais informados pela geometria foram empregados em problemas tridimensionais de equações diferenciais parciais [25]. Esses resultados fornecem base metodológica para a representação aerodinâmica por grafos.

1.7 Estado da arte em otimização aero-stealth de UCAVs

A otimização aero-stealth evoluiu de formulações com modelos disciplinares simplificados para ambientes de projeto que integram CFD, CEM, modelos substitutos e técnicas de sensibilidade. Hu e Yu combinaram aerodinâmica, stealth e estruturas em um problema MDO de UCAV [14]. Nguyen et al. utilizaram uma arquitetura multifidelidade no projeto de sistemas UCAV [15]. O programa SACCON/MULDICON consolidou uma plataforma de pesquisa multidisciplinar para aeronaves de baixa observabilidade [10].

A otimização matemática determinística ocupa papel relevante nessa evolução. Em MDO, as funções objetivo, restrições e variáveis das diferentes disciplinas podem ser organizadas em arquiteturas monolíticas ou decompostas [6]. Métodos baseados em gradientes reduzem o número de avaliações necessárias quando derivadas confiáveis estão disponíveis. Li et al. empregaram Programação Quadrática Sequencial (*Sequential Quadratic Programming*, SQP) em otimização aero-stealth de uma configuração *flying-wing*, combinando CFD, PO e sensitividades adjuntas [26]. Thoulon et al. utilizaram o algoritmo *Sequential Least Squares Programming* (SLSQP), CFD com RANS e PO para construir uma fronteira de compromisso aero-stealth em uma aeronave simplificada [27].

A pesquisa também considera formulações com variáveis contínuas e discretas. Problemas com variáveis contínuas e relações não lineares podem ser formulados como **Programação Não Linear (Nonlinear Programming, NLP)**. Quando decisões discretas — por exemplo, escolhas de configuração, número de elementos geométricos ou categorias de materiais — são combinadas com variáveis contínuas e relações não lineares, surge a **Programação Não**

Linear Inteira Mista (Mixed-Integer Nonlinear Programming, MINLP) [28], [29]. Em aplicações aeroespaciais, formulações mistas já foram empregadas para integrar decisões de missão, alocação e projeto de aeronaves [30].

Esse interesse é particularmente relevante para o presente framework. Os modelos substitutos baseados em GNN podem fornecer avaliações rápidas e diferenciáveis de respostas físicas, enquanto a otimização matemática determinística pode explorar explicitamente gradientes, restrições e estrutura combinatória. A formulação final será contínua ou inteira mista de acordo com a natureza real das variáveis de projeto, preservando compatibilidade com arquiteturas MDO e com métodos determinísticos de otimização local ou global.

Trabalhos recentes mantêm ativo o problema aero-stealth. Aleisa et al. investigaram o projeto conceitual de um UCAV *flying-wing* [11]. Thoulon et al. demonstraram uma metodologia gradiente para compromisso entre arrasto e assinatura radar [27]. Nikbay et al. apresentaram em 2026 uma otimização multidisciplinar de um conceito UCAV não planar, combinando CFD, RCS e modelos de Kriging por **Partial Least Squares (KPLS)** para reduzir o número de avaliações das análises de maior demanda de recursos [12].

1.8 GNNs para análise aerodinâmica e eletromagnética

A representação de malhas por grafos estabelece uma conexão natural entre geometria discretizada e aprendizado de máquina. MeshGraphNets demonstrou a aplicação de redes de grafos à simulação sobre malhas [2], enquanto a literatura de *geometric deep learning* fornece o arcabouço para explorar conectividade, simetrias e transformações geométricas [1].

No eletromagnetismo, Shan et al. empregaram aprendizado residual informado pela física sobre grafos para equações integrais de espalhamento de alvos tridimensionais condutores perfeitos [3]. Kong et al. desenvolveram um preditor de campo distante espalhado a partir de nuvens de pontos de alvos tridimensionais [31]. Esses trabalhos mostram que a geometria discretizada pode ser diretamente utilizada para aproximar respostas eletromagnéticas complexas.

O antecedente mais próximo da integração aero-eletromagnética por GNN identificado na literatura recente é o trabalho de Li et al. [4]. Os autores desenvolveram uma GNN de difusão multitarefa definida sobre malhas superficiais não estruturadas de configurações *blended-wing-body*. O modelo prediz simultaneamente o campo de coeficiente de pressão C_p , os coeficientes globais C_L e C_D e valores médios de RCS monoestático para polarizações horizontal e vertical. O estudo reporta aproximadamente 35× de aceleração de inferência para o conjunto de saídas em relação aos solvers utilizados na geração dos dados [4].

Esse resultado estabelece um benchmark diretamente relacionado ao presente problema e demonstra a viabilidade de um modelo de grafo compartilhado entre as disciplinas aerodinâmica e eletromagnética. A presente pesquisa amplia essa linha ao incorporar fidelidades distintas, preservar a dependência angular e de polarização da RCS, integrar os modelos substitutos a

uma formulação de otimização matemática determinística e utilizar Álgebra Geométrica como formalismo comum de representação da geometria, da física e das operações algébricas.

1.9 Lacuna de pesquisa

A lacuna abordada nesta pesquisa concentra-se na **integração sistemática de modelagem geométrica, física, aprendizado multifidelidade e otimização matemática para configurações UCAV**. A literatura recente apresenta avanços importantes em cada um desses componentes, porém a articulação conjunta permanece limitada.

A contribuição proposta reúne cinco elementos em uma única arquitetura metodológica:

1. representação de geometrias UCAV por malhas e grafos capazes de alimentar simultaneamente modelos aerodinâmicos e eletromagnéticos;
2. aprendizado multifidelidade explícito entre níveis de análise com diferentes graus de detalhamento e diferentes demandas de recursos computacionais;
3. predição da RCS preservando sua dependência angular e de polarização, em vez de restringir a resposta a um valor médio global;
4. integração dos modelos substitutos a uma formulação de otimização matemática determinística, com suporte a NLP e, quando houver decisões discretas, MINLP;
5. adoção da Álgebra Geométrica como linguagem matemática comum para representar geometria, operadores físicos e relações empregadas no aprendizado e na otimização.

Essa integração será avaliada pelo desempenho preditivo dos modelos, pela demanda de recursos computacionais, pelo tempo total de processamento e pela qualidade das soluções obtidas após reavaliação com modelos de referência.

1.10 Justificativa

A justificativa de engenharia decorre do forte acoplamento entre geometria, aerodinâmica e assinatura radar em UCAVs de baixa observabilidade. Uma alteração geométrica capaz de reduzir retornos eletromagnéticos pode modificar distribuição de pressão, arrasto, sustentação e estabilidade. O tratamento integrado dessas respostas reduz a possibilidade de soluções ótimas em uma disciplina produzirem desempenho inadequado em outra [9], [10], [16].

A justificativa computacional decorre da demanda de recursos associada às avaliações disciplinares repetidas. Modelos CEM e CFD com maior detalhamento podem requerer tempos elevados de CPU/GPU, maior uso de memória e malhas com grande número de graus de liberdade. Uma otimização que exija centenas ou milhares de avaliações multiplica essa demanda. Revisões sobre MDO baseada em metamodelos destacam esse problema como uma das principais motivações para modelos substitutos em sistemas aeroespaciais [19], e estudos recentes de eficiência em

MDO de aeronaves continuam a tratar a redução de avaliações disciplinares como tema central [13].

A justificativa metodológica está na compatibilidade entre a estrutura dos dados e o modelo de aprendizado. Malhas CEM e CFD já contêm relações topológicas entre vértices, arestas, faces e células. GNNs permitem incorporar essas relações diretamente ao modelo. A multifidelidade, por sua vez, permite distribuir o orçamento de simulação entre modelos com diferentes demandas de recursos, preservando avaliações de maior fidelidade para calibração e revalidação.

A Álgebra Geométrica fornece o eixo matemático comum do framework. No eletromagnetismo, a Álgebra do Espaço-Tempo permite reunir as equações de Maxwell em uma formulação multivetorial compacta [32]. No domínio aerodinâmico, a AG será empregada para representar vetores, bivectores, orientações, operadores diferenciais e transformações geométricas, buscando formulações mais compactas e linearizações operacionais quando matematicamente admissíveis. Na otimização, a arquitetura priorizará variáveis, operadores e restrições formulados em termos geométricos e multivetoriais, recorrendo a projeções escalares quando exigidas pelos solvers numéricos [33], [34].

A justificativa científica completa-se pela continuidade com a infraestrutura de RCS já estabelecida por Rocha Silva [18]. A passagem de caracterização de alvos fixos para otimização de famílias geométricas cria uma trajetória integrada entre modelagem física, aprendizado, otimização e revalidação.

1.11 Formulação inicial do problema multidisciplinar

Seja $x \in \mathbb{R}^n$ o vetor de variáveis contínuas de projeto. Caso o espaço de decisão inclua escolhas discretas, seja $z \in \mathbb{Z}^m$ o vetor correspondente. Uma formulação multiobjetivo pode ser escrita como

$$\min_{x,z} \begin{bmatrix} J_{\text{EM}}(x, z) \\ J_{\text{aero}}(x, z) \end{bmatrix}$$

sujeita a

$$g_i(x, z) \leq 0, \quad h_j(x, z) = 0,$$

além de limites geométricos e condições operacionais.

O objetivo eletromagnético será obtido a partir da resposta angular de RCS,

$$J_{\text{EM}}(x, z) = \mathcal{R}[\sigma(\phi, \theta, f, p; x, z)],$$

em que $\mathcal{R}$ representa uma operação de agregação ou risco definida para setores angulares e condições de interesse. No domínio aerodinâmico, formulações possíveis incluem minimização de C_D com restrição de sustentação ou maximização de eficiência aerodinâmica, equivalente a

$$J_{\text{aero}}(x, z) = -\frac{L}{D}.$$

A otimização multiobjetivo poderá ser tratada por escalarização, método ε -constraint ou outras estratégias compatíveis com otimização matemática determinística. Quando todas as variáveis forem contínuas, cada subproblema poderá assumir a forma de um NLP. A presença de decisões discretas combinadas com relações não lineares conduz a uma formulação MINLP [28], [29].

1.12 Papel das GNNs e da multifidelidade na otimização

O modelo substituto terá como função aproximar respostas disciplinares a partir da geometria e das condições operacionais:

$$\mathcal{G}_\theta : (G, c, y_{LF}) \longrightarrow (\hat{y}_{EM}, \hat{y}_{aero}).$$

O grafo G representa a geometria discretizada, c reúne condições de operação e y_{LF} contém respostas provenientes de modelos de menor fidelidade quando disponíveis. A arquitetura multifidelidade aprenderá a relação entre níveis de modelagem, reduzindo o número de avaliações de maior demanda de recursos necessárias para cobrir o espaço de projeto.

Durante a otimização, a maior parte das avaliações de objetivos e restrições poderá ser realizada pelas GNNs. Modelos físicos de referência permanecerão associados à geração de dados, à verificação de regiões críticas e à reavaliação das soluções selecionadas. A combinação entre inferência rápida, diferenciação automática e otimização matemática determinística é particularmente relevante para problemas com muitas variáveis e restrições.

1.13 Quantificação de incerteza e aprendizado ativo como estratégias auxiliares

A **Quantificação de Incerteza (Uncertainty Quantification, UQ)** corresponde à estimativa da incerteza associada às previsões do modelo. Em modelos substitutos, essa informação pode indicar regiões do espaço de projeto pouco representadas pelos dados e apoiar a decisão sobre quais soluções exigem nova avaliação por modelos de maior fidelidade.

O **aprendizado ativo (active learning)** é uma estratégia sequencial de geração de dados na qual o próprio estado do modelo auxilia a escolha das próximas amostras a serem avaliadas. Sua utilização é justificável quando as avaliações de maior fidelidade demandam recursos suficientes para tornar ineficiente uma amostragem uniforme ou exclusivamente predefinida. Critérios de seleção podem combinar incerteza preditiva, discrepância entre fidelidades ou relevância para a região de Pareto.

UQ e aprendizado ativo são tratados nesta pesquisa como **estratégias auxiliares a serem avaliadas**, e não como componentes obrigatórios da arquitetura. Sua adoção dependerá de evidência de que acrescentam informação útil ao processo multifidelidade em relação a um plano de experimentos previamente definido.

1.14 Questão de pesquisa

Em que medida um framework baseado em Álgebra Geométrica, Graph Neural Networks multifidelidade e otimização matemática determinística pode reduzir a demanda de recursos computacionais e o tempo total de processamento da otimização aero-stealth de configurações UCAV, preservando a precisão das respostas físicas e a qualidade das soluções reavaliadas por modelos de referência?

1.15 Objetivo geral

Desenvolver e validar um framework de otimização multidisciplinar aero-stealth para configurações UCAV, baseado em Álgebra Geométrica e modelos substitutos por Graph Neural Networks multifidelidade, de forma a reduzir a demanda de recursos computacionais das avaliações eletromagnéticas e aerodinâmicas e viabilizar sua integração com métodos determinísticos de otimização matemática.

1.16 Objetivos específicos

1. Contextualizar e formalizar o problema de engenharia de UCAVs, distinguindo a classe funcional do veículo das configurações aerodinâmicas empregadas no espaço de projeto.
2. Definir uma parametrização geométrica reproduzível para as configurações estudadas e estabelecer o fluxo CAD $\rightarrow$ malha $\rightarrow$ grafo.

3. **Formular em Álgebra Geométrica as representações geométricas e físicas relevantes**, incluindo operações associadas às equações de Maxwell, ao escoamento de Euler e às transformações empregadas no processo de otimização.
4. **Definir os níveis de fidelidade eletromagnéticos e aerodinâmicos** a partir do conteúdo físico, da discretização e da demanda de recursos de cada modelo.
5. **Construir bases de dados multifidelidade** para RCS e aerodinâmica, preservando condições operacionais, metadados de simulação e rastreabilidade entre níveis.
6. **Desenvolver GNNs baseadas em malha** para prever curvas angulares e polarizadas de RCS, coeficientes aerodinâmicos e, quando necessário, campos físicos intermediários.
7. **Desenvolver estratégias de aprendizado multifidelidade** capazes de transferir ou corrigir informação entre modelos de diferentes níveis de fidelidade.
8. **Incorporar conhecimento físico às GNNs** por meio de representações e restrições derivadas das formulações em Álgebra Geométrica de Maxwell e Euler.
9. **Integrar os modelos substitutos a uma formulação de otimização matemática determinística multiobjetivo**, utilizando NLP para variáveis contínuas e MINLP quando o espaço de decisão incorporar variáveis discretas.
10. **Validar o framework de forma end-to-end**, quantificando precisão, demanda de recursos computacionais, tempo de processamento, número de avaliações dos solvers e qualidade da fronteira de Pareto após reavaliação por modelos de referência.

1.17 Hipóteses de pesquisa

As hipóteses centrais são formuladas como relações testáveis entre desempenho preditivo, recursos empregados e qualidade das decisões de otimização.

Representação por grafos. GNNs que recebem a geometria discretizada e sua conectividade deverão apresentar melhor generalização para geometrias não vistas do que modelos baseados exclusivamente em parâmetros globais, sob condições comparáveis de treinamento.

Aprendizado multifidelidade. Para uma quantidade fixa de avaliações de maior fidelidade, a combinação de informações provenientes de diferentes fidelidades deverá produzir menor erro preditivo ou melhor qualidade das soluções de otimização do que o treinamento realizado apenas com o subconjunto de maior fidelidade.

Consistência física. A incorporação de relações físicas formuladas em Álgebra Geométrica às representações, perdas ou saídas auxiliares das GNNs deverá melhorar a consistência física e a eficiência amostral em relação a um modelo puramente supervisionado com a mesma base de dados.

Aceleração da otimização. A utilização das GNNs multifidelidade no ciclo MDO deverá reduzir o tempo total de processamento e o número de avaliações de maior demanda de recursos necessários para obter uma fronteira de Pareto reavaliada, preservando a qualidade das soluções selecionadas.

1.18 Métricas de avaliação

A avaliação deverá combinar métricas de predição, otimização e utilização de recursos. Para RCS, serão considerados erro médio da curva, erro de pico, deslocamento angular de picos e erro por setor. Para aerodinâmica, serão considerados erros em C_L , C_D , C_m , L/D e, quando aplicável, em campos físicos.

A utilização de recursos será caracterizada por **tempo de processamento**, **horas de CPU/GPU**, **pico de memória**, **armazenamento**, **número de avaliações dos modelos de referência** e **tempo de geração dos dados de treinamento**. Quando UQ for empregada, serão acrescentadas métricas de calibração e cobertura.

Duas medidas de aceleração são particularmente relevantes:

$$S_{\text{eval}} = \frac{T_{\text{solver}}}{T_{\text{GNN}}}$$

para uma avaliação individual, e

$$S_{\text{MDO}} = \frac{T_{\text{MDO, referência}}}{T_{\text{dados}} + T_{\text{treinamento}} + T_{\text{otimização}} + T_{\text{reavaliação}}}$$

para o processo completo. A segunda métrica evita atribuir aceleração ao framework sem contabilizar os recursos empregados para geração de dados e treinamento.

A qualidade da otimização será avaliada pela comparação entre a fronteira de Pareto prevista e a fronteira reavaliada, utilizando indicadores apropriados de dominância, hipervolume e erro das soluções selecionadas.

1.19 Estudos de ablação

O protocolo experimental incluirá modelos de referência capazes de separar a contribuição das principais camadas metodológicas:

- baseline baseado em parâmetros globais da geometria;
- GNN com representação geométrica convencional;
- GNN com representação e operações em Álgebra Geométrica;
- GNN com incorporação explícita de relações físicas;
- GNN multifidelidade integrada ao processo de otimização.

A Álgebra Geométrica permanece como formalismo adotado no framework final. A ablação tem a função de quantificar como cada componente modifica precisão, estabilidade, demanda de dados e comportamento da otimização, e não de decidir sua adoção.

1.20 Progressão experimental de 2D para 3D

A validação do framework será realizada em duas etapas complementares. A primeira utilizará problemas bidimensionais de aerofólios e espalhamento eletromagnético para construir e testar, de ponta a ponta, a representação geométrica, a conversão malha-grafo, os atributos em Álgebra Geométrica, os modelos substitutos e os protocolos de treinamento e validação. Essa etapa não será tratada como substituta do problema tridimensional: seu papel é fornecer um ambiente controlado no qual hipóteses arquiteturais, fontes de erro e ganhos de recursos possam ser isolados com maior transparência.

A segunda etapa estenderá a infraestrutura validada para geometrias tridimensionais de configurações UCAV. As conclusões obtidas em 2D serão consideradas evidência metodológica preliminar, e propriedades como generalização geométrica, sensibilidade a remalhamento, dependências eletromagnéticas de longo alcance e desempenho em otimização serão novamente avaliadas no domínio 3D antes de qualquer conclusão de engenharia sobre a configuração completa.

1.21 Delimitação do estudo

O trabalho concentra-se na integração entre geometria UCAV, RCS, aerodinâmica subsônica, Álgebra Geométrica, GNNs multifidelidade e otimização matemática. Os solvers físicos de referência serão utilizados para geração de dados e reavaliação, enquanto as reformulações em AG terão profundidade suficiente para sustentar as representações, relações físicas e operações empregadas pelo modelo substituto e pela otimização.

O resultado esperado é um **framework reproduzível de otimização aero-stealth** no qual a aceleração seja demonstrada por medidas de tempo e recursos computacionais, e a validade das decisões seja sustentada por reavaliação eletromagnética e aerodinâmica em níveis de fidelidade adequados.

2 Álgebra Geométrica para representação física, geométrica e computacional

A **Álgebra Geométrica (AG)**, também denominada álgebra de Clifford quando se enfatiza sua construção algébrica, constitui o formalismo matemático estruturante adotado neste trabalho. Seu papel é fornecer uma linguagem comum para representar geometria orientada, transformações, campos físicos e atributos utilizados pelos modelos de aprendizado em grafos, reduzindo a fragmentação entre notações vetoriais, matriciais, tensoriais e de formas diferenciais quando essas descrições admitem uma representação geométrica comum [33], [34], [35].

A adoção da AG não implica que toda formulação matricial ou tensorial deva ser substituída por um multivetor. Matrizes permanecem representações coordenadas naturais de aplicações lineares; tensores gerais preservam seu papel quando expressam relações multilineares que não são antissimétricas; e solucionadores numéricos podem requerer vetores, matrizes e escalares convencionais em suas interfaces. A contribuição da AG consiste em organizar, de modo geometricamente explícito, os objetos para os quais métrica, orientação, produtos, graus, dualidade e transformações podem ser tratados dentro de uma única álgebra associativa.

Essa distinção é particularmente importante para o problema aero-stealth. A geometria superficial de um **Unmanned Combat Aerial Vehicle (UCAV)**, os campos eletromagnéticos, os campos aerodinâmicos e as mensagens trocadas por uma **Graph Neural Network (GNN)** apresentam estruturas geométricas diferentes. O objetivo deste capítulo é construir a linguagem que permitirá representar essas estruturas sem confundir o objeto geométrico com suas componentes em uma base particular.

2.1 Partindo de objetos familiares: vetores, comprimento, ângulo e orientação

Um vetor pode ser compreendido geometricamente como uma quantidade que possui magnitude e direção. Em um espaço euclidiano tridimensional, deslocamento, velocidade e força são exemplos familiares. Quando uma base cartesiana ortonormal $\{e_1, e_2, e_3\}$ é escolhida, um vetor a pode ser escrito como

$$a = a^1 e_1 + a^2 e_2 + a^3 e_3.$$

Os números a^1, a^2, a^3 são **componentes** do vetor naquela base. Eles não são o vetor em si. Se a base for girada, as componentes mudam, embora o vetor geométrico representado permaneça o mesmo.

O produto interno fornece duas informações geométricas familiares. Para vetores a e b ,

$$a \cdot b = \|a\| \|b\| \cos \theta,$$

onde θ é o ângulo entre eles. Consequentemente,

$$a \cdot a = \|a\|^2.$$

Se $a \cdot b = 0$, os vetores são ortogonais. Assim, o produto interno mede a parcela de uma direção alinhada com outra e introduz a noção de comprimento e ângulo.

Entretanto, comprimento e alinhamento não esgotam a geometria produzida por dois vetores. Dois vetores não colineares também determinam um **plano orientado**. A Álgebra Geométrica introduz um objeto próprio para representar esse plano: o **bivetor**. A partir dessa observação nasce a ideia central do capítulo: em vez de representar todas as entidades geométricas por listas de números ou por vetores tridimensionais auxiliares, diferentes tipos de objetos geométricos são mantidos explicitamente dentro da mesma álgebra.

2.2 Do espaço vetorial métrico à álgebra de Clifford

2.2.1 O espaço vetorial e a métrica

Considere um espaço vetorial real finito-dimensional V . Para transformar esse espaço em um espaço no qual seja possível falar de comprimentos e ângulos, introduz-se uma forma bilinear simétrica

$$g : V \times V \rightarrow \mathbb{R}.$$

A palavra **bilinear** significa que g é linear em cada argumento separadamente. A palavra **simétrica** significa

$$g(a, b) = g(b, a).$$

Quando se escreve

$$a \cdot b = g(a, b),$$

a forma bilinear passa a ser interpretada como produto interno ou, em assinaturas indefinidas, como produto métrico.

Em uma base geral $\{e_i\}$, define-se

$$g_{ij} = e_i \cdot e_j.$$

Os números g_{ij} formam a matriz métrica ou matriz de Gram. Em uma base cartesiana ortonormal euclidiana,

$$g_{ij} = \delta_{ij},$$

isto é, os termos diagonais são iguais a 1 e os termos fora da diagonal são zero. Em uma base oblíqua, por outro lado, termos fora da diagonal podem ser diferentes de zero porque os vetores da base não são perpendiculares [36].

A métrica determina a **assinatura** da álgebra. A notação $Cl(p, q)$ indica, em uma base ortogonal não degenerada, p direções cujo quadrado é $+1$ e q direções cujo quadrado é -1 . Para geometria euclidiana tridimensional utiliza-se $Cl(3, 0)$. Em espaço-tempo, uma assinatura indefinida é utilizada e sua convenção deve ser explicitada antes das manipulações físicas.

2.2.2 A relação fundamental de Clifford

A álgebra de Clifford $Cl(V, g)$ é gerada pelos vetores de V impondo

$$a^2 = g(a, a).$$

Em um espaço euclidiano, essa expressão afirma que o quadrado geométrico de um vetor é o quadrado de seu comprimento. A identidade pode parecer simples, mas ela determina a relação entre produtos de vetores. Aplicando-a a $a + b$,

$$(a + b)^2 = a^2 + ab + ba + b^2.$$

Por outro lado,

$$(a + b)^2 = g(a + b, a + b) = a^2 + 2g(a, b) + b^2.$$

Comparando as duas expressões, obtém-se

$$\boxed{ab + ba = 2g(a, b)}.$$

Portanto,

$$a \cdot b = \frac{1}{2}(ab + ba).$$

Essa relação é o ponto de partida para compreender por que o produto geométrico contém simultaneamente informação métrica e informação de orientação [33], [34].

2.3 Produto geométrico, produto interno e produto exterior

2.3.1 O produto geométrico de dois vetores

Para dois vetores $a, b \in V$, o **produto geométrico** é denotado simplesmente por justaposição, ab . Ele pode ser decomposto em duas partes:

$$\boxed{ab = a \cdot b + a \wedge b}.$$

A primeira parte,

$$a \cdot b = \frac{1}{2}(ab + ba),$$

é simétrica e escalar. A segunda,

$$a \wedge b = \frac{1}{2}(ab - ba),$$

é antissimétrica e bivetorial [37].

Essa decomposição pode ser interpretada da seguinte maneira:

- $a \cdot b$ informa **quanto os vetores estão alinhados**;
- $a \wedge b$ informa **qual plano orientado os dois vetores constroem**;
- ab conserva simultaneamente as duas informações.

Considere, em $Cl(2, 0)$, uma base ortonormal $\{e_1, e_2\}$ e os vetores

$$a = e_1, \quad b = e_1 + 2e_2.$$

Como $e_1 \cdot e_1 = 1$ e $e_1 \cdot e_2 = 0$,

$$a \cdot b = 1.$$

Como $e_1 \wedge e_1 = 0$,

$$a \wedge b = 2e_1 \wedge e_2.$$

Logo,

$$ab = 1 + 2e_{12},$$

onde $e_{12} = e_1 e_2 = e_1 \wedge e_2$. O resultado não é apenas um escalar nem apenas um vetor: é um multivetor composto por uma parte escalar e uma parte bivetorial.

2.3.2 Casos geométricos importantes

Se a e b são paralelos, então

$$a \wedge b = 0,$$

e o produto geométrico reduz-se ao produto interno.

Se a e b são ortogonais, então

$$a \cdot b = 0,$$

e

$$ab = a \wedge b.$$

Em uma base ortonormal, portanto,

$$e_i e_j = -e_j e_i, \quad i \neq j.$$

Essa anticomutatividade entre vetores ortogonais é a origem de muitas identidades da AG.

2.3.3 O produto exterior como área orientada

O produto exterior satisfaz

$$a \wedge b = -b \wedge a.$$

Trocar a ordem dos vetores muda a orientação do plano e, por isso, muda o sinal. Em particular,

$$a \wedge a = 0,$$

pois um único vetor repetido não gera área.

No caso euclidiano,

$$\|a \wedge b\| = \|a\| \|b\| \sin \theta.$$

Essa é exatamente a área do paralelogramo definido por a e b . Assim, o bivector $a \wedge b$ reúne três informações em um único objeto: o plano, sua orientação e sua magnitude de área [38].

Em três dimensões, o produto vetorial tradicional $a \times b$ também codifica essa área, mas o faz por meio de um pseudovetor perpendicular ao plano. Na AG, o plano orientado é representado diretamente pelo bivector; o pseudovetor perpendicular pode ser recuperado posteriormente por dualidade.

2.3.4 Associatividade e não comutatividade

O produto geométrico é distributivo e associativo:

$$a(bc) = (ab)c.$$

Essa propriedade permite formar produtos de três, quatro ou mais vetores sem introduzir um novo tipo de operação a cada etapa.

Em geral,

$$ab \neq ba.$$

A não comutatividade não é uma inconveniência algébrica; ela carrega informação geométrica. A diferença entre ab e ba contém precisamente a orientação expressa pelo produto exterior.

2.3.5 Produto de um vetor por um elemento de grau definido

A decomposição $ab = a \cdot b + a \wedge b$ não se limita a dois vetores. Se A_r é homogêneo de grau r , o produto aA_r possui, em geral, uma parcela de grau $r - 1$ e outra de grau $r + 1$:

$$aA_r = a \cdot A_r + a \wedge A_r.$$

Com a convenção de contração utilizada neste texto,

$$a \cdot A_r = \frac{1}{2} (aA_r - (-1)^r A_r a),$$

$$a \wedge A_r = \frac{1}{2} (aA_r + (-1)^r A_r a).$$

Para $r = 1$, essas fórmulas recuperam exatamente o produto interno e o produto exterior de dois vetores. Para $r = 2$, o produto de um vetor com um bivector pode produzir uma parte vetorial e uma parte trivetorial. Essa regra de “baixar ou subir o grau” será útil mais adiante para derivadas geométricas e para separar equações multivetoriais por conteúdo geométrico.

2.4 Grades, blades e multivetores

2.4.1 O que significa grau

A Álgebra Geométrica organiza seus elementos por **grau**. O grau informa a dimensão geométrica do objeto elementar representado:

- grau 0: escalares;
- grau 1: vetores;
- grau 2: bivectores, associados a planos orientados;
- grau 3: trivetores, associados a volumes orientados;
- graus superiores: extensões naturais em dimensões maiores.

Essa classificação não significa que todo elemento da álgebra possua um único grau. Ela significa que a álgebra é construída como soma de subespaços de diferentes graus.

2.4.2 Blades: objetos simples de grau definido

Um **blade** ou **lâmina** de grau r é um r -vetor decomponível da forma

$$A_r = a_1 \wedge a_2 \wedge \cdots \wedge a_r.$$

Um vetor não nulo é um blade de grau 1. Um bivector simples $a \wedge b$ é um blade de grau 2. Um trivector simples $a \wedge b \wedge c$ é um blade de grau 3.

A palavra **simples** é importante. Um r -vetor geral pode ser soma de vários blades de mesmo grau e nem sempre pode ser fatorado em um único produto exterior. Portanto, todo blade de grau r é um r -vetor, mas nem todo r -vetor é necessariamente um blade simples.

2.4.3 Multivetores: diferentes graus no mesmo elemento

Um **multivetor** é um elemento geral da álgebra e pode possuir componentes de vários graus simultaneamente:

$$A = \sum_{r=0}^n \langle A \rangle_r.$$

A notação $\langle A \rangle_r$ significa: “extraia de A apenas a parte de grau r ”. Por exemplo, se

$$A = 3 + 2e_1 - e_{12} + 4e_{123},$$

então

$$\langle A \rangle_0 = 3,$$

$$\langle A \rangle_1 = 2e_1,$$

$$\langle A \rangle_2 = -e_{12},$$

$$\langle A \rangle_3 = 4e_{123}.$$

Essa projeção por grau é um mecanismo central da AG porque permite combinar informações em um único elemento sem perder a natureza geométrica de cada parcela.

2.4.4 Por que aparecem 2^n componentes

Se $\dim V = n$, o número de componentes independentes de grau r é

$$\dim \Lambda^r V = \binom{n}{r}.$$

Os coeficientes binomiais $\binom{n}{r}$ são exatamente os números que aparecem na linha de ordem n do **triângulo de Pascal**. Cada coeficiente conta quantas maneiras existem de escolher r direções distintas entre os n vetores de uma base; em AG, essas escolhas correspondem aos blades de base de grau r . Para $n = 3$, a linha

$$1 \quad 3 \quad 3 \quad 1$$

indica, respectivamente, um elemento de base de grau 0, três de grau 1, três de grau 2 e um de grau 3. A soma dos elementos dessa linha é obtida também pelo binômio de Newton:

$$(1 + 1)^n = \sum_{r=0}^n \binom{n}{r} = 2^n.$$

Portanto,

$$\dim Cl(V, g) = \sum_{r=0}^n \binom{n}{r} = 2^n.$$

Em $Cl(3, 0)$, uma base conveniente é

$$\{1, e_1, e_2, e_3, e_{12}, e_{23}, e_{31}, e_{123}\}.$$

Há oito elementos de base: um escalar, três vetores, três bivectores e um trivetor. Essa estrutura aparece explicitamente em formulações de AG para mecânica dos fluidos e eletromagnetismo [37].

2.5 Bases, métrica e independência de coordenadas

2.5.1 Objeto geométrico e componentes

Considere novamente um vetor v . Em uma base $\{e_i\}$, ele pode ser escrito como

$$v = v^i e_i.$$

Os números v^i dependem da base. Se a base for modificada, os números mudam de forma a preservar o mesmo vetor geométrico. Essa distinção é particularmente importante em coordenadas curvilíneas e em malhas, nas quais bases locais podem variar de ponto para ponto [36].

2.5.2 O conceito de base recíproca

Se a base direta $\{e_i\}$ não é ortonormal, simplesmente calcular $v \cdot e_i$ não fornece, em geral, os coeficientes v^i da expansão $v = v^i e_i$. Para extrair essas componentes de maneira sistemática, introduz-se a **base recíproca** $\{e^i\}$, definida pela condição

$$e^i \cdot e_j = \delta^i_j,$$

onde o **delta de Kronecker** é

$$\delta^i_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Essa condição pode ser lida geometricamente: cada vetor e^i da base recíproca tem produto interno igual a 1 com o vetor direto correspondente e_i e produto interno zero com todos os demais vetores da base direta.

A base recíproca funciona, portanto, como um conjunto de “sondas” para extrair as componentes associadas à base direta:

$$v^i = v \cdot e^i,$$

e

$$v = (v \cdot e^i) e_i.$$

2.5.2.1 Exemplo em uma base oblíqua

Considere, no plano euclidiano,

$$e_1 = (1, 0), \quad e_2 = (1, 1).$$

Os vetores e_1 e e_2 formam uma base, mas não são ortogonais. Uma base recíproca que satisfaz $e^i \cdot e_j = \delta^i_j$ é

$$e^1 = (1, -1), \quad e^2 = (0, 1).$$

De fato,

$$e^1 \cdot e_1 = 1, \quad e^1 \cdot e_2 = 0,$$

$$e^2 \cdot e_1 = 0, \quad e^2 \cdot e_2 = 1.$$

Para o vetor

$$v = (3, 2),$$

as componentes na base direta são extraídas por

$$v^1 = v \cdot e^1 = 1, \quad v^2 = v \cdot e^2 = 2.$$

Logo,

$$v = e_1 + 2e_2 = (1, 0) + 2(1, 1) = (3, 2).$$

Esse exemplo mostra por que a base recíproca é especialmente útil quando a base direta é oblíqua ou varia espacialmente.

2.5.2.2 Relação com a métrica

A métrica da base direta é

$$g_{ij} = e_i \cdot e_j,$$

e sua inversa matricial é denotada por g^{ij} . As bases direta e recíproca relacionam-se por

$$e^i = g^{ij}e_j, \quad e_i = g_{ij}e^j.$$

Da mesma maneira, componentes contravariantes e covariantes podem ser relacionadas por

$$v_i = g_{ij}v^j, \quad v^i = g^{ij}v_j.$$

Essa é a ponte entre a linguagem de bases recíprocas e a notação tensorial de índices superiores e inferiores [36].

2.5.2.3 Sobre unidades físicas

O adjetivo “recíproca” refere-se primeiramente à relação algébrica $e^i \cdot e_j = \delta^i_j$. As unidades físicas de e^i dependem da forma como as coordenadas e a base direta foram definidas. Em alguns contextos, como redes recíprocas em cristalografia, vetores recíprocos possuem interpretação de frequência espacial e unidades de inverso de comprimento. Essa interpretação, porém, não deve ser atribuída automaticamente a toda base recíproca usada em cálculo tensorial ou em AG. No presente trabalho, a base recíproca será utilizada principalmente para formular derivadas, componentes e operações independentes da escolha de coordenadas.

2.6 Pseudoescalar e dualidade

2.6.1 O elemento de grau máximo

Dada uma base orientada $\{e_1, \dots, e_n\}$, o produto exterior de todos os vetores da base define

$$I = e_1 \wedge e_2 \wedge \dots \wedge e_n.$$

Esse elemento é chamado **pseudoescalar**. Ele representa o elemento orientado de dimensão máxima do espaço. Em duas dimensões, representa a orientação do plano inteiro; em três dimensões, a orientação do volume.

Em uma base ortogonal,

$$I^2 = (-1)^{n(n-1)/2} \prod_{i=1}^n e_i^2.$$

Em $Cl(3, 0)$,

$$I = e_{123}, \quad I^2 = -1.$$

A propriedade $I^2 = -1$ ajuda a explicar por que subestruturas da AG reproduzem construções conhecidas de números complexos e quatérnios.

2.6.2 Dualidade como correspondência entre dimensões complementares

Quando I é inversível, adota-se neste trabalho a convenção de dual à direita

$$A^\star = AI^{-1}.$$

A dualidade transforma um objeto de grau r em um objeto de grau complementar $n - r$. Em três dimensões:

- o dual de um escalar é um trivetor;
- o dual de um vetor é um bivector;
- o dual de um bivector é um vetor;
- o dual de um trivetor é um escalar.

Considere $B = e_{12}$ em $Cl(3, 0)$. Como $I^{-1} = -I$,

$$B^\star = e_{12}I^{-1} = e_3.$$

Assim, o plano orientado e_{12} tem como dual a direção normal e_3 . O produto vetorial tridimensional pode ser visto precisamente como uma forma dual de representar um bivector. Essa interpretação é útil porque o plano orientado permanece o objeto primário, enquanto a normal vetorial é obtida quando necessária [37].

A convenção de dualidade deve ser declarada porque o sinal depende de três escolhas: orientação da base, assinatura da métrica e uso de dual à esquerda ou à direita.

2.7 Involuções, reversão, conjugação e inversa

2.7.1 Por que são necessárias operações involutivas

Em álgebra linear, operações como transposição e conjugação são usadas para construir simetrias, produtos escalares e inversas. A AG possui operações análogas, mas definidas diretamente sobre os graus dos multivetores.

Uma **involução** é uma operação que, aplicada duas vezes, devolve o elemento original.

2.7.2 Involução de grau

Para um elemento homogêneo A_r ,

$$\widehat{A}_r = (-1)^r A_r.$$

Ela troca o sinal dos graus ímpares e preserva os graus pares. Se

$$A = s + v + B + T,$$

com s escalar, v vetor, B bivetor e T trivetor, então

$$\widehat{A} = s - v + B - T.$$

Essa operação permite separar as partes pares e ímpares da álgebra.

2.7.3 Reversão

A **reversão** inverte a ordem dos fatores vetoriais:

$$a_1 \widetilde{a_2 \cdots a_r} = a_r \cdots a_2 a_1.$$

Para um elemento homogêneo,

$$\widetilde{A}_r = (-1)^{r(r-1)/2} A_r.$$

Em particular,

$$\widetilde{a} = a,$$

para vetores, enquanto para um bivector simples

$$\widetilde{a \wedge b} = b \wedge a = -a \wedge b.$$

A reversão aparece de maneira essencial na definição da inversa de versores e na ação de rotores.

2.7.4 Conjugação de Clifford

A conjugação de Clifford combina involução de grau e reversão. Para um elemento homogêneo,

$$\overline{A_r} = (-1)^{r(r+1)/2} A_r.$$

Embora não seja necessário memorizar imediatamente todos os sinais, é importante reconhecer que essas três operações desempenham papéis diferentes e que seus efeitos podem ser determinados diretamente pelo grau.

2.7.5 Inversa de vetores e versores

Para um vetor a não nulo em métrica não degenerada,

$$a^{-1} = \frac{a}{a^2},$$

pois

$$aa^{-1} = a \frac{a}{a^2} = 1.$$

Se a é unitário euclidiano, $a^2 = 1$ e, portanto,

$$a^{-1} = a.$$

Um **versor** é um produto de vetores inversíveis,

$$V = a_1 a_2 \cdots a_k.$$

Para essa classe de elementos,

$$V^{-1} = \frac{\widetilde{V}}{V\widetilde{V}},$$

desde que o denominador seja não nulo. Para multivetores completamente gerais, entretanto, não se deve presumir que essa expressão fornece uma inversa. A existência e o cálculo da inversa dependem da estrutura do elemento.

2.8 Projeção, rejeição, reflexão e rotação

2.8.1 Decompondo um vetor em partes paralela e perpendicular

Considere um vetor não nulo a e um vetor b . Geometricamente, b pode ser decomposto em uma parcela paralela a a e outra perpendicular:

$$b = b_{\parallel} + b_{\perp}.$$

Na AG,

$$b_{\parallel} = (b \cdot a)a^{-1},$$

$$b_{\perp} = (b \wedge a)a^{-1}.$$

A primeira expressão é a **projeção** de b sobre a ; a segunda é a **rejeição**, isto é, a parcela removida da direção de a .

Se $a = e_1$ e

$$b = 3e_1 + 2e_2,$$

então

$$b_{\parallel} = 3e_1, \quad b_{\perp} = 2e_2.$$

A utilidade dessa forma é que a mesma linguagem se estende para projeções e rejeições relativas a blades de maior grau.

2.8.2 Reflexão

Se n é normal ao hiperplano de reflexão, a reflexão de x pode ser escrita como

$$\boxed{x' = -n x n^{-1}}.$$

Considere $n = e_1$ e

$$x = x_1 e_1 + x_2 e_2.$$

Como $e_1^{-1} = e_1$,

$$x' = -e_1 x e_1 = -x_1 e_1 + x_2 e_2.$$

A componente normal ao plano muda de sinal e a componente tangencial é preservada, exatamente como esperado geometricamente.

2.8.3 De duas reflexões a uma rotação

Uma propriedade fundamental da geometria é que a composição de duas reflexões em planos apropriados produz uma rotação. Na AG, produtos pares de vetores que implementam essas composições formam **rotores**.

Se B é um bivetor unitário euclidiano que representa o plano de rotação, com

$$B^2 = -1,$$

um rotor de ângulo θ pode ser escrito como

$$R = \exp\left(-\frac{\theta}{2}B\right).$$

Como $B^2 = -1$, a exponencial assume a forma

$$R = \cos \frac{\theta}{2} - B \sin \frac{\theta}{2}.$$

A transformação é aplicada por

$$\boxed{x' = R x \widetilde{R}}.$$

Para rotores normalizados,

$$R\widetilde{R} = 1.$$

Em $Cl(2, 0)$, escolhendo $B = e_{12}$ e $\theta = \pi/2$, o rotor transforma

$$e_1 \mapsto e_2.$$

A presença de $\theta/2$ na definição do rotor é característica da representação por ação sanduíche: o rotor aparece uma vez à esquerda e uma vez à direita do objeto transformado.

Rotores armazenam o plano e o ângulo da rotação em um objeto algébrico compacto. Isso é especialmente útil para representar orientações relativas de elementos de malha, embora matrizes de rotação permaneçam disponíveis quando exigidas por bibliotecas numéricas [34], [35].

2.9 Aplicações lineares, tensores, dyadics e matrizes

2.9.1 Aplicação linear e sua matriz

Uma aplicação linear

$$F : V \rightarrow W$$

é uma regra que preserva combinações lineares:

$$F(\alpha a + \beta b) = \alpha F(a) + \beta F(b).$$

Depois que bases são escolhidas em V e W , essa aplicação pode ser representada por uma matriz $[F]^i_j$. A matriz depende das bases; a aplicação linear abstrata não.

Essa distinção é importante para evitar uma identificação frequente: **matriz e transformação não são a mesma coisa**. A matriz é a descrição coordenada da transformação.

2.9.2 Dyadics como operadores lineares

Na análise diádica, um *dyadic* pode ser escrito como combinação de produtos diádicos de vetores e atua como operador linear sobre outro vetor. Van Bladel [39] mostra que a mesma transformação vetorial pode ser apresentada tanto em forma matricial quanto em forma diádica.

Para vetores a e b , o operador diádico $a \otimes b$ atua sobre x como

$$(a \otimes b)x = a(b \cdot x),$$

adotada essa convenção de ação. O resultado é um vetor paralelo a a , cuja magnitude depende da projeção de x sobre b .

2.9.3 Tensor não é sinônimo de multivetor

Um tensor geral representa uma aplicação multilinear. Um r -vetor, por outro lado, pertence ao espaço exterior $\Lambda^r V$ e corresponde à parcela totalmente antissimétrica apropriada de uma estrutura tensorial. Portanto, a AG não permite identificar automaticamente qualquer tensor com um multivetor.

Um exemplo decisivo para este trabalho aparece no fluxo de quantidade de movimento das equações de Euler para um fluido compressível. Nesse contexto, ρ representa a densidade do fluido, u é o vetor velocidade, p é a pressão termodinâmica e I é o tensor identidade. O fluxo convectivo de quantidade de movimento e a contribuição isotrópica da pressão aparecem combinados na estrutura

$$\rho u \otimes u + pI.$$

O termo $u \otimes u$ é um tensor ou operador de segunda ordem. Quando aplicado a um vetor v ,

$$(u \otimes u)v = u(u \cdot v).$$

Já o produto geométrico de u consigo mesmo é

$$u^2 = u \cdot u = \|u\|^2$$

no caso euclidiano, portanto é um **escalar**. Logo,

$$\boxed{u \otimes u \neq u^2}.$$

Essa distinção será preservada na formulação aerodinâmica: operadores e tensores continuam sendo utilizados quando sua ação multilinear é essencial, enquanto multivetores representam estruturas geométricas para as quais grau, orientação, produto exterior ou dualidade são naturais.

2.10 Outermorphisms e extensão de transformações

2.10.1 Por que uma transformação de vetores precisa ser estendida

Suponha que F transforme vetores. Se uma face orientada é representada pelo bivector

$$B = a \wedge b,$$

é desejável que a transformação da face seja obtida a partir da transformação de suas arestas. A extensão de F que realiza essa tarefa é chamada **outermorphism** e será denotada por $\underline{F}$.

Ela é definida por

$$\underline{F}(a_1 \wedge \cdots \wedge a_r) = F(a_1) \wedge \cdots \wedge F(a_r),$$

com

$$\underline{F}(1) = 1.$$

Consequentemente,

$$\underline{F}(A \wedge B) = \underline{F}(A) \wedge \underline{F}(B).$$

Essa propriedade significa que a relação geométrica construída pelo produto exterior é preservada pela extensão da transformação.

2.10.2 Exemplo: transformação de área

Considere, no plano,

$$F(e_1) = 2e_1, \quad F(e_2) = 3e_2.$$

A área orientada unitária é representada por

$$B = e_1 \wedge e_2.$$

Após a transformação,

$$\underline{F}(B) = (2e_1) \wedge (3e_2) = 6e_{12}.$$

A área é multiplicada por 6, exatamente o determinante da transformação. Em dimensão n , para o pseudoescalar I ,

$$\underline{F}(I) = \det(F)I.$$

Dessa forma, o determinante adquire uma interpretação geométrica direta: ele mede como o elemento orientado de volume é escalado e se sua orientação é preservada ou invertida [33], [34].

O termo **extensor** será usado, quando necessário, para aplicações lineares ou multilineares estendidas a multivetores. Essa terminologia ajuda a distinguir o operador do multivetor sobre o qual ele atua.

2.11 Derivada geométrica e cálculo de campos

2.11.1 Da derivada direcional ao operador vetorial

Em cálculo vetorial, operadores como gradiente, divergência e *curl* aparecem frequentemente como construções diferentes. A AG reúne essas operações por meio de uma derivada vetorial.

Em uma base recíproca $\{e^i\}$, escreve-se formalmente

$$\nabla = e^i \partial_i,$$

onde ∂_i representa a derivada parcial em relação à coordenada correspondente. O uso da base recíproca é precisamente o que permite que a derivada seja construída de maneira compatível com a base escolhida.

Quando ∇ atua sobre um campo vetorial u , o produto geométrico separa-se em

$$\boxed{\nabla u = \nabla \cdot u + \nabla \wedge u}.$$

A primeira parcela é escalar; a segunda é bivetorial.

2.11.2 Divergência: expansão ou compressão local

A divergência

$$\nabla \cdot u$$

mede, localmente, a tendência de um campo vetorial de se afastar ou convergir para um ponto. Em um campo de velocidade, divergência positiva indica expansão volumétrica local; divergência negativa indica compressão; divergência nula caracteriza um campo solenoidal.

Por exemplo, em duas dimensões,

$$u = ax e_1 + by e_2,$$

produz

$$\nabla \cdot u = a + b.$$

2.11.3 Derivada exterior: circulação local orientada

A parcela

$$\nabla \wedge u$$

é um bivetor e representa a parte antissimétrica do gradiente do campo. Em três dimensões euclidianas, o *curl* tradicional é obtido por dualidade; a entidade geométrica primária é o bivetor $\nabla \wedge u$ [37].

Considere o campo plano de rotação rígida

$$u = -\omega y e_1 + \omega x e_2.$$

Sua divergência é zero,

$$\nabla \cdot u = 0,$$

mas

$$\nabla \wedge u = 2\omega e_{12}.$$

O bivetor e_{12} identifica diretamente o plano de rotação e o sinal de ω determina seu sentido. Esse exemplo mostra a vantagem de representar a circulação por um objeto orientado, e não apenas por um número.

Para um campo de velocidade, será conveniente definir o bivetor

$$\Omega = \nabla \wedge u,$$

associado à vorticidade geométrica. A literatura demonstra o uso de bivetores para representar planos de rotação e estruturas vorticais em campos amostrados [38].

2.12 Ponte computacional para geometrias bidimensionais

Antes da aplicação em superfícies tridimensionais, a mesma linguagem será usada em um estudo bidimensional. No plano euclidiano, a álgebra $Cl(2,0)$ possui base

$$\{1, e_1, e_2, e_{12}\},$$

com pseudoescalar $I = e_{12}$. Para dois pontos consecutivos de um contorno discretizado, x_i e x_{i+1} , define-se a aresta orientada

$$r_i = x_{i+1} - x_i.$$

Seu comprimento é $\ell_i = \|r_i\|$, e a tangente unitária é $t_i = r_i/\ell_i$. A normal orientada pode ser construída por dualidade, desde que a orientação do contorno e a convenção de dual estejam fixadas de forma consistente. Produtos internos entre tangentes vizinhas medem alinhamento, enquanto produtos exteriores registram a orientação da mudança local de direção.

Essas quantidades serão usadas como atributos de grafos construídos a partir de aerofólios e contornos eletromagnéticos 2D. O objetivo é transformar as definições algébricas deste capítulo em operações numéricas verificáveis antes de estender a implementação para $Cl(3,0)$, bivetores de faces e rotores em superfícies tridimensionais.

2.13 Representação geométrica de malhas

2.13.1 De vértices a arestas

Malhas de **Computational Electromagnetics (CEM)** e **Computational Fluid Dynamics (CFD)** são normalmente armazenadas por coordenadas de vértices e conectividade. Para uma face triangular orientada $f = (i, j, k)$, sejam x_i, x_j, x_k as posições dos vértices. As arestas relativas podem ser representadas por

$$r_{ij} = x_j - x_i, \quad r_{ik} = x_k - x_i.$$

Esses vetores já são mais geométricos do que as coordenadas absolutas, pois representam relações entre pontos da malha.

2.13.2 A face como bivector de área

A face orientada pode ser representada por

$$B_f = \frac{1}{2} r_{ij} \wedge r_{ik}.$$

O fator $1/2$ converte a área do paralelogramo na área do triângulo. No caso euclidiano,

$$\|B_f\| = A_f,$$

onde A_f é a área da face.

Considere o triângulo com

$$x_1 = (0, 0, 0), \quad x_2 = (1, 0, 0), \quad x_3 = (0, 1, 0).$$

Então

$$r_{12} = e_1, \quad r_{13} = e_2,$$

e

$$B_f = \frac{1}{2} e_{12}.$$

A magnitude é $1/2$, exatamente a área do triângulo, e o sinal de e_{12} registra a ordem dos vértices.

2.13.3 Da face orientada à normal

Em $Cl(3,0)$, adotando dual à direita,

$$n_f = \frac{B_f I^{-1}}{\|B_f\|}.$$

Para o triângulo do exemplo,

$$n_f = e_3.$$

Se a ordem dos vértices for invertida, B_f muda de sinal e a normal também. Assim, área e orientação não são atributos desconectados: ambas são propriedades do mesmo bivector.

2.13.4 Relações entre faces vizinhas

Para duas faces vizinhas, o produto interno

$$n_i \cdot n_j$$

mede alinhamento. Já

$$n_i \wedge n_j$$

retém o plano e o sentido da variação de orientação. Um rotor R_{ij} pode ainda representar diretamente a rotação que leva a orientação local da face i à da face j .

Essa estrutura é especialmente útil em grafos derivados de malhas: uma aresta do grafo não precisa carregar apenas distância e ângulo escalar; ela pode transportar relações geométricas orientadas.

2.13.5 Estados multivetoriais em nós ou faces

Uma representação local pode combinar graus diferentes,

$$X_i = s_i + v_i + B_i + \tau_i I,$$

onde:

- s_i reúne atributos escalares, como pressão, densidade, área ou curvatura escalar;
- v_i reúne grandezas vetoriais, como posição relativa ou velocidade;
- B_i reúne planos ou áreas orientadas;
- $\tau_i I$ representa uma componente pseudoescalar apenas quando houver significado físico ou geométrico para ela.

A presença de todos esses graus em $Cl(3,0)$ não significa que todos devam ser sempre utilizados. Cada canal deve corresponder a uma grandeza cuja lei de transformação e significado físico sejam conhecidos.

2.14 Ponte para o eletromagnetismo

2.14.1 Campo eletromagnético como bivector de espaço-tempo

Na **Spacetime Algebra (STA)**, ou Álgebra do Espaço-Tempo, o campo eletromagnético pode ser organizado em um único bivector F . Com assinatura, unidades e convenção de corrente declaradas, as equações de Maxwell podem ser reunidas em uma equação multivetorial do tipo

$$\nabla F = J,$$

onde J representa a corrente de espaço-tempo [32], [34].

A razão pela qual uma única equação contém várias equações físicas é a estrutura por graus do produto geométrico. Quando ∇F é separado em parcelas de diferentes graus, recuperam-se as contribuições associadas às equações homogêneas e não homogêneas de Maxwell.

Essa escrita deve ser entendida como **unificação representacional**, não como “linearização” das equações. Em meios lineares, Maxwell já é linear nos campos. A vantagem da STA consiste em representar, dentro de uma mesma estrutura, campo, dualidade, polarização, transformações e operadores.

Para o problema de **Radar Cross Section (RCS)**, essa base será usada no capítulo de física para distinguir campo incidente, campo espalhado, condições constitutivas, condições de contorno e extração do campo distante.

2.15 Ponte para a dinâmica dos fluidos

2.15.1 Vorticidade como bivector

A mecânica dos fluidos fornece um exemplo natural de grandeza cuja interpretação geométrica é favorecida por bivectores. Em três dimensões, a vorticidade é tradicionalmente representada por um pseudovetor associado ao *curl* da velocidade. Na AG, pode-se utilizar diretamente

$$\Omega = \nabla \wedge u.$$

O bivector identifica o plano local de rotação do campo de velocidade. Sen [37] emprega essa estrutura em uma formulação geométrica que relaciona vorticidade e vetor de Lamb. Por sua vez, Parameswaran et al. [40] desenvolvem equações fluidodinâmicas análogas às de Maxwell em espaço-tempo.

2.15.2 O termo convectivo continua não linear

Uma identidade útil de cálculo geométrico é

$$(u \cdot \nabla)u = u \cdot (\nabla \wedge u) + \frac{1}{2}\nabla(u^2).$$

Ela separa o termo convectivo em uma contribuição relacionada à rotação local e outra relacionada ao gradiente da energia cinética específica. A identidade melhora a interpretação geométrica, mas não remove a dependência quadrática em u . Portanto, ela **não transforma as equações de Euler em um sistema globalmente linear** [37].

No caso compressível conservativo, estruturas como

$$\rho u \otimes u$$

continuam sendo tensoriais. O uso da AG concentra-se nas parcelas para as quais orientação, vorticidade, derivadas geométricas e transformações admitem uma representação multivetorial consistente.

2.16 Ponte para Graph Neural Networks

2.16.1 Por que a geometria interessa ao aprendizado em grafos

Uma GNN processa dados por meio de nós, arestas e agregação de mensagens. Em uma malha física, entretanto, os atributos associados a esses elementos não são apenas números abstratos: posição relativa é um vetor, orientação de face pode ser um bivector, alinhamento pode ser um escalar e transformação relativa pode ser um rotor.

Codificar essas grandezas apenas como uma sequência de números é possível, mas transfere para a rede a responsabilidade de aprender, a partir dos dados, relações geométricas que já são conhecidas analiticamente. A AG oferece uma forma de manter parte dessa estrutura explícita.

Zhong e Cao [41] propõem uma **Graph Geometric Algebra Network (GGAN)** na qual atributos são organizados como componentes multivetoriais e operações de AG participam da agregação de vizinhança. Esse antecedente demonstra a viabilidade computacional da combinação entre AG e GNNs, embora suas tarefas de classificação de nós e grafos sejam distintas da predição de campos físicos em malhas.

2.16.2 Uma mensagem geometricamente estruturada

Em forma abstrata, uma mensagem entre nós ou faces i e j pode ser escrita como

$$m_{ij} = \Phi_{\theta}(X_i, X_j, R_{ij}, B_{ij}, c),$$

seguida de

$$X'_i = \Psi_{\theta}(X_i, \text{AGG}_{j \in \mathcal{N}(i)} m_{ij}).$$

Aqui:

- X_i e X_j são estados locais, possivelmente multivetoriais;
- R_{ij} representa orientação relativa;
- B_{ij} representa uma relação plana ou área orientada;
- c reúne condições físicas globais, como Mach, ângulo de ataque, frequência ou polarização;
- Φ_{θ} e Ψ_{θ} são funções aprendidas;
- AGG agrega as mensagens da vizinhança.

A arquitetura concreta deve respeitar como cada grandeza se transforma sob rotação, reflexão e mudança de referencial. Um escalar, por exemplo, não deve ser tratado como se tivesse a mesma lei de transformação de um vetor ou de um bivector.

2.16.3 Estudos de ablação

A AG permanece como formalismo do framework. Estudos de ablação serão utilizados para quantificar a contribuição de escolhas específicas: canais bivetoriais, rotores, produtos geométricos ou atributos cartesianos convencionais. O objetivo é medir impacto em precisão, generalização e eficiência, e não decidir se a estrutura matemática fundamental será abandonada.

2.17 Critérios computacionais

Uma expressão algebricamente mais compacta não é necessariamente mais rápida em computador. Uma implementação multivetorial pode reduzir parâmetros ou evitar transformações redundantes, mas também pode introduzir mais componentes e produtos.

Por isso, qualquer vantagem computacional será tratada como resultado experimental. A avaliação considerará, conforme aplicável:

- número de parâmetros treináveis;
- memória de pico durante treinamento e inferência;
- tempo de treinamento;
- tempo de inferência;
- número de operações ou kernels relevantes;
- estabilidade numérica;
- erro de predição;
- generalização a geometrias não vistas;
- sensibilidade a rotações e mudanças de referencial;
- impacto no número de avaliações dos modelos físicos de referência;
- impacto no tempo total da otimização aero-stealth.

A AG é, portanto, o formalismo matemático adotado; o ganho computacional de cada representação é uma propriedade a ser demonstrada por benchmark.

2.18 Síntese

A construção apresentada neste capítulo começa com objetos familiares e adiciona estrutura progressivamente. Vetores fornecem direção; o produto interno introduz métrica; o produto exterior representa subespaços orientados; e o produto geométrico reúne essas informações em uma operação associativa. A graduação distingue escalares, vetores, bivectores e elementos de ordem superior, enquanto multivetores permitem combinar graus sem perder sua identidade geométrica.

A base recíproca permite extrair componentes e construir operadores diferenciais mesmo quando a base não é ortonormal. O pseudoescalar introduz dualidade entre dimensões complementares.

Involuções e reversão permitem controlar sinais e construir inversas. Versores e rotores transformam reflexões e rotações em produtos da própria álgebra. Outermorphisms estendem transformações de vetores a áreas e volumes orientados. A derivada geométrica reúne divergência e derivada exterior em um único produto.

Para o framework aero-stealth, essas ferramentas sustentam três conexões. A primeira é geométrica: faces, áreas orientadas, normais e transformações relativas de uma malha podem ser representadas sem reduzir toda informação a coordenadas cartesianas. A segunda é física: o eletromagnetismo admite uma formulação particularmente compacta em espaço-tempo, enquanto a aerodinâmica se beneficia de representações geométricas de vorticidade e derivadas sem perder a estrutura tensorial e não linear das equações de Euler. A terceira é computacional: atributos e operações de AG podem integrar mensagens e estados internos das GNNs empregadas como modelos substitutos multifidelidade.

A partir dessa base, o capítulo seguinte formula as equações eletromagnéticas e aerodinâmicas, especificando quais objetos serão representados por multivetores, quais permanecerão tensores ou operadores e quais projeções escalares serão necessárias para discretização, aprendizado e otimização.

3 Física governante: eletromagnetismo, RCS e aerodinâmica compressível

Este capítulo estabelece os modelos físicos que sustentam as duas respostas centrais do problema aero-stealth de configurações de **Unmanned Combat Aerial Vehicle (UCAV)**: a **assinatura eletromagnética**, representada principalmente pela **Radar Cross Section (RCS)**, e o **desempenho aerodinâmico**, representado por distribuições de pressão, forças e momentos. O objetivo não é apenas registrar equações conhecidas, mas construir uma ponte explícita entre três níveis de descrição usados ao longo do livro: a formulação física convencional, sua interpretação em **Álgebra Geométrica (AG)** e a forma pela qual essas grandezas poderão alimentar modelos substitutos baseados em **Graph Neural Networks (GNNs)**.

A AG é empregada como linguagem estruturante quando oferece uma representação geometricamente natural. Isso não implica substituir indiscriminadamente tensores, matrizes ou discretizações numéricas por multivetores. No eletromagnetismo, as equações de Maxwell em meios lineares já constituem um sistema linear nos campos; a contribuição da **Álgebra do Espaço-Tempo (*Spacetime Algebra*, STA)** é reunir a estrutura elétrica e magnética em uma representação multivetorial compacta e geometricamente coerente [32], [34]. Na aerodinâmica compressível, por outro lado, as equações de Euler contêm não linearidades físicas intrínsecas, em especial na advecção da quantidade de movimento e na relação entre energia, pressão, densidade e velocidade. A AG pode reorganizar e explicitar estruturas geométricas desses campos, mas não elimina essas não linearidades.

3.1 Parte I — Eletromagnetismo, espalhamento e Radar Cross Section

3.2 Do campo eletromagnético às equações de Maxwell

3.2.1 Campos, fontes e meio material

Uma forma intuitiva de organizar o eletromagnetismo clássico é separar três perguntas. **Quais campos existem em cada ponto do espaço? Quais fontes os produzem? Como o material responde a esses campos?** As equações de Maxwell conectam as duas primeiras perguntas; as relações constitutivas respondem à terceira.

No Sistema Internacional de Unidades, as grandezas fundamentais utilizadas aqui são:

- **E**: campo elétrico, em volts por metro (V/m);
- **H**: campo magnético, em ampères por metro (A/m);
- **D**: densidade de fluxo elétrico, em coulombs por metro quadrado (C/m²);
- **B**: densidade de fluxo magnético, em teslas (T);
- ρ_e : densidade volumétrica de carga elétrica, em C/m³;
- **J**: densidade de corrente elétrica, em A/m².

É importante distinguir **E** e **H**, que descrevem intensidades de campo, de **D** e **B**, que incorporam a resposta constitutiva do meio. Em um meio linear, homogêneo e isotrópico,

$$\mathbf{D} = \varepsilon \mathbf{E}, \quad \mathbf{B} = \mu \mathbf{H},$$

onde ε é a permissividade elétrica e μ a permeabilidade magnética. Para um meio condutor linear também se utiliza

$$\mathbf{J} = \sigma_c \mathbf{E},$$

com σ_c representando a condutividade elétrica. Essas relações não são meros detalhes auxiliares: mudar o material altera a forma pela qual os campos se relacionam e, portanto, altera a solução de espalhamento.

No vácuo,

$$\varepsilon = \varepsilon_0, \quad \mu = \mu_0,$$

e a velocidade de propagação eletromagnética é

$$c = \frac{1}{\sqrt{\mu_0 \varepsilon_0}}.$$

Para grande parte do domínio externo de um problema radar atmosférico, o ar pode ser aproximado eletromagneticamente pelo vácuo. Essa aproximação não elimina a necessidade de modelar corretamente a superfície do alvo e, quando relevantes, revestimentos, radomes, materiais absorvedores ou cavidades.

3.2.2 As quatro equações de Maxwell

Antes de escrever as equações, convém separar duas ideias. O **divergente** mede, localmente, se um campo apresenta comportamento de fonte ou sumidouro. O **rotacional** mede sua tendência de circulação. As quatro equações de Maxwell combinam essas duas estruturas com as fontes elétricas e com a variação temporal dos campos.

Na forma diferencial convencional,

$$\nabla \cdot \mathbf{D} = \rho_e,$$

$$\nabla \cdot \mathbf{B} = 0,$$

$$\nabla \times \mathbf{E} = -\frac{\partial \mathbf{B}}{\partial t},$$

$$\nabla \times \mathbf{H} = \mathbf{J} + \frac{\partial \mathbf{D}}{\partial t}.$$

A primeira equação é a lei de Gauss para o campo elétrico: a densidade de carga atua como fonte do fluxo elétrico. A segunda exprime a ausência de monopolos magnéticos no modelo clássico. A terceira é a lei de Faraday: um campo magnético variável está associado à circulação de campo elétrico. A quarta é a lei de Ampère-Maxwell: corrente elétrica e variação do fluxo elétrico estão associadas à circulação do campo magnético.

Em uma região homogênea sem cargas nem correntes impostas, $\rho_e = 0$ e $\mathbf{J} = 0$, mas os campos não precisam desaparecer. Uma onda eletromagnética que se propaga no espaço livre é precisamente um exemplo em que $\mathbf{E}$ e $\mathbf{B}$ continuam acoplados por Faraday e Ampère-Maxwell mesmo na ausência de fontes locais.

Essas quatro relações compõem um único sistema físico. Essa unidade ficará particularmente clara quando o sistema for retomado em STA.

3.3 Do domínio do tempo ao domínio da frequência

3.3.1 Por que usar fasores?

No **domínio do tempo**, os campos são funções de posição e tempo, como $\mathbf{E}(\mathbf{x}, t)$. Essa representação é indispensável quando se deseja acompanhar transientes, pulsos ou respostas não estacionárias. Entretanto, muitos problemas de RCS consideram uma iluminação senoidal permanente em uma frequência conhecida. Depois que os transientes desaparecem, todos os

campos de um sistema linear excitado em uma única frequência oscilam na mesma frequência angular ω , embora possam apresentar amplitudes e fases diferentes em cada ponto.

A ideia do fasor é retirar da equação a oscilação temporal conhecida e manter apenas sua **amplitude complexa**. Considere primeiro uma grandeza escalar simples,

$$x(t) = A \cos(\omega t + \phi).$$

Pela fórmula de Euler, essa oscilação pode ser escrita como

$$x(t) = \Re \{ \tilde{x} e^{j\omega t} \}, \quad \tilde{x} = A e^{j\phi},$$

onde $\tilde{x}$ armazena simultaneamente amplitude A e fase ϕ . Derivar no tempo fornece

$$\frac{dx}{dt} = \Re \{ j\omega \tilde{x} e^{j\omega t} \}.$$

Portanto, na representação fasorial,

$$\boxed{\frac{\partial}{\partial t} \longleftrightarrow j\omega}$$

e, analogamente,

$$\frac{\partial^2}{\partial t^2} \longleftrightarrow -\omega^2.$$

Esse é o ganho essencial da passagem para o **domínio da frequência**: as derivadas **temporais** tornam-se multiplicações algébricas por $j\omega$. Em problemas lineares de frequência única, isso simplifica fortemente a dependência temporal. A transformação, contudo, não converte todo o problema de Maxwell em um sistema puramente algébrico: os operadores espaciais $\nabla \cdot$, $\nabla \times$ e ∇^2 permanecem diferenciais até que também sejam discretizados numericamente.

3.3.2 Maxwell no domínio da frequência

Assumindo a convenção temporal $e^{j\omega t}$, escreve-se, por exemplo,

$$\mathbf{E}(\mathbf{x}, t) = \Re \left\{ \tilde{\mathbf{E}}(\mathbf{x}) e^{j\omega t} \right\}.$$

A lei de Faraday passa de

$$\nabla \times \mathbf{E} = -\frac{\partial \mathbf{B}}{\partial t}$$

para

$$\boxed{\nabla \times \tilde{\mathbf{E}} = -j\omega \tilde{\mathbf{B}}}.$$

De forma semelhante, a lei de Ampère-Maxwell torna-se

$$\boxed{\nabla \times \tilde{\mathbf{H}} = \tilde{\mathbf{J}} + j\omega \tilde{\mathbf{D}}}.$$

Em meio homogêneo, linear e sem fontes, a combinação das equações conduz à equação vetorial de Helmholtz,

$$\nabla^2 \tilde{\mathbf{E}} + k^2 \tilde{\mathbf{E}} = 0,$$

com

$$k = \omega \sqrt{\mu \varepsilon} = \frac{2\pi}{\lambda},$$

onde k é o número de onda e λ o comprimento de onda.

Como exemplo, uma frequência maior implica λ menor no mesmo meio. Uma borda, cavidade ou detalhe geométrico de dimensão fixa torna-se, portanto, **eletricamente maior** quando a frequência aumenta. Essa razão entre dimensão física e comprimento de onda ajuda a determinar mecanismos dominantes de espalhamento, resolução de malha e adequação de aproximações assintóticas.

Para RCS em regime harmônico, a aplicação prática é direta: cada frequência é tratada como um problema fasorial. Uma varredura em frequência exige resolver ou aproximar vários desses problemas. Para pulsos de banda larga, materiais não lineares ou fenômenos transientes, a formulação no domínio do tempo pode voltar a ser mais apropriada.

3.4 O problema de espalhamento eletromagnético

3.4.1 Campo incidente, campo espalhado e campo total

A intuição do espalhamento é a mesma de muitas situações ondulatórias: existe uma onda que chegaria à região mesmo se o objeto não estivesse presente; o objeto perturba essa onda; e a perturbação se propaga para longe. No problema radar, a primeira parcela é o **campo incidente** e a perturbação produzida pelo alvo é o **campo espalhado**.

O campo total é escrito como

$$\mathbf{E}_{\text{tot}} = \mathbf{E}_{\text{inc}} + \mathbf{E}_{\text{sca}},$$

$$\mathbf{H}_{\text{tot}} = \mathbf{H}_{\text{inc}} + \mathbf{H}_{\text{sca}}.$$

A RCS não mede diretamente o campo total na vizinhança do alvo. Ela caracteriza a intensidade com que o objeto redireciona energia eletromagnética para uma determinada direção no campo distante [22].

3.4.2 Onda plana incidente

Quando o radar está suficientemente distante em comparação com a dimensão do alvo, uma pequena região ao redor do veículo pode ser iluminada aproximadamente por frentes de onda planas. Em meio homogêneo,

$$\tilde{\mathbf{E}}_{\text{inc}}(\mathbf{x}) = \mathbf{E}_0 e^{-j\mathbf{k} \cdot \mathbf{x}},$$

onde

$$\mathbf{k} = k\hat{\mathbf{k}}$$

é o vetor de onda. Sua direção $\hat{\mathbf{k}}$ indica a propagação e seu módulo k controla a variação de fase no espaço. Se a propagação ocorre, por exemplo, ao longo de $+x$, então $\mathbf{k} \cdot \mathbf{x} = kx$ e superfícies com mesmo x possuem a mesma fase.

O campo magnético associado, para uma onda plana em meio isotrópico sem perdas, satisfaz

$$\tilde{\mathbf{H}}_{\text{inc}} = \frac{1}{\eta} \hat{\mathbf{k}} \times \tilde{\mathbf{E}}_{\text{inc}},$$

com impedância intrínseca

$$\eta = \sqrt{\frac{\mu}{\varepsilon}}.$$

Assim, $\tilde{\mathbf{E}}$, $\tilde{\mathbf{H}}$ e $\hat{\mathbf{k}}$ formam direções mutuamente ortogonais no caso ideal de onda plana. O vetor $\mathbf{E}_0$ define amplitude e polarização. Para o problema aero-stealth, frequência, direção de incidência e polarização são, portanto, entradas físicas tão importantes quanto a própria geometria.

3.4.3 Condições de contorno

As equações no domínio não bastam para determinar uma solução única: é preciso informar o que acontece nas interfaces materiais e exigir que o campo espalhado se propague para fora do domínio.

Para um **Perfect Electric Conductor (PEC)** ideal, cargas livres se reorganizam de modo que o campo elétrico tangencial total na superfície seja nulo:

$$\boxed{\hat{\mathbf{n}} \times \mathbf{E}_{\text{tot}} = 0},$$

onde $\hat{\mathbf{n}}$ é a normal unitária à superfície. A corrente superficial associada pode ser representada por

$$\mathbf{J}_s = \hat{\mathbf{n}} \times \mathbf{H}_{\text{tot}}.$$

Geometricamente, a condição PEC conecta diretamente a orientação local da superfície aos campos. Em uma malha triangular, a normal e o bivector orientado de cada face tornam-se, por isso, atributos naturais para uma representação física em grafo.

Em materiais dielétricos, magnéticos ou absorvedores, as condições são mais gerais e envolvem continuidade apropriada das componentes tangenciais e normais, além das relações constitutivas de cada meio. No exterior do alvo, uma condição de radiação exclui soluções artificiais que chegariam do infinito.

3.5 Do campo próximo ao campo distante

3.5.1 Intuição física

Muito perto de um objeto espalhador, o campo registra detalhes locais: correntes, acoplamentos entre superfícies, cavidades e variações rápidas de fase e amplitude. À medida que o observador se afasta, esses detalhes deixam de ser percebidos separadamente e o campo assume a estrutura assintótica de uma onda que se propaga radialmente. A primeira situação é associada ao **campo próximo**; a segunda, ao **campo distante**.

Para um alvo com dimensão característica máxima D , a ordem de grandeza

$$r \gg \frac{2D^2}{\lambda}$$

é frequentemente usada como referência de região de Fraunhofer, embora a fronteira exata dependa da geometria e do critério adotado [22]. O ponto conceitual importante é que a distância necessária para observar comportamento de campo distante também depende do comprimento de onda.

No limite assintótico,

$$\tilde{\mathbf{E}}_{\text{sca}}(r, \hat{\mathbf{r}}) \sim \frac{e^{-jkr}}{r} \mathbf{F}_E(\hat{\mathbf{r}}), \quad r \rightarrow \infty,$$

onde $\mathbf{F}_E$ é a amplitude vetorial de espalhamento e $\hat{\mathbf{r}}$ a direção de observação. O fator $1/r$ descreve o decaimento da amplitude; consequentemente, a densidade de potência decai como $1/r^2$. A função $\mathbf{F}_E$ retém a informação angular e de polarização que interessa à assinatura radar.

3.5.2 Radar Cross Section como área equivalente

A **Radar Cross Section** pode ser interpretada intuitivamente como uma **área equivalente de espalhamento**: ela responde à pergunta “quão intenso é o campo devolvido por esse alvo, naquela direção, quando comparado à iluminação recebida?”. Essa área equivalente não precisa coincidir com a área geométrica projetada do objeto. Interferência, orientação, materiais, bordas e cavidades podem produzir uma RCS muito maior ou muito menor que uma área física aparente.

Formalmente,

$$\sigma(\hat{\mathbf{r}}) = \lim_{r \rightarrow \infty} 4\pi r^2 \frac{\|\mathbf{E}_{\text{sca}}(r, \hat{\mathbf{r}})\|^2}{\|\mathbf{E}_{\text{inc}}\|^2}$$

em condições compatíveis de normalização [22]. A unidade de σ é área, normalmente metros quadrados.

Como a variação pode abranger muitas ordens de grandeza, é comum empregar decibéis por metro quadrado:

$$\sigma_{\text{dBsm}} = 10 \log_{10} \left(\frac{\sigma}{1 \text{ m}^2} \right).$$

Assim, 1 m^2 corresponde a 0 dBsm, 10^{-2} m^2 corresponde a -20 dBsm e 10^2 m^2 corresponde a $+20$ dBsm. O exemplo serve apenas para interpretar a escala logarítmica; não associa esses valores a uma plataforma específica.

3.5.3 RCS monoestática e biestática

Na configuração **monoestática**, transmissor e receptor estão essencialmente co-localizados. O receptor observa, portanto, o retroespalhamento na direção de retorno ao radar. Na configuração **biestática**, transmissor e receptor ocupam posições diferentes e a direção de observação não coincide, em geral, com a direção de retorno.

Essa distinção importa porque um mesmo alvo pode apresentar um pico intenso em uma direção e baixa assinatura em outra. Para o framework deste livro, a curva angular de RCS deve ser tratada como uma resposta física rica, e não reduzida prematuramente a um único valor médio. Métricas agregadas podem ser calculadas posteriormente, preservando-se antes os lóbulos, picos especulares e regiões de baixa assinatura.

3.5.4 Polarização

A polarização especifica a orientação e a evolução temporal do campo elétrico transversal à direção de propagação. Em problemas radar, escolhe-se uma base de polarização — frequentemente descrita como horizontal e vertical em relação a uma convenção geométrica — e mede-se como o alvo transforma a componente transmitida na componente recebida.

Podem ser consideradas respostas co-polarizadas e cruzadas, como HH, VV, HV e VH. Os rótulos dependem da base de referência escolhida e, por isso, a convenção deve acompanhar os dados. Uma representação abstrata é

$$\sigma = \sigma(\theta_i, \phi_i, \theta_s, \phi_s, f, \text{pol}),$$

onde os índices i e s indicam incidência e observação. Em um cenário monoestático, parte dessa parametrização se reduz geometricamente, mas frequência e polarização continuam sendo variáveis essenciais.

3.6 Mecanismos de espalhamento e geometria da aeronave

A RCS não é uma soma de “RCS locais” independentes. O campo espalhado é uma soma **coerente**: amplitudes complexas provenientes de diferentes regiões chegam com fases distintas e podem reforçar-se ou cancelar-se.

Uma superfície aproximadamente plana e eletricamente grande pode produzir forte reflexão especular em certas direções. Uma borda pode difratar energia para regiões que não receberiam contribuição apenas pela reflexão geométrica. Cavidades e entradas podem sustentar múltiplas interações internas. Pequenas alterações de ângulo ou posição de uma superfície podem modificar fases relativas e deslocar picos angulares [22].

Essa dependência explica por que uma representação de malha para GNN não deve carregar apenas coordenadas dos vértices. Normais, áreas, orientação relativa entre faces, conectividade, bordas e condições de incidência carregam informação diretamente relacionada aos mecanismos físicos de espalhamento.

3.7 Métodos numéricos e níveis de fidelidade eletromagnética

A escolha do método computacional depende do que precisa ser resolvido e da relação entre dimensão geométrica e comprimento de onda. Métodos de onda completa procuram representar diretamente a solução de Maxwell dentro das hipóteses constitutivas adotadas; aproximações assintóticas exploram regimes em que a estrutura da propagação permite simplificações controladas.

Yee [42] constitui uma referência clássica para **Finite-Difference Time-Domain (FDTD)**: espaço e tempo são discretizados e os campos evoluem passo a passo. Uma vantagem conceitual é que uma única excitação transitória pode conter várias frequências; em contrapartida, o domínio volumétrico e a resolução exigida pelo menor comprimento de onda podem elevar a demanda de memória e processamento.

Em alvos PEC, formulações integrais de superfície podem reduzir as incógnitas às correntes na superfície. As funções de base de Rao, Wilton e Glisson [43] são fundamentais em implementações do **Method of Moments (MoM)** para malhas triangulares. Após a discretização, o problema é convertido em um sistema linear cujas propriedades computacionais dependem do tamanho da malha e da formulação utilizada.

Quando o alvo é eletricamente grande, aproximações de alta frequência, como **Physical Optics (PO)** e técnicas baseadas em raios, podem reduzir a demanda de recursos ao representar mecanismos dominantes sem resolver todos os detalhes de uma formulação de onda completa. Essa economia vem acompanhada de hipóteses adicionais, especialmente relevantes em bordas, regiões de sombra, cavidades ou múltiplas interações.

Por isso, **fidelidade** não deve ser confundida com o nome do solver. Um nível de fidelidade é definido pelo conteúdo físico e numérico efetivamente representado: aproximações, resolução de malha, tratamento de bordas e cavidades, propriedades materiais, frequência, critérios de convergência e demais hipóteses. A classificação será retomada no capítulo de modelagem multifidelidade.

3.8 Maxwell em Álgebra Geométrica do espaço-tempo

3.8.1 Da separação E/B a um único campo geométrico

Na formulação tridimensional usual, campos elétrico e magnético são escritos como vetores separados e aparecem em quatro equações. A STA parte de uma observação diferente: no espaço-tempo relativístico, as componentes que um observador chama de “elétricas” e “magnéticas” pertencem a um único campo eletromagnético. A separação entre **E** e **B** depende da escolha do observador, enquanto o campo espaço-temporal completo pode ser representado por um único bivector [32], [34].

A álgebra adotada é associada ao espaço-tempo de Minkowski. Neste livro utiliza-se a assinatura

$$\gamma_0^2 = +1, \quad \gamma_k^2 = -1, \quad k = 1, 2, 3,$$

correspondente a $Cl(1, 3)$. Outras assinaturas são encontradas na literatura; resultados intermediários podem mudar de sinal quando convenções são trocadas, razão pela qual a assinatura deve ser declarada antes das manipulações.

3.8.2 O operador derivada no espaço-tempo

No capítulo anterior, a derivada geométrica reuniu divergência e parte exterior em uma única operação. Em quatro dimensões define-se, analogamente,

$$\nabla = \gamma^\mu \partial_\mu,$$

com soma sobre $\mu = 0, 1, 2, 3$. Usando $x^0 = ct$, a direção temporal e as três direções espaciais fazem parte do mesmo operador.

Quando F é um bivector,

$$\nabla F = \nabla \cdot F + \nabla \wedge F.$$

O produto de um vetor derivada com um bivector produz partes de graus diferentes: uma parte vetorial e uma parte trivectorial. Essa separação por grau é a chave para recuperar, dentro de uma única equação, os dois pares de equações de Maxwell.

3.8.3 O campo de Faraday como bivector

O campo eletromagnético é representado pelo bivector F , frequentemente chamado **bivector de Faraday**. Em uma decomposição relativa a um observador, as componentes elétricas ocupam planos espaço-temporais, enquanto as componentes magnéticas correspondem a planos puramente espaciais. Usando vetores espaciais relativos e unidades compatíveis, essa decomposição pode ser representada esquematicamente por

$$F = \mathbf{E} + cI\mathbf{B},$$

com sinais e fatores de c dependentes da convenção adotada. Aqui, $I = \gamma_0\gamma_1\gamma_2\gamma_3$ é o pseudo-escalar do espaço-tempo. A expressão não deve ser lida como simples concatenação de seis componentes: F é um objeto bivectorial cuja decomposição em partes elétrica e magnética depende do observador [32].

As fontes podem ser reunidas em um quatro-vetor de corrente. Para evitar esconder fatores de unidades, denota-se por $\mathcal{J}$ o quatro-vetor fonte já escalado de acordo com a convenção de F , c , ε_0 e μ_0 adotada. Em unidades e normalizações compatíveis,

$$\boxed{\nabla F = \mathcal{J}}.$$

No vácuo sem fontes,

$$\boxed{\nabla F = 0}.$$

A igualdade deve ser entendida por graus: a parte $\nabla \cdot F$ contém as equações não homogêneas associadas às fontes; a parte $\nabla \wedge F$ contém as equações homogêneas. A escrita única não apaga as quatro leis — ela mostra que elas são projeções de grau de uma mesma relação geométrica. Dressel, Bliokh e Nori [32] discutem extensamente essa unificação do campo eletromagnético em STA.

3.8.4 O que a formulação compacta faz — e o que não faz

A escrita

$$\nabla F = \mathcal{J}$$

não “lineariza” Maxwell. Em meios lineares, o sistema já é linear nos campos. A contribuição da STA é de **unificação representacional**, manipulação geométrica e acesso natural a invariantes e transformações de Lorentz [32].

Também não se conclui, apenas pela compacidade da notação, que um solver em AG será mais rápido. Um cálculo de RCS ainda precisa discretizar geometria e materiais, impor condições de contorno, resolver as incógnitas e extrair o campo distante. Eventual redução de tempo, memória ou número de operações deve ser demonstrada por benchmark com implementações comparáveis.

3.9 Validação eletromagnética progressiva

A validação deve separar erros de formulação de dificuldades introduzidas pela geometria. Uma sequência apropriada começa com propagação de onda plana em meio homogêneo, passa pela reflexão em plano PEC, pelo espalhamento em esfera condutora e por uma placa ou face triangular, e somente depois avança para geometrias aeronáuticas e para a configuração UCAV de interesse. Em cada etapa devem ser verificadas convenções de fase, polarização, orientação de normais, condições de contorno e extração do campo distante antes de se atribuir discrepâncias à complexidade do alvo.

3.10 Parte II — Aerodinâmica compressível e equações de Euler

3.11 Do escoamento contínuo ao sistema de conservação

3.11.1 O que o modelo de fluido representa

Na aerodinâmica contínua, o ar não é acompanhado molécula por molécula. Assume-se que grandezas como densidade, pressão, temperatura e velocidade podem ser definidas como campos contínuos no espaço e no tempo. Essa hipótese transforma o problema microscópico em um sistema de leis de conservação aplicadas a pequenos volumes de fluido.

Uma maneira útil de antecipar as equações é pensar em qualquer volume de controle: **acumulação dentro do volume + fluxo líquido através da fronteira = fontes externas**. As

equações de Euler aplicam essa ideia à massa, à quantidade de movimento e à energia, sob hipóteses específicas sobre o fluido.

3.11.2 Hipóteses do modelo

O modelo introduzido neste capítulo é o escoamento externo **compressível, invíscido e de gás caloricamente perfeito**. A hipótese invíscida omite tensões viscosas e condução térmica das equações governantes. Isso não significa que a viscosidade real do ar seja zero; significa que, neste nível de modelagem, camada limite, atrito de parede, dissipação viscosa e separação controlada pela viscosidade não são representados explicitamente.

Essas limitações têm consequência direta para a interpretação dos resultados. Um solver Euler pode representar pressão, ondas de compressão, efeitos de compressibilidade e parte importante da distribuição de carga aerodinâmica, mas não fornece arrasto de atrito e pode não representar adequadamente fenômenos dominados por separação viscosa. Modelos baseados em **Reynolds-Averaged Navier-Stokes (RANS)** ou abordagens mais completas tornam-se necessários quando esses efeitos são relevantes.

O regime de interesse é predominantemente subsônico,

$$M_\infty < 1,$$

mas a formulação compressível é preservada. “Subsônico” não significa “incompressível”: a densidade ainda pode variar e a importância dessas variações cresce à medida que a velocidade se aproxima da velocidade do som.

3.11.3 Variáveis primitivas e significado físico

As variáveis primitivas utilizadas são

- ρ : densidade do fluido;
- $\mathbf{u} = (u, v, w)$: vetor velocidade;
- p : pressão termodinâmica;
- T : temperatura;
- e : energia interna específica;
- E : energia total específica.

A energia total específica soma energia interna e energia cinética:

$$E = e + \frac{1}{2} \|\mathbf{u}\|^2.$$

Para um gás caloricamente perfeito,

$$p = \rho RT, \quad e = c_v T,$$

onde R é a constante específica do gás e c_v o calor específico a volume constante. Com

$$\gamma = \frac{c_p}{c_v},$$

obtém-se

$$p = (\gamma - 1) \left(\rho E - \frac{1}{2} \rho \|\mathbf{u}\|^2 \right).$$

Essa relação fecha o sistema ao conectar a variável conservativa de energia à pressão.

3.11.4 Velocidade do som e número de Mach

A velocidade do som não é apenas uma constante do ar: ela depende do estado termodinâmico. Para o gás perfeito considerado,

$$a = \sqrt{\gamma \frac{p}{\rho}} = \sqrt{\gamma RT}.$$

O número de Mach é

$$M = \frac{\|\mathbf{u}\|}{a}.$$

Ele compara a velocidade do escoamento com a velocidade de propagação de pequenas perturbações de pressão. Como exemplo meramente ilustrativo, se $V = 240$ m/s e $a = 340$ m/s, então $M \approx 0,71$. Como a varia com a temperatura, o mesmo valor de velocidade não corresponde necessariamente ao mesmo Mach em todas as condições atmosféricas.

Para uma configuração UCAV, M_∞ , ângulo de ataque, altitude ou condições equivalentes de p_∞ , T_∞ e ρ_∞ fazem parte da definição da condição de voo.

3.12 Conservação de massa

3.12.1 Intuição: o que entra, o que sai e o que se acumula

Considere um volume de controle fixo. Se mais massa sai pela fronteira do que entra, a massa contida no volume diminui. Em forma local, essa ideia é

$$\frac{\partial \rho}{\partial t} + \nabla \cdot (\rho \mathbf{u}) = 0.$$

O primeiro termo mede a variação temporal local da densidade; o segundo mede o balanço espacial do fluxo de massa $\rho \mathbf{u}$.

Em um escoamento unidimensional permanente por um tubo cuja área varia lentamente, a mesma conservação conduz à relação familiar

$$\rho u A = \text{constante}.$$

O exemplo ajuda a interpretar a equação diferencial: se a área diminui e a densidade não compensa integralmente essa mudança, a velocidade deve se ajustar para conservar a vazão mássica.

Em regime permanente,

$$\frac{\partial \rho}{\partial t} = 0,$$

e permanece

$$\nabla \cdot (\rho \mathbf{u}) = 0.$$

3.13 Conservação de quantidade de movimento

3.13.1 Da segunda lei de Newton ao fluxo por uma superfície

A quantidade de movimento por unidade de volume é $\rho \mathbf{u}$. Para um fluido, não basta acompanhar sua variação local: a própria quantidade de movimento é transportada através das superfícies do volume de controle. Na ausência de forças de corpo e de tensões viscosas,

$$\frac{\partial(\rho \mathbf{u})}{\partial t} + \nabla \cdot (\rho \mathbf{u} \otimes \mathbf{u} + p \mathbf{I}) = 0.$$

Nesta expressão, $\mathbf{I}$ é o tensor identidade. O operador

$$\rho \mathbf{u} \otimes \mathbf{u}$$

representa o transporte convectivo da quantidade de movimento, enquanto

$$p\mathbf{I}$$

representa a contribuição isotrópica da pressão.

A interpretação sobre uma face torna o produto tensorial mais concreto. Se $\hat{\mathbf{n}}$ é a normal da face,

$$(\rho \mathbf{u} \otimes \mathbf{u})\hat{\mathbf{n}} = \rho \mathbf{u}(\mathbf{u} \cdot \hat{\mathbf{n}}).$$

O escalar $\mathbf{u} \cdot \hat{\mathbf{n}}$ mede quanto do escoamento atravessa a face; multiplicá-lo por $\rho \mathbf{u}$ fornece a quantidade de movimento transportada nessa direção. Essa leitura explica por que fluxos e faces orientadas aparecem naturalmente em métodos de volumes finitos.

Também retoma uma cautela central do capítulo de AG. O produto tensorial é um operador de segunda ordem:

$$(\mathbf{u} \otimes \mathbf{u})\mathbf{v} = \mathbf{u}(\mathbf{u} \cdot \mathbf{v}).$$

Já o quadrado geométrico de um vetor euclidiano é

$$\mathbf{u}^2 = \mathbf{u} \cdot \mathbf{u} = \|\mathbf{u}\|^2,$$

que é escalar. Portanto,

$$\boxed{\mathbf{u} \otimes \mathbf{u} \neq \mathbf{u}^2}.$$

Uma formulação em AG deve preservar essa diferença e representar o fluxo de quantidade de movimento como aplicação linear ou extensor quando necessário.

3.14 Conservação de energia

A energia total por unidade de volume é ρE . Além de ser transportada pelo escoamento, a energia também é transferida pelo trabalho realizado pela pressão. Em Euler,

$$\frac{\partial(\rho E)}{\partial t} + \nabla \cdot [(\rho E + p)\mathbf{u}] = 0.$$

A parcela $\rho E\mathbf{u}$ representa transporte convectivo de energia; $p\mathbf{u}$ representa trabalho de pressão. Juntamente com massa, quantidade de movimento e equação de estado, essa relação completa o sistema de Euler compressível.

3.15 Por que os solvers usam variáveis conservativas?

As variáveis primitivas são intuitivas para interpretar o escoamento, mas as leis físicas são naturalmente formuladas em termos de quantidades conservadas. Agrupam-se então

$$\mathbf{U} = \begin{bmatrix} \rho \\ \rho u \\ \rho v \\ \rho w \\ \rho E \end{bmatrix}.$$

Em coordenadas cartesianas,

$$\frac{\partial \mathbf{U}}{\partial t} + \frac{\partial \mathbf{F}_x}{\partial x} + \frac{\partial \mathbf{F}_y}{\partial y} + \frac{\partial \mathbf{F}_z}{\partial z} = 0.$$

Um método de volumes finitos integra essa expressão em cada célula e calcula os fluxos pelas faces. A consequência prática é importante para este livro: a mesma malha que define conectividade geométrica também organiza os balanços físicos. Normais, áreas e orientação das faces não são apenas atributos geométricos; participam diretamente da discretização das leis de conservação.

3.16 Condições de contorno aerodinâmicas

3.16.1 Parede invíscida: não penetração

Em uma parede sólida invíscida, o fluido não atravessa a superfície. Se $\hat{\mathbf{n}}$ é a normal unitária,

$$\boxed{\mathbf{u} \cdot \hat{\mathbf{n}} = 0}.$$

A componente tangencial, contudo, não é forçada a zero. Essa é a condição de parede deslizante de Euler e a diferencia da condição de não deslizamento utilizada em Navier-Stokes viscoso.

3.16.2 Campo distante e condição de voo

A fronteira externa deve ser compatível com o escoamento livre,

$$(\rho_\infty, \mathbf{u}_\infty, p_\infty, M_\infty, \alpha, \beta),$$

onde α é o ângulo de ataque e β o ângulo de derrapagem. Para ilustrar a geometria, em um plano de simetria e com $\beta = 0$, uma convenção simples pode escrever

$$\mathbf{u}_\infty = V_\infty (\cos \alpha \mathbf{e}_x + \sin \alpha \mathbf{e}_z),$$

com o sinal de $\mathbf{e}_z$ dependente da convenção de eixos adotada. Em um solver compressível, condições características distinguem informação que entra e que sai do domínio; portanto, “impor o campo livre” não significa fixar arbitrariamente todas as variáveis em toda a fronteira.

3.16.3 Simetria

Quando geometria e condição de voo admitem simetria, uma fronteira de simetria pode reduzir o domínio. A hipótese deve ser removida quando incidência, geometria, controle ou resposta física romperem essa simetria.

3.17 Da pressão superficial a forças, momentos e coeficientes

3.17.1 Pressão local

Uma saída local particularmente útil é o coeficiente de pressão,

$$C_p = \frac{p - p_\infty}{q_\infty},$$

onde

$$q_\infty = \frac{1}{2} \rho_\infty V_\infty^2$$

é a pressão dinâmica de referência. O campo C_p mostra onde a geometria acelera, desacelera e redireciona o escoamento e fornece uma ponte entre predição local e forças integradas.

3.17.2 Força e momento integrados

Em Euler invíscido, a tração na parede decorre apenas da pressão. Para uma superfície S com normal externa $\hat{\mathbf{n}}$,

$$\mathbf{F}_{\text{aero}} = - \int_S p \hat{\mathbf{n}} dS.$$

Após escolher os eixos aerodinâmicos, a força é decomposta em sustentação L , arrasto D e força lateral. Os coeficientes correspondentes são

$$C_L = \frac{L}{q_\infty S_{\text{ref}}},$$

$$C_D = \frac{D}{q_\infty S_{\text{ref}}},$$

$$C_m = \frac{M_y}{q_\infty S_{\text{ref}} c_{\text{ref}}},$$

onde S_{ref} é uma área de referência e c_{ref} um comprimento de referência. A razão

$$\frac{L}{D} = \frac{C_L}{C_D}$$

é uma medida de eficiência aerodinâmica dentro do modelo considerado.

É essencial registrar convenções de eixos, sinais, ponto de referência dos momentos, S_{ref} e c_{ref} . Também é essencial lembrar a física ausente: um C_D obtido por Euler não contém arrasto de atrito viscoso e pode diferir de uma solução RANS ou experimental quando separação e camada limite forem importantes.

3.18 A derivada geométrica e a estrutura local do escoamento

No capítulo anterior foi introduzida

$$\nabla \mathbf{u} = \nabla \cdot \mathbf{u} + \nabla \wedge \mathbf{u}.$$

Agora as duas parcelas recebem interpretação fluidodinâmica. A parte escalar

$$\nabla \cdot \mathbf{u}$$

mede expansão ou compressão volumétrica local do campo de velocidade. Em escoamentos compressíveis ela não precisa ser nula. A parte bivetorial

$$\Omega = \nabla \wedge \mathbf{u}$$

representa a estrutura rotacional local.

Dois campos simples ajudam a distinguir as parcelas. Para uma expansão isotrópica idealizada $\mathbf{u} = a(x\mathbf{e}_1 + y\mathbf{e}_2 + z\mathbf{e}_3)$, o divergente é não nulo e a parte rotacional é nula. Para uma rotação rígida no plano xy ,

$$\mathbf{u} = -\Omega_0 y \mathbf{e}_1 + \Omega_0 x \mathbf{e}_2,$$

o divergente é nulo e $\nabla \wedge \mathbf{u}$ é um bivetor no plano e_{12} . Em três dimensões, o dual dessa parte bivetorial corresponde à vorticidade vetorial convencional.

Sen [37] emprega essa interpretação bivetorial da vorticidade ao formular analogias entre dinâmica dos fluidos e eletromagnetismo. O interesse para este trabalho é geométrico: o plano orientado de rotação pode ser tratado diretamente como bivetor, em vez de apenas por seu pseudovetor dual.

3.19 O termo convectivo e a não linearidade de Euler

3.19.1 Por que um escoamento permanente ainda pode acelerar?

Em dinâmica dos fluidos, “permanente” significa que o campo em um ponto fixo não muda com o tempo. Isso não implica que uma partícula de fluido mantenha a mesma velocidade enquanto se desloca por regiões onde $\mathbf{u}$ varia no espaço.

Em uma situação unidimensional idealizada, $u = u(x)$ e $\partial u / \partial t = 0$, mas a aceleração convectiva é

$$u \frac{du}{dx},$$

que pode ser não nula. Em três dimensões, o termo correspondente é

$$(\mathbf{u} \cdot \nabla) \mathbf{u}.$$

Ele é não linear porque o próprio campo de velocidade atua como coeficiente do operador diferencial aplicado a si mesmo.

Uma identidade útil reorganiza essa aceleração como

$$(\mathbf{u} \cdot \nabla) \mathbf{u} = \mathbf{u} \cdot (\nabla \wedge \mathbf{u}) + \frac{1}{2} \nabla (\mathbf{u}^2).$$

Como

$$\mathbf{u}^2 = \|\mathbf{u}\|^2$$

no espaço euclidiano, a segunda parcela é o gradiente da energia cinética por unidade de massa e a primeira relaciona a velocidade à estrutura bivetorial de rotação. A decomposição revela geometria, mas **não elimina a não linearidade**: $\nabla \wedge \mathbf{u}$ continua dependendo de $\mathbf{u}$, e produtos entre campos permanecem presentes.

Sen [37] constrói uma analogia formal envolvendo vorticidade e vetor de Lamb para escoamentos compressíveis, incompressíveis, viscosos e invíscidos, com termos-fonte ajustados ao caso físico. A formulação parte, porém, da dinâmica não linear do fluido e reorganiza suas quantidades; não demonstra que Navier-Stokes ou Euler se tornem lineares pelo uso de AG. O próprio artigo apresenta a analogia de Maxwell como uma reorganização dos campos de vorticidade e vetor de Lamb.

3.20 Vorticidade, vetor de Lamb e analogias com Maxwell

A vorticidade vetorial clássica é

$$\omega = \nabla \times \mathbf{u}.$$

Ela descreve a tendência local de rotação do escoamento. O vetor de Lamb é frequentemente definido por

$$\mathbf{L} = \omega \times \mathbf{u},$$

com convenções de sinal que podem variar entre fontes. Em AG tridimensional, a mesma estrutura rotacional pode ser mantida como o bivector

$$\Omega = \nabla \wedge \mathbf{u}.$$

Em construções espaço-temporais mais amplas, quantidades associadas à vorticidade e ao vetor de Lamb podem ser reunidas em um bivector de campo. Parameswaran et al. [40] apresentam uma construção desse tipo e mostram como quatro equações análogas às de Maxwell podem ser reunidas em uma expressão multivetorial; o trabalho também relaciona o dual de Hodge à multiplicação pelo pseudoescalar.

A aplicação ao presente trabalho exige uma distinção rigorosa. Essas analogias são úteis para representar **estrutura geométrica dos campos**, mas não equivalem automaticamente à formulação conservativa completa de Euler empregada em um solver aerodinâmico. O sistema conservativo contém densidade, fluxo tensorial de quantidade de movimento, energia e uma equação de estado. Logo, uma implementação deve manter esses objetos explicitamente identificados.

3.21 O que pode ser representado por multivetores — e o que continua sendo operador

A AG oferece representações naturais para vetores velocidade, bivectores de vorticidade, bivectores de faces e transformações por rotores. Já o fluxo

$$\rho \mathbf{u} \otimes \mathbf{u} + p \mathbf{I}$$

não é um bivector. Trata-se de um operador de segunda ordem. Em AG, sua representação adequada deve utilizar uma aplicação linear, extensor ou estrutura equivalente, e não uma identificação indevida com um multivetor de grau fixo.

Essa separação é metodologicamente importante. A meta não é forçar toda a física para dentro de um único multivetor, mas usar AG onde ela preserva e explicita estrutura geométrica, mantendo tensores e operadores quando a natureza matemática do objeto assim exigir.

3.22 Métodos e níveis de fidelidade aerodinâmica

Para um leitor vindo do eletromagnetismo, é útil interpretar os principais níveis aerodinâmicos pelo conteúdo físico que adicionam. Métodos potenciais ou de painéis descrevem o escoamento com hipóteses fortes que podem ser adequadas em regimes suaves e longe de efeitos viscosos dominantes. Euler adiciona conservação compressível não linear e permite representar ondas e variações de densidade, mas continua invíscido. RANS acrescenta viscosidade e um fechamento estatístico para os efeitos turbulentos sobre o escoamento médio.

Essa sequência não constitui uma escala universal de “baixo para alto custo”. Resolução de malha, critérios de convergência, número de condições de voo, modelo turbulento e implementação podem mudar substancialmente o consumo de CPU/GPU, memória e tempo. A fidelidade deve ser definida pelo conteúdo físico e numérico efetivamente representado, juntamente com a demanda de recursos observada.

3.23 Validação aerodinâmica progressiva

Antes de aplicar o modelo a uma geometria UCAV completa, a validação deve avançar de problemas elementares para problemas integrados: conservação em estados uniformes, casos com solução conhecida ou benchmark consolidado, perfis bidimensionais, asas simples e finalmente a geometria tridimensional de interesse.

A comparação não deve se restringir a C_L , C_D e C_m . Campos intermediários, como C_p , pressão superficial e balanços de conservação, ajudam a identificar compensações de erro que poderiam produzir um coeficiente integrado aparentemente correto. Quando houver resultados experimentais ou soluções de referência adequadas, eles devem ser usados para distinguir erro de discretização, limitação do modelo físico e erro do futuro surrogate.

3.24 Problemas bidimensionais e respostas tridimensionais

A etapa bidimensional exige distinguir simplificação geométrica de equivalência física. Em aerodinâmica, um aerofólio 2D representa uma seção e permite estudar coeficientes seccionais e campos associados a um escoamento bidimensional; esses resultados não incluem efeitos tridimensionais de asa finita, como vórtices de ponta e arrasto induzido.

No eletromagnetismo, a distinção é ainda mais importante. Um problema de espalhamento estritamente bidimensional é frequentemente formulado em termos de uma grandeza por unidade de comprimento, como *scattering width*, cuja dimensão física não é a mesma da RCS tridimensional em m^2 . Se os dados utilizados nos estudos 2D forem provenientes de uma extrusão finita ou de um solver tridimensional parametrizado por uma seção 2D, a saída poderá continuar sendo RCS, desde que a geometria e a normalização correspondentes sejam explicitadas. Caso sejam dados de um problema EM verdadeiramente 2D, a grandeza física deverá ser denominada e interpretada de acordo com a formulação que a gerou.

Essa distinção será preservada na ingestão dos dados e nas funções de perda: nenhuma conversão entre *scattering width* e RCS será realizada implicitamente.

3.25 Ponte entre os dois domínios físicos e as GNNs

Os domínios eletromagnético e aerodinâmico compartilham a mesma geometria de superfície, mas respondem a condições físicas diferentes. Isso motiva a investigação de representações geométricas compartilháveis sem pressupor que um único modelo multitarefa seja necessariamente superior.

Uma geometria discretizada pode ser representada por um grafo

$$G = (V, E, \mathcal{F}),$$

no qual nós, arestas ou faces carregam atributos. A partir do capítulo anterior, exemplos naturais são posição $\mathbf{x}_i$, normal $\hat{\mathbf{n}}_i$, área A_i , bivector orientado de face B_i , curvatura local, vetores relativos e rotores associados à orientação entre elementos vizinhos.

Para o problema eletromagnético, uma representação abstrata é

$$\mathcal{G}_{\text{EM}} : (G, f, \theta, \phi, \text{pol}) \longrightarrow \sigma(\theta_s, \phi_s, \text{pol}_s),$$

ou, quando campos intermediários forem incluídos,

$$\mathcal{G}_{\text{EM}} : (G, c_{\text{EM}}) \longrightarrow (\mathbf{J}_s, \mathbf{E}_{\text{sca}}, \sigma).$$

Para aerodinâmica,

$$\mathcal{G}_{\text{aero}} : (G, M_\infty, \alpha, \beta, \rho_\infty, p_\infty, \dots) \longrightarrow (C_p, C_L, C_D, C_m, \dots).$$

O mesmo G fornece uma base geométrica comum; os condicionantes físicos e as saídas permanecem específicos de cada domínio. Compartilhamento de codificadores, cabeças especializadas ou modelos separados são hipóteses arquiteturais a serem comparadas empiricamente.

3.26 Resíduos físicos como informação de treinamento

A incorporação de física ao treinamento só é válida quando o resíduo pode ser calculado a partir das variáveis produzidas pela rede. Se a GNN prevê campos eletromagnéticos compatíveis com a formulação em STA, um resíduo conceitual é

$$\mathcal{R}_M = \nabla F - \mathcal{J},$$

acompanhado, quando apropriado, por resíduos de condições de contorno e radiação.

Se a rede prevê variáveis conservativas aerodinâmicas,

$$\mathcal{R}_\rho = \frac{\partial \rho}{\partial t} + \nabla \cdot (\rho \mathbf{u}),$$

$$\mathcal{R}_{\rho \mathbf{u}} = \frac{\partial(\rho \mathbf{u})}{\partial t} + \nabla \cdot (\rho \mathbf{u} \otimes \mathbf{u} + p \mathbf{I}),$$

$$\mathcal{R}_{\rho E} = \frac{\partial(\rho E)}{\partial t} + \nabla \cdot [(\rho E + p) \mathbf{u}].$$

Por outro lado, uma rede que prevê apenas C_L , C_D ou uma RCS agregada não contém informação suficiente para calcular diretamente esses resíduos diferenciais. Nesse caso, devem ser usadas consistências compatíveis com as saídas disponíveis ou devem ser previstos campos intermediários.

Uma função de perda genérica pode assumir a forma

$$\mathcal{L} = \mathcal{L}_{\text{dados}} + \lambda_{\text{phys}} \mathcal{L}_{\text{phys}} + \lambda_{\text{bc}} \mathcal{L}_{\text{bc}}.$$

Como os termos podem possuir unidades e escalas muito diferentes, normalização ou adimensionalização deve ser considerada antes de interpretar os pesos λ . Um peso numericamente pequeno não significa, por si só, baixa importância física.

3.27 Síntese do capítulo

A assinatura radar e o desempenho aerodinâmico derivam de sistemas físicos diferentes, mas ambos são condicionados pela geometria e podem ser discretizados sobre malhas. No eletromagnetismo, Maxwell conecta fontes, materiais e propagação; a passagem para o domínio da frequência transforma derivadas temporais em multiplicações por $j\omega$, mantendo a estrutura diferencial espacial; condições de contorno produzem o campo espalhado, e seu comportamento assintótico conduz à RCS. Na STA, os campos elétrico e magnético podem ser reunidos no bivector de Faraday F , sem atribuir à AG uma linearização que não existe.

Na aerodinâmica, Euler aplica conservação de massa, quantidade de movimento e energia a um gás perfeito compressível e invíscido. A forma conservativa conecta naturalmente fluxos às faces da malha. A derivada geométrica separa expansão e rotação local, enquanto bivectores fornecem uma representação natural para vorticidade. Entretanto, o fluxo de quantidade de movimento permanece um operador tensorial e a não linearidade convectiva continua fisicamente presente.

Esses dois blocos definem variáveis, hipóteses, condições de contorno, campos intermediários e respostas integradas que serão utilizados nos capítulos seguintes. A continuidade metodológica é deliberada: **física** $\rightarrow$ **representação geométrica** $\rightarrow$ **dados multifidelidade** $\rightarrow$ **GNN** $\rightarrow$ **otimização determinística**, sem confundir compacidade matemática com simplificação física nem precisão preditiva com validade de engenharia.

4 Graph Neural Networks para modelagem substituta baseada em malhas

As **Graph Neural Networks (GNNs)** constituem a principal camada computacional de modelagem substituta deste trabalho. Os solvers de **Computational Electromagnetics (CEM)** e **Computational Fluid Dynamics (CFD)** permanecem como modelos de referência para gerar dados, validar respostas e reavaliar soluções de projeto; a função da GNN é aproximar, com menor demanda de recursos por avaliação, a relação entre geometria, condições de operação e respostas físicas durante as muitas consultas exigidas pela otimização aero-stealth.

A motivação para usar grafos nasce da própria discretização. Superfícies e volumes empregados em CEM e CFD são representados por malhas cujas entidades possuem conectividade, posição, orientação, área ou volume e, frequentemente, variáveis físicas associadas. Uma GNN pode operar diretamente sobre essa estrutura relacional sem exigir uma grade cartesiana regular nem uma dimensão fixa de entrada. Essa adequação geométrica, entretanto, não garante superioridade por si só: a representação do grafo, o alcance das interações, as variáveis previstas e a robustez a mudanças de discretização precisam ser avaliados empiricamente [1], [2].

A utilidade do modelo substituto será julgada em dois níveis. O primeiro é **físico-preditivo**: erro em campos, coeficientes e curvas de Radar Cross Section (RCS), generalização para geometrias não vistas e consistência com relações físicas relevantes. O segundo é **computacional e de engenharia**: tempo de inferência, uso de CPU/GPU e memória, quantidade de avaliações dos modelos de referência e qualidade das soluções produzidas pela otimização após reavaliação.

4.1 Da malha numérica ao grafo

4.1.1 Por que não tratar a geometria apenas como um vetor?

Considere duas triangulações de uma mesma superfície. Se as coordenadas de todos os vértices forem simplesmente concatenadas em um vetor, a representação passa a depender da numeração dos vértices. Trocar a ordem dos índices altera esse vetor, embora a superfície física permaneça a mesma. Geometrias com números diferentes de vértices também passam a produzir vetores de dimensões diferentes.

Uma imagem ou grade regular evita parte desse problema ao impor posições fixas, mas introduz outra hipótese: a vizinhança passa a ser determinada por deslocamentos regulares em linhas,

colunas ou voxels. Malhas de aeronaves, painéis eletromagnéticos e discretizações CFD são, em geral, não estruturadas; o tamanho dos elementos varia e regiões de maior gradiente podem receber refinamento local.

O grafo preserva explicitamente a relação **quem é vizinho de quem**, sem exigir uma indexação regular. Essa propriedade permite representar malhas com números variáveis de entidades e conectividades distintas.

4.1.2 Definição de grafo e atributos

Um grafo é representado por

$$G = (V, E),$$

em que V é o conjunto de nós e E é o conjunto de arestas. O índice $i \in V$ identifica um nó, enquanto o par $(i, j) \in E$ identifica uma relação entre os nós i e j . Dependendo da implementação, uma aresta geométrica não orientada pode ser representada internamente por duas arestas direcionadas, $i \rightarrow j$ e $j \rightarrow i$.

Para aprendizado, três níveis de atributos são úteis:

- $\mathbf{x}_i \in \mathbb{R}^{d_x}$: vetor de atributos do nó i , com d_x componentes;
- $\mathbf{e}_{ij} \in \mathbb{R}^{d_e}$: vetor de atributos da aresta que relaciona i e j ;
- $\mathbf{g} \in \mathbb{R}^{d_g}$: vetor de atributos globais do caso analisado.

No problema aero-stealth, $\mathbf{x}_i$ pode conter posição, normal, área associada, curvatura, material ou um campo físico local. O vetor $\mathbf{e}_{ij}$ pode conter deslocamento relativo, distância, ângulo entre normais ou propriedades de uma interface. O vetor global $\mathbf{g}$ pode conter frequência, direção de incidência e polarização no problema eletromagnético, ou número de Mach, ângulo de ataque e outras condições do escoamento no problema aerodinâmico.

A correspondência entre nós do grafo e entidades da malha não é única. Ela deve respeitar onde as incógnitas do modelo numérico estão definidas.

4.1.3 Grafo primal, grafo de faces e grafo de células

Em uma malha superficial triangular, o **grafo primal** associa cada vértice da malha a um nó e conecta dois nós quando os vértices correspondentes compartilham uma aresta. Essa escolha é natural para campos definidos nos vértices.

Outra representação toma cada face triangular como um nó. Duas faces tornam-se vizinhas quando compartilham uma aresta. Esse **grafo de faces** é conveniente quando a grandeza física está definida por elemento, como uma pressão de face ou uma corrente superficial discretizada.

Em uma malha volumétrica de volumes finitos, cada célula pode ser representada por um nó, e duas células são conectadas quando compartilham uma face. Nesse caso, a aresta do grafo corresponde diretamente a uma interface através da qual o solver calcula um fluxo numérico.

Portanto, não existe uma transformação universal de malha em grafo. A representação deve ser compatível com a localização das variáveis físicas e com o operador discreto que produziu os dados.

4.1.4 O que a conectividade preserva — e o que ela não preserva

A conectividade determina relações de vizinhança, mas não determina sozinha a geometria. Dois grafos combinatoriamente idênticos podem representar superfícies geometricamente diferentes. Comprimentos, áreas, orientações e posições relativas continuam necessários para distinguir essas geometrias.

O inverso também é relevante: uma mesma superfície física pode ser remalhada. A numeração dos vértices e a conectividade local podem mudar sem que a aeronave tenha mudado de forma relevante. Uma GNN adequada deve ser insensível à simples permutação dos índices e, quando o uso pretendido exigir, robusta a mudanças de discretização que preservem a geometria e a física.

4.2 Message Passing Neural Networks

4.2.1 Intuição: informação que percorre a conectividade

Em muitos métodos numéricos, a atualização de uma variável depende de entidades vizinhas. Em volumes finitos, fluxos atravessam faces compartilhadas; em elementos finitos, graus de liberdade são acoplados pela conectividade dos elementos. Uma GNN baseada em **message passing** utiliza uma ideia análoga em nível arquitetural: cada nó recebe informações de seus vizinhos, agrega essas informações e atualiza uma representação interna.

Uma **Message Passing Neural Network (MPNN)** é uma família de GNNs em que esse ciclo mensagem–agregação–atualização é repetido por uma ou mais camadas. A mensagem é aprendida a partir dos estados das entidades relacionadas e de seus atributos; a agregação precisa ser compatível com o fato de que a ordem de enumeração dos vizinhos não possui significado físico; a atualização produz o novo estado latente do nó. Essa formulação é suficientemente geral para englobar grande número de arquiteturas de GNN e aparece também em simuladores aprendidos sobre malhas [1], [2].

Neste livro, a expressão **MPNN convencional** designa o baseline em que estados latentes e atributos são representados por vetores reais usuais e as funções aprendidas são redes neurais genéricas, sem impor explicitamente operações multivetoriais de Álgebra Geométrica (AG)

ou uma lei de equivariância rotacional. “Convencional” não significa “sem geometria” ou “sem física”: vetores relativos, normais, áreas e condições físicas podem continuar presentes como atributos. O termo apenas distingue esse baseline de variantes com estrutura geométrica adicional.

4.2.2 Formalização de uma camada

Considere uma camada de índice ℓ . O vetor

$$\mathbf{h}_i^{(\ell)} \in \mathbb{R}^{d_h}$$

representa o **estado latente** do nó i nessa camada, com d_h componentes aprendidas. Para o nó i , define-se o conjunto de vizinhos

$$\mathcal{N}(i) = \{j \in V : (j, i) \in E\}.$$

Assim, $j \in \mathcal{N}(i)$ significa que existe uma aresta pela qual informação pode ser enviada de j para i . O atributo $\mathbf{e}_{ij}$ descreve essa relação, e $\mathbf{g}$ contém condições globais compartilhadas por todo o caso.

A mensagem enviada por j para i pode ser escrita como

$$\mathbf{m}_{ij}^{(\ell)} = \phi_e^{(\ell)} \left(\mathbf{h}_i^{(\ell)}, \mathbf{h}_j^{(\ell)}, \mathbf{e}_{ij}, \mathbf{g} \right),$$

onde $\mathbf{m}_{ij}^{(\ell)}$ é o vetor-mensagem e $\phi_e^{(\ell)}$ é uma função aprendida da camada, frequentemente implementada por uma pequena rede multilayer perceptron (MLP).

O nó i pode receber várias mensagens, uma para cada $j \in \mathcal{N}(i)$. Elas são combinadas por um operador de agregação $\oplus$:

$$\overline{\mathbf{m}}_i^{(\ell)} = \bigoplus_{j \in \mathcal{N}(i)} \mathbf{m}_{ij}^{(\ell)}.$$

O vetor $\overline{\mathbf{m}}_i^{(\ell)}$ é a mensagem agregada recebida pelo nó. Soma, média e máximo são exemplos de $\oplus$ que não dependem da ordem em que os vizinhos são enumerados.

O novo estado do nó é então calculado por

$$\mathbf{h}_i^{(\ell+1)} = \phi_v^{(\ell)} \left(\mathbf{h}_i^{(\ell)}, \overline{\mathbf{m}}_i^{(\ell)}, \mathbf{g} \right),$$

em que $\phi_v^{(\ell)}$ é a função aprendida de atualização do nó. A camada completa, portanto, executa três operações: construir mensagens nas arestas, agregar mensagens incidentes e atualizar os nós.

4.2.3 Exemplo mínimo e campo receptivo

Considere três faces f_1, f_2, f_3 , com f_1 adjacente a f_2 e f_2 adjacente a f_3 . Em uma única camada local, f_1 recebe informação de f_2 , mas não diretamente de f_3 . Depois de duas camadas, informação originada em f_3 pode alcançar f_1 através de f_2 .

Esse exemplo introduz o **campo receptivo** da GNN. Após K camadas de message passing local, um nó pode incorporar informação proveniente de entidades separadas por até K arestas do grafo. Em uma malha grande, aumentar K indefinidamente eleva o número de operações e o armazenamento de ativações e pode degradar o treinamento. A arquitetura precisa, portanto, equilibrar interação local e comunicação de maior alcance.

4.3 Do message passing ao Geometric Deep Learning

Geometric Deep Learning (GDL) é um paradigma mais amplo que organiza arquiteturas de aprendizado de acordo com a estrutura geométrica do domínio e com as transformações sob as quais o problema possui regularidades, como permutações, translações, rotações ou simetrias de grupos. Grafos constituem um desses domínios; GNNs são uma das famílias de modelos estudadas nesse quadro [1].

A relação é, portanto,

Geometric Deep Learning $\supset$ Graph Neural Networks $\supset$ Message Passing Neural Networks,

quando se considera a MPNN como uma família particular de GNNs baseada em troca local de mensagens.

GDL e **Álgebra Geométrica** não são sinônimos. GDL é um quadro conceitual para construir redes que respeitem estruturas e simetrias do domínio. AG é o formalismo algébrico desenvolvido no Capítulo 2 para representar vetores, bivectores, rotores e outros objetos geométricos. Neste trabalho, AG pode fornecer atributos, canais latentes e operadores para uma GNN; GDL fornece a linguagem arquitetural para discutir propriedades como invariância e equivariância.

4.4 Encoder, processador, decoder e readout

Uma organização frequente em problemas de malha é o padrão **encode–process–decode** [2]. O **encoder** converte atributos de entrada em estados latentes; o **processador** aplica K etapas de message passing; o **decoder** transforma os estados resultantes na grandeza física desejada.

Se $\mathbf{x}_i$ representa os atributos iniciais do nó, $\mathbf{e}_{ij}$ os atributos da aresta e $\mathbf{g}$ as condições globais, a sequência pode ser representada por

$$\{\mathbf{x}_i, \mathbf{e}_{ij}, \mathbf{g}\} \xrightarrow{\text{encoder}} \{\mathbf{h}_i^{(0)}\} \xrightarrow{K \text{ passos}} \{\mathbf{h}_i^{(K)}\} \xrightarrow{\text{decoder}} \hat{\mathbf{y}}.$$

O símbolo $\hat{\mathbf{y}}$ indica a resposta **predita** pela rede, em contraste com a resposta de referência $\mathbf{y}$ produzida pelo conjunto de dados ou pelo solver.

Quando a saída é local, como um coeficiente de pressão por face, o decoder pode produzir uma previsão para cada nó. Quando a saída é global, como C_L , C_D ou uma medida integrada de RCS, é necessário um **readout** que reúna os estados de todo o grafo.

Se $N = |V|$ é o número de nós, um readout médio simples é

$$\mathbf{h}_G = \frac{1}{N} \sum_{i \in V} \mathbf{h}_i^{(K)},$$

onde $\mathbf{h}_G$ é uma representação global do grafo. Em uma malha superficial com refinamento não uniforme, todos os nós não correspondem necessariamente à mesma área física. Se A_i é a área associada ao nó ou elemento i , um readout ponderado pode ser escrito como

$$\mathbf{h}_G = \frac{\sum_{i \in V} A_i \mathbf{h}_i^{(K)}}{\sum_{i \in V} A_i}.$$

A escolha entre pooling uniforme e ponderado faz parte da modelagem: uma quantidade com interpretação integral deve respeitar a medida geométrica apropriada.

4.5 Aprender um simulador dinâmico não é o mesmo que aprender um surrogate estacionário

Parte importante da literatura de GNNs para física considera modelos que avançam um estado no tempo. MeshGraphNets, por exemplo, aprende atualizações sobre malhas para simulação

dinâmica [2]. O uso principal neste livro é diferente: as consultas da otimização correspondem predominantemente a soluções estacionárias de aerodinâmica ou soluções harmônicas de eletromagnetismo.

A tarefa pode ser escrita como um operador paramétrico

$$\mathcal{G}_\theta : (G, \mathbf{c}) \mapsto \hat{\mathbf{y}},$$

em que θ representa todos os parâmetros treináveis da rede, $\mathbf{c}$ reúne as condições físicas do caso e $\hat{\mathbf{y}}$ é a resposta predita. Essa resposta pode conter campos locais, coeficientes integrados ou curvas angulares. A GNN atua, portanto, como **modelo substituto (surrogate)** da solução convergida; ela não precisa reproduzir a marcha temporal interna do solver.

4.6 Localidade, longo alcance e escala da malha

A conectividade de malha fornece uma hipótese indutiva local útil, mas nem todas as dependências relevantes são estritamente locais. Em formulações integrais de eletromagnetismo, regiões geometricamente distantes podem estar acopladas por funções de Green. A RCS em campo distante resulta da combinação coerente de amplitudes e fases provenientes de diferentes regiões da superfície.

Na aerodinâmica, as equações diferenciais são locais, mas a solução estacionária externa reflete o acoplamento do campo ao redor de toda a configuração. Uma alteração geométrica em uma região pode modificar a distribuição de pressão em regiões afastadas.

Se $N = |V|$ e $|E|$ é o número de arestas, message passing em um grafo esparso tende a depender principalmente de $|E|$ por camada. Em contraste, uma atenção densa entre todos os pares de nós envolve N^2 pares e pode elevar significativamente memória e processamento. Hierarquias de malha, pooling multiescala, arestas de longo alcance, estados globais ou mecanismos de atenção são alternativas para ampliar a comunicação. Nenhuma delas deve ser assumida como superior sem comparação de erro e recursos medidos.

4.7 Construção dos atributos do grafo

4.7.1 Geometria relativa

Se $\mathbf{x}_i, \mathbf{x}_j \in \mathbb{R}^3$ são as posições de dois nós, define-se o vetor relativo

$$\mathbf{r}_{ij} = \mathbf{x}_j - \mathbf{x}_i.$$

Esse vetor não muda sob uma translação rígida aplicada simultaneamente aos dois pontos. Sua norma

$$r_{ij} = \|\mathbf{r}_{ij}\|$$

é também invariante a rotações rígidas. Em uma malha superficial, outros atributos possíveis incluem normal, área, curvatura estimada, tipo de fronteira, material e medidas locais de qualidade de malha. A inclusão de cada variável deve possuir uma justificativa geométrica ou física e ser verificada por ablação.

4.7.2 Condições globais e parâmetros físicos

Uma mesma geometria produz respostas distintas sob condições de operação distintas. Essas condições devem ser apresentadas à rede de forma coerente com a física.

No eletromagnetismo, a frequência f , o comprimento de onda λ , o número de onda $k = 2\pi/\lambda$, a direção de incidência, a polarização e as propriedades dos materiais podem alterar a solução. Se L é um comprimento de referência da configuração, o produto adimensional

$$kL = \frac{2\pi L}{\lambda}$$

mede o tamanho elétrico do alvo e explicita a razão entre escala geométrica e comprimento de onda.

Na aerodinâmica de Euler, condições como o número de Mach do escoamento livre M_∞ , o ângulo de ataque α , o ângulo de derrapagem β e a razão de calores específicos γ têm interpretação direta. Quando a saída é adimensional, parâmetros dimensionais redundantes podem ser evitados; quando campos dimensionais são previstos, as escalas termodinâmicas necessárias devem permanecer disponíveis.

Ângulos periódicos requerem cuidado. Usar somente um azimute ϕ introduz uma descontinuidade artificial entre 0 e 2π . A codificação

$$(\cos \phi, \sin \phi)$$

ou o uso direto de um vetor unitário de direção representa a periodicidade sem esse corte numérico.

4.7.3 Normalização e adimensionalização

Misturar coordenadas em metros, frequência em gigahertz, pressão em pascals e coeficientes da ordem da unidade sem escalonamento pode dificultar a otimização numérica da rede. A normalização deve preservar a capacidade de reconstruir e interpretar as grandezas físicas.

Coordenadas podem ser divididas por um comprimento de referência; pressões podem ser expressas pelo coeficiente C_p ; frequência pode ser substituída ou complementada por kL . Toda transformação aplicada aos dados deve ser registrada para que previsões normalizadas possam ser convertidas novamente às unidades ou convenções de engenharia.

4.8 Álgebra Geométrica como fonte de estrutura

Para uma face triangular f formada pelos vértices i, j, k , sejam

$$\mathbf{r}_{ij} = \mathbf{x}_j - \mathbf{x}_i, \quad \mathbf{r}_{ik} = \mathbf{x}_k - \mathbf{x}_i$$

os vetores de aresta. O bivector de área orientada definido no Capítulo 2 é

$$B_f = \frac{1}{2} \mathbf{r}_{ij} \wedge \mathbf{r}_{ik}.$$

Sua magnitude fornece a área da face,

$$A_f = \|B_f\|.$$

Em $Cl(3, 0)$, sendo I o pseudoescalar unitário e I^{-1} seu inverso, uma normal orientada pode ser obtida pela dualidade

$$\mathbf{n}_f = \frac{B_f I^{-1}}{\|B_f\|}.$$

O bivector B_f reúne área e orientação em um único objeto geométrico. Entre faces vizinhas i e j , o produto interno $\mathbf{n}_i \cdot \mathbf{n}_j$ mede alinhamento das normais, enquanto $\mathbf{n}_i \wedge \mathbf{n}_j$ representa o plano orientado associado à mudança de direção. Rotores podem, quando necessário, representar a transformação entre referenciais locais.

Há três níveis de incorporação de AG que precisam ser distinguidos empiricamente:

1. **features derivadas de AG** fornecidas a uma MPNN convencional;
2. **canais multivetoriais** mantidos no espaço latente, com operações compatíveis com graus e produto geométrico;

3. **arquitetura explicitamente equivariante**, cuja lei de transformação sob rotações é imposta por construção.

O primeiro nível não torna automaticamente a rede equivariante. Da mesma forma, armazenar componentes de um bivector em um vetor numérico não garante que as camadas seguintes respeitem sua transformação geométrica. O benefício de cada nível deve ser medido em estudos de ablação.

4.9 Invariância, equivariância e simetrias físicas

4.9.1 Permutação de nós

A numeração dos nós não possui significado físico. Se uma permutação apenas reordena os índices, uma saída global deve permanecer inalterada, enquanto uma saída local deve ser reindexada pela mesma permutação. Agregadores simétricos em MPNNs são um mecanismo para obter essa propriedade.

4.9.2 Translação e rotação

Considere uma rotação própria $Q \in SO(3)$ e uma translação $\mathbf{t} \in \mathbb{R}^3$. A posição de um nó transforma-se como

$$\mathbf{x}'_i = Q\mathbf{x}_i + \mathbf{t}.$$

Um escalar geométrico, como área, permanece invariante. Um vetor físico $\mathbf{v}$ transforma-se como

$$\mathbf{v}' = Q\mathbf{v}.$$

Em AG, a mesma rotação pode ser representada por um rotor unitário R , com reverso $\widetilde{R}$:

$$\mathbf{v}' = R\mathbf{v}\widetilde{R}.$$

Uma rede é **invariante** a uma transformação quando a grandeza de saída que deveria permanecer fisicamente igual não muda. Ela é **equivariante** quando a saída se transforma segundo a lei apropriada ao objeto físico. Essas ideias pertencem ao quadro de Geometric Deep Learning [1].

No problema aero-stealth, a transformação precisa envolver o sistema físico completo. Rotacionar apenas a aeronave em relação à onda incidente ou ao escoamento modifica o problema. Se

geometria, direção incidente, direção de observação e base de polarização forem rotacionadas de maneira consistente em um meio isotrópico, uma RCS escalar definida no mesmo referencial físico deve ser preservada. O mesmo princípio vale para forças aerodinâmicas e eixos de referência.

4.10 Reparametrização e remalhamento

Duas malhas podem aproximar praticamente a mesma superfície com números de elementos e conectividades diferentes. Isso é relevante em otimização geométrica, porque pequenas mudanças de projeto podem desencadear novo processo de tesselação.

Uma estratégia mantém topologia de malha consistente durante a parametrização, facilitando correspondência entre entidades. Outra aceita remalhamento e exige generalização entre discretizações. A primeira reduz variabilidade topológica; a segunda oferece maior flexibilidade geométrica, mas torna mais difícil separar erro do surrogate de efeitos da discretização.

Um teste direto consiste em avaliar uma mesma geometria com duas malhas de qualidade comparável. Se a previsão variar de forma incompatível com a diferença observada no solver de referência, a rede aprendeu dependência indesejada da discretização.

4.11 Campos locais e respostas globais

4.11.1 Predição direta de coeficientes

Quando apenas grandezas integradas são necessárias ao otimizador, uma rede pode mapear diretamente o grafo e as condições $\mathbf{c}$ para respostas escalares:

$$(G, \mathbf{c}) \mapsto (\widehat{C}_L, \widehat{C}_D, \widehat{C}_m, \widehat{\sigma}_{\text{res}}, \dots).$$

Aqui, $\widehat{C}_L$, $\widehat{C}_D$ e $\widehat{C}_m$ são previsões dos coeficientes de sustentação, arrasto e momento; $\widehat{\sigma}_{\text{res}}$ representa alguma medida resumida de RCS definida previamente, como média em um setor angular. Essa abordagem é compacta, mas não permite verificar a estrutura espacial que produz os coeficientes.

4.11.2 Predição de campo seguida de integração

Uma alternativa é prever um campo local e derivar as respostas globais. Para uma malha superficial com faces indexadas por f , seja $\hat{p}_f$ a pressão prevista na face, A_f sua área e $\mathbf{n}_f$ sua normal externa. A força de pressão prevista é

$$\hat{\mathbf{F}}_p = - \sum_f \hat{p}_f \mathbf{n}_f A_f.$$

Projetando $\hat{\mathbf{F}}_p$ nos eixos de sustentação e arrasto obtêm-se $\hat{L}$ e $\hat{D}$. Se q_∞ é a pressão dinâmica do escoamento livre e S_{ref} a área de referência,

$$\hat{C}_L = \frac{\hat{L}}{q_\infty S_{\text{ref}}}, \quad \hat{C}_D = \frac{\hat{D}}{q_\infty S_{\text{ref}}}.$$

Essa construção permite verificar se a resposta global é coerente com o campo previsto. Para dados de Euler, o arrasto obtido dessa integração corresponde à contribuição de pressão compatível com o modelo invíscido; arrasto de atrito não está presente nessa fidelidade.

4.11.3 Aprendizado multitarefa

Uma terceira possibilidade combina um decoder local e decoders globais. A rede pode prever C_p em cada face e, simultaneamente, C_L , C_D e C_m . A diferença entre coeficientes diretamente previstos e aqueles reconstruídos por integração pode ser usada como termo de consistência.

Um antecedente direto para análise aero-eletromagnética emprega uma GNN de difusão multitarefa sobre malhas superficiais não estruturadas, com previsão de C_p , C_L , C_D e RCS monostática média em polarizações horizontal e vertical [4]. No conjunto de 3.800 geometrias descrito pelos autores, foram reportados $R^2 = 0,969$ para C_p , erros absolutos médios de 0,0065 e 0,0013 para C_L e C_D , erros de 0,381 e 0,358 dB para as respostas médias de RCS e aceleração de aproximadamente $35\times$ no cenário conjunto considerado [4].

Esse resultado estabelece a viabilidade de uma abordagem mesh-native conjunta, mas não determina a arquitetura deste trabalho. Aqui, a RCS deve preservar sua dependência angular e de polarização; a multifidelidade será explícita; as representações de AG serão testadas separadamente; e as soluções da otimização serão reavaliadas com modelos de referência.

4.12 Surrogate eletromagnético

4.12.1 O problema de entrada e saída

O surrogate eletromagnético recebe uma geometria discretizada e as condições que definem o experimento radar. Seja

$$\mathcal{G}_{\text{EM},\theta}$$

o operador aprendido, parametrizado pelos pesos θ da rede. A entrada é o grafo G e um vetor de condições eletromagnéticas $\mathbf{c}_{\text{EM}}$; a saída $\hat{\mathbf{y}}_{\text{EM}}$ é a resposta prevista:

$$\mathcal{G}_{\text{EM},\theta} : (G, \mathbf{c}_{\text{EM}}) \mapsto \hat{\mathbf{y}}_{\text{EM}}.$$

Uma escolha possível para as condições é

$$\mathbf{c}_{\text{EM}} = (kL, \hat{\mathbf{k}}_{\text{inc}}, \text{pol}_{\text{inc}}, \mathbf{p}_{\text{mat}}).$$

Nessa expressão, $k = 2\pi/\lambda$ é o número de onda, L é o comprimento de referência, $\hat{\mathbf{k}}_{\text{inc}}$ é o vetor unitário na direção de propagação da onda incidente, pol_{inc} codifica sua polarização e $\mathbf{p}_{\text{mat}}$ reúne os parâmetros constitutivos relevantes dos materiais. Para um alvo perfeitamente condutor sem revestimentos, parte de $\mathbf{p}_{\text{mat}}$ pode ser constante e dispensada da entrada.

A saída pode ser uma única grandeza integrada, um campo intermediário ou uma curva de RCS. Para preservar a informação direcional, considera-se

$$\hat{\sigma} = \hat{\sigma}(\hat{\mathbf{r}}_{\text{obs}}, \text{pol}_{\text{obs}}),$$

em que $\hat{\sigma}$ é a RCS prevista, $\hat{\mathbf{r}}_{\text{obs}}$ é o vetor unitário da direção de observação e pol_{obs} define a componente de polarização recebida. No caso monostático, incidência e observação obedecem à geometria específica de retroespalhamento; no caso bistático, essas direções são independentes dentro do experimento definido.

4.12.2 Grade angular fixa ou consulta condicionada

Se as direções de observação forem sempre avaliadas em uma grade fixa com Q pontos, a rede pode produzir um vetor

$$\hat{\sigma} = (\hat{\sigma}_1, \dots, \hat{\sigma}_Q)$$

em uma única inferência. O índice $q = 1, \dots, Q$ identifica uma direção e uma polarização previamente definidas.

Uma alternativa é usar um decoder condicionado por consulta. Se $\mathbf{c}_{\text{inc}}$ reúne as condições de incidência, o valor na consulta q pode ser escrito como

$$\hat{\sigma}_q = f_{\theta} \left(G, \mathbf{c}_{\text{inc}}, \hat{\mathbf{r}}_q, \text{pol}_q \right),$$

onde f_{θ} é a função aprendida, $\hat{\mathbf{r}}_q$ é a direção de observação da consulta e pol_q sua polarização de recepção. A saída em grade fixa favorece inferência vetorizada de toda a curva; a consulta condicionada permite resolução angular variável. A escolha deve ser testada no domínio de operação relevante.

4.12.3 Prever RCS diretamente ou prever campos intermediários?

A RCS pode ser prevista diretamente. Outra possibilidade é prever quantidades intermediárias, como a densidade de corrente superficial complexa $\tilde{\mathbf{J}}_s$ ou o campo elétrico espalhado complexo $\tilde{\mathbf{E}}_{\text{sca}}$. O til indica fasor no regime harmônico definido no Capítulo 3.

Para uma face f , uma corrente complexa pode ser armazenada em canais reais por

$$\tilde{\mathbf{J}}_{s,f} \longleftrightarrow \left(\Re \tilde{\mathbf{J}}_{s,f}, \Im \tilde{\mathbf{J}}_{s,f} \right).$$

As duas componentes preservam amplitude e fase sem introduzir o salto artificial associado à representação angular da fase em $(-\pi, \pi]$. Se amplitude e fase forem usadas diretamente, a periodicidade da fase precisa ser tratada explicitamente.

A coerência de fase é essencial porque o campo distante resulta da soma complexa das contribuições espalhadas. O módulo ao quadrado deve ser aplicado **depois** dessa soma coerente; somar magnitudes locais antes de combinar as fases elimina interferências construtivas e destrutivas que fazem parte da física da RCS.

Há trabalhos recentes que usam modelos de grafos ou representações geométricas para problemas de espalhamento eletromagnético, incluindo aprendizado residual informado pela física para equações integrais e previsão de campos distantes a partir da geometria [3], [31]. Esses resultados

justificam a investigação, mas não substituem a validação específica em frequência, polarização, ângulo e geometria de UCAV.

4.12.4 Escala linear e escala logarítmica

Se σ é a RCS em m^2 , sua representação em decibéis por metro quadrado é

$$\sigma_{\text{dBsm}} = 10 \log_{10} \left(\frac{\sigma}{1 \text{ m}^2} \right).$$

Uma função de perda em escala linear dá maior peso absoluto a picos grandes. Uma perda em dB altera esse balanço e tende a enfatizar diferenças relativas em níveis menores. A avaliação deve, portanto, reportar métricas nas escalas relevantes e verificar separadamente picos, vales e setores angulares de interesse.

4.13 Surrogate aerodinâmico

4.13.1 O problema de entrada e saída

Para o regime compressível invíscido do Capítulo 3, seja

$$\mathcal{G}_{\text{aero},\theta}$$

o operador aprendido para a disciplina aerodinâmica. Uma formulação de entrada-saída é

$$\mathcal{G}_{\text{aero},\theta} : (G, M_\infty, \alpha, \beta, \gamma) \mapsto \left(\{\widehat{C}_{p,f}\}_{f=1}^{N_f}, \widehat{C}_L, \widehat{C}_D, \widehat{C}_m \right).$$

Aqui, M_∞ é o número de Mach do escoamento livre; α é o ângulo de ataque; β é o ângulo de derrapagem; γ é a razão de calores específicos; N_f é o número de faces da malha superficial; $\widehat{C}_{p,f}$ é o coeficiente de pressão previsto na face f ; e $\widehat{C}_L$, $\widehat{C}_D$ e $\widehat{C}_m$ são os coeficientes integrados previstos.

O coeficiente de pressão é definido por

$$C_p = \frac{p - p_\infty}{q_\infty},$$

em que p é a pressão local, p_∞ é a pressão do escoamento livre e $q_\infty = \frac{1}{2} \rho_\infty V_\infty^2$ é a pressão dinâmica. Usar C_p como alvo adimensional facilita a comparação entre condições que obedecem à mesma similaridade física.

GNNs já foram usadas para aproximar campos de escoamento em geometrias não estruturadas e também em formulações com termos physics-informed [23], [24]. Esses antecedentes não demonstram automaticamente generalização para aerodinâmica externa tridimensional de configurações UCAV; essa propriedade deve ser testada no domínio geométrico e operacional deste trabalho.

4.13.2 Perda de campo ponderada por área

Em uma malha com forte refinamento local, uma média simples dos erros por face dá maior peso às regiões que contêm mais elementos, mesmo quando essas regiões ocupam pequena área física. Seja $C_{p,f}$ o valor de referência na face f , $\widehat{C}_{p,f}$ a previsão correspondente e A_f a área da face. Uma perda quadrática ponderada por área é

$$\mathcal{L}_{C_p} = \frac{\sum_{f=1}^{N_f} A_f (\widehat{C}_{p,f} - C_{p,f})^2}{\sum_{f=1}^{N_f} A_f}.$$

Essa perda aproxima uma medida superficial do erro em vez de uma média dependente apenas da densidade de elementos. Em uma representação nodal, áreas duais podem desempenhar papel semelhante.

4.14 Física incorporada ao aprendizado

A expressão **physics-informed GNN** cobre mecanismos distintos e não deve ser usada como rótulo único para qualquer modelo que receba variáveis físicas.

O primeiro nível de incorporação está na representação: conectividade, vetores relativos, normais, áreas, bivectores e parâmetros adimensionais já introduzem estrutura física. O segundo nível impõe consistência entre diferentes saídas do próprio modelo. O terceiro utiliza condições de contorno ou identidades físicas avaliáveis nas previsões. O quarto emprega resíduos diferenciais ou integrais das equações governantes.

Considere quatro termos de perda:

- $\mathcal{L}_{\text{data}}$: erro de supervisão em relação aos dados de referência;
- $\mathcal{L}_{\text{cons}}$: erro de consistência entre saídas relacionadas, como C_L direto e C_L integrado de C_p ;
- $\mathcal{L}_{\text{bc}}$: violação de condições de contorno avaliáveis;
- $\mathcal{L}_{\text{phys}}$: resíduo de uma relação física diferencial ou integral.

Com pesos não negativos λ_{data} , λ_{cons} , λ_{bc} e λ_{phys} , a função de perda pode ser escrita como

$$\mathcal{L} = \lambda_{\text{data}} \mathcal{L}_{\text{data}} + \lambda_{\text{cons}} \mathcal{L}_{\text{cons}} + \lambda_{\text{bc}} \mathcal{L}_{\text{bc}} + \lambda_{\text{phys}} \mathcal{L}_{\text{phys}}.$$

Se um mecanismo não for utilizado, seu peso pode ser nulo. Os termos precisam ser normalizados de modo compatível com suas escalas; caso contrário, um resíduo numericamente grande pode dominar o treinamento sem corresponder a maior relevância física.

4.14.1 Quando um resíduo de PDE é realmente calculável?

Um resíduo de equação governante só pode ser calculado quando a rede fornece as variáveis necessárias e existe um operador discreto consistente para avaliá-lo.

Para Euler conservativo, seja

$$\mathbf{U} = [\rho, \rho u, \rho v, \rho w, \rho E]^T$$

o vetor de variáveis conservadas, com densidade ρ , componentes de velocidade u, v, w e energia total específica E . Em regime estacionário, o resíduo simbólico pode ser escrito como

$$\mathcal{R}_U = \nabla \cdot \mathbf{F}(\mathbf{U}),$$

onde $\mathbf{F}(\mathbf{U})$ representa o conjunto de fluxos conservativos de massa, quantidade de movimento e energia. Se a rede prevê somente C_L e C_D , $\mathbf{U}$ não está disponível e esse resíduo não pode ser avaliado.

Para Maxwell em STA, o resíduo compacto

$$\mathcal{R}_M = \nabla F - \mathcal{J}$$

requer o bivector de campo eletromagnético F , o operador derivada geométrica ∇ e o quatrorvetor de fonte $\mathcal{J}$ na mesma convenção de unidades e assinatura definida no Capítulo 3. Uma rede que prevê somente RCS não contém essas variáveis locais.

Assim, consistências integrais ou relações entre campo e resposta global podem ser mais apropriadas do que um resíduo PDE completo quando a saída do surrogate é reduzida.

4.15 Surrogates separados ou arquitetura multitarefa?

Eletromagnetismo e aerodinâmica compartilham a mesma geometria, mas possuem operadores físicos e condições de operação diferentes. Três organizações são particularmente naturais:

- dois modelos independentes, um para cada disciplina;
- um encoder geométrico compartilhado, seguido de processadores ou decoders específicos;
- uma arquitetura multitarefa na qual parte da representação é compartilhada durante o processamento.

Compartilhar parâmetros pode reduzir duplicação e permitir reaproveitamento de descritores geométricos, mas também pode causar **interferência negativa entre tarefas**, isto é, atualizações de treinamento favoráveis a uma disciplina podem degradar a outra. Resultados positivos de uma arquitetura multitarefa em problema correlato demonstram viabilidade, não superioridade universal [4]. Modelos separados e compartilhados devem ser comparados sob o mesmo conjunto de dados, divisão experimental e orçamento de treinamento.

4.16 Generalização e prevenção de vazamento de dados

4.16.1 Divisão por geometria

Suponha que cada geometria seja simulada em dez condições de operação. Se oito condições forem destinadas ao treino e duas ao teste por sorteio independente, a mesma geometria poderá aparecer nos dois subconjuntos. O teste medirá principalmente interpolação em condições de operação.

Para avaliar generalização a novas configurações, a divisão deve ser realizada primeiro por geometria: todas as condições associadas a uma geometria permanecem no mesmo subconjunto. Essa estratégia é denominada **geometry-disjoint** e já foi usada em problema aero-eletromagnético baseado em GNN [4].

Convém separar pelo menos quatro perguntas experimentais: desempenho em geometria não vista com condições conhecidas; desempenho em condições não vistas sobre geometria conhecida; desempenho quando geometria e condições são simultaneamente não vistas; e sensibilidade a remalhamento de uma mesma geometria. Cada teste caracteriza uma forma diferente de generalização.

4.16.2 Interpolação, extrapolação e domínio de aplicabilidade

Um surrogate treinado somente no intervalo

$$0,5 \leq M_{\infty} \leq 0,8$$

não está validado em $M_{\infty} = 1,5$ apenas porque a rede aceita numericamente esse valor. A mesma restrição vale para frequência, ângulos, curvatura, enflechamento e demais variáveis geométricas.

O domínio coberto pelos dados deve acompanhar o modelo como informação de aplicabilidade. Essa precaução é especialmente importante em otimização, porque o algoritmo pode buscar regiões próximas às fronteiras do domínio em que o surrogate possui pouco suporte empírico.

4.17 Métricas de erro para campos e respostas integradas

Para um conjunto de n valores de referência y_s e previsões $\hat{y}_s$, o **Mean Absolute Error (MAE)** é

$$\text{MAE} = \frac{1}{n} \sum_{s=1}^n |\hat{y}_s - y_s|,$$

e o **Root Mean Squared Error (RMSE)** é

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{s=1}^n (\hat{y}_s - y_s)^2}.$$

O coeficiente de determinação R^2 pode complementar essas métricas, mas não substitui erros com interpretação física direta.

Para campos locais, além de MAE e RMSE, são úteis normas relativas e mapas espaciais de erro. Para C_L , C_D e C_m , erros absolutos possuem interpretação de engenharia. Para curvas angulares de RCS, médias globais devem ser complementadas por erro na posição e magnitude de picos, comportamento em setores angulares de interesse e consistência entre polarizações.

Um pequeno erro médio em C_p não garante pequeno erro em C_D , porque diferenças pequenas distribuídas sobre a superfície podem se acumular na integração. Erros locais e globais devem ser reportados conjuntamente.

4.18 Precisão não é o mesmo que utilidade para otimização

Se T_{solver} é o tempo de uma avaliação do modelo de referência e T_{GNN} é o tempo de uma inferência equivalente do surrogate, define-se o speedup por avaliação como

$$S_{\text{eval}} = \frac{T_{\text{solver}}}{T_{\text{GNN}}}.$$

Essa razão não inclui o custo de construir o surrogate. Para o processo completo, sejam $T_{\text{MDO,ref}}$ o tempo de uma otimização realizada com os modelos de referência, T_{data} o tempo de geração dos dados, T_{train} o tempo de treinamento, T_{opt} o tempo da otimização usando surrogates e T_{reval} o tempo de reavaliação das soluções selecionadas. Uma medida end-to-end é

$$S_{\text{MDO}} = \frac{T_{\text{MDO,ref}}}{T_{\text{data}} + T_{\text{train}} + T_{\text{opt}} + T_{\text{reval}}}.$$

Além do tempo de parede, devem ser registrados horas de CPU/GPU, pico de memória, armazenamento, tamanho das malhas, número de avaliações de referência e throughput de inferência. Uma arquitetura com menor erro, mas custo de inferência ou treinamento muito maior, pode ser menos adequada ao objetivo de acelerar milhares de avaliações em MDO.

A diferenciabilidade interna da GNN também não garante gradientes completos em relação aos parâmetros de projeto. Se a cadeia parâmetros de projeto $\rightarrow$ geometria $\rightarrow$ malha inclui remalhamento ou operações não diferenciáveis, a derivada da saída em relação às coordenadas dos nós não coincide automaticamente com a derivada em relação ao vetor de projeto.

4.19 Incerteza e domínio de aplicabilidade

Em um surrogate treinado com dados determinísticos, a **incerteza epistemológica** está associada à limitação do conhecimento do modelo em regiões pouco representadas pelo conjunto de treinamento. Ensembles e aproximações bayesianas podem fornecer indicadores dessa incerteza, mas suas saídas não devem ser tratadas como probabilidades calibradas sem validação específica.

Um indicador de incerteza pode auxiliar a selecionar candidatos para reavaliação com o solver de referência ou a escolher novos casos de treinamento. Esse uso conecta-se naturalmente a aprendizado ativo, mas a estratégia somente se justifica se o benefício em número de simulações ou recursos superar a complexidade adicional.

4.20 Ponte para multifidelidade

Até este ponto, a GNN foi apresentada como aproximação de um conjunto de dados de referência. O próximo passo é reconhecer que diferentes modelos físicos e discretizações podem produzir respostas relacionadas com demandas de recursos distintas.

Se y_{LF} é uma resposta obtida por um modelo de menor fidelidade, y_{HF} é a resposta correspondente de maior fidelidade e $\mathbf{c}$ reúne as condições físicas, uma relação corretiva conceitual é

$$y_{\text{HF}} = y_{\text{LF}} + \Delta_{\theta}(G, y_{\text{LF}}, \mathbf{c}),$$

onde Δ_{θ} é uma correção aprendida. Essa forma aditiva é apenas uma possibilidade; ela não deve ser adotada antes de verificar se descreve adequadamente a relação entre os níveis. GNNs multifidelidade já foram investigadas em problemas de malha e PDEs [20], [21].

No problema aero-stealth, a fidelidade será definida separadamente para eletromagnetismo e aerodinâmica em função das hipóteses físicas, discretização, critérios numéricos e demanda de recursos. O Capítulo 5 desenvolve essa estrutura.

4.21 Estudos de ablação e comparação justa

A contribuição de cada componente deve ser separada experimentalmente. Um conjunto informativo de comparações inclui um baseline sem grafo, uma MPNN convencional com conectividade e atributos geométricos usuais, variantes com atributos geométricos adicionais, versões com features ou canais de AG, regularização física, mecanismos explícitos de equivariância e, posteriormente, multifidelidade.

As comparações devem compartilhar, tanto quanto possível, o mesmo conjunto de dados, a mesma divisão treino–validação–teste, critérios semelhantes de seleção de hiperparâmetros e as mesmas métricas. Caso contrário, uma melhora atribuída à AG ou à regularização física pode resultar apenas de maior capacidade da rede, maior tempo de treinamento ou diferença na distribuição dos dados.

4.22 Posição em relação à literatura recente

A literatura recente mostra diferentes formas de aproximar física em malhas. GNNs foram utilizadas para aprender dinâmica sobre malhas não estruturadas e campos aerodinâmicos [2], [23]. Formulações physics-informed em grafos foram exploradas em escoamentos [24]. No eletromagnetismo, modelos de grafos e representações geométricas foram aplicados a espalhamento e campos distantes [3], [31]. Operadores neurais informados por geometria

representam uma família vizinha para PDEs tridimensionais e constituem alternativa relevante em comparações futuras [25].

O antecedente mais próximo do acoplamento aero-eletromagnético deste livro emprega uma GNN multitarefa sobre malha superficial para prever simultaneamente respostas aerodinâmicas e médias de RCS [4]. A contribuição perseguida aqui está na integração de cinco dimensões: **RCS angular e polarizada, multifidelidade explícita, representações e operadores baseados em Álgebra Geométrica, otimização matemática determinística e avaliação end-to-end de recursos com revalidação por modelos de referência.**

A questão científica, portanto, não é se GNNs podem ser usadas em aerodinâmica ou eletromagnetismo. O problema é estabelecer se uma arquitetura baseada em malhas, geometricamente estruturada e posteriormente multifidelidade alcança precisão, robustez e eficiência suficientes para acelerar de maneira mensurável a otimização aero-stealth de configurações UCAV.

4.23 Arquitetura conceitual do framework

Sem fixar prematuramente uma implementação vencedora, o framework pode ser organizado em blocos estáveis. A geometria parametrizada gera uma malha e um grafo. O encoder converte atributos geométricos e condições físicas em estados latentes. O processador propaga informação local e, quando necessário, global. Decoders específicos produzem campos ou respostas eletromagnéticas e aerodinâmicas. Relações de consistência conectam campos a quantidades integradas. O módulo multifidelidade relaciona respostas de modelos com níveis distintos de fidelidade. Finalmente, o otimizador consulta os surrogates e envia soluções selecionadas aos modelos de referência.

Em forma compacta,

$$\text{geometria} \rightarrow \text{malha/graf} \rightarrow \text{GNN condicionada} \rightarrow \begin{cases} \text{RCS/campos EM,} \\ \text{campos/coefs. aero} \end{cases} \rightarrow \text{MDO determinística.}$$

A AG atua transversalmente na representação geométrica e, se os experimentos justificarem, nos canais e operadores internos da GNN. A multifidelidade atua na relação entre dados provenientes de modelos distintos. A física orienta atributos, alvos, condições de contorno, integrais e perdas. Nenhum desses componentes elimina a necessidade de validação e reavaliação com os solvers de referência.

4.24 Progressão experimental dos grafos 2D para 3D

Os conceitos deste capítulo serão avaliados primeiro em grafos derivados de contornos e malhas bidimensionais. Nessa etapa, cada configuração geométrica será mantida integralmente em um único subconjunto de treino, validação ou teste, evitando que nós ou condições da mesma geometria contaminem mais de uma partição quando o objetivo for medir generalização geométrica.

A mesma interface conceitual será posteriormente reutilizada em superfícies tridimensionais. O que muda entre as etapas é a complexidade geométrica e física: em 2D predominam contornos, arestas e relações em $Cl(2,0)$; em 3D surgem faces orientadas, bivectores de área, rotores entre referenciais locais, maior variabilidade de malha e interações físicas de alcance potencialmente maior. Arquiteturas e hiperparâmetros bem-sucedidos em 2D serão tratados como pontos de partida, não como escolhas automaticamente válidas em 3D.

4.25 Síntese

A principal vantagem conceitual das GNNs neste problema é operar diretamente sobre malhas irregulares e aprender interações condicionadas pela geometria e pelas condições físicas. Para que essa vantagem se converta em contribuição de engenharia, a formulação precisa manter significado matemático explícito, tratar corretamente simetrias e orientação, controlar dependências da discretização, fornecer alcance suficiente para interações não locais e separar erro de campo, erro de resposta integrada e economia real de recursos.

No eletromagnetismo, direção, polarização, frequência e coerência de fase precisam ser preservadas quando relevantes. Na aerodinâmica, campos superficiais e coeficientes integrados devem ser relacionados de maneira compatível com a discretização e com as hipóteses do modelo de Euler. Em ambas as disciplinas, generalização deve ser demonstrada em geometrias não vistas, e não apenas em novas condições sobre geometrias já presentes no treinamento.

Com essa base, o Capítulo 5 passa à combinação explícita de dados provenientes de níveis distintos de fidelidade, com o objetivo de reduzir a quantidade de avaliações de referência necessária sem perder controle sobre a qualidade das respostas usadas pela otimização.

5 Modelagem multifidelidade, parametrização e representação geométrica do estudo 2D

Este capítulo estabelece o primeiro bloco experimental do framework. O objetivo é transformar a formulação desenvolvida nos capítulos anteriores em um pipeline reproduzível para geometrias bidimensionais, preservando o significado físico das respostas e preparando a extensão tridimensional. O estudo 2D será usado para validar representação, ingestão de dados, construção de grafos, atributos em Álgebra Geométrica e relações entre níveis de fidelidade antes de aumentar a complexidade geométrica.

5.1 Escopo do estudo bidimensional

Serão considerados dois problemas disciplinares complementares. Na aerodinâmica, cada configuração corresponde a um aerofólio discretizado, acompanhado de respostas como C_L , C_D e L/D , além das condições de operação necessárias à interpretação dessas grandezas. No eletromagnetismo, cada configuração corresponde a uma geometria bidimensional ou a uma geometria tridimensional parametrizada a partir de uma seção 2D, acompanhada da resposta de espalhamento fornecida pelo solver.

A grandeza eletromagnética deverá ser identificada a partir dos metadados do conjunto de dados. Se o solver resolver um problema estritamente bidimensional, a saída poderá corresponder a *scattering width* ou outra grandeza por unidade de comprimento. Se a resposta tiver sido calculada para uma extrusão finita ou uma geometria tridimensional, poderá ser uma RCS em m^2 ou dBsm . O pipeline não converterá implicitamente uma definição na outra.

5.2 Parametrização geométrica e vetor de projeto

A malha ou o contorno é a entrada natural da GNN, mas não é, por si só, uma parametrização adequada para otimização contínua. Para gerar novas geometrias de forma controlada, define-se um vetor de projeto

$$\mathbf{d} = [d_1, \dots, d_p]^T,$$

em que cada componente d_k modifica uma característica geométrica com domínio e significado conhecidos. Um gerador geométrico $\mathcal{P}$ transforma esse vetor em uma geometria contínua,

$$\Gamma = \mathcal{P}(\mathbf{d}),$$

e uma etapa de discretização $\mathcal{M}$ produz a malha ou o contorno usado pela GNN,

$$G = \mathcal{M}(\mathcal{P}(\mathbf{d})).$$

No estudo de aerofólios, parametrizações como **Class-Shape Transformation (CST)** constituem uma alternativa compacta e amplamente usada para representar famílias de perfis [44]. Splines, PARSEC, *free-form deformation* e outras técnicas permanecem alternativas possíveis. A escolha não será fixada antes da inspeção dos 50 casos, porque é necessário saber se os CSVs preservam os parâmetros geradores ou apenas as coordenadas discretizadas.

Se os dados fornecerem somente coordenadas, a GNN poderá ser treinada normalmente sobre os grafos, mas a otimização contínua de novas formas exigirá posteriormente ajustar ou definir um mapeamento $\mathcal{P}$. Essa distinção impede confundir **representação para aprendizado** com **parametrização para geração de projeto**.

5.3 Design of Experiments e construção do banco de dados

A geração planejada de dados deve cobrir conjuntamente o espaço geométrico e as condições físicas sem contaminar a avaliação final do surrogate. Seja $\mathbf{c}$ o vetor de condições de operação e seja f um identificador do nível de fidelidade. Uma amostra computacional pode ser representada por

$$\mathcal{D} = \{(\mathbf{d}^{(s)}, \mathbf{c}^{(s)}, f^{(s)}, G^{(s)}, \mathbf{y}^{(s)})\}_{s=1}^N,$$

em que s identifica a amostra, $G^{(s)}$ é o grafo correspondente e $\mathbf{y}^{(s)}$ contém as respostas físicas disponíveis.

Quando novas configurações forem geradas, o **Design of Experiments (DoE)** deverá ser definido sobre os limites admissíveis de $\mathbf{d}$ e $\mathbf{c}$. Latin Hypercube Sampling (LHS) é uma alternativa clássica para cobrir espaços multidimensionais sem exigir uma grade cartesiana completa [45], mas não será adotado automaticamente: a estratégia deverá respeitar restrições geométricas, regiões fisicamente admissíveis e o orçamento de simulação.

No conjunto inicial de aproximadamente 50 configurações, a primeira tarefa será caracterizar como essas amostras foram produzidas. Se forem dados já existentes, não serão reclassificados

retroativamente como um DoE planejado. A cobertura do espaço de projeto será medida a partir dos parâmetros disponíveis ou, na ausência deles, por descritores geométricos apropriados.

A partição de teste será congelada antes de qualquer ajuste adaptativo do banco de dados. Novas simulações escolhidas por DoE sequencial ou aprendizado ativo poderão enriquecer treino e validação, mas não serão selecionadas para melhorar diretamente o desempenho observado no teste final.

Em um conjunto multifidelidade, deve-se ainda registrar quais configurações possuem avaliações em cada nível. Amostras de referência podem ser um subconjunto das amostras do modelo de base ou seguir outro desenho explicitamente documentado. O requisito essencial é que respostas usadas em fusão ou correção representem a mesma grandeza física sob condições comparáveis [7].

5.4 Unidade de amostragem e identificação das configurações

A unidade estatística primária será a **configuração geométrica**, identificada por um campo persistente como `configuration_id`. Todos os nós, arestas, faces, condições de operação e respostas pertencentes à mesma configuração deverão permanecer associados a esse identificador.

Essa regra é essencial para evitar vazamento de dados. A divisão entre treinamento, validação e teste será realizada por configuração, e não por linha de CSV, nó ou elemento de malha.

5.5 Contrato inicial dos dados em CSV

Os arquivos recebidos poderão possuir formatos diferentes, mas serão convertidos internamente para uma representação canônica. Para uma malha ou contorno nodal, o núcleo geométrico deverá conter, no mínimo,

- identificador da configuração;
- identificador do nó;
- coordenadas x e y ;
- conectividade, quando não puder ser inferida de maneira inequívoca pela ordenação dos pontos.

As condições físicas deverão ser preservadas em campos próprios. Para aerodinâmica, podem incluir M_∞ , α , número de Reynolds e outras variáveis realmente presentes no solver. Para eletromagnetismo, podem incluir frequência, direção de incidência, polarização, propriedades materiais e direção de observação.

As respostas globais serão armazenadas separadamente dos atributos geométricos. No primeiro conjunto experimental, espera-se trabalhar com aproximadamente 50 configurações e alvos como

$$C_L, \quad C_D, \quad \frac{L}{D}, \quad R_{\text{EM}},$$

em que R_{EM} representa genericamente a resposta eletromagnética até que sua definição física seja confirmada pelos metadados do conjunto de dados.

5.6 Reconstrução geométrica em $Cl(2, 0)$

Considere um contorno orientado por pontos consecutivos $\mathbf{x}_i \in \mathbb{R}^2$. A aresta orientada é

$$\mathbf{e}_i = \mathbf{x}_{i+1} - \mathbf{x}_i.$$

Seu comprimento e sua tangente unitária são

$$\ell_i = \|\mathbf{e}_i\|, \quad \mathbf{t}_i = \frac{\mathbf{e}_i}{\ell_i}.$$

Em $Cl(2, 0)$, com pseudoescalar $I = e_1 e_2$, a orientação do contorno permite construir uma normal local por dualidade. A convenção de sinal será fixada de acordo com a orientação escolhida para o contorno e verificada numericamente.

Entre elementos vizinhos, produtos como

$$\mathbf{t}_i \cdot \mathbf{t}_j$$

medem alinhamento, enquanto

$$\mathbf{t}_i \wedge \mathbf{t}_j$$

representam a mudança orientada de direção no plano. Essas grandezas podem ser usadas para construir medidas discretas de curvatura e atributos geometricamente estruturados para a GNN.

Se o arquivo representar uma malha triangular 2D, a área orientada da célula $f = (i, j, k)$ será representada por

$$B_f = \frac{1}{2} \mathbf{r}_{ij} \wedge \mathbf{r}_{ik},$$

com $\mathbf{r}_{ij} = \mathbf{x}_j - \mathbf{x}_i$ e $\mathbf{r}_{ik} = \mathbf{x}_k - \mathbf{x}_i$.

5.7 Do CSV ao grafo

A conversão geométrica produzirá um grafo

$$G = (V, E),$$

em que os nós representam as entidades escolhidas da discretização e as arestas preservam a conectividade física ou geométrica. A escolha entre grafo de vértices, grafo de segmentos e grafo de células será determinada pela estrutura real dos CSVs e pela localização das variáveis de entrada.

O primeiro baseline utilizará atributos convencionais, como posição relativa, comprimento, normal, curvatura e condições globais. Uma variante posterior acrescentará atributos derivados de Álgebra Geométrica. A comparação entre essas representações será feita com a mesma divisão de dados e orçamento de treinamento.

5.8 Respostas globais e campos locais

A disponibilidade apenas de C_L , C_D , L/D e uma resposta eletromagnética global permite treinar um modelo de **resposta global**, mas não reconstruir a solução física completa.

Para aerodinâmica, a reconstrução de campos exigiria, por exemplo, C_p , pressão, densidade ou velocidade definidos nos nós ou elementos. Para eletromagnetismo, seriam necessários campos ou correntes complexas, como $\tilde{\mathbf{E}}_{\text{sca}}$ ou $\tilde{\mathbf{J}}_s$.

O pipeline inicial será, portanto,

$$G, \mathbf{c} \mapsto \text{respostas globais},$$

em que $\mathbf{c}$ reúne as condições de operação. Caso campos locais sejam incorporados posteriormente, o mesmo grafo poderá sustentar uma segunda etapa de predição campo–integração–resposta global.

5.9 Consistência de L/D

A razão aerodinâmica não é uma quarta grandeza independente quando C_L e C_D estão disponíveis:

$$\frac{L}{D} = \frac{C_L}{C_D}.$$

O baseline deverá prever C_L e C_D , calculando L/D a partir dessas previsões. Uma cabeça adicional para predição direta de L/D poderá ser avaliada posteriormente, mas sua saída deverá ser comparada com

$$\frac{\widehat{C}_L}{\widehat{C}_D}$$

como teste de consistência.

5.10 Definição de fidelidade no conjunto 2D

Um nível de fidelidade será caracterizado por seu conteúdo físico e numérico, não apenas pelo nome do solver. Para cada conjunto de dados deverão ser registrados, quando disponíveis,

- equações ou aproximações físicas;
- dimensionalidade do problema;
- discretização e resolução;
- condições de contorno;
- propriedades de material ou modelo de turbulência;
- critérios de convergência;
- tempo de processamento;
- uso de CPU/GPU, memória e armazenamento.

A relação entre níveis somente será modelada como multifidelidade se o conjunto de dados contiver respostas comparáveis para a mesma grandeza física. Se o primeiro conjunto de 50 configurações possuir uma única fidelidade, o experimento começará com um baseline *single-fidelity* e a extensão multifidelidade será adicionada apenas quando houver dados compatíveis.

5.11 Estratégias multifidelidade a avaliar

Quando pares ou conjuntos de fidelidades estiverem disponíveis, uma hipótese inicial será a correção de discrepância

$$y_{\text{ref}} = y_{\text{base}} + \Delta_{\theta}(G, y_{\text{base}}, \mathbf{c}),$$

em que y_{base} é a resposta do nível de base, y_{ref} é a resposta do nível de referência, G é o grafo, $\mathbf{c}$ contém as condições físicas e Δ_{θ} é uma correção aprendida. A forma aditiva será tratada como hipótese e comparada com alternativas quando os dados permitirem.

Também poderão ser avaliadas transferência de representação, treinamento *coarse-to-fine* e compartilhamento parcial de parâmetros entre fidelidades [20], [21]. A classificação mais ampla de métodos multifidelidade inclui estratégias de adaptação, fusão e filtragem; essa taxonomia será usada para posicionar as alternativas implementadas sem reduzir multifidelidade a uma única correção aditiva [7].

5.12 Reprodutibilidade da preparação dos dados

A divisão oficial do conjunto utilizará semente fixa

$$\text{seed} = 42.$$

As proporções de treino, validação e teste serão parâmetros do job. Um valor inicial de referência é 70%/15%/15%, mas nenhuma proporção será codificada de forma rígida no código.

O manifest de cada execução deverá registrar, no mínimo, identificadores das configurações em cada subconjunto, versão dos arquivos de entrada, transformações geométricas aplicadas e parâmetros usados para construir o grafo.

5.13 Especificação computacional de referência

A implementação associada ao estudo 2D deverá manter transparentes as operações geométricas usadas na construção dos atributos do grafo. Em $Cl(2, 0)$, um multivetor pode ser representado por

$$M = m_0 + m_1 e_1 + m_2 e_2 + m_{12} e_{12},$$

com componentes escalar, vetoriais e bivetorial. A implementação deverá verificar explicitamente as relações

$$e_1^2 = e_2^2 = 1, \quad e_1 e_2 = e_{12}, \quad e_2 e_1 = -e_{12}, \quad e_{12}^2 = -1.$$

Essa escolha permite testar produto geométrico, dualidade, orientação e sinais antes de incorporar as quantidades resultantes à GNN.

5.13.1 Features geométricas de referência

Para um grafo nodal construído a partir de um contorno ordenado, um vetor inicial de atributos pode reunir

$$[x_i, y_i, t_{x,i}, t_{y,i}, n_{x,i}, n_{y,i}, d_i, b_i],$$

em que (x_i, y_i) são as coordenadas do nó, $\mathbf{t}_i$ é a tangente unitária local, $\mathbf{n}_i$ é a normal externa, d_i é o produto interno entre tangentes adjacentes e b_i é o coeficiente de e_{12} do produto exterior entre essas tangentes. O par (d_i, b_i) separa alinhamento e mudança orientada de direção.

As arestas direcionadas podem armazenar deslocamento relativo, comprimento e direção unitária. O conjunto final de features será confirmado a partir da semântica real dos CSVs e mantido idêntico entre baselines quando a comparação buscar isolar o efeito da Álgebra Geométrica.

5.13.2 Serialização e rastreabilidade

A preparação dos dados deverá produzir, para cada configuração, uma representação serializável independente da biblioteca de GNN escolhida para o treinamento. Essa representação deverá preservar identificadores, features nodais e de arestas, conectividade, orientação, respostas globais e condições físicas.

Além dos grafos, cada job de preparação deverá registrar um **manifest do dataset** e um **manifest do split**. Esses artefatos documentarão a origem dos dados, as configurações alocadas a treino, validação e teste, a seed utilizada e as transformações aplicadas. Essa separação permite reproduzir o mesmo conjunto de entrada em arquiteturas de GNN diferentes sem reconstruir silenciosamente as partições.

5.14 Limites da primeira etapa computacional

A primeira etapa computacional será formulada para **contornos fechados 2D ordenados**, hipótese adequada a aerofólios representados pela fronteira e a geometrias eletromagnéticas descritas por um contorno equivalente. Essa delimitação não implica suporte antecipado a qualquer malha bidimensional volumétrica.

Se os CSVs fornecidos contiverem células triangulares, conectividade explícita, múltiplos componentes de contorno ou campos internos, o contrato será estendido depois de inspecionar a estrutura real dos arquivos. Essa extensão preservará os princípios definidos aqui, mas não será inferida antecipadamente.

Da mesma forma, o campo chamado provisoriamente de RCS no conjunto de dados será renomeado no pipeline caso os metadados mostrem que se trata de *scattering width* ou de outra grandeza eletromagnética.

5.15 Saídas computacionais deste capítulo

A primeira implementação deverá fornecer

- validação do contrato dos CSVs;
- reconstrução de contornos 2D;
- atributos convencionais e derivados de $Cl(2, 0)$;
- grafos serializáveis independentes do framework de GNN;
- divisão por configuração com semente 42;
- manifestos de dados e split;
- testes unitários para o produto geométrico, dualidade, orientação, comprimentos, grafos e ausência de vazamento entre partições.

Os resultados experimentais serão produzidos somente depois que os CSVs reais forem incorporados e seu contrato físico-numérico for validado. O Capítulo 6 utilizará os artefatos desse pipeline para treinamento, validação e comparação das GNNs.

6 GNNs, treinamento, validação e otimização no estudo 2D

Este capítulo transforma os grafos construídos no Capítulo 5 em experimentos de aprendizado reproduzíveis. O objetivo é estabelecer baselines, treinar modelos disciplinares, testar a contribuição de atributos em Álgebra Geométrica e, quando houver dados adequados, incorporar multifidelidade. A otimização somente será introduzida depois que o comportamento do surrogate estiver caracterizado.

6.1 Pipeline executável

O fluxo computacional será organizado como

CSV $\rightarrow$ validação $\rightarrow$ AG 2D $\rightarrow$ grafo $\rightarrow$ split $\rightarrow$ GNN $\rightarrow$ treinamento $\rightarrow$ validação $\rightarrow$ teste.

Cada etapa deverá ser executável de forma independente e produzir artefatos persistentes que permitam rastrear o caminho entre uma configuração original e sua previsão final.

6.2 Reprodutibilidade

A execução oficial utilizará a semente

`seed = 42.`

Ela deverá ser aplicada, quando tecnicamente possível, às bibliotecas de aleatoriedade da linguagem, NumPy, PyTorch, inicialização de pesos, embaralhamento, geração dos splits e operações CUDA controláveis. Operações que permaneçam não determinísticas deverão ser documentadas.

A seed de referência será 42 para todos os resultados publicados. Experimentos de sensibilidade com outras sementes poderão ser executados separadamente, sem substituir o resultado oficial.

6.3 Jobs configuráveis

Hiperparâmetros e proporções de dados não deverão exigir edição do código-fonte. Cada job receberá uma configuração externa contendo, por exemplo,

- proporções de treino, validação e teste;
- *learning rate*;
- número máximo de épocas;
- *batch size*;
- *weight decay*;
- critério e paciência de *early stopping*;
- dimensão latente;
- número de camadas;
- função de agregação;
- *dropout*;
- arquitetura e conjunto de features.

A interface de linha de comando poderá sobrescrever valores do arquivo de configuração para permitir execução em estação de trabalho ou HPC.

6.4 Baselines e ablações

A progressão experimental deverá separar a contribuição de cada mecanismo. A sequência de referência será:

1. modelo sem grafo baseado em descritores globais;
2. MPNN convencional;
3. MPNN com atributos geométricos estruturados;
4. MPNN com features derivadas de Álgebra Geométrica;
5. canais multivetoriais ou operações geometricamente estruturadas, quando implementados de forma matematicamente consistente;
6. variante multifidelidade, quando houver dados compatíveis;
7. arquitetura multitarefa aero-EM, somente depois da validação dos modelos disciplinares.

As comparações deverão manter o mesmo split por configuração e um orçamento de treinamento comparável.

6.5 Surrogate aerodinâmico 2D

O primeiro modelo disciplinar será escrito como

$$\mathcal{G}_{\text{aero},\theta} : (G, \mathbf{c}_{\text{aero}}) \mapsto (\widehat{C}_L, \widehat{C}_D),$$

em que G representa a geometria discretizada, $\mathbf{c}_{\text{aero}}$ contém as condições físicas e θ reúne os parâmetros treináveis.

A eficiência aerodinâmica prevista será derivada de

$$\widehat{L/D} = \frac{\widehat{C}_L}{\widehat{C}_D}.$$

Se houver uma saída direta adicional para L/D , será avaliada sua consistência com essa relação.

6.6 Surrogate eletromagnético 2D

O segundo modelo disciplinar será

$$\mathcal{G}_{\text{EM},\theta} : (G, \mathbf{c}_{\text{EM}}) \mapsto \widehat{R}_{\text{EM}},$$

em que $\widehat{R}_{\text{EM}}$ receberá o nome e a unidade da grandeza fornecida pelo solver. Se o alvo for uma curva angular, a saída será vetorial ou condicionada por direção de observação; se for escalar, será modelada como resposta global.

A função de perda deverá respeitar a escala física usada pelo conjunto de dados. Resultados em escala linear e logarítmica não serão comparados sem explicitar a transformação.

6.7 Modelos separados antes do compartilhamento

Aerodinâmica e eletromagnetismo compartilharão a mesma geometria, mas serão inicialmente treinados com processadores separados. Esse baseline permite medir o desempenho de cada disciplina sem interferência entre tarefas.

Somente após essa caracterização será testada uma arquitetura com encoder geométrico compartilhado e heads específicos. Eventual ganho será tratado como resultado experimental, não como consequência automática do compartilhamento.

6.8 Treinamento, validação e teste

O subconjunto de treinamento será usado para ajuste dos parâmetros. A validação controlará seleção de hiperparâmetros e *early stopping*. O teste permanecerá isolado até a escolha final da configuração experimental.

Com aproximadamente 50 geometrias, o tamanho do conjunto limita a precisão com que se pode estimar generalização. A interpretação dos resultados deverá considerar intervalos, sensibilidade ao split e, quando apropriado, uma análise complementar por validação cruzada agrupada por geometria.

6.9 Métricas preditivas

Para um alvo escalar y e sua previsão $\hat{y}$, serão reportados pelo menos MAE, RMSE e R^2 . Para aerodinâmica, as métricas serão calculadas separadamente para C_L , C_D e L/D .

Se a resposta eletromagnética for angular, métricas médias serão complementadas por erro de pico, deslocamento angular do pico, erro por setor e, quando aplicável, comparação entre polarizações.

6.10 Métricas de recursos

Além da precisão, cada job deverá registrar

- tempo de treinamento;
- tempo de inferência;
- throughput;
- número de parâmetros;
- pico de memória;
- uso de CPU/GPU;
- armazenamento dos artefatos;
- número de avaliações dos modelos físicos utilizadas para gerar o conjunto.

A utilidade do surrogate será julgada pela combinação de erro e demanda de recursos.

6.11 Artefatos de cada execução

Cada job deverá produzir um diretório rastreável contendo, no mínimo,

- arquivo de configuração efetivamente utilizado;

- manifest do dataset e do split;
- histórico de treinamento;
- checkpoint selecionado;
- métricas de validação e teste;
- previsões por configuração;
- informações do ambiente de software;
- tempos e uso de recursos.

6.12 Enriquecimento sequencial e aprendizado ativo

O **aprendizado ativo** será tratado como um mecanismo explícito de enriquecimento do conjunto de dados, mas sua ativação dependerá de evidência de que novas simulações de referência são suficientemente onerosas e de que o critério de aquisição seleciona casos mais informativos do que uma expansão fixa do DoE.

Depois de treinar um surrogate inicial, um ciclo de enriquecimento poderá ser escrito como

$$\mathcal{D}_k \rightarrow \mathcal{G}_{\theta_k} \rightarrow \mathcal{A}_k(\mathbf{d}, \mathbf{c}) \rightarrow \text{nova avaliação de referência} \rightarrow \mathcal{D}_{k+1},$$

em que $\mathcal{D}_k$ é o conjunto disponível na iteração k , $\mathcal{G}_{\theta_k}$ é o surrogate treinado e $\mathcal{A}_k$ é um critério de aquisição. Esse critério poderá combinar incerteza epistemológica validada, discrepância entre fidelidades, distância em relação aos dados existentes e relevância para regiões promissoras da fronteira de Pareto.

O subconjunto de teste permanecerá congelado e fora do ciclo de aquisição. Caso dados de validação sejam usados repetidamente para decisões de enriquecimento ou hiperparâmetros, uma avaliação final independente continuará necessária. Assim, aprendizado ativo não será usado para melhorar artificialmente a métrica de teste.

6.13 Otimização: pré-condição geométrica

Uma GNN treinada a partir de 50 geometrias pode avaliar novas amostras representadas como grafos, mas uma otimização geométrica contínua exige uma parametrização explícita do espaço de projeto.

Se cada configuração possuir um vetor de parâmetros

$$\mathbf{d} = [d_1, \dots, d_p],$$

a cadeia poderá ser escrita como

$$\mathbf{d} \rightarrow \text{geometria} \rightarrow G \rightarrow \text{GNN} \rightarrow (\widehat{C}_L, \widehat{C}_D, \widehat{R}_{\text{EM}}).$$

Sem $\mathbf{d}$ ou outro gerador de geometria, a etapa será corretamente descrita como seleção ou avaliação assistida por surrogate, e não como otimização contínua de novas formas.

6.14 Formulação aero-stealth 2D

Quando a parametrização estiver disponível, seja $\mathbf{d} \in \mathbb{R}^p$ o vetor de projeto e seja $\mathcal{D}_{\text{adm}}$ o domínio de geometrias admissíveis. Uma formulação multiobjetivo de referência é

$$\min_{\mathbf{d} \in \mathcal{D}_{\text{adm}}} \begin{bmatrix} J_{\text{EM}}(\mathbf{d}) \\ C_D(\mathbf{d}) \end{bmatrix},$$

sujeita, por exemplo, a

$$C_L(\mathbf{d}) \geq C_{L,\min}, \quad g_r(\mathbf{d}) \leq 0, \quad r = 1, \dots, n_g.$$

Aqui, J_{EM} é uma métrica eletromagnética definida a partir da resposta realmente fornecida pelo solver, $C_{L,\min}$ é a sustentação mínima requerida e g_r representa restrições geométricas ou operacionais. Restrições de espessura, área seccional ou suavidade somente serão incluídas quando fizerem parte do espaço de projeto real.

O problema pertence à família de **otimização baseada em surrogate**, em que o modelo aprendido acelera consultas, mas soluções selecionadas retornam aos modelos físicos de referência [5]. Para variáveis contínuas, o foco permanece em métodos determinísticos de NLP, incluindo escalarização e ε -constraint para explorar compromissos multiobjetivo. Métodos evolutivos como NSGA-II ou NSGA-III poderão aparecer como comparadores, mas não serão adotados como algoritmo padrão sem justificativa experimental. MINLP será utilizado somente se houver decisões discretas reais.

A classificação da arquitetura MDO também será feita a partir do acoplamento efetivo. No estudo 2D, aerodinâmica e eletromagnetismo compartilham a geometria e as variáveis de decisão, mas não se assume a existência de uma iteração de estados entre as duas disciplinas. Portanto, não há fundamento para declarar antecipadamente uma arquitetura MDF apenas porque ambas são consultadas pelo otimizador. Se surgirem variáveis de acoplamento disciplinares, MDF, IDF ou outra arquitetura será escolhida e formulada segundo a taxonomia de MDO [6].

As soluções selecionadas deverão ser reavaliadas com os modelos físicos de referência. A qualidade do surrogate será então medida não apenas pelo erro pontual, mas também pela preservação das decisões relevantes para a otimização.

6.15 Ponte para o estudo 3D

O encerramento do caso 2D deverá produzir uma infraestrutura reutilizável: loaders, validação de dados, splits, construção de grafos, modelos, treinamento, métricas e rastreamento de artefatos. Os Capítulos 7 e 8 estenderão essa infraestrutura para malhas superficiais tridimensionais e para a otimização de configurações UCAV, sem assumir que hiperparâmetros ou conclusões do domínio 2D permaneçam válidos automaticamente.

7 Modelagem multifidelidade e representação geométrica do estudo 3D

Este capítulo estenderá para três dimensões a infraestrutura validada no estudo 2D. A passagem para 3D não será tratada como simples aumento do número de coordenadas: superfícies triangulares, orientação de faces, remalhamento, campos vetoriais e dependências eletromagnéticas de longo alcance introduzem novas exigências geométricas, físicas e computacionais.

7.1 Geometrias UCAV e parametrização 3D

A geometria tridimensional deverá ser gerada a partir de um espaço de projeto explicitamente parametrizado. Cada configuração manterá rastreabilidade entre parâmetros de projeto, CAD ou representação geométrica intermediária, malha superficial, grafo e respostas dos solvers.

7.2 Design of Experiments e banco de dados 3D

A extensão tridimensional exigirá um DoE próprio no espaço de parâmetros geométricos e condições físicas. A estratégia de amostragem deverá considerar restrições de fabricação ou integração, validade geométrica do CAD, qualidade da malha e orçamento dos solvers. Técnicas como LHS podem fornecer cobertura inicial [45], mas a amostragem final deverá ser compatível com a parametrização 3D e com o custo observado de cada fidelidade.

Quando houver múltiplos níveis de fidelidade, o plano de dados deverá documentar a relação entre os conjuntos de amostras e reservar avaliações de referência para validação e reavaliação final. Estratégias multifidelidade serão selecionadas de acordo com a correlação observada, a compatibilidade das respostas e a relação entre recurso consumido e informação acrescentada [7].

7.3 Malhas superficiais e grafos

Serão avaliados grafos de vértices e de faces, escolhidos de acordo com a localização das variáveis físicas e com a discretização dos modelos de referência. A robustez a alterações de densidade e conectividade da malha será testada explicitamente.

7.4 Álgebra Geométrica em $Cl(3, 0)$

Para uma face triangular $f = (i, j, k)$, o bivetor de área orientada será

$$B_f = \frac{1}{2} \mathbf{r}_{ij} \wedge \mathbf{r}_{ik},$$

e sua magnitude fornecerá a área. Normais, dualidade, rotores entre referenciais locais e relações de orientação entre faces serão incorporados de forma compatível com as definições do Capítulo 2.

7.5 Aerodinâmica tridimensional

As respostas poderão incluir C_p , C_L , C_D , C_m e demais coeficientes relevantes. Os níveis de fidelidade serão definidos por conteúdo físico, discretização, modelos de turbulência quando aplicáveis, condições de contorno, convergência e demanda de recursos.

7.6 Espalhamento eletromagnético tridimensional

A resposta eletromagnética será tratada como RCS tridimensional quando sua definição física e normalização corresponderem a essa grandeza. A dependência angular, de frequência e de polarização deverá ser preservada:

$$\sigma = \sigma(\theta, \phi, f, \text{pol}).$$

Quando campos ou correntes locais estiverem disponíveis, serão preservadas amplitude e fase para permitir reconstruções fisicamente coerentes de campo distante.

7.7 Fidelidades EM e aero

As hierarquias não serão definidas apenas por nomes de solvers. Cada nível deverá ser documentado por suas hipóteses, discretização, resolução, tratamento de bordas ou viscosidade, critérios numéricos e recursos observados.

7.8 Correspondência entre fidelidades

A construção multifidelidade exigirá compatibilidade entre grandezas. Respostas LF e HF deverão representar a mesma quantidade física sob condições equivalentes antes de serem usadas em correção residual, transferência de representação ou aprendizado conjunto.

7.9 Dados, manifestos e rastreabilidade

Cada configuração 3D deverá manter identificadores persistentes para geometria, malha, fidelidade e condições físicas. Os splits continuarão sendo realizados por geometria, evitando vazamento entre remalhamentos ou condições derivadas da mesma configuração.

7.10 Transferência do pipeline 2D

Loaders, configuração de jobs, seed oficial, métricas e estrutura de artefatos serão reutilizados. A representação geométrica, os hiperparâmetros e as arquiteturas serão novamente avaliados, pois desempenho no caso 2D não constitui validação automática em 3D.

7.11 Critérios de prontidão para o Capítulo 8

Antes da otimização tridimensional, os surrogates disciplinares deverão demonstrar generalização em geometrias não vistas, estabilidade frente a remalhamento e erro compatível com as decisões de projeto que serão tomadas no domínio aero-stealth.

8 GNNs multifidelidade e otimização aero-stealth no estudo 3D

Este capítulo integrará os modelos tridimensionais ao problema aero-stealth de configurações UCAV. A análise combinará treinamento de GNNs sobre malhas superficiais, multifidelidade explícita, respostas aerodinâmicas e eletromagnéticas, otimização matemática determinística e reavaliação por modelos de referência.

8.1 Baselines tridimensionais

O estudo começará por modelos disciplinares separados e por uma MPNN convencional. Features geométricas usuais, atributos derivados de Álgebra Geométrica, canais multivetoriais, mecanismos de longo alcance e arquiteturas compartilhadas serão acrescentados por ablação.

8.2 Surrogate aerodinâmico 3D

A formulação poderá prever campos locais e coeficientes integrados:

$$\mathcal{G}_{\text{aero},\theta} : (G, \mathbf{c}_{\text{aero}}) \mapsto (C_p, C_L, C_D, C_m, \dots).$$

Quando campos forem previstos, a consistência entre integração superficial e coeficientes globais será usada como métrica adicional.

8.3 Surrogate eletromagnético 3D

A saída deverá preservar, conforme o conjunto de dados, a dependência angular e de polarização:

$$\mathcal{G}_{\text{EM},\theta} : (G, \mathbf{c}_{\text{EM}}) \mapsto \sigma(\theta, \phi, \text{pol}).$$

Arquiteturas condicionadas por consulta poderão ser comparadas com decoders que produzam curvas ou mapas angulares completos.

8.4 Multifidelidade tridimensional

Serão avaliadas correção residual, transferência entre níveis, compartilhamento parcial de representação e outras estratégias justificadas pela estrutura dos dados. A redução de avaliações de referência será medida explicitamente.

8.5 Modelos separados e multitarefa

Após os baselines disciplinares, será testado compartilhamento de representação geométrica entre aerodinâmica e eletromagnetismo. A comparação deverá detectar tanto transferência positiva quanto interferência negativa entre tarefas.

8.6 Interações de longo alcance

O caso 3D permitirá avaliar se message passing local é suficiente ou se mecanismos multiescala, arestas de longo alcance, estados globais ou atenção são necessários. Ganhos serão julgados por precisão e recursos computacionais, não apenas por capacidade arquitetural.

8.7 Variáveis de projeto

O vetor de decisão será definido a partir da parametrização geométrica real. Variáveis contínuas conduzirão a formulações NLP; variáveis inteiras ou categóricas somente justificarão MINLP quando representarem decisões físicas reais.

8.8 Objetivos e restrições

Seja $\mathbf{d}$ o vetor de parâmetros geométricos 3D e seja $\mathcal{D}_{\text{adm}}$ o conjunto de configurações admissíveis. Uma formulação de referência é

$$\min_{\mathbf{d} \in \mathcal{D}_{\text{adm}}} \begin{bmatrix} J_{\text{RCS}}(\mathbf{d}) \\ C_D(\mathbf{d}) \end{bmatrix},$$

sujeita a

$$C_L(\mathbf{d}) \geq C_{L,\min}, \quad V_{\text{int}}(\mathbf{d}) \geq V_{\min}, \quad g_r(\mathbf{d}) \leq 0, \quad r = 1, \dots, n_g.$$

Nessa escrita, J_{RCS} é uma medida explicitamente definida a partir da curva de RCS, V_{int} é o volume interno disponível e g_r reúne outras restrições geométricas, operacionais ou de integração que forem efetivamente adotadas. A RCS poderá ser agregada por setores, máximos, quantis ou outras medidas de risco, preservando a curva original para validação.

A arquitetura MDO será escolhida depois de identificar variáveis de acoplamento e a necessidade, ou não, de consistência interdisciplinar iterativa. A nomenclatura MDF, IDF ou equivalente será empregada no sentido formal da literatura de arquiteturas MDO [6], e não como sinônimo genérico de uso simultâneo de vários surrogates.

8.9 Otimização assistida por surrogate

A GNN realizará a maior parte das consultas do otimizador, enquanto os solvers de referência serão usados na geração de dados, em regiões críticas e na reavaliação de soluções selecionadas.

8.10 Enriquecimento sequencial em regiões relevantes

Depois do DoE inicial, aprendizado ativo poderá selecionar novas avaliações de referência em regiões de maior incerteza, maior discrepância entre fidelidades ou maior relevância para a fronteira de Pareto. O critério de aquisição deverá ser validado contra um plano de expansão não adaptativo para demonstrar que a complexidade adicional reduz efetivamente o número de simulações ou a demanda total de recursos.

A região de Pareto não será o único alvo possível: amostras também podem ser necessárias para corrigir violações de restrições, picos estreitos de RCS ou regiões em que o surrogate apresente extrapolação geométrica. O conjunto de teste final permanecerá isolado desse ciclo.

8.11 Reavaliação e qualidade de Pareto

Soluções nondominadas previstas deverão ser reavaliadas com modelos de referência. Serão analisados erro após reavaliação, dominância, hipervolume e outros indicadores adequados ao conjunto de soluções.

8.12 Recursos e aceleração end-to-end

A aceleração será medida contabilizando geração dos dados, treinamento, otimização e reavaliação:

$$S_{\text{MDO}} = \frac{T_{\text{MDO,ref}}}{T_{\text{data}} + T_{\text{train}} + T_{\text{opt}} + T_{\text{reval}}}.$$

Também serão registrados CPU/GPU horas, memória de pico, armazenamento, número de avaliações dos modelos de referência e throughput de inferência.

8.13 Validação final

As conclusões de engenharia serão baseadas nas respostas reavaliadas pelos modelos de referência e, quando viável, comparadas com evidência experimental. A contribuição do framework será julgada pela combinação de precisão, robustez, recursos e qualidade das decisões aero-stealth.

- [1] M. M. Bronstein, J. Bruna, T. Cohen, e P. Veličković, “Geometric Deep Learning: Grids, Groups, Graphs, Geodesics, and Gauges”, *arXiv preprint arXiv:2104.13478*, 2021, doi: [10.48550/arXiv.2104.13478](https://doi.org/10.48550/arXiv.2104.13478).
- [2] T. Pfaff, M. Fortunato, A. Sanchez-Gonzalez, e P. W. Battaglia, “Learning Mesh-Based Simulation with Graph Networks”, em *International Conference on Learning Representations*, 2021. Disponível em: https://openreview.net/forum?id=roNqYL0_XP
- [3] T. Shan, M. Li, F. Yang, e S. Xu, “Solving Combined Field Integral Equations With Physics-Informed Graph Residual Learning for EM Scattering of 3-D PEC Targets”, *IEEE Transactions on Antennas and Propagation*, v. 72, n. 1, p. 733–744, 2024, doi: [10.1109/TAP.2023.3331262](https://doi.org/10.1109/TAP.2023.3331262).
- [4] C. Li, B. Shu, K. Zhao, L. Yu, Y. Li, e H. Zhao, “Multi-task Diffusion Graph Model for Aero-Electromagnetic Analysis of Blended-Wing-Body Configurations”, *Physics of Fluids*, v. 38, n. 5, p. 057104, 2026, doi: [10.1063/5.0326519](https://doi.org/10.1063/5.0326519).
- [5] N. V. Queipo, R. T. Haftka, W. Shyy, T. Goel, R. Vaidyanathan, e P. K. Tucker, “Surrogate-Based Analysis and Optimization”, *Progress in Aerospace Sciences*, v. 41, n. 1, p. 1–28, 2005, doi: [10.1016/j.paerosci.2005.02.001](https://doi.org/10.1016/j.paerosci.2005.02.001).
- [6] J. R. R. A. Martins e A. B. Lambe, “Multidisciplinary Design Optimization: A Survey of Architectures”, *AIAA Journal*, v. 51, n. 9, p. 2049–2075, 2013, doi: [10.2514/1.J051895](https://doi.org/10.2514/1.J051895).
- [7] B. Peherstorfer, K. Willcox, e M. Gunzburger, “Survey of Multifidelity Methods in Uncertainty Propagation, Inference, and Optimization”, *SIAM Review*, v. 60, n. 3, p. 550–591, 2018, doi: [10.1137/16M1082469](https://doi.org/10.1137/16M1082469).
- [8] Department of the Air Force, “Air Force Instruction 16-401: Designating and Naming Defense Military Aerospace Vehicles”. Department of the Air Force, 2020.
- [9] E. Sepulveda e H. Smith, “Technology Challenges of Stealth Unmanned Combat Aerial Vehicles”, *The Aeronautical Journal*, v. 121, n. 1243, p. 1261–1295, 2017, doi: [10.1017/aer.2017.53](https://doi.org/10.1017/aer.2017.53).

- [10] C. M. Liersch, R. M. Cummings, A. Schütte, J. Vormweg, R. G. Maye, e T. L. Jeans, “Multi-Disciplinary Design and Performance Assessment of Effective, Agile NATO Air Vehicles”, *Aerospace Science and Technology*, v. 99, p. 105764, 2020, doi: [10.1016/j.ast.2020.105764](https://doi.org/10.1016/j.ast.2020.105764).
- [11] H. Aleisa, K. Kontis, B. Pirlepel, e M. Nikbay, “Conceptual Design of a Nonconstant Swept Flying Wing Unmanned Combat Aerial Vehicle”, *Journal of Aircraft*, v. 60, n. 6, p. 1872–1888, 2023, doi: [10.2514/1.C037257](https://doi.org/10.2514/1.C037257).
- [12] M. Nikbay, S. Yildiz, B. Pirlepel, e K. Kontis, “Multidisciplinary Design Optimization of a Non-Planar Flying Wing UCAV Concept”, *Aerospace Science and Technology*, v. 177, p. 112285, 2026, doi: [10.1016/j.ast.2026.112285](https://doi.org/10.1016/j.ast.2026.112285).
- [13] J.-X. Leng, Z.-G. Wang, W. Huang, Y. Shen, e K. An, “Multidisciplinary Design Optimization Processes for Efficiency Improvement of Aircraft: State-of-the-Art Review”, *International Journal of Aeronautical and Space Sciences*, v. 26, n. 4, p. 2020–2042, 2025, doi: [10.1007/s42405-024-00811-8](https://doi.org/10.1007/s42405-024-00811-8).
- [14] T. Hu e X. Yu, “Aerodynamic/Stealthy/Structural Multidisciplinary Design Optimization of Unmanned Combat Air Vehicle”, *Chinese Journal of Aeronautics*, v. 22, n. 4, p. 380–386, 2009, doi: [10.1016/S1000-9361\(08\)60114-4](https://doi.org/10.1016/S1000-9361(08)60114-4).
- [15] N.-V. Nguyen *et al.*, “Multidisciplinary Unmanned Combat Air Vehicle System Design Using Multi-Fidelity Model”, *Aerospace Science and Technology*, v. 26, n. 1, p. 200–210, 2013, doi: [10.1016/j.ast.2012.04.004](https://doi.org/10.1016/j.ast.2012.04.004).
- [16] E. Sepulveda, H. Smith, e D. Sziroczak, “Multidisciplinary Analysis of Subsonic Stealth Unmanned Combat Aerial Vehicles”, *CEAS Aeronautical Journal*, v. 10, p. 431–442, 2019, doi: [10.1007/s13272-018-0325-0](https://doi.org/10.1007/s13272-018-0325-0).
- [17] A. Papageorgiou, M. Tarkian, K. Amadori, e J. Ölvander, “Multidisciplinary Optimization of Unmanned Aircraft Considering Radar Signature, Sensors, and Trajectory Constraints”, *Journal of Aircraft*, v. 55, n. 3, 2018, doi: [10.2514/1.C034314](https://doi.org/10.2514/1.C034314).
- [18] J. P. R. Silva, “Implementação Teórica e Prática para Caracterização de Seção Reta Radar em Laboratório”, Bachelor's thesis, Universidade de Brasília, Brasília, DF, 2026.
- [19] R. Shi, T. Long, N. Ye, Y. Wu, Z. Wei, e Z. Liu, “Metamodel-Based Multidisciplinary Design Optimization Methods for Aerospace System”, *Astrodynamics*, v. 5, p. 185–215, 2021, doi: [10.1007/s42064-021-0109-x](https://doi.org/10.1007/s42064-021-0109-x).
- [20] N. Black e A. R. Najafi, “Learning Finite Element Convergence with the Multi-Fidelity Graph Neural Network”, *Computer Methods in Applied Mechanics and Engineering*, v. 397, p. 115120, 2022, doi: [10.1016/j.cma.2022.115120](https://doi.org/10.1016/j.cma.2022.115120).
- [21] M. Taghizadeh, M. A. Nabian, e N. Alemazkoo, “Multifidelity Graph Neural Networks for Efficient and Accurate Mesh-Based Partial Differential Equations Surrogate Modeling”, *Computer-Aided Civil and Infrastructure Engineering*, v. 40, n. 7, p. 841–858, 2025, doi: [10.1111/mice.13312](https://doi.org/10.1111/mice.13312).
- [22] E. F. Knott, J. F. Shaeffer, e M. T. Tuley, *Radar Cross Section*, 2^o ed. Artech House, 1993.

- [23] J. Chen, E. Hachem, e J. Viquerat, “Graph Neural Networks for Laminar Flow Prediction Around Random Two-Dimensional Shapes”, *Physics of Fluids*, v. 33, n. 12, p. 123607, 2021, doi: [10.1063/5.0064108](https://doi.org/10.1063/5.0064108).
- [24] J.-Z. Peng, Y. Hua, N. Aubry, Z.-H. Chen, M. Mei, e W.-T. Wu, “Data and Physics-Driven Modeling for Fluid Flow with a Physics-Informed Graph Convolutional Neural Network”, *Ocean Engineering*, v. 301, p. 117551, 2024, doi: [10.1016/j.oceaneng.2024.117551](https://doi.org/10.1016/j.oceaneng.2024.117551).
- [25] Z. Li *et al.*, “Geometry-Informed Neural Operator for Large-Scale 3D PDEs”, em *Advances in Neural Information Processing Systems*, 2023, p. 35836–35854. doi: [10.52202/075280-1556](https://doi.org/10.52202/075280-1556).
- [26] M. Li, J. Bai, L. Li, X. Meng, Q. Liu, e B. Chen, “A Gradient-Based Aero-Stealth Optimization Design Method for Flying Wing Aircraft”, *Aerospace Science and Technology*, v. 92, p. 156–169, 2019, doi: [10.1016/j.ast.2019.05.067](https://doi.org/10.1016/j.ast.2019.05.067).
- [27] C. Thoulon, G. Roge, e O. Pironneau, “Gradient-Based Aero-Stealth Optimization of a Simplified Aircraft”, *Fluids*, v. 9, n. 8, p. 174, 2024, doi: [10.3390/fluids9080174](https://doi.org/10.3390/fluids9080174).
- [28] J. Lee e S. Leyffer, Org., *Mixed Integer Nonlinear Programming*, v. 154. New York: Springer, 2012. doi: [10.1007/978-1-4614-1927-3](https://doi.org/10.1007/978-1-4614-1927-3).
- [29] P. Belotti, C. Kirches, S. Leyffer, J. Linderoth, J. Luedtke, e A. Mahajan, “Mixed-Integer Nonlinear Optimization”, *Acta Numerica*, v. 22, p. 1–131, 2013, doi: [10.1017/S0962492913000032](https://doi.org/10.1017/S0962492913000032).
- [30] S. Roy, K. Moore, J. T. Hwang, J. S. Gray, W. A. Crossley, e J. R. R. A. Martins, “A Mixed Integer Efficient Global Optimization Algorithm for the Simultaneous Aircraft Allocation-Mission-Design Problem”, em *58th AIAA/ASCE/AHS/ASC Structures, Structural Dynamics, and Materials Conference*, 2017. doi: [10.2514/6.2017-1305](https://doi.org/10.2514/6.2017-1305).
- [31] D.-H. Kong, J.-N. Cao, W.-W. Zhang, W.-C. Huang, X. He, *et al.*, “An AI Predictor: From Point Clouds to Scattered Far Fields for 3-D PEC Targets”, *IEEE Transactions on Antennas and Propagation*, v. 72, n. 6, p. 5179–5190, 2024, doi: [10.1109/TAP.2024.3390615](https://doi.org/10.1109/TAP.2024.3390615).
- [32] J. Dressel, K. Y. Bliokh, e F. Nori, “Spacetime Algebra as a Powerful Tool for Electromagnetism”, *Physics Reports*, v. 589, p. 1–71, 2015, doi: [10.1016/j.physrep.2015.06.001](https://doi.org/10.1016/j.physrep.2015.06.001).
- [33] D. Hestenes e G. Sobczyk, *Clifford Algebra to Geometric Calculus: A Unified Language for Mathematics and Physics*. Dordrecht, The Netherlands: D. Reidel Publishing Company, 1984. doi: [10.1007/978-94-009-6292-7](https://doi.org/10.1007/978-94-009-6292-7).
- [34] C. Doran e A. Lasenby, *Geometric Algebra for Physicists*. Cambridge University Press, 2003. doi: [10.1017/CBO9780511807497](https://doi.org/10.1017/CBO9780511807497).
- [35] W. E. Baylis, Org., *Clifford (Geometric) Algebras with Applications to Physics, Mathematics, and Engineering*. Birkhäuser, 1996. doi: [10.1007/978-1-4612-4104-1](https://doi.org/10.1007/978-1-4612-4104-1).
- [36] P. Grinfeld, *Introduction to Tensor Analysis and the Calculus of Moving Surfaces*. Springer, 2013. doi: [10.1007/978-1-4614-7867-6](https://doi.org/10.1007/978-1-4614-7867-6).
- [37] D. Sen, “Field Theoretic Formulation of Fluid Mechanics According to the Geometric Algebra”, *Pramana – Journal of Physics*, v. 97, p. 132, 2023, doi: [10.1007/s12043-023-02617-x](https://doi.org/10.1007/s12043-023-02617-x).

- [38] S. Pollock e S. Mann, “Vortex Detection in Vector Fields Using Geometric Algebra”, *Advances in Applied Clifford Algebras*, v. 24, p. 423–442, 2014, doi: [10.1007/s00006-013-0434-0](https://doi.org/10.1007/s00006-013-0434-0).
- [39] J. G. Van Bladel, *Electromagnetic Fields*, 2^o ed. Wiley-IEEE Press, 2007.
- [40] R. Parameswaran, S. M. Panakkal, e M. J. Vedan, “Fluid Maxwell’s Equations in the Language of Geometric Algebra”, *Pramana – Journal of Physics*, v. 98, p. 62, 2024, doi: [10.1007/s12043-024-02731-4](https://doi.org/10.1007/s12043-024-02731-4).
- [41] J. Zhong e W. Cao, “Graph Geometric Algebra Networks for Graph Representation Learning”, *Scientific Reports*, v. 15, p. 170, 2025, doi: [10.1038/s41598-024-84483-0](https://doi.org/10.1038/s41598-024-84483-0).
- [42] K. S. Yee, “Numerical Solution of Initial Boundary Value Problems Involving Maxwell’s Equations in Isotropic Media”, *IEEE Transactions on Antennas and Propagation*, v. 14, n. 3, p. 302–307, 1966, doi: [10.1109/TAP.1966.1138693](https://doi.org/10.1109/TAP.1966.1138693).
- [43] S. M. Rao, D. R. Wilton, e A. W. Glisson, “Electromagnetic Scattering by Surfaces of Arbitrary Shape”, *IEEE Transactions on Antennas and Propagation*, v. 30, n. 3, p. 409–418, 1982, doi: [10.1109/TAP.1982.1142818](https://doi.org/10.1109/TAP.1982.1142818).
- [44] B. M. Kulfan, “Universal Parametric Geometry Representation Method”, *Journal of Aircraft*, v. 45, n. 1, p. 142–158, 2008, doi: [10.2514/1.29958](https://doi.org/10.2514/1.29958).
- [45] M. D. McKay, R. J. Beckman, e W. J. Conover, “A Comparison of Three Methods for Selecting Values of Input Variables in the Analysis of Output from a Computer Code”, *Technometrics*, v. 21, n. 2, p. 239–245, 1979, doi: [10.1080/00401706.1979.10489755](https://doi.org/10.1080/00401706.1979.10489755).