

Graph Neural Networks e Álgebra Geométrica para Otimização Aero-Stealth de UCAVs

**Modelagem multifidelidade de Maxwell e Euler e aceleração da otimização
multidisciplinar**

Índice

UCAV Aero-Stealth Optimization with Multifidelity Graph Neural Networks	6
Sobre este projeto	6
Objetivo geral	6
Arquitetura da pesquisa	7
Questões metodológicas centrais	7
Organização do eBook	7
1 Contexto e Definição do Problema Aero-Stealth de um UCAV	9
1.1 UCAV: conceito, escopo e terminologia	9
1.2 UCAV como problema de engenharia multidisciplinar	10
1.3 Continuidade em relação à caracterização de RCS	11
1.4 Fidelidade e modelagem multifidelidade	11
1.5 Radar Cross Section como resposta de projeto	12
1.6 Desempenho aerodinâmico no regime subsônico	13
1.7 Estado da arte em otimização aero-stealth de UCAVs	13
1.8 GNNs para análise aerodinâmica e eletromagnética	14
1.9 Lacuna de pesquisa	15
1.10 Justificativa	15
1.11 Formulação inicial do problema multidisciplinar	16
1.12 Papel das GNNs e da multifidelidade na otimização	17
1.13 Quantificação de incerteza e aprendizado ativo como estratégias auxiliares	18
1.14 Questão de pesquisa	18
1.15 Objetivo geral	18
1.16 Objetivos específicos	19
1.17 Hipóteses de pesquisa	19
1.18 Métricas de avaliação	20
1.19 Estudos de ablação	21
1.20 Delimitação do estudo	21
2 Álgebra Geométrica para representação física, geométrica e computacional	22
2.1 Partindo de objetos familiares: vetores, comprimento, ângulo e orientação	23
2.2 Do espaço vetorial métrico à álgebra de Clifford	23
2.2.1 O espaço vetorial e a métrica	23
2.2.2 A relação fundamental de Clifford	25

2.3	Produto geométrico, produto interno e produto exterior	25
2.3.1	O produto geométrico de dois vetores	25
2.3.2	Casos geométricos importantes	27
2.3.3	O produto exterior como área orientada	27
2.3.4	Associatividade e não comutatividade	28
2.3.5	Produto de um vetor por um elemento de grau definido	28
2.4	Grades, blades e multivetores	29
2.4.1	O que significa grau	29
2.4.2	Blades: objetos simples de grau definido	29
2.4.3	Multivetores: diferentes graus no mesmo elemento	30
2.4.4	Por que aparecem 2^n componentes	30
2.5	Bases, métrica e independência de coordenadas	31
2.5.1	Objeto geométrico e componentes	31
2.5.2	O conceito de base recíproca	32
2.6	Pseudoescalar e dualidade	34
2.6.1	O elemento de grau máximo	34
2.6.2	Dualidade como correspondência entre dimensões complementares	35
2.7	Involuções, reversão, conjugação e inversa	35
2.7.1	Por que são necessárias operações involutivas	35
2.7.2	Involução de grau	36
2.7.3	Reversão	36
2.7.4	Conjugação de Clifford	37
2.7.5	Inversa de vetores e versores	37
2.8	Projeção, rejeição, reflexão e rotação	38
2.8.1	Decompondo um vetor em partes paralela e perpendicular	38
2.8.2	Reflexão	39
2.8.3	De duas reflexões a uma rotação	39
2.9	Aplicações lineares, tensores, dyadics e matrizes	40
2.9.1	Aplicação linear e sua matriz	40
2.9.2	Dyadics como operadores lineares	41
2.9.3	Tensor não é sinônimo de multivetor	41
2.10	Outermorphisms e extensão de transformações	42
2.10.1	Por que uma transformação de vetores precisa ser estendida	42
2.10.2	Exemplo: transformação de área	43
2.11	Derivada geométrica e cálculo de campos	43
2.11.1	Da derivada direcional ao operador vetorial	43
2.11.2	Divergência: expansão ou compressão local	44
2.11.3	Derivada exterior: circulação local orientada	44
2.12	Representação geométrica de malhas	45
2.12.1	De vértices a arestas	45
2.12.2	A face como bivector de área	46
2.12.3	Da face orientada à normal	46
2.12.4	Relações entre faces vizinhas	47

2.12.5	Estados multivetoriais em nós ou faces	47
2.13	Ponte para o eletromagnetismo	48
2.13.1	Campo eletromagnético como bivector de espaço-tempo	48
2.14	Ponte para a dinâmica dos fluidos	48
2.14.1	Vorticidade como bivector	48
2.14.2	O termo convectivo continua não linear	49
2.15	Ponte para Graph Neural Networks	49
2.15.1	Por que a geometria interessa ao aprendizado em grafos	49
2.15.2	Uma mensagem geometricamente estruturada	50
2.15.3	Estudos de ablação	50
2.16	Crítérios computacionais	50
2.17	Síntese	51
3	Electromagnetic and Aerodynamic Governing Equations	52
3.1	Electromagnetics	52
3.1.1	Maxwell equations	52
3.1.2	Differential-form representation	52
3.1.3	Geometric Algebra formulation	52
3.1.4	Electromagnetic scattering and RCS	52
3.2	Aerodynamics	53
3.2.1	Perfect gas and inviscid subsonic flow	53
3.2.2	Euler equations	53
3.2.3	Geometric Algebra formulation	53
3.2.4	Aerodynamic outputs	53
3.3	Uso na regularização das GNNs	53
4	Graph Neural Networks for Physics-Based Surrogate Modeling	54
4.1	Why graphs?	54
4.2	Meshes as graphs	54
4.3	Message passing	54
4.4	Node, edge and face features	54
4.5	Geometric representations	55
4.6	Equivariance and invariance	55
4.7	Physics-informed GNNs	55
4.8	Electromagnetic surrogate	55
4.9	Aerodynamic surrogate	55
4.10	Uncertainty quantification	55
4.11	Estudos de ablação	56
5	Multifidelity Learning and Adaptive Data Generation	57
5.1	Computational cost hierarchy	57
5.2	Low- and high-fidelity models	57
5.3	Electromagnetic fidelity hierarchy	57

5.4	Aerodynamic fidelity hierarchy	57
5.5	Multi-Fidelity GNNs	58
5.6	Residual correction and transfer learning	58
5.7	Active learning	58
5.8	Uncertainty-driven sampling	58
6	GNN-Accelerated Multidisciplinary Aero-Stealth Optimization	59
6.1	Design variables	59
6.2	Objectives	59
6.3	Constraints	59
6.4	NLP and MINLP	59
6.5	Multiobjective optimization	59
6.6	Surrogate-assisted optimization	60
6.7	High-fidelity revalidation	60
6.8	Computational speed-up	60
6.9	Pareto quality	60

UCAV Aero-Stealth Optimization with Multifidelity Graph Neural Networks

Sobre este projeto

Este eBook documenta o desenvolvimento de um framework de otimização multidisciplinar aero-stealth para **configurações UCAV de baixa observabilidade**. A expressão UCAV (*Unmanned Combat Aerial Vehicle*) designa uma classe funcional de aeronave não tripulada de combate e não uma configuração aerodinâmica específica. Configurações sem cauda, *flying-wing*, *blended-wing-body* e outras famílias geométricas podem ser consideradas conforme o espaço de projeto for formalizado.

A contribuição computacional central é o emprego de **Graph Neural Networks (GNNs) multifidelidade** como modelos substitutos para reduzir a demanda de recursos computacionais e o tempo de processamento das avaliações eletromagnéticas e aerodinâmicas repetidas durante a otimização.

A **Álgebra Geométrica (AG)** é adotada como formalismo matemático estruturante para representar geometria, operações físicas e relações empregadas no aprendizado e na otimização. O projeto buscará formulações multivetoriais mais compactas e, quando matematicamente admissível, representações lineares nos objetos algébricos escolhidos, preservando explicitamente as não linearidades físicas intrínsecas.

Objetivo geral

Desenvolver e validar um framework de otimização multidisciplinar aero-stealth para configurações UCAV, baseado em Álgebra Geométrica e modelos substitutos por Graph Neural Networks multifidelidade, de forma a reduzir a demanda de recursos computacionais das avaliações eletromagnéticas e aerodinâmicas e viabilizar sua integração com métodos determinísticos de otimização matemática.

Arquitetura da pesquisa

A arquitetura metodológica de referência é:

CAD/OpenVSP → malha/grafos → modelos em diferentes fidelidades → GNN multifidelidade → otimização m

A motivação para grafos decorre da estrutura natural de malhas triangulares e não estruturadas, amplamente explorada em *geometric deep learning* e simulação baseada em malhas (Bronstein et al. 2021; Pfaff et al. 2021). Trabalhos recentes já demonstram GNNs para modelagem eletromagnética tridimensional (Shan et al. 2024) e análise aero-eletromagnética multitarefa em malhas de configurações *blended-wing-body* (Li et al. 2026). O presente framework integra essa capacidade de modelagem a uma arquitetura multifidelidade e a métodos determinísticos de otimização multidisciplinar.

Questões metodológicas centrais

O projeto investiga, entre outras questões:

1. quanto as GNNs reduzem o tempo de processamento e o número de avaliações dos modelos eletromagnéticos e aerodinâmicos de referência;
2. como combinar modelos de diferentes fidelidades para ampliar o espaço de projeto avaliado com a mesma infraestrutura computacional;
3. como incorporar relações físicas de Maxwell e Euler, formuladas em Álgebra Geométrica, à representação e ao treinamento das GNNs;
4. como integrar os modelos substitutos a formulações determinísticas de otimização multi-objetivo, incluindo NLP e, quando houver variáveis discretas, MINLP;
5. quanto o processo completo reduz a demanda de CPU/GPU, memória e tempo de processamento após contabilizar geração de dados, treinamento, otimização e reavaliação;
6. em que medida a fronteira de Pareto prevista preserva sua qualidade após reavaliação pelos modelos físicos de referência.

Quantificação de incerteza e aprendizado ativo poderão ser avaliados como estratégias auxiliares de seleção de novas simulações, caso acrescentem informação relevante ao processo multifidelidade.

Organização do eBook

Os capítulos são organizados em torno de:

- contexto UCAV e definição do problema aero-stealth;
- fundamentos e aplicação da Álgebra Geométrica;
- equações físicas de Maxwell/RCS e Euler/aerodinâmica;
- GNNs para *surrogate modeling*;
- modelagem multifidelidade e estratégias de geração de dados;
- otimização matemática multidisciplinar acelerada e validação.

1 Contexto e Definição do Problema Aero-Stealth de um UCAV

Este capítulo apresenta o contexto de engenharia, a justificativa, a lacuna de pesquisa, os objetivos e a formulação inicial do problema de otimização aero-stealth de um **Unmanned Combat Aerial Vehicle (UCAV)**. A contribuição computacional central consiste no uso de **Graph Neural Networks (GNNs)** multifidelidade como modelos substitutos para reduzir a demanda de recursos computacionais e o tempo de processamento associados às avaliações eletromagnéticas e aerodinâmicas repetidas durante a otimização multidisciplinar.

A **Álgebra Geométrica (AG)** é adotada como formalismo matemático estruturante do trabalho. Ela será empregada na representação da geometria, na reformulação das relações físicas e na construção dos modelos de aprendizado e otimização. O objetivo é obter descrições algébricas mais compactas, reduzir a dependência de representações exclusivamente matriciais e explorar formulações lineares nos objetos multivetoriais sempre que a estrutura matemática do problema permitir. Não linearidades físicas intrínsecas, como os termos convectivos das equações de Euler, permanecem explicitamente representadas.

1.1 UCAV: conceito, escopo e terminologia

A expressão **Unmanned Aerial Vehicle (UAV)** designa, de forma ampla, um veículo aéreo não tripulado. A classe **Unmanned Combat Aerial Vehicle (UCAV)** particulariza esse conceito para plataformas destinadas a missões de combate. A classificação está associada à função, à missão e à integração do sistema, e não a uma configuração aerodinâmica específica (Department of the Air Force 2020; Sepulveda e Smith 2017).

Consequentemente, UCAV e *flying wing* não são termos equivalentes. Configurações sem cauda (*tailless*), *flying-wing*, *lambda-wing*, *blended-wing-body* e outras arquiteturas aparecem na literatura de baixa observabilidade porque determinadas escolhas geométricas podem favorecer integração volumétrica, desempenho aerodinâmico e controle de assinatura radar. Essas configurações representam famílias de projeto possíveis dentro da classe UCAV.

A literatura ilustra essa diversidade. O programa NATO Science and Technology Organization (NATO STO) AVT-251 desenvolveu e avaliou a configuração MULDISCON, derivada do SACCON, como um conceito UCAV multidisciplinar com ênfase em aerodinâmica, controlabilidade e baixa assinatura (Liersch et al. 2020). Aleisa et al. estudaram especificamente um UCAV

de configuração *flying-wing* com enfilechamento não constante (Aleisa et al. 2023). Nikbay et al. investigaram uma configuração UCAV não planar derivada de um conceito planar de asa integrada (Nikbay et al. 2026).

O objeto desta pesquisa é, portanto, uma **família geometricamente parametrizada de configurações UCAV de baixa observabilidade**. A arquitetura aerodinâmica específica será definida pelo espaço de projeto e pelas restrições de engenharia adotadas, preservando a distinção entre a classe funcional do veículo e sua configuração geométrica.

1.2 UCAV como problema de engenharia multidisciplinar

O projeto de um UCAV integra requisitos aerodinâmicos, eletromagnéticos, estruturais, propulsores, de estabilidade e controle, além de requisitos próprios de sistemas não tripulados, como autonomia, sensores, comunicação e gerenciamento de missão (Sepulveda e Smith 2017). Essas disciplinas interagem por meio de variáveis de projeto comuns e podem produzir objetivos conflitantes.

A **Otimização Multidisciplinar de Projeto (Multidisciplinary Design Optimization, MDO)** fornece o arcabouço para formular essas interações como um problema integrado de otimização numérica (Martins e Lambe 2013). Revisões recentes continuam a destacar a MDO como elemento central do projeto de aeronaves avançadas, especialmente quando modelos disciplinares de diferentes níveis de detalhe precisam ser combinados sob restrições de desempenho e de recursos computacionais (Leng et al. 2025).

No recorte desta pesquisa, o acoplamento principal envolve **desempenho aerodinâmico, assinatura radar e geometria**. Hu e Yu formularam um problema MDO aerodinâmico-stealth-estrutural para um UCAV (Hu e Yu 2009). Nguyen et al. integraram modelos de diferentes fidelidades ao projeto multidisciplinar de UCAVs (Nguyen et al. 2013). Sepulveda, Smith e Sziroczak desenvolveram uma análise multidisciplinar de UCAVs subsônicos de baixa observabilidade (Sepulveda et al. 2019), enquanto Papageorgiou et al. incorporaram assinatura radar, sensores, aerodinâmica e trajetória em um problema integrado de projeto de aeronave não tripulada (Papageorgiou et al. 2018).

Esses antecedentes mostram que alterações na forma externa do veículo afetam simultaneamente sustentação, arrasto, estabilidade, distribuição de pressão e mecanismos de espalhamento eletromagnético. O problema de engenharia consiste, portanto, em identificar geometrias que produzam compromissos tecnicamente adequados entre respostas aerodinâmicas e eletromagnéticas sob um conjunto explícito de restrições de projeto.

1.3 Continuidade em relação à caracterização de RCS

A pesquisa parte de uma base experimental e computacional previamente desenvolvida para caracterização de **Radar Cross Section (RCS)**, ou seção reta radar. No Trabalho de Conclusão de Curso de **João Pedro Rocha Silva (2026)**, foram avaliados alvos canônicos e alvos aeroespaciais complexos por meio de diferentes técnicas de **Eletromagnetismo Computacional (Computational Electromagnetics, CEM)** e de medição experimental (Silva 2026).

Entre os métodos empregados encontram-se a **Óptica Física (Physical Optics, PO)**, a **Large Element Physical Optics (LE-PO)**, a **Ray Launching Geometrical Optics (RL-GO)** e a técnica **Shooting and Bouncing Rays Plus (SBR+)**, implementadas em ferramentas como Altair Feko e Ansys **High Frequency Structure Simulator (HFSS)**. O trabalho também implementou, para geometrias canônicas, o **Método das Diferenças Finitas no Domínio do Tempo (Finite-Difference Time-Domain, FDTD)**, o **Método dos Momentos (Method of Moments, MoM)** e o **Método dos Elementos Finitos (Finite Element Method, FEM)** (Silva 2026).

A contribuição dessa base para a presente pesquisa está na experiência acumulada com modelagem eletromagnética, comparação entre métodos e validação experimental. A nova etapa desloca a ênfase da caracterização de geometrias previamente definidas para a exploração de **famílias paramétricas de configurações UCAV** dentro de um processo de otimização.

Os resultados de Rocha Silva também evidenciam diferenças relevantes entre modelos eletromagnéticos. Em geometrias canônicas, métodos distintos reproduzem com diferentes níveis de precisão mecanismos como reflexão especular, múltiplas reflexões e difração (Silva 2026). Essa observação conduz diretamente ao conceito de fidelidade utilizado no framework.

1.4 Fidelidade e modelagem multifidelidade

Neste trabalho, **fidelidade** representa o grau de detalhamento físico e numérico com que um modelo aproxima o fenômeno e a resposta de referência relevantes ao problema. A fidelidade depende de vários elementos: equações governantes, hipóteses físicas, discretização espacial, resolução da malha, tratamento de condições de contorno, modelos constitutivos e método numérico. Portanto, a classificação de um modelo como de menor ou maior fidelidade é sempre relativa ao regime físico e à resposta de interesse.

Modelos de maior fidelidade tendem a representar mais fenômenos ou a empregar discretizações mais detalhadas, o que geralmente aumenta a demanda de **tempo de CPU/GPU, memória e armazenamento**. Modelos de menor fidelidade utilizam aproximações físicas, discretizações mais simples ou resoluções reduzidas e, por isso, permitem avaliar um número maior de configurações com a mesma infraestrutura computacional.

A **modelagem multifidelidade** combina sistematicamente informações provenientes de dois ou mais níveis de fidelidade. O objetivo é aproveitar a ampla cobertura do espaço de projeto proporcionada por modelos de menor demanda de recursos e utilizar um conjunto menor de avaliações de maior fidelidade para corrigir, calibrar ou enriquecer a aproximação (Nguyen et al. 2013; Shi et al. 2021; Black e Najafi 2022; Taghizadeh et al. 2025). A relação entre níveis pode ser aprendida, por exemplo, por uma correção de discrepância

$$y_{HF} = y_{LF} + \Delta_{\theta}(G, y_{LF}, c),$$

em que y_{LF} e y_{HF} representam respostas de menor e maior fidelidade, G representa a geometria codificada como grafo, c reúne as condições operacionais e Δ_{θ} é um modelo treinável de correção.

No domínio eletromagnético, uma hierarquia poderá combinar métodos assintóticos de alta frequência e métodos com representação mais detalhada dos mecanismos de espalhamento, sempre mediante validação para o regime de interesse. No domínio aerodinâmico, modelos de painel, equações de Euler e formulações viscosas baseadas nas equações de Navier–Stokes com médias de Reynolds podem ocupar diferentes níveis dessa hierarquia. A classificação final será definida pelas respostas que cada modelo reproduz e pelos recursos necessários para sua execução.

1.5 Radar Cross Section como resposta de projeto

A RCS quantifica a intensidade com que um alvo espalha energia eletromagnética na direção do receptor e pode ser interpretada como uma área efetiva de espalhamento sob condições especificadas (Knott et al. 1993). Na equação de alcance radar monoestática idealizada, a distância máxima de detecção varia com a quarta raiz de σ , o que estabelece uma conexão direta entre assinatura radar e detectabilidade (Knott et al. 1993; Silva 2026).

A RCS depende da frequência, da direção de incidência e observação, da polarização, das propriedades materiais e dos mecanismos de espalhamento. Em alvos eletricamente grandes, a geometria local influencia reflexão especular, difração em bordos e pontas, múltiplas reflexões e ondas de superfície (Knott et al. 1993; Silva 2026). Consequentemente, a resposta eletromagnética relevante para projeto é angular e pode apresentar picos estreitos em determinados setores.

A modelagem proposta preservará essa estrutura por meio de curvas de RCS em função de azimute, elevação, frequência e polarização. Para condições $c_{EM} = (\phi, \theta, f, p)$,

$$\sigma = \sigma(\phi, \theta, f, p; x),$$

em que x representa a geometria parametrizada. A partir da curva podem ser construídos objetivos escalares, como média setorial, valor máximo, quantis ou outras medidas de risco. Essa separação permite avaliar simultaneamente a fidelidade física da curva e sua utilização em otimização matemática.

1.6 Desempenho aerodinâmico no regime subsônico

O domínio aerodinâmico concentra-se inicialmente em escoamento externo subsônico de ar tratado como gás perfeito. A **Dinâmica dos Fluidos Computacional (Computational Fluid Dynamics, CFD)** será utilizada em níveis de fidelidade compatíveis com a fase do estudo. Modelos potenciais ou de painel podem fornecer respostas de menor demanda de recursos; as equações compressíveis e invíscidas de Euler constituem um nível intermediário relevante; e modelos viscosos baseados nas **Reynolds-Averaged Navier–Stokes (RANS)** podem servir como referência de maior fidelidade para condições selecionadas.

As respostas aerodinâmicas de interesse incluem o coeficiente de sustentação C_L , o coeficiente de arrasto C_D , o coeficiente de momento C_m , a razão L/D e, quando necessário, campos de pressão e outras grandezas locais. GNNs já foram aplicadas a malhas não estruturadas e *body-fitted* para aproximar campos de escoamento em geometrias variáveis (Chen et al. 2021; Peng et al. 2024), e operadores neurais informados pela geometria foram empregados em problemas tridimensionais de equações diferenciais parciais (Li et al. 2023). Esses resultados fornecem base metodológica para a representação aerodinâmica por grafos.

1.7 Estado da arte em otimização aero-stealth de UCAVs

A otimização aero-stealth evoluiu de formulações com modelos disciplinares simplificados para ambientes de projeto que integram CFD, CEM, modelos substitutos e técnicas de sensibilidade. Hu e Yu combinaram aerodinâmica, stealth e estruturas em um problema MDO de UCAV (Hu e Yu 2009). Nguyen et al. utilizaram uma arquitetura multifidelidade no projeto de sistemas UCAV (Nguyen et al. 2013). O programa SACCON/MULDICON consolidou uma plataforma de pesquisa multidisciplinar para aeronaves de baixa observabilidade (Liersch et al. 2020).

A otimização matemática determinística ocupa papel relevante nessa evolução. Em MDO, as funções objetivo, restrições e variáveis das diferentes disciplinas podem ser organizadas em arquiteturas monolíticas ou decompostas (Martins e Lambe 2013). Métodos baseados em gradientes reduzem o número de avaliações necessárias quando derivadas confiáveis estão disponíveis. Li et al. empregaram Programação Quadrática Sequencial (*Sequential Quadratic Programming*, SQP) em otimização aero-stealth de uma configuração *flying-wing*, combinando CFD, PO e sensitividades adjuntas (Li et al. 2019). Thoulon et al. utilizaram o algoritmo *Sequential Least Squares Programming* (SLSQP), CFD com RANS e PO para construir uma fronteira de compromisso aero-stealth em uma aeronave simplificada (Thoulon et al. 2024).

A pesquisa também considera formulações com variáveis contínuas e discretas. Problemas com variáveis contínuas e relações não lineares podem ser formulados como **Programação Não Linear (Nonlinear Programming, NLP)**. Quando decisões discretas — por exemplo, escolhas de configuração, número de elementos geométricos ou categorias de materiais — são combinadas com variáveis contínuas e relações não lineares, surge a **Programação Não Linear Inteira Mista (Mixed-Integer Nonlinear Programming, MINLP)** (Lee e Leyffer 2012; Belotti et al. 2013). Em aplicações aeroespaciais, formulações mistas já foram empregadas para integrar decisões de missão, alocação e projeto de aeronaves (Roy et al. 2017).

Esse interesse é particularmente relevante para o presente framework. Os modelos substitutos baseados em GNN podem fornecer avaliações rápidas e diferenciáveis de respostas físicas, enquanto a otimização matemática determinística pode explorar explicitamente gradientes, restrições e estrutura combinatória. A formulação final será contínua ou inteira mista de acordo com a natureza real das variáveis de projeto, preservando compatibilidade com arquiteturas MDO e com métodos determinísticos de otimização local ou global.

Trabalhos recentes mantêm ativo o problema aero-stealth. Aleisa et al. investigaram o projeto conceitual de um UCAV *flying-wing* (Aleisa et al. 2023). Thoulon et al. demonstraram uma metodologia gradiente para compromisso entre arrasto e assinatura radar (Thoulon et al. 2024). Nikbay et al. apresentaram em 2026 uma otimização multidisciplinar de um conceito UCAV não planar, combinando CFD, RCS e modelos de Kriging por **Partial Least Squares (KPLS)** para reduzir o número de avaliações das análises de maior demanda de recursos (Nikbay et al. 2026).

1.8 GNNs para análise aerodinâmica e eletromagnética

A representação de malhas por grafos estabelece uma conexão natural entre geometria discretizada e aprendizado de máquina. MeshGraphNets demonstrou a aplicação de redes de grafos à simulação sobre malhas (Pfaff et al. 2021), enquanto a literatura de *geometric deep learning* fornece o arcabouço para explorar conectividade, simetrias e transformações geométricas (Bronstein et al. 2021).

No eletromagnetismo, Shan et al. empregaram aprendizado residual informado pela física sobre grafos para equações integrais de espalhamento de alvos tridimensionais condutores perfeitos (Shan et al. 2024). Kong et al. desenvolveram um preditor de campo distante espalhado a partir de nuvens de pontos de alvos tridimensionais (Kong et al. 2024). Esses trabalhos mostram que a geometria discretizada pode ser diretamente utilizada para aproximar respostas eletromagnéticas complexas.

O antecedente mais próximo da integração aero-eletromagnética por GNN identificado na literatura recente é o trabalho de Li et al. (Li et al. 2026). Os autores desenvolveram uma GNN de difusão multitarefa definida sobre malhas superficiais não estruturadas de configurações *blended-wing-body*. O modelo prediz simultaneamente o campo de coeficiente de pressão C_p , os

coeficientes globais C_L e C_D e valores médios de RCS monoestático para polarizações horizontal e vertical. O estudo reporta aproximadamente $35\times$ de aceleração de inferência para o conjunto de saídas em relação aos solvers utilizados na geração dos dados (Li et al. 2026).

Esse resultado estabelece um benchmark diretamente relacionado ao presente problema e demonstra a viabilidade de um modelo de grafo compartilhado entre as disciplinas aerodinâmica e eletromagnética. A presente pesquisa amplia essa linha ao incorporar fidelidades distintas, preservar a dependência angular e de polarização da RCS, integrar os modelos substitutos a uma formulação de otimização matemática determinística e utilizar Álgebra Geométrica como formalismo comum de representação da geometria, da física e das operações algébricas.

1.9 Lacuna de pesquisa

A lacuna abordada nesta pesquisa concentra-se na **integração sistemática de modelagem geométrica, física, aprendizado multifidelidade e otimização matemática para configurações UCAV**. A literatura recente apresenta avanços importantes em cada um desses componentes, porém a articulação conjunta permanece limitada.

A contribuição proposta reúne cinco elementos em uma única arquitetura metodológica:

1. representação de geometrias UCAV por malhas e grafos capazes de alimentar simultaneamente modelos aerodinâmicos e eletromagnéticos;
2. aprendizado multifidelidade explícito entre níveis de análise com diferentes graus de detalhamento e diferentes demandas de recursos computacionais;
3. predição da RCS preservando sua dependência angular e de polarização, em vez de restringir a resposta a um valor médio global;
4. integração dos modelos substitutos a uma formulação de otimização matemática determinística, com suporte a NLP e, quando houver decisões discretas, MINLP;
5. adoção da Álgebra Geométrica como linguagem matemática comum para representar geometria, operadores físicos e relações empregadas no aprendizado e na otimização.

Essa integração será avaliada pelo desempenho preditivo dos modelos, pela demanda de recursos computacionais, pelo tempo total de processamento e pela qualidade das soluções obtidas após reavaliação com modelos de referência.

1.10 Justificativa

A justificativa de engenharia decorre do forte acoplamento entre geometria, aerodinâmica e assinatura radar em UCAVs de baixa observabilidade. Uma alteração geométrica capaz de reduzir retornos eletromagnéticos pode modificar distribuição de pressão, arrasto, sustentação e estabilidade. O tratamento integrado dessas respostas reduz a possibilidade de soluções ótimas

em uma disciplina produzirem desempenho inadequado em outra (Sepulveda e Smith 2017; Sepulveda et al. 2019; Liersch et al. 2020).

A justificativa computacional decorre da demanda de recursos associada às avaliações disciplinares repetidas. Modelos CEM e CFD com maior detalhamento podem requerer tempos elevados de CPU/GPU, maior uso de memória e malhas com grande número de graus de liberdade. Uma otimização que exija centenas ou milhares de avaliações multiplica essa demanda. Revisões sobre MDO baseada em metamodelos destacam esse problema como uma das principais motivações para modelos substitutos em sistemas aeroespaciais (Shi et al. 2021), e estudos recentes de eficiência em MDO de aeronaves continuam a tratar a redução de avaliações disciplinares como tema central (Leng et al. 2025).

A justificativa metodológica está na compatibilidade entre a estrutura dos dados e o modelo de aprendizado. Malhas CEM e CFD já contêm relações topológicas entre vértices, arestas, faces e células. GNNs permitem incorporar essas relações diretamente ao modelo. A multifidelidade, por sua vez, permite distribuir o orçamento de simulação entre modelos com diferentes demandas de recursos, preservando avaliações de maior fidelidade para calibração e revalidação.

A Álgebra Geométrica fornece o eixo matemático comum do framework. No eletromagnetismo, a Álgebra do Espaço-Tempo permite reunir as equações de Maxwell em uma formulação multivetorial compacta (Dressel et al. 2015). No domínio aerodinâmico, a AG será empregada para representar vetores, bivectores, orientações, operadores diferenciais e transformações geométricas, buscando formulações mais compactas e linearizações operacionais quando matematicamente admissíveis. Na otimização, a arquitetura priorizará variáveis, operadores e restrições formulados em termos geométricos e multivetoriais, recorrendo a projeções escalares quando exigidas pelos solvers numéricos (Hestenes e Sobczyk 1984; Doran e Lasenby 2003).

A justificativa científica completa-se pela continuidade com a infraestrutura de RCS já estabelecida por Rocha Silva (Silva 2026). A passagem de caracterização de alvos fixos para otimização de famílias geométricas cria uma trajetória integrada entre modelagem física, aprendizado, otimização e revalidação.

1.11 Formulação inicial do problema multidisciplinar

Seja $x \in \mathbb{R}^n$ o vetor de variáveis contínuas de projeto. Caso o espaço de decisão inclua escolhas discretas, seja $z \in \mathbb{Z}^m$ o vetor correspondente. Uma formulação multiobjetivo pode ser escrita como

$$\min_{x,z} \begin{bmatrix} J_{\text{EM}}(x, z) \\ J_{\text{aero}}(x, z) \end{bmatrix}$$

sujeita a

$$g_i(x, z) \leq 0, \quad h_j(x, z) = 0,$$

além de limites geométricos e condições operacionais.

O objetivo eletromagnético será obtido a partir da resposta angular de RCS,

$$J_{\text{EM}}(x, z) = \mathcal{R}[\sigma(\phi, \theta, f, p; x, z)],$$

em que $\mathcal{R}$ representa uma operação de agregação ou risco definida para setores angulares e condições de interesse. No domínio aerodinâmico, formulações possíveis incluem minimização de C_D com restrição de sustentação ou maximização de eficiência aerodinâmica, equivalente a

$$J_{\text{aero}}(x, z) = -\frac{L}{D}.$$

A otimização multiobjetivo poderá ser tratada por escalarização, método ε -constraint ou outras estratégias compatíveis com otimização matemática determinística. Quando todas as variáveis forem contínuas, cada subproblema poderá assumir a forma de um NLP. A presença de decisões discretas combinadas com relações não lineares conduz a uma formulação MINLP (Lee e Leyffer 2012; Belotti et al. 2013).

1.12 Papel das GNNs e da multifidelidade na otimização

O modelo substituto terá como função aproximar respostas disciplinares a partir da geometria e das condições operacionais:

$$\mathcal{G}_\theta : (G, c, y_{LF}) \longrightarrow (\hat{y}_{EM}, \hat{y}_{aero}).$$

O grafo G representa a geometria discretizada, c reúne condições de operação e y_{LF} contém respostas provenientes de modelos de menor fidelidade quando disponíveis. A arquitetura multifidelidade aprenderá a relação entre níveis de modelagem, reduzindo o número de avaliações de maior demanda de recursos necessárias para cobrir o espaço de projeto.

Durante a otimização, a maior parte das avaliações de objetivos e restrições poderá ser realizada pelas GNNs. Modelos físicos de referência permanecerão associados à geração de dados, à verificação de regiões críticas e à reavaliação das soluções selecionadas. A combinação entre inferência rápida, diferenciação automática e otimização matemática determinística é particularmente relevante para problemas com muitas variáveis e restrições.

1.13 Quantificação de incerteza e aprendizado ativo como estratégias auxiliares

A **Quantificação de Incerteza (Uncertainty Quantification, UQ)** corresponde à estimativa da incerteza associada às previsões do modelo. Em modelos substitutos, essa informação pode indicar regiões do espaço de projeto pouco representadas pelos dados e apoiar a decisão sobre quais soluções exigem nova avaliação por modelos de maior fidelidade.

O **aprendizado ativo (active learning)** é uma estratégia sequencial de geração de dados na qual o próprio estado do modelo auxilia a escolha das próximas amostras a serem avaliadas. Sua utilização é justificável quando as avaliações de maior fidelidade demandam recursos suficientes para tornar ineficiente uma amostragem uniforme ou exclusivamente predefinida. Critérios de seleção podem combinar incerteza preditiva, discrepância entre fidelidades ou relevância para a região de Pareto.

UQ e aprendizado ativo são tratados nesta pesquisa como **estratégias auxiliares a serem avaliadas**, e não como componentes obrigatórios da arquitetura. Sua adoção dependerá de evidência de que acrescentam informação útil ao processo multifidelidade em relação a um plano de experimentos previamente definido.

1.14 Questão de pesquisa

Em que medida um framework baseado em Álgebra Geométrica, Graph Neural Networks multifidelidade e otimização matemática determinística pode reduzir a demanda de recursos computacionais e o tempo total de processamento da otimização aero-stealth de configurações UCAV, preservando a precisão das respostas físicas e a qualidade das soluções reavaliadas por modelos de referência?

1.15 Objetivo geral

Desenvolver e validar um framework de otimização multidisciplinar aero-stealth para configurações UCAV, baseado em Álgebra Geométrica e modelos substitutos por Graph Neural Networks multifidelidade, de forma a reduzir a demanda de recursos computacionais das avaliações eletromagnéticas e aerodinâmicas e viabilizar sua integração com métodos determinísticos de otimização matemática.

1.16 Objetivos específicos

1. **Contextualizar e formalizar o problema de engenharia de UCAVs**, distinguindo a classe funcional do veículo das configurações aerodinâmicas empregadas no espaço de projeto.
2. **Definir uma parametrização geométrica reproduzível** para as configurações estudadas e estabelecer o fluxo CAD $\rightarrow$ malha $\rightarrow$ grafo.
3. **Formular em Álgebra Geométrica as representações geométricas e físicas relevantes**, incluindo operações associadas às equações de Maxwell, ao escoamento de Euler e às transformações empregadas no processo de otimização.
4. **Definir os níveis de fidelidade eletromagnéticos e aerodinâmicos** a partir do conteúdo físico, da discretização e da demanda de recursos de cada modelo.
5. **Construir bases de dados multifidelidade** para RCS e aerodinâmica, preservando condições operacionais, metadados de simulação e rastreabilidade entre níveis.
6. **Desenvolver GNNs baseadas em malha** para prever curvas angulares e polarizadas de RCS, coeficientes aerodinâmicos e, quando necessário, campos físicos intermediários.
7. **Desenvolver estratégias de aprendizado multifidelidade** capazes de transferir ou corrigir informação entre modelos de diferentes níveis de fidelidade.
8. **Incorporar conhecimento físico às GNNs** por meio de representações e restrições derivadas das formulações em Álgebra Geométrica de Maxwell e Euler.
9. **Integrar os modelos substitutos a uma formulação de otimização matemática determinística multiobjetivo**, utilizando NLP para variáveis contínuas e MINLP quando o espaço de decisão incorporar variáveis discretas.
10. **Validar o framework de forma end-to-end**, quantificando precisão, demanda de recursos computacionais, tempo de processamento, número de avaliações dos solvers e qualidade da fronteira de Pareto após reavaliação por modelos de referência.

1.17 Hipóteses de pesquisa

As hipóteses centrais são formuladas como relações testáveis entre desempenho preditivo, recursos empregados e qualidade das decisões de otimização.

Representação por grafos. GNNs que recebem a geometria discretizada e sua conectividade deverão apresentar melhor generalização para geometrias não vistas do que modelos baseados exclusivamente em parâmetros globais, sob condições comparáveis de treinamento.

Aprendizado multifidelidade. Para uma quantidade fixa de avaliações de maior fidelidade, a combinação de informações provenientes de diferentes fidelidades deverá produzir menor erro preditivo ou melhor qualidade das soluções de otimização do que o treinamento realizado apenas com o subconjunto de maior fidelidade.

Consistência física. A incorporação de relações físicas formuladas em Álgebra Geométrica às representações, perdas ou saídas auxiliares das GNNs deverá melhorar a consistência física e a eficiência amostral em relação a um modelo puramente supervisionado com a mesma base de dados.

Aceleração da otimização. A utilização das GNNs multifidelidade no ciclo MDO deverá reduzir o tempo total de processamento e o número de avaliações de maior demanda de recursos necessários para obter uma fronteira de Pareto reavaliada, preservando a qualidade das soluções selecionadas.

1.18 Métricas de avaliação

A avaliação deverá combinar métricas de predição, otimização e utilização de recursos. Para RCS, serão considerados erro médio da curva, erro de pico, deslocamento angular de picos e erro por setor. Para aerodinâmica, serão considerados erros em C_L , C_D , C_m , L/D e, quando aplicável, em campos físicos.

A utilização de recursos será caracterizada por **tempo de processamento**, **horas de CPU/GPU**, **pico de memória**, **armazenamento**, **número de avaliações dos modelos de referência** e **tempo de geração dos dados de treinamento**. Quando UQ for empregada, serão acrescentadas métricas de calibração e cobertura.

Duas medidas de aceleração são particularmente relevantes:

$$S_{\text{eval}} = \frac{T_{\text{solver}}}{T_{\text{GNN}}}$$

para uma avaliação individual, e

$$S_{\text{MDO}} = \frac{T_{\text{MDO, referência}}}{T_{\text{dados}} + T_{\text{treinamento}} + T_{\text{otimização}} + T_{\text{reavaliação}}}$$

para o processo completo. A segunda métrica evita atribuir aceleração ao framework sem contabilizar os recursos empregados para geração de dados e treinamento.

A qualidade da otimização será avaliada pela comparação entre a fronteira de Pareto prevista e a fronteira reavaliada, utilizando indicadores apropriados de dominância, hipervolume e erro das soluções selecionadas.

1.19 Estudos de ablação

O protocolo experimental incluirá modelos de referência capazes de separar a contribuição das principais camadas metodológicas:

- baseline baseado em parâmetros globais da geometria;
- GNN com representação geométrica convencional;
- GNN com representação e operações em Álgebra Geométrica;
- GNN com incorporação explícita de relações físicas;
- GNN multifidelidade integrada ao processo de otimização.

A Álgebra Geométrica permanece como formalismo adotado no framework final. A ablação tem a função de quantificar como cada componente modifica precisão, estabilidade, demanda de dados e comportamento da otimização, e não de decidir sua adoção.

1.20 Delimitação do estudo

O trabalho concentra-se na integração entre geometria UCAV, RCS, aerodinâmica subsônica, Álgebra Geométrica, GNNs multifidelidade e otimização matemática. Os solvers físicos de referência serão utilizados para geração de dados e reavaliação, enquanto as reformulações em AG terão profundidade suficiente para sustentar as representações, relações físicas e operações empregadas pelo modelo substituto e pela otimização.

O resultado esperado é um **framework reproduzível de otimização aero-stealth** no qual a aceleração seja demonstrada por medidas de tempo e recursos computacionais, e a validade das decisões seja sustentada por reavaliação eletromagnética e aerodinâmica em níveis de fidelidade adequados.

2 Álgebra Geométrica para representação física, geométrica e computacional

A **Álgebra Geométrica (AG)**, também denominada álgebra de Clifford quando se enfatiza sua construção algébrica, constitui o formalismo matemático estruturante adotado neste trabalho. Seu papel é fornecer uma linguagem comum para representar geometria orientada, transformações, campos físicos e atributos utilizados pelos modelos de aprendizado em grafos, reduzindo a fragmentação entre notações vetoriais, matriciais, tensoriais e de formas diferenciais quando essas descrições admitem uma representação geométrica comum (Hestenes e Sobczyk 1984; Doran e Lasenby 2003; Baylis 1996).

Este capítulo foi organizado para que a AG possa ser acompanhada por um leitor que conhece álgebra linear e cálculo vetorial, mas ainda não teve contato sistemático com multivetores. Por essa razão, cada conceito é introduzido em três níveis: primeiro sua interpretação geométrica, depois sua definição algébrica e, por fim, sua utilidade para o problema aero-stealth. A intenção não é substituir de imediato toda notação conhecida, mas mostrar como objetos familiares — vetores, áreas orientadas, rotações, operadores e derivadas — passam a fazer parte de uma estrutura algébrica única.

A adoção da AG não implica que toda formulação matricial ou tensorial deva ser substituída por um multivetor. Matrizes permanecem representações coordenadas naturais de aplicações lineares; tensores gerais preservam seu papel quando expressam relações multilineares que não são antissimétricas; e solucionadores numéricos podem requerer vetores, matrizes e escalares convencionais em suas interfaces. A contribuição da AG consiste em organizar, de modo geometricamente explícito, os objetos para os quais métrica, orientação, produtos, graus, dualidade e transformações podem ser tratados dentro de uma única álgebra associativa.

Essa distinção é particularmente importante para o problema aero-stealth. A geometria superficial de um **Unmanned Combat Aerial Vehicle (UCAV)**, os campos eletromagnéticos, os campos aerodinâmicos e as mensagens trocadas por uma **Graph Neural Network (GNN)** apresentam estruturas geométricas diferentes. O objetivo deste capítulo é construir, passo a passo, a linguagem que permitirá representar essas estruturas sem confundir o objeto geométrico com suas componentes em uma base particular.

2.1 Partindo de objetos familiares: vetores, comprimento, ângulo e orientação

Um vetor pode ser compreendido geometricamente como uma quantidade que possui magnitude e direção. Em um espaço euclidiano tridimensional, deslocamento, velocidade e força são exemplos familiares. Quando uma base cartesiana ortonormal $\{e_1, e_2, e_3\}$ é escolhida, um vetor a pode ser escrito como

$$a = a^1 e_1 + a^2 e_2 + a^3 e_3.$$

Os números a^1, a^2, a^3 são **componentes** do vetor naquela base. Eles não são o vetor em si. Se a base for girada, as componentes mudam, embora o vetor geométrico representado permaneça o mesmo.

O produto interno fornece duas informações geométricas familiares. Para vetores a e b ,

$$a \cdot b = \|a\| \|b\| \cos \theta,$$

onde θ é o ângulo entre eles. Consequentemente,

$$a \cdot a = \|a\|^2.$$

Se $a \cdot b = 0$, os vetores são ortogonais. Assim, o produto interno mede a parcela de uma direção alinhada com outra e introduz a noção de comprimento e ângulo.

Entretanto, comprimento e alinhamento não esgotam a geometria produzida por dois vetores. Dois vetores não colineares também determinam um **plano orientado**. A Álgebra Geométrica introduz um objeto próprio para representar esse plano: o **bivetor**. A partir dessa observação nasce a ideia central do capítulo: em vez de representar todas as entidades geométricas por listas de números ou por vetores tridimensionais auxiliares, diferentes tipos de objetos geométricos são mantidos explicitamente dentro da mesma álgebra.

2.2 Do espaço vetorial métrico à álgebra de Clifford

2.2.1 O espaço vetorial e a métrica

Considere um espaço vetorial real finito-dimensional V . Para transformar esse espaço em um espaço no qual seja possível falar de comprimentos e ângulos, introduz-se uma forma bilinear simétrica

$$g : V \times V \rightarrow \mathbb{R}.$$

A palavra **bilinear** significa que g é linear em cada argumento separadamente. A palavra **simétrica** significa

$$g(a, b) = g(b, a).$$

Quando se escreve

$$a \cdot b = g(a, b),$$

a forma bilinear passa a ser interpretada como produto interno ou, em assinaturas indefinidas, como produto métrico.

Em uma base geral $\{e_i\}$, define-se

$$g_{ij} = e_i \cdot e_j.$$

Os números g_{ij} formam a matriz métrica ou matriz de Gram. Em uma base cartesiana ortonormal euclidiana,

$$g_{ij} = \delta_{ij},$$

isto é, os termos diagonais são iguais a 1 e os termos fora da diagonal são zero. Em uma base oblíqua, por outro lado, termos fora da diagonal podem ser diferentes de zero porque os vetores da base não são perpendiculares (Grinfeld 2013).

A métrica determina a **assinatura** da álgebra. A notação $Cl(p, q)$ indica, em uma base ortogonal não degenerada, p direções cujo quadrado é $+1$ e q direções cujo quadrado é -1 . Para geometria euclidiana tridimensional utiliza-se $Cl(3, 0)$. Em espaço-tempo, uma assinatura indefinida é utilizada e sua convenção deve ser explicitada antes das manipulações físicas.

2.2.2 A relação fundamental de Clifford

A álgebra de Clifford $Cl(V, g)$ é gerada pelos vetores de V impondo

$$a^2 = g(a, a).$$

Em um espaço euclidiano, essa expressão afirma que o quadrado geométrico de um vetor é o quadrado de seu comprimento. A identidade pode parecer simples, mas ela determina a relação entre produtos de vetores. Aplicando-a a $a + b$,

$$(a + b)^2 = a^2 + ab + ba + b^2.$$

Por outro lado,

$$(a + b)^2 = g(a + b, a + b) = a^2 + 2g(a, b) + b^2.$$

Comparando as duas expressões, obtém-se

$$\boxed{ab + ba = 2g(a, b)}.$$

Portanto,

$$a \cdot b = \frac{1}{2}(ab + ba).$$

Essa relação é o ponto de partida para compreender por que o produto geométrico contém simultaneamente informação métrica e informação de orientação (Hestenes e Sobczyk 1984; Doran e Lasenby 2003).

2.3 Produto geométrico, produto interno e produto exterior

2.3.1 O produto geométrico de dois vetores

Para dois vetores $a, b \in V$, o **produto geométrico** é denotado simplesmente por justaposição, ab . Ele pode ser decomposto em duas partes:

$$\boxed{ab = a \cdot b + a \wedge b}.$$

A primeira parte,

$$a \cdot b = \frac{1}{2}(ab + ba),$$

é simétrica e escalar. A segunda,

$$a \wedge b = \frac{1}{2}(ab - ba),$$

é antissimétrica e bivetorial (Sen 2023).

Essa decomposição pode ser interpretada da seguinte maneira:

- $a \cdot b$ informa **quanto os vetores estão alinhados**;
- $a \wedge b$ informa **qual plano orientado os dois vetores constroem**;
- ab conserva simultaneamente as duas informações.

Considere, em $Cl(2, 0)$, uma base ortonormal $\{e_1, e_2\}$ e os vetores

$$a = e_1, \quad b = e_1 + 2e_2.$$

Como $e_1 \cdot e_1 = 1$ e $e_1 \cdot e_2 = 0$,

$$a \cdot b = 1.$$

Como $e_1 \wedge e_1 = 0$,

$$a \wedge b = 2e_1 \wedge e_2.$$

Logo,

$$ab = 1 + 2e_{12},$$

onde $e_{12} = e_1 e_2 = e_1 \wedge e_2$. O resultado não é apenas um escalar nem apenas um vetor: é um multivetor composto por uma parte escalar e uma parte bivetorial.

2.3.2 Casos geométricos importantes

Se a e b são paralelos, então

$$a \wedge b = 0,$$

e o produto geométrico reduz-se ao produto interno.

Se a e b são ortogonais, então

$$a \cdot b = 0,$$

e

$$ab = a \wedge b.$$

Em uma base ortonormal, portanto,

$$e_i e_j = -e_j e_i, \quad i \neq j.$$

Essa anticomutatividade entre vetores ortogonais é a origem de muitas identidades da AG.

2.3.3 O produto exterior como área orientada

O produto exterior satisfaz

$$a \wedge b = -b \wedge a.$$

Trocar a ordem dos vetores muda a orientação do plano e, por isso, muda o sinal. Em particular,

$$a \wedge a = 0,$$

pois um único vetor repetido não gera área.

No caso euclidiano,

$$\|a \wedge b\| = \|a\| \|b\| \sin \theta.$$

Essa é exatamente a área do paralelogramo definido por a e b . Assim, o bivector $a \wedge b$ reúne três informações em um único objeto: o plano, sua orientação e sua magnitude de área (Pollock e Mann 2014).

Em três dimensões, o produto vetorial tradicional $a \times b$ também codifica essa área, mas o faz por meio de um pseudovetor perpendicular ao plano. Na AG, o plano orientado é representado diretamente pelo bivector; o pseudovetor perpendicular pode ser recuperado posteriormente por dualidade.

2.3.4 Associatividade e não comutatividade

O produto geométrico é distributivo e associativo:

$$a(bc) = (ab)c.$$

Essa propriedade permite formar produtos de três, quatro ou mais vetores sem introduzir um novo tipo de operação a cada etapa.

Em geral,

$$ab \neq ba.$$

A não comutatividade não é uma inconveniência algébrica; ela carrega informação geométrica. A diferença entre ab e ba contém precisamente a orientação expressa pelo produto exterior.

2.3.5 Produto de um vetor por um elemento de grau definido

A decomposição $ab = a \cdot b + a \wedge b$ não se limita a dois vetores. Se A_r é homogêneo de grau r , o produto aA_r possui, em geral, uma parcela de grau $r - 1$ e outra de grau $r + 1$:

$$aA_r = a \cdot A_r + a \wedge A_r.$$

Com a convenção de contração utilizada neste texto,

$$a \cdot A_r = \frac{1}{2} (aA_r - (-1)^r A_r a),$$

$$a \wedge A_r = \frac{1}{2} (aA_r + (-1)^r A_r a).$$

Para $r = 1$, essas fórmulas recuperam exatamente o produto interno e o produto exterior de dois vetores. Para $r = 2$, o produto de um vetor com um bivector pode produzir uma parte vetorial e uma parte trivectorial. Essa regra de “baixar ou subir o grau” será útil mais adiante para derivadas geométricas e para separar equações multivetoriais por conteúdo geométrico.

2.4 Grades, blades e multivetores

2.4.1 O que significa grau

A Álgebra Geométrica organiza seus elementos por **grau**. O grau informa a dimensão geométrica do objeto elementar representado:

- grau 0: escalares;
- grau 1: vetores;
- grau 2: bivectores, associados a planos orientados;
- grau 3: trivectores, associados a volumes orientados;
- graus superiores: extensões naturais em dimensões maiores.

Essa classificação não significa que todo elemento da álgebra possua um único grau. Ela significa que a álgebra é construída como soma de subespaços de diferentes graus.

2.4.2 Blades: objetos simples de grau definido

Um **blade** ou **lâmina** de grau r é um r -vetor decomponível da forma

$$A_r = a_1 \wedge a_2 \wedge \cdots \wedge a_r.$$

Um vetor não nulo é um blade de grau 1. Um bivector simples $a \wedge b$ é um blade de grau 2. Um trivector simples $a \wedge b \wedge c$ é um blade de grau 3.

A palavra **simples** é importante. Um r -vetor geral pode ser soma de vários blades de mesmo grau e nem sempre pode ser fatorado em um único produto exterior. Portanto, todo blade de grau r é um r -vetor, mas nem todo r -vetor é necessariamente um blade simples.

2.4.3 Multivetores: diferentes graus no mesmo elemento

Um **multivetor** é um elemento geral da álgebra e pode possuir componentes de vários graus simultaneamente:

$$A = \sum_{r=0}^n \langle A \rangle_r.$$

A notação $\langle A \rangle_r$ significa: “extraia de A apenas a parte de grau r ”. Por exemplo, se

$$A = 3 + 2e_1 - e_{12} + 4e_{123},$$

então

$$\langle A \rangle_0 = 3,$$

$$\langle A \rangle_1 = 2e_1,$$

$$\langle A \rangle_2 = -e_{12},$$

$$\langle A \rangle_3 = 4e_{123}.$$

Essa projeção por grau é um mecanismo central da AG porque permite combinar informações em um único elemento sem perder a natureza geométrica de cada parcela.

2.4.4 Por que aparecem 2^n componentes

Se $\dim V = n$, o número de componentes independentes de grau r é

$$\dim \Lambda^r V = \binom{n}{r}.$$

Os coeficientes binomiais $\binom{n}{r}$ são exatamente os números que aparecem na linha de ordem n do **triângulo de Pascal**. Cada coeficiente conta quantas maneiras existem de escolher r direções distintas entre os n vetores de uma base; em AG, essas escolhas correspondem aos blades de base de grau r . Para $n = 3$, a linha

$$1 \quad 3 \quad 3 \quad 1$$

indica, respectivamente, um elemento de base de grau 0, três de grau 1, três de grau 2 e um de grau 3. A soma dos elementos dessa linha é obtida também pelo binômio de Newton:

$$(1 + 1)^n = \sum_{r=0}^n \binom{n}{r} = 2^n.$$

Portanto,

$$\dim Cl(V, g) = \sum_{r=0}^n \binom{n}{r} = 2^n.$$

Em $Cl(3, 0)$, uma base conveniente é

$$\{1, e_1, e_2, e_3, e_{12}, e_{23}, e_{31}, e_{123}\}.$$

Há oito elementos de base: um escalar, três vetores, três bivectores e um trivetor. Essa estrutura aparece explicitamente em formulações de AG para mecânica dos fluidos e eletromagnetismo (Sen 2023).

2.5 Bases, métrica e independência de coordenadas

2.5.1 Objeto geométrico e componentes

Considere novamente um vetor v . Em uma base $\{e_i\}$, ele pode ser escrito como

$$v = v^i e_i.$$

Os números v^i dependem da base. Se a base for modificada, os números mudam de forma a preservar o mesmo vetor geométrico. Essa distinção é particularmente importante em coordenadas curvilíneas e em malhas, nas quais bases locais podem variar de ponto para ponto (Grinfeld 2013).

2.5.2 O conceito de base recíproca

Se a base direta $\{e_i\}$ não é ortonormal, simplesmente calcular $v \cdot e_i$ não fornece, em geral, os coeficientes v^i da expansão $v = v^i e_i$. Para extrair essas componentes de maneira sistemática, introduz-se a **base recíproca** $\{e^i\}$, definida pela condição

$$\boxed{e^i \cdot e_j = \delta^i_j},$$

onde o **delta de Kronecker** é

$$\delta^i_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Essa condição pode ser lida geometricamente: cada vetor e^i da base recíproca tem produto interno igual a 1 com o vetor direto correspondente e_i e produto interno zero com todos os demais vetores da base direta.

A base recíproca funciona, portanto, como um conjunto de “sondas” para extrair as componentes associadas à base direta:

$$v^i = v \cdot e^i,$$

e

$$v = (v \cdot e^i) e_i.$$

2.5.2.1 Exemplo em uma base oblíqua

Considere, no plano euclidiano,

$$e_1 = (1, 0), \quad e_2 = (1, 1).$$

Os vetores e_1 e e_2 formam uma base, mas não são ortogonais. Uma base recíproca que satisfaz $e^i \cdot e_j = \delta^i_j$ é

$$e^1 = (1, -1), \quad e^2 = (0, 1).$$

De fato,

$$e^1 \cdot e_1 = 1, \quad e^1 \cdot e_2 = 0,$$

$$e^2 \cdot e_1 = 0, \quad e^2 \cdot e_2 = 1.$$

Para o vetor

$$v = (3, 2),$$

as componentes na base direta são extraídas por

$$v^1 = v \cdot e^1 = 1, \quad v^2 = v \cdot e^2 = 2.$$

Logo,

$$v = e_1 + 2e_2 = (1, 0) + 2(1, 1) = (3, 2).$$

Esse exemplo mostra por que a base recíproca é especialmente útil quando a base direta é oblíqua ou varia espacialmente.

2.5.2.2 Relação com a métrica

A métrica da base direta é

$$g_{ij} = e_i \cdot e_j,$$

e sua inversa matricial é denotada por g^{ij} . As bases direta e recíproca relacionam-se por

$$e^i = g^{ij}e_j, \quad e_i = g_{ij}e^j.$$

Da mesma maneira, componentes contravariantes e covariantes podem ser relacionadas por

$$v_i = g_{ij}v^j, \quad v^i = g^{ij}v_j.$$

Essa é a ponte entre a linguagem de bases recíprocas e a notação tensorial de índices superiores e inferiores (Grinfeld 2013).

2.5.2.3 Sobre unidades físicas

O adjetivo “recíproca” refere-se primeiramente à relação algébrica $e^i \cdot e_j = \delta^i_j$. As unidades físicas de e^i dependem da forma como as coordenadas e a base direta foram definidas. Em alguns contextos, como redes recíprocas em cristalografia, vetores recíprocos possuem interpretação de frequência espacial e unidades de inverso de comprimento. Essa interpretação, porém, não deve ser atribuída automaticamente a toda base recíproca usada em cálculo tensorial ou em AG. No presente trabalho, a base recíproca será utilizada principalmente para formular derivadas, componentes e operações independentes da escolha de coordenadas.

2.6 Pseudoescalar e dualidade

2.6.1 O elemento de grau máximo

Dada uma base orientada $\{e_1, \dots, e_n\}$, o produto exterior de todos os vetores da base define

$$I = e_1 \wedge e_2 \wedge \dots \wedge e_n.$$

Esse elemento é chamado **pseudoescalar**. Ele representa o elemento orientado de dimensão máxima do espaço. Em duas dimensões, representa a orientação do plano inteiro; em três dimensões, a orientação do volume.

Em uma base ortogonal,

$$I^2 = (-1)^{n(n-1)/2} \prod_{i=1}^n e_i^2.$$

Em $Cl(3, 0)$,

$$I = e_{123}, \quad I^2 = -1.$$

A propriedade $I^2 = -1$ ajuda a explicar por que subestruturas da AG reproduzem construções conhecidas de números complexos e quatérnios.

2.6.2 Dualidade como correspondência entre dimensões complementares

Quando I é inversível, adota-se neste trabalho a convenção de dual à direita

$$A^* = AI^{-1}.$$

A dualidade transforma um objeto de grau r em um objeto de grau complementar $n - r$. Em três dimensões:

- o dual de um escalar é um trivetor;
- o dual de um vetor é um bivector;
- o dual de um bivector é um vetor;
- o dual de um trivetor é um escalar.

Considere $B = e_{12}$ em $Cl(3, 0)$. Como $I^{-1} = -I$,

$$B^* = e_{12}I^{-1} = e_3.$$

Assim, o plano orientado e_{12} tem como dual a direção normal e_3 . O produto vetorial tridimensional pode ser visto precisamente como uma forma dual de representar um bivector. Essa interpretação é útil porque o plano orientado permanece o objeto primário, enquanto a normal vetorial é obtida quando necessária (Sen 2023).

A convenção de dualidade deve ser declarada porque o sinal depende de três escolhas: orientação da base, assinatura da métrica e uso de dual à esquerda ou à direita.

2.7 Involuções, reversão, conjugação e inversa

2.7.1 Por que são necessárias operações involutivas

Em álgebra linear, operações como transposição e conjugação são usadas para construir simetrias, produtos escalares e inversas. A AG possui operações análogas, mas definidas diretamente sobre os graus dos multivetores.

Uma **involução** é uma operação que, aplicada duas vezes, devolve o elemento original.

2.7.2 Involução de grau

Para um elemento homogêneo A_r ,

$$\widehat{A}_r = (-1)^r A_r.$$

Ela troca o sinal dos graus ímpares e preserva os graus pares. Se

$$A = s + v + B + T,$$

com s escalar, v vetor, B bivetor e T trivetor, então

$$\widehat{A} = s - v + B - T.$$

Essa operação permite separar as partes pares e ímpares da álgebra.

2.7.3 Reversão

A **reversão** inverte a ordem dos fatores vetoriais:

$$a_1 \widetilde{a_2 \cdots a_r} = a_r \cdots a_2 a_1.$$

Para um elemento homogêneo,

$$\widetilde{A}_r = (-1)^{r(r-1)/2} A_r.$$

Em particular,

$$\widetilde{a} = a,$$

para vetores, enquanto para um bivetor simples

$$\widetilde{a \wedge b} = b \wedge a = -a \wedge b.$$

A reversão aparece de maneira essencial na definição da inversa de versores e na ação de rotores.

2.7.4 Conjugação de Clifford

A conjugação de Clifford combina involução de grau e reversão. Para um elemento homogêneo,

$$\overline{A_r} = (-1)^{r(r+1)/2} A_r.$$

Embora não seja necessário memorizar imediatamente todos os sinais, é importante reconhecer que essas três operações desempenham papéis diferentes e que seus efeitos podem ser determinados diretamente pelo grau.

2.7.5 Inversa de vetores e versores

Para um vetor a não nulo em métrica não degenerada,

$$a^{-1} = \frac{a}{a^2},$$

pois

$$aa^{-1} = a \frac{a}{a^2} = 1.$$

Se a é unitário euclidiano, $a^2 = 1$ e, portanto,

$$a^{-1} = a.$$

Um **versor** é um produto de vetores inversíveis,

$$V = a_1 a_2 \cdots a_k.$$

Para essa classe de elementos,

$$V^{-1} = \frac{\widetilde{V}}{V\widetilde{V}},$$

desde que o denominador seja não nulo. Para multivetores completamente gerais, entretanto, não se deve presumir que essa expressão fornece uma inversa. A existência e o cálculo da inversa dependem da estrutura do elemento.

2.8 Projeção, rejeição, reflexão e rotação

2.8.1 Decompondo um vetor em partes paralela e perpendicular

Considere um vetor não nulo a e um vetor b . Geometricamente, b pode ser decomposto em uma parcela paralela a a e outra perpendicular:

$$b = b_{\parallel} + b_{\perp}.$$

Na AG,

$$b_{\parallel} = (b \cdot a)a^{-1},$$

$$b_{\perp} = (b \wedge a)a^{-1}.$$

A primeira expressão é a **projeção** de b sobre a ; a segunda é a **rejeição**, isto é, a parcela removida da direção de a .

Se $a = e_1$ e

$$b = 3e_1 + 2e_2,$$

então

$$b_{\parallel} = 3e_1, \quad b_{\perp} = 2e_2.$$

A utilidade dessa forma é que a mesma linguagem se estende para projeções e rejeições relativas a blades de maior grau.

2.8.2 Reflexão

Se n é normal ao hiperplano de reflexão, a reflexão de x pode ser escrita como

$$\boxed{x' = -n x n^{-1}}.$$

Considere $n = e_1$ e

$$x = x_1 e_1 + x_2 e_2.$$

Como $e_1^{-1} = e_1$,

$$x' = -e_1 x e_1 = -x_1 e_1 + x_2 e_2.$$

A componente normal ao plano muda de sinal e a componente tangencial é preservada, exatamente como esperado geometricamente.

2.8.3 De duas reflexões a uma rotação

Uma propriedade fundamental da geometria é que a composição de duas reflexões em planos apropriados produz uma rotação. Na AG, produtos pares de vetores que implementam essas composições formam **rotores**.

Se B é um bivetor unitário euclidiano que representa o plano de rotação, com

$$B^2 = -1,$$

um rotor de ângulo θ pode ser escrito como

$$R = \exp\left(-\frac{\theta}{2} B\right).$$

Como $B^2 = -1$, a exponencial assume a forma

$$R = \cos \frac{\theta}{2} - B \sin \frac{\theta}{2}.$$

A transformação é aplicada por

$$\boxed{x' = R x \widetilde{R}}.$$

Para rotores normalizados,

$$R\widetilde{R} = 1.$$

Em $Cl(2, 0)$, escolhendo $B = e_{12}$ e $\theta = \pi/2$, o rotor transforma

$$e_1 \mapsto e_2.$$

A presença de $\theta/2$ na definição do rotor é característica da representação por ação sanduíche: o rotor aparece uma vez à esquerda e uma vez à direita do objeto transformado.

Rotores armazenam o plano e o ângulo da rotação em um objeto algébrico compacto. Isso é especialmente útil para representar orientações relativas de elementos de malha, embora matrizes de rotação permaneçam disponíveis quando exigidas por bibliotecas numéricas (Doran e Lasenby 2003; Baylis 1996).

2.9 Aplicações lineares, tensores, dyadics e matrizes

2.9.1 Aplicação linear e sua matriz

Uma aplicação linear

$$F : V \rightarrow W$$

é uma regra que preserva combinações lineares:

$$F(\alpha a + \beta b) = \alpha F(a) + \beta F(b).$$

Depois que bases são escolhidas em V e W , essa aplicação pode ser representada por uma matriz $[F]^i_j$. A matriz depende das bases; a aplicação linear abstrata não.

Essa distinção é importante para evitar uma identificação frequente: **matriz e transformação não são a mesma coisa**. A matriz é a descrição coordenada da transformação.

2.9.2 Dyadics como operadores lineares

Na análise diádica, um *dyadic* pode ser escrito como combinação de produtos diádicos de vetores e atua como operador linear sobre outro vetor. Van Bladel (2007) mostra que a mesma transformação vetorial pode ser apresentada tanto em forma matricial quanto em forma diádica.

Para vetores a e b , o operador diádico $a \otimes b$ atua sobre x como

$$(a \otimes b)x = a(b \cdot x),$$

adotada essa convenção de ação. O resultado é um vetor paralelo a a , cuja magnitude depende da projeção de x sobre b .

2.9.3 Tensor não é sinônimo de multivetor

Um tensor geral representa uma aplicação multilinear. Um r -vetor, por outro lado, pertence ao espaço exterior $\Lambda^r V$ e corresponde à parcela totalmente antissimétrica apropriada de uma estrutura tensorial. Portanto, a AG não permite identificar automaticamente qualquer tensor com um multivetor.

Um exemplo decisivo para este trabalho aparece no fluxo de quantidade de movimento das equações de Euler para um fluido compressível. Nesse contexto, ρ representa a densidade do fluido, u é o vetor velocidade, p é a pressão termodinâmica e I é o tensor identidade. O fluxo convectivo de quantidade de movimento e a contribuição isotrópica da pressão aparecem combinados na estrutura

$$\rho u \otimes u + pI.$$

O termo $u \otimes u$ é um tensor ou operador de segunda ordem. Quando aplicado a um vetor v ,

$$(u \otimes u)v = u(u \cdot v).$$

Já o produto geométrico de u consigo mesmo é

$$u^2 = u \cdot u = \|u\|^2$$

no caso euclidiano, portanto é um **escalar**. Logo,

$$\boxed{u \otimes u \neq u^2}.$$

Essa distinção será preservada na formulação aerodinâmica: operadores e tensores continuam sendo utilizados quando sua ação multilinear é essencial, enquanto multivetores representam estruturas geométricas para as quais grau, orientação, produto exterior ou dualidade são naturais.

2.10 Outermorphisms e extensão de transformações

2.10.1 Por que uma transformação de vetores precisa ser estendida

Suponha que F transforme vetores. Se uma face orientada é representada pelo bivector

$$B = a \wedge b,$$

é desejável que a transformação da face seja obtida a partir da transformação de suas arestas. A extensão de F que realiza essa tarefa é chamada **outermorphism** e será denotada por $\underline{F}$.

Ela é definida por

$$\underline{F}(a_1 \wedge \cdots \wedge a_r) = F(a_1) \wedge \cdots \wedge F(a_r),$$

com

$$\underline{F}(1) = 1.$$

Consequentemente,

$$\underline{F}(A \wedge B) = \underline{F}(A) \wedge \underline{F}(B).$$

Essa propriedade significa que a relação geométrica construída pelo produto exterior é preservada pela extensão da transformação.

2.10.2 Exemplo: transformação de área

Considere, no plano,

$$F(e_1) = 2e_1, \quad F(e_2) = 3e_2.$$

A área orientada unitária é representada por

$$B = e_1 \wedge e_2.$$

Após a transformação,

$$\underline{F}(B) = (2e_1) \wedge (3e_2) = 6e_{12}.$$

A área é multiplicada por 6, exatamente o determinante da transformação. Em dimensão n , para o pseudoescalar I ,

$$\underline{F}(I) = \det(F)I.$$

Dessa forma, o determinante adquire uma interpretação geométrica direta: ele mede como o elemento orientado de volume é escalado e se sua orientação é preservada ou invertida (Hestenes e Sobczyk 1984; Doran e Lasenby 2003).

O termo **extensor** será usado, quando necessário, para aplicações lineares ou multilineares estendidas a multivetores. Essa terminologia ajuda a distinguir o operador do multivetor sobre o qual ele atua.

2.11 Derivada geométrica e cálculo de campos

2.11.1 Da derivada direcional ao operador vetorial

Em cálculo vetorial, operadores como gradiente, divergência e *curl* aparecem frequentemente como construções diferentes. A AG reúne essas operações por meio de uma derivada vetorial.

Em uma base recíproca $\{e^i\}$, escreve-se formalmente

$$\nabla = e^i \partial_i,$$

onde ∂_i representa a derivada parcial em relação à coordenada correspondente. O uso da base recíproca é precisamente o que permite que a derivada seja construída de maneira compatível com a base escolhida.

Quando ∇ atua sobre um campo vetorial u , o produto geométrico separa-se em

$$\boxed{\nabla u = \nabla \cdot u + \nabla \wedge u}.$$

A primeira parcela é escalar; a segunda é bivetorial.

2.11.2 Divergência: expansão ou compressão local

A divergência

$$\nabla \cdot u$$

mede, localmente, a tendência de um campo vetorial de se afastar ou convergir para um ponto. Em um campo de velocidade, divergência positiva indica expansão volumétrica local; divergência negativa indica compressão; divergência nula caracteriza um campo solenoidal.

Por exemplo, em duas dimensões,

$$u = ax e_1 + by e_2,$$

produz

$$\nabla \cdot u = a + b.$$

2.11.3 Derivada exterior: circulação local orientada

A parcela

$$\nabla \wedge u$$

é um bivetor e representa a parte antissimétrica do gradiente do campo. Em três dimensões euclidianas, o *curl* tradicional é obtido por dualidade; a entidade geométrica primária é o bivetor $\nabla \wedge u$ (Sen 2023).

Considere o campo plano de rotação rígida

$$u = -\omega y e_1 + \omega x e_2.$$

Sua divergência é zero,

$$\nabla \cdot u = 0,$$

mas

$$\nabla \wedge u = 2\omega e_{12}.$$

O bivector e_{12} identifica diretamente o plano de rotação e o sinal de ω determina seu sentido. Esse exemplo mostra a vantagem de representar a circulação por um objeto orientado, e não apenas por um número.

Para um campo de velocidade, será conveniente definir o bivector

$$\Omega = \nabla \wedge u,$$

associado à vorticidade geométrica. A literatura demonstra o uso de bivectores para representar planos de rotação e estruturas vorticais em campos amostrados (Pollock e Mann 2014).

2.12 Representação geométrica de malhas

2.12.1 De vértices a arestas

Malhas de **Computational Electromagnetics (CEM)** e **Computational Fluid Dynamics (CFD)** são normalmente armazenadas por coordenadas de vértices e conectividade. Para uma face triangular orientada $f = (i, j, k)$, sejam x_i, x_j, x_k as posições dos vértices. As arestas relativas podem ser representadas por

$$r_{ij} = x_j - x_i, \quad r_{ik} = x_k - x_i.$$

Esses vetores já são mais geométricos do que as coordenadas absolutas, pois representam relações entre pontos da malha.

2.12.2 A face como bivector de área

A face orientada pode ser representada por

$$B_f = \frac{1}{2} r_{ij} \wedge r_{ik}.$$

O fator $1/2$ converte a área do paralelogramo na área do triângulo. No caso euclidiano,

$$\|B_f\| = A_f,$$

onde A_f é a área da face.

Considere o triângulo com

$$x_1 = (0, 0, 0), \quad x_2 = (1, 0, 0), \quad x_3 = (0, 1, 0).$$

Então

$$r_{12} = e_1, \quad r_{13} = e_2,$$

e

$$B_f = \frac{1}{2} e_{12}.$$

A magnitude é $1/2$, exatamente a área do triângulo, e o sinal de e_{12} registra a ordem dos vértices.

2.12.3 Da face orientada à normal

Em $Cl(3, 0)$, adotando dual à direita,

$$n_f = \frac{B_f I^{-1}}{\|B_f\|}.$$

Para o triângulo do exemplo,

$$n_f = e_3.$$

Se a ordem dos vértices for invertida, B_f muda de sinal e a normal também. Assim, área e orientação não são atributos desconectados: ambas são propriedades do mesmo bivector.

2.12.4 Relações entre faces vizinhas

Para duas faces vizinhas, o produto interno

$$n_i \cdot n_j$$

mede alinhamento. Já

$$n_i \wedge n_j$$

retém o plano e o sentido da variação de orientação. Um rotor R_{ij} pode ainda representar diretamente a rotação que leva a orientação local da face i à da face j .

Essa estrutura é especialmente útil em grafos derivados de malhas: uma aresta do grafo não precisa carregar apenas distância e ângulo escalar; ela pode transportar relações geométricas orientadas.

2.12.5 Estados multivetoriais em nós ou faces

Uma representação local pode combinar graus diferentes,

$$X_i = s_i + v_i + B_i + \tau_i I,$$

onde:

- s_i reúne atributos escalares, como pressão, densidade, área ou curvatura escalar;
- v_i reúne grandezas vetoriais, como posição relativa ou velocidade;
- B_i reúne planos ou áreas orientadas;
- $\tau_i I$ representa uma componente pseudoescalar apenas quando houver significado físico ou geométrico para ela.

A presença de todos esses graus em $Cl(3,0)$ não significa que todos devam ser sempre utilizados. Cada canal deve corresponder a uma grandeza cuja lei de transformação e significado físico sejam conhecidos.

2.13 Ponte para o eletromagnetismo

2.13.1 Campo eletromagnético como bivector de espaço-tempo

Na **Spacetime Algebra (STA)**, ou Álgebra do Espaço-Tempo, o campo eletromagnético pode ser organizado em um único bivector F . Com assinatura, unidades e convenção de corrente declaradas, as equações de Maxwell podem ser reunidas em uma equação multivetorial do tipo

$$\nabla F = J,$$

onde J representa a corrente de espaço-tempo (Dressel et al. 2015; Doran e Lasenby 2003).

A razão pela qual uma única equação contém várias equações físicas é a estrutura por graus do produto geométrico. Quando ∇F é separado em parcelas de diferentes graus, recuperam-se as contribuições associadas às equações homogêneas e não homogêneas de Maxwell.

Essa escrita deve ser entendida como **unificação representacional**, não como “linearização” das equações. Em meios lineares, Maxwell já é linear nos campos. A vantagem da STA consiste em representar, dentro de uma mesma estrutura, campo, dualidade, polarização, transformações e operadores.

Para o problema de **Radar Cross Section (RCS)**, essa base será usada no capítulo de física para distinguir campo incidente, campo espalhado, condições constitutivas, condições de contorno e extração do campo distante.

2.14 Ponte para a dinâmica dos fluidos

2.14.1 Vorticidade como bivector

A mecânica dos fluidos fornece um exemplo natural de grandeza cuja interpretação geométrica é favorecida por bivectores. Em três dimensões, a vorticidade é tradicionalmente representada por um pseudovetor associado ao *curl* da velocidade. Na AG, pode-se utilizar diretamente

$$\Omega = \nabla \wedge u.$$

O bivector identifica o plano local de rotação do campo de velocidade. Sen (2023) emprega essa estrutura em uma formulação geométrica que relaciona vorticidade e vetor de Lamb. Por sua vez, Parameswaran et al. (2024) desenvolvem equações fluidodinâmicas análogas às de Maxwell em espaço-tempo.

2.14.2 O termo convectivo continua não linear

Uma identidade útil de cálculo geométrico é

$$(u \cdot \nabla)u = u \cdot (\nabla \wedge u) + \frac{1}{2}\nabla(u^2).$$

Ela separa o termo convectivo em uma contribuição relacionada à rotação local e outra relacionada ao gradiente da energia cinética específica. A identidade melhora a interpretação geométrica, mas não remove a dependência quadrática em u . Portanto, ela **não transforma as equações de Euler em um sistema globalmente linear** (Sen 2023).

No caso compressível conservativo, estruturas como

$$\rho u \otimes u$$

continuam sendo tensoriais. O uso da AG concentra-se nas parcelas para as quais orientação, vorticidade, derivadas geométricas e transformações admitem uma representação multivetorial consistente.

2.15 Ponte para Graph Neural Networks

2.15.1 Por que a geometria interessa ao aprendizado em grafos

Uma GNN processa dados por meio de nós, arestas e agregação de mensagens. Em uma malha física, entretanto, os atributos associados a esses elementos não são apenas números abstratos: posição relativa é um vetor, orientação de face pode ser um bivector, alinhamento pode ser um escalar e transformação relativa pode ser um rotor.

Codificar essas grandezas apenas como uma sequência de números é possível, mas transfere para a rede a responsabilidade de aprender, a partir dos dados, relações geométricas que já são conhecidas analiticamente. A AG oferece uma forma de manter parte dessa estrutura explícita.

Zhong e Cao (2025) propõem uma **Graph Geometric Algebra Network (GGAN)** na qual atributos são organizados como componentes multivetoriais e operações de AG participam da agregação de vizinhança. Esse antecedente demonstra a viabilidade computacional da combinação entre AG e GNNs, embora suas tarefas de classificação de nós e grafos sejam distintas da predição de campos físicos em malhas.

2.15.2 Uma mensagem geometricamente estruturada

Em forma abstrata, uma mensagem entre nós ou faces i e j pode ser escrita como

$$m_{ij} = \Phi_{\theta}(X_i, X_j, R_{ij}, B_{ij}, c),$$

seguida de

$$X'_i = \Psi_{\theta}(X_i, \text{AGG}_{j \in \mathcal{N}(i)} m_{ij}).$$

Aqui:

- X_i e X_j são estados locais, possivelmente multivetoriais;
- R_{ij} representa orientação relativa;
- B_{ij} representa uma relação plana ou área orientada;
- c reúne condições físicas globais, como Mach, ângulo de ataque, frequência ou polarização;
- Φ_{θ} e Ψ_{θ} são funções aprendidas;
- AGG agrega as mensagens da vizinhança.

A arquitetura concreta deve respeitar como cada grandeza se transforma sob rotação, reflexão e mudança de referencial. Um escalar, por exemplo, não deve ser tratado como se tivesse a mesma lei de transformação de um vetor ou de um bivector.

2.15.3 Estudos de ablação

A AG permanece como formalismo do framework. Estudos de ablação serão utilizados para quantificar a contribuição de escolhas específicas: canais bivectoriais, rotores, produtos geométricos ou atributos cartesianos convencionais. O objetivo é medir impacto em precisão, generalização e eficiência, e não decidir se a estrutura matemática fundamental será abandonada.

2.16 Critérios computacionais

Uma expressão algebricamente mais compacta não é necessariamente mais rápida em computador. Uma implementação multivetorial pode reduzir parâmetros ou evitar transformações redundantes, mas também pode introduzir mais componentes e produtos.

Por isso, qualquer vantagem computacional será tratada como resultado experimental. A avaliação considerará, conforme aplicável:

- número de parâmetros treináveis;
- memória de pico durante treinamento e inferência;

- tempo de treinamento;
- tempo de inferência;
- número de operações ou kernels relevantes;
- estabilidade numérica;
- erro de predição;
- generalização a geometrias não vistas;
- sensibilidade a rotações e mudanças de referencial;
- impacto no número de avaliações dos modelos físicos de referência;
- impacto no tempo total da otimização aero-stealth.

A AG é, portanto, o formalismo matemático adotado; o ganho computacional de cada representação é uma propriedade a ser demonstrada por benchmark.

2.17 Síntese

A construção apresentada neste capítulo começa com objetos familiares e adiciona estrutura progressivamente. Vetores fornecem direção; o produto interno introduz métrica; o produto exterior representa subespaços orientados; e o produto geométrico reúne essas informações em uma operação associativa. A graduação distingue escalares, vetores, bivectores e elementos de ordem superior, enquanto multivetores permitem combinar graus sem perder sua identidade geométrica.

A base recíproca permite extrair componentes e construir operadores diferenciais mesmo quando a base não é ortonormal. O pseudoescalar introduz dualidade entre dimensões complementares. Involuções e reversão permitem controlar sinais e construir inversas. Versores e rotores transformam reflexões e rotações em produtos da própria álgebra. Outermorphisms estendem transformações de vetores a áreas e volumes orientados. A derivada geométrica reúne divergência e derivada exterior em um único produto.

Para o framework aero-stealth, essas ferramentas sustentam três conexões. A primeira é geométrica: faces, áreas orientadas, normais e transformações relativas de uma malha podem ser representadas sem reduzir toda informação a coordenadas cartesianas. A segunda é física: o eletromagnetismo admite uma formulação particularmente compacta em espaço-tempo, enquanto a aerodinâmica se beneficia de representações geométricas de vorticidade e derivadas sem perder a estrutura tensorial e não linear das equações de Euler. A terceira é computacional: atributos e operações de AG podem integrar mensagens e estados internos das GNNs empregadas como modelos substitutos multifidelidade.

A partir dessa base, o capítulo seguinte formula as equações eletromagnéticas e aerodinâmicas, especificando quais objetos serão representados por multivetores, quais permanecerão tensores ou operadores e quais projeções escalares serão necessárias para discretização, aprendizado e otimização.

3 Electromagnetic and Aerodynamic Governing Equations

Este capítulo reunirá os dois domínios físicos que geram os dados e as restrições usadas pelas GNNs.

3.1 Electromagnetics

3.1.1 Maxwell equations

Apresentação convencional das equações de Maxwell, condições constitutivas e condições de contorno relevantes ao espalhamento eletromagnético.

3.1.2 Differential-form representation

Ponte entre cálculo vetorial, formas diferenciais e formulações independentes de coordenadas.

3.1.3 Geometric Algebra formulation

Maxwell será investigado em Álgebra Geométrica/Álgebra do Espaço-Tempo como **unificação compacta das equações**, e não como uma suposta linearização de um sistema que já é linear nos campos em meios lineares.

3.1.4 Electromagnetic scattering and RCS

- campo incidente e espalhado;
- condições PEC e materiais;
- correntes superficiais;
- campo distante;
- RCS e polarizações;
- fidelidades CEM relevantes.

3.2 Aerodynamics

3.2.1 Perfect gas and inviscid subsonic flow

Definição do modelo físico e domínio de validade.

3.2.2 Euler equations

- conservação de massa;
- conservação de quantidade de movimento;
- conservação de energia;
- equação de estado de gás perfeito;
- condições de contorno.

3.2.3 Geometric Algebra formulation

A AG será usada para investigar uma reformulação geometricamente estruturada das equações de Euler. A não linearidade física das equações de Euler deverá ser preservada e tratada explicitamente.

3.2.4 Aerodynamic outputs

- distribuição de pressão;
- C_L ;
- C_D ;
- C_m ;
- L/D ;
- fidelidades aerodinâmicas de referência.

3.3 Uso na regularização das GNNs

O capítulo culminará na definição de resíduos físicos e condições de contorno que possam ser incorporados às funções de perda dos modelos aprendidos.

Status M0: estrutura editorial preparada; as derivações serão incluídas após revisão específica da literatura de Maxwell/GA e Euler/GA.

4 Graph Neural Networks for Physics-Based Surrogate Modeling

As Graph Neural Networks constituem a **principal contribuição computacional** do projeto: substituir grande parte das avaliações repetidas dos solvers físicos por inferências rápidas dentro do processo de otimização, mantendo revalidação de alta fidelidade para as soluções relevantes.

4.1 Why graphs?

A justificativa partirá da correspondência natural entre malhas CEM/CFD e estruturas de grafo.

4.2 Meshes as graphs

Serão avaliadas representações por nós, arestas, faces e, quando necessário, células volumétricas.

4.3 Message passing

Formalização do ciclo mensagem-agregação-atualização-readout e sua interpretação em problemas de PDEs discretizadas.

4.4 Node, edge and face features

Features geométricas, físicas, operacionais e, posteriormente, atributos derivados de Álgebra Geométrica.

4.5 Geometric representations

Comparação entre coordenadas cartesianas, invariantes geométricos, representações equivariantes e possíveis objetos multivetoriais.

4.6 Equivariance and invariance

Definição das propriedades desejáveis frente a rotações, translações, mudança de orientação e remalhamento.

4.7 Physics-informed GNNs

A física será incorporada prioritariamente como regularização, supervisão auxiliar ou informação de baixa fidelidade, evitando pressupor que uma PINN completa seja a solução adequada ao loop de otimização.

4.8 Electromagnetic surrogate

Entradas, saídas de RCS/campo e tarefas auxiliares serão especificadas durante o desenvolvimento.

4.9 Aerodynamic surrogate

Predição de coeficientes e, quando necessário, campos intermediários adequados à regularização pelas equações de Euler.

4.10 Uncertainty quantification

A incerteza epistemológica será usada tanto para validação quanto para *active learning*.

4.11 Estudos de ablação

O projeto deverá separar empiricamente os ganhos de:

1. uso de grafo;
2. representação geométrica/AG;
3. regularização física;
4. multifidelidade.

Status M0: estrutura editorial preparada; este capítulo será priorizado após a definição do problema no M1.

5 Multifidelity Learning and Adaptive Data Generation

A multifidelidade é central para tornar o treinamento das GNNs economicamente viável quando dados de alta fidelidade são caros.

5.1 Computational cost hierarchy

Caracterização explícita do custo dos diferentes níveis de solver.

5.2 Low- and high-fidelity models

Definição de baixa, média e alta fidelidade e critérios de compatibilidade entre respostas.

5.3 Electromagnetic fidelity hierarchy

Estrutura preliminar a revisar durante o projeto:

PO/LE-PO $\rightarrow$ SBR+/UTD/PTD ou equivalente HF $\rightarrow$ validação experimental, quando disponível.

5.4 Aerodynamic fidelity hierarchy

Estrutura preliminar:

painel/VSPAERO $\rightarrow$ Euler $\rightarrow$ RANS/CFD de referência.

5.5 Multi-Fidelity GNNs

Uma hipótese de referência será aprender a discrepância entre níveis:

$$y_{HF} = y_{LF} + \Delta_{\theta}(G, y_{LF}).$$

5.6 Residual correction and transfer learning

Serão comparadas estratégias de correção residual, *coarse-to-fine*, currículo e transferência entre fidelidades.

5.7 Active learning

A aquisição de novos casos deverá considerar:

- incerteza epistemológica;
- discrepância LF–HF;
- proximidade de regiões promissoras para a fronteira de Pareto;
- risco de picos de RCS ou degradação aerodinâmica.

5.8 Uncertainty-driven sampling

A incerteza será avaliada como componente explícito do ciclo de geração de dados.

Status M0: estrutura editorial preparada; o conteúdo será expandido após o capítulo de GNNs.

6 GNN-Accelerated Multidisciplinary Aero-Stealth Optimization

Este capítulo integrará os surrogates eletromagnético e aerodinâmico ao processo de otimização multidisciplinar.

6.1 Design variables

Variáveis contínuas, inteiras e categóricas serão definidas a partir da parametrização real do UCAV.

6.2 Objectives

Serão investigadas funções objetivo relacionadas a RCS, risco de picos e desempenho aerodinâmico.

6.3 Constraints

Restrições físicas, geométricas e operacionais serão explicitadas antes da escolha final do algoritmo de otimização.

6.4 NLP and MINLP

O problema será classificado como NLP ou MINLP somente após a definição das variáveis discretas. A Álgebra Geométrica estruturará representações e modelos físicos, enquanto os solvers de otimização operarão sobre objetivos e restrições escalares.

6.5 Multiobjective optimization

A análise será orientada à fronteira de Pareto aero-stealth.

6.6 Surrogate-assisted optimization

A GNN será usada para substituir avaliações caras durante grande parte da busca, com chamadas HF seletivas para calibração e validação.

6.7 High-fidelity revalidation

Soluções candidatas deverão ser reavaliadas nos solvers de referência antes de conclusões de engenharia.

6.8 Computational speed-up

Uma métrica central será o *speed-up* da otimização completa:

$$S_{\text{MDO}} = \frac{T_{\text{MDO,baseline}}}{T_{\text{MDO,GNN}}}.$$

O tempo total deverá incluir geração dos dados, treinamento, otimização e revalidação para evitar estimativas artificiais de aceleração.

6.9 Pareto quality

Serão definidas métricas para comparar a fronteira produzida pelo surrogate com soluções revalidadas em alta fidelidade.

Status M0: estrutura editorial preparada; a formulação final será desenvolvida após a consolidação das disciplinas físicas e dos surrogates.

Aleisa, Hassan, Konstantinos Kontis, Berkay Pirlepel, e Melike Nikbay. 2023. “Conceptual Design of a Nonconstant Swept Flying Wing Unmanned Combat Aerial Vehicle”. *Journal of Aircraft* 60 (6): 1872–88. <https://doi.org/10.2514/1.C037257>.

Baylis, William E., org. 1996. *Clifford (Geometric) Algebras with Applications to Physics, Mathematics, and Engineering*. Birkhäuser. <https://doi.org/10.1007/978-1-4612-4104-1>.

Belotti, Pietro, Christian Kirches, Sven Leyffer, Jeff Linderoth, James Luedtke, e Ashutosh Mahajan. 2013. “Mixed-Integer Nonlinear Optimization”. *Acta Numerica* 22: 1–131. <https://doi.org/10.1017/S0962492913000032>.

- Black, Nolan, e Ahmad R. Najafi. 2022. “Learning Finite Element Convergence with the Multi-Fidelity Graph Neural Network”. *Computer Methods in Applied Mechanics and Engineering* 397: 115120. <https://doi.org/10.1016/j.cma.2022.115120>.
- Bronstein, Michael M., Joan Bruna, Taco Cohen, e Petar Veličković. 2021. “Geometric Deep Learning: Grids, Groups, Graphs, Geodesics, and Gauges”. *arXiv preprint arXiv:2104.13478*. <https://arxiv.org/abs/2104.13478>.
- Chen, Junfeng, Elie Hachem, e Jonathan Viquerat. 2021. “Graph Neural Networks for Laminar Flow Prediction Around Random Two-Dimensional Shapes”. *Physics of Fluids* 33 (12): 123607. <https://doi.org/10.1063/5.0064108>.
- Department of the Air Force. 2020. *Air Force Instruction 16-401: Designating and Naming Defense Military Aerospace Vehicles*. Department of the Air Force.
- Doran, Chris, e Anthony Lasenby. 2003. *Geometric Algebra for Physicists*. Cambridge University Press. <https://doi.org/10.1017/CBO9780511807497>.
- Dressel, Justin, Konstantin Y. Bliokh, e Franco Nori. 2015. “Spacetime Algebra as a Powerful Tool for Electromagnetism”. *Physics Reports* 589: 1–71. <https://doi.org/10.1016/j.physrep.2015.06.001>.
- Grinfeld, Pavel. 2013. *Introduction to Tensor Analysis and the Calculus of Moving Surfaces*. Springer. <https://doi.org/10.1007/978-1-4614-7867-6>.
- Hestenes, David, e Garret Sobczyk. 1984. *Clifford Algebra to Geometric Calculus: A Unified Language for Mathematics and Physics*. D. Reidel Publishing Company.
- Hu, Tianyuan, e Xiongqing Yu. 2009. “Aerodynamic/Stealthy/Structural Multidisciplinary Design Optimization of Unmanned Combat Air Vehicle”. *Chinese Journal of Aeronautics* 22 (4): 380–86. [https://doi.org/10.1016/S1000-9361\(08\)60114-4](https://doi.org/10.1016/S1000-9361(08)60114-4).
- Knott, Eugene F., John F. Shaeffer, e Michael T. Tuley. 1993. *Radar Cross Section*. 2^o ed. Artech House.
- Kong, De-Hua, Jia-Ning Cao, Wen-Wei Zhang, Wen-Chi Huang, Xiaoyang He, et al. 2024. “An AI Predictor: From Point Clouds to Scattered Far Fields for 3-D PEC Targets”. *IEEE Transactions on Antennas and Propagation* 72 (6): 5179–90. <https://doi.org/10.1109/TAP.2024.3390615>.
- Lee, Jon, e Sven Leyffer, org. 2012. *Mixed Integer Nonlinear Programming*. V. 154. The IMA Volumes em Mathematics e its Applications. Springer. <https://doi.org/10.1007/978-1-4614-1927-3>.

- Leng, Jun-Xue, Zhen-Guo Wang, Wei Huang, Yang Shen, e Kai An. 2025. “Multidisciplinary Design Optimization Processes for Efficiency Improvement of Aircraft: State-of-the-Art Review”. *International Journal of Aeronautical and Space Sciences* 26 (4): 2020–42. <https://doi.org/10.1007/s42405-024-00811-8>.
- Li, Chunyun, Bowen Shu, Ke Zhao, Longzhou Yu, Yongbo Li, e Huan Zhao. 2026. “Multi-task Diffusion Graph Model for Aero-Electromagnetic Analysis of Blended-Wing-Body Configurations”. *Physics of Fluids* 38 (5): 057104. <https://doi.org/10.1063/5.0326519>.
- Li, Ming, Junqiang Bai, Li Li, Xiaoxuan Meng, Qing Liu, e Bai Chen. 2019. “A Gradient-Based Aero-Stealth Optimization Design Method for Flying Wing Aircraft”. *Aerospace Science and Technology* 92: 156–69. <https://doi.org/10.1016/j.ast.2019.05.067>.
- Li, Zongyi, Nikola Kovachki, Chris Choy, et al. 2023. “Geometry-Informed Neural Operator for Large-Scale 3D PDEs”. *Advances in Neural Information Processing Systems* 36. <https://doi.org/10.52202/075280-1556>.
- Liersch, Carsten M., Russell M. Cummings, Andreas Schütte, Jan Vormweg, Ryan G. Maye, e Tiger L. Jeans. 2020. “Multi-Disciplinary Design and Performance Assessment of Effective, Agile NATO Air Vehicles”. *Aerospace Science and Technology* 99: 105764. <https://doi.org/10.1016/j.ast.2020.105764>.
- Martins, Joaquim R. R. A., e Andrew B. Lambe. 2013. “Multidisciplinary Design Optimization: A Survey of Architectures”. *AIAA Journal* 51 (9): 2049–75. <https://doi.org/10.2514/1.J051895>.
- Nguyen, Nhu-Van, Seok-Min Choi, Wan-Sub Kim, et al. 2013. “Multidisciplinary Unmanned Combat Air Vehicle System Design Using Multi-Fidelity Model”. *Aerospace Science and Technology* 26 (1): 200–210. <https://doi.org/10.1016/j.ast.2012.04.004>.
- Nikbay, Melike, Sihmehmet Yildiz, Berkay Pirlepel, e Konstantinos Kontis. 2026. “Multidisciplinary Design Optimization of a Non-Planar Flying Wing UCAV Concept”. *Aerospace Science and Technology* 177: 112285. <https://doi.org/10.1016/j.ast.2026.112285>.
- Papageorgiou, Athanasios, Mehdi Tarkian, Kristian Amadori, e Johan Ölvander. 2018. “Multidisciplinary Optimization of Unmanned Aircraft Considering Radar Signature, Sensors, and Trajectory Constraints”. *Journal of Aircraft* 55 (3). <https://doi.org/10.2514/1.C034314>.
- Parameswaran, R., Susan Mathew Panakkal, e M. J. Vedan. 2024. “Fluid Maxwell’s Equations in the Language of Geometric Algebra”. *Pramana – Journal of Physics* 98: 62. <https://doi.org/10.1007/s12043-024-02731-4>.
- Peng, Jiang-Zhou, Yue Hua, Nadine Aubry, Zhi-Hua Chen, Mei Mei, e Wei-Tao Wu. 2024. “Data

- and Physics-Driven Modeling for Fluid Flow with a Physics-Informed Graph Convolutional Neural Network”. *Ocean Engineering* 301: 117551. <https://doi.org/10.1016/j.oceaneng.2024.117551>.
- Pfaff, Tobias, Meire Fortunato, Alvaro Sanchez-Gonzalez, e Peter W. Battaglia. 2021. “Learning Mesh-Based Simulation with Graph Networks”. *International Conference on Learning Representations*.
- Pollock, Stuart, e Stephen Mann. 2014. “Vortex Detection in Vector Fields Using Geometric Algebra”. *Advances in Applied Clifford Algebras* 24: 423–42. <https://doi.org/10.1007/s00006-013-0434-0>.
- Roy, Satadru, Kenneth Moore, John T. Hwang, Justin S. Gray, William A. Crossley, e Joaquim R. R. A. Martins. 2017. “A Mixed Integer Efficient Global Optimization Algorithm for the Simultaneous Aircraft Allocation-Mission-Design Problem”. *58th AIAA/ASCE/AHS/ASC Structures, Structural Dynamics, and Materials Conference*. <https://doi.org/10.2514/6.2017-1305>.
- Sen, D. 2023. “Field Theoretic Formulation of Fluid Mechanics According to the Geometric Algebra”. *Pramana – Journal of Physics* 97: 132. <https://doi.org/10.1007/s12043-023-02617-x>.
- Sepulveda, Eduardo, e Howard Smith. 2017. “Technology Challenges of Stealth Unmanned Combat Aerial Vehicles”. *The Aeronautical Journal* 121 (1243): 1261–95. <https://doi.org/10.1017/aer.2017.53>.
- Sepulveda, E., H. Smith, e D. Sziroczak. 2019. “Multidisciplinary Analysis of Subsonic Stealth Unmanned Combat Aerial Vehicles”. *CEAS Aeronautical Journal* 10: 431–42. <https://doi.org/10.1007/s13272-018-0325-0>.
- Shan, Tao, Maokun Li, Fan Yang, e Shenheng Xu. 2024. “Solving Combined Field Integral Equations With Physics-Informed Graph Residual Learning for EM Scattering of 3-D PEC Targets”. *IEEE Transactions on Antennas and Propagation* 72 (1): 733–44. <https://doi.org/10.1109/TAP.2023.3331262>.
- Shi, Renhe, Teng Long, Nianhui Ye, Yufei Wu, Zhao Wei, e Zhenyu Liu. 2021. “Metamodel-Based Multidisciplinary Design Optimization Methods for Aerospace System”. *Astrodynamics* 5: 185–215. <https://doi.org/10.1007/s42064-021-0109-x>.
- Silva, João Pedro Rocha. 2026. *Implementação Teórica e Prática para Caracterização de Seção Reta Radar em Laboratório*. Trabalho de Conclusão de Curso, Bacharelado em Engenharia Aeroespacial, Universidade de Brasília.

- Taghizadeh, Mohammad, Mohammad Amin Nabian, e Negin Alemazkoo. 2025. “Multifidelity Graph Neural Networks for Efficient and Accurate Mesh-Based Partial Differential Equations Surrogate Modeling”. *Computer-Aided Civil and Infrastructure Engineering* 40: 841–58. <https://doi.org/10.1111/mice.13312>.
- Thoulon, C., G. Roge, e O. Pironneau. 2024. “Gradient-Based Aero-Stealth Optimization of a Simplified Aircraft”. *Fluids* 9 (8): 174. <https://doi.org/10.3390/fluids9080174>.
- Van Bladel, Jean G. 2007. *Electromagnetic Fields*. 2^o ed.
- Zhong, Jianqi, e Wenming Cao. 2025. “Graph Geometric Algebra Networks for Graph Representation Learning”. *Scientific Reports* 15: 170. <https://doi.org/10.1038/s41598-024-84483-0>.