

Graph Neural Networks e Álgebra Geométrica para Otimização Aero-Stealth de UCAVs

**Modelagem multifidelidade de Maxwell e Euler e aceleração da otimização
multidisciplinar**

Índice

UCAV Aero-Stealth Optimization with Multifidelity Graph Neural Networks	5
Sobre este projeto	5
Objetivo geral	5
Arquitetura da pesquisa	6
Questões metodológicas centrais	6
Organização do eBook	6
1 Contexto e Definição do Problema Aero-Stealth de um UCAV	8
1.1 UCAV: conceito, escopo e terminologia	8
1.2 UCAV como problema de engenharia multidisciplinar	9
1.3 Continuidade em relação à caracterização de RCS	10
1.4 Fidelidade e modelagem multifidelidade	10
1.5 Radar Cross Section como resposta de projeto	11
1.6 Desempenho aerodinâmico no regime subsônico	12
1.7 Estado da arte em otimização aero-stealth de UCAVs	12
1.8 GNNs para análise aerodinâmica e eletromagnética	13
1.9 Lacuna de pesquisa	14
1.10 Justificativa	14
1.11 Formulação inicial do problema multidisciplinar	15
1.12 Papel das GNNs e da multifidelidade na otimização	16
1.13 Quantificação de incerteza e aprendizado ativo como estratégias auxiliares	17
1.14 Questão de pesquisa	17
1.15 Objetivo geral	17
1.16 Objetivos específicos	18
1.17 Hipóteses de pesquisa	18
1.18 Métricas de avaliação	19
1.19 Estudos de ablação	20
1.20 Delimitação do estudo	20
2 Geometric Algebra for Physical and Geometric Representation	21
2.1 Da álgebra linear e tensorial à Álgebra Geométrica	21
2.2 Álgebra de Clifford	21
2.3 Matrizes, tensores e sistemas de equações	21
2.4 Representação de malhas	22
2.5 Papel da AG no aprendizado	22

3	Electromagnetic and Aerodynamic Governing Equations	23
3.1	Electromagnetics	23
3.1.1	Maxwell equations	23
3.1.2	Differential-form representation	23
3.1.3	Geometric Algebra formulation	23
3.1.4	Electromagnetic scattering and RCS	23
3.2	Aerodynamics	24
3.2.1	Perfect gas and inviscid subsonic flow	24
3.2.2	Euler equations	24
3.2.3	Geometric Algebra formulation	24
3.2.4	Aerodynamic outputs	24
3.3	Uso na regularização das GNNs	24
4	Graph Neural Networks for Physics-Based Surrogate Modeling	25
4.1	Why graphs?	25
4.2	Meshes as graphs	25
4.3	Message passing	25
4.4	Node, edge and face features	25
4.5	Geometric representations	26
4.6	Equivariance and invariance	26
4.7	Physics-informed GNNs	26
4.8	Electromagnetic surrogate	26
4.9	Aerodynamic surrogate	26
4.10	Uncertainty quantification	26
4.11	Estudos de ablação	27
5	Multifidelity Learning and Adaptive Data Generation	28
5.1	Computational cost hierarchy	28
5.2	Low- and high-fidelity models	28
5.3	Electromagnetic fidelity hierarchy	28
5.4	Aerodynamic fidelity hierarchy	28
5.5	Multi-Fidelity GNNs	29
5.6	Residual correction and transfer learning	29
5.7	Active learning	29
5.8	Uncertainty-driven sampling	29
6	GNN-Accelerated Multidisciplinary Aero-Stealth Optimization	30
6.1	Design variables	30
6.2	Objectives	30
6.3	Constraints	30
6.4	NLP and MINLP	30
6.5	Multiobjective optimization	30
6.6	Surrogate-assisted optimization	31

6.7	High-fidelity revalidation	31
6.8	Computational speed-up	31
6.9	Pareto quality	31

UCAV Aero-Stealth Optimization with Multifidelity Graph Neural Networks

Sobre este projeto

Este eBook documenta o desenvolvimento de um framework de otimização multidisciplinar aero-stealth para **configurações UCAV de baixa observabilidade**. A expressão UCAV (*Unmanned Combat Aerial Vehicle*) designa uma classe funcional de aeronave não tripulada de combate e não uma configuração aerodinâmica específica. Configurações sem cauda, *flying-wing*, *blended-wing-body* e outras famílias geométricas podem ser consideradas conforme o espaço de projeto for formalizado.

A contribuição computacional central é o emprego de **Graph Neural Networks (GNNs) multifidelidade** como modelos substitutos para reduzir a demanda de recursos computacionais e o tempo de processamento das avaliações eletromagnéticas e aerodinâmicas repetidas durante a otimização.

A **Álgebra Geométrica (AG)** é adotada como formalismo matemático estruturante para representar geometria, operações físicas e relações empregadas no aprendizado e na otimização. O projeto buscará formulações multivetoriais mais compactas e, quando matematicamente admissível, representações lineares nos objetos algébricos escolhidos, preservando explicitamente as não linearidades físicas intrínsecas.

Objetivo geral

Desenvolver e validar um framework de otimização multidisciplinar aero-stealth para configurações UCAV, baseado em Álgebra Geométrica e modelos substitutos por Graph Neural Networks multifidelidade, de forma a reduzir a demanda de recursos computacionais das avaliações eletromagnéticas e aerodinâmicas e viabilizar sua integração com métodos determinísticos de otimização matemática.

Arquitetura da pesquisa

A arquitetura metodológica de referência é:

CAD/OpenVSP → malha/grafos → modelos em diferentes fidelidades → GNN multifidelidade → otimização m

A motivação para grafos decorre da estrutura natural de malhas triangulares e não estruturadas, amplamente explorada em *geometric deep learning* e simulação baseada em malhas (Bronstein et al. 2021; Pfaff et al. 2021). Trabalhos recentes já demonstram GNNs para modelagem eletromagnética tridimensional (Shan et al. 2024) e análise aero-eletromagnética multitarefa em malhas de configurações *blended-wing-body* (Li et al. 2026). O presente framework integra essa capacidade de modelagem a uma arquitetura multifidelidade e a métodos determinísticos de otimização multidisciplinar.

Questões metodológicas centrais

O projeto investiga, entre outras questões:

1. quanto as GNNs reduzem o tempo de processamento e o número de avaliações dos modelos eletromagnéticos e aerodinâmicos de referência;
2. como combinar modelos de diferentes fidelidades para ampliar o espaço de projeto avaliado com a mesma infraestrutura computacional;
3. como incorporar relações físicas de Maxwell e Euler, formuladas em Álgebra Geométrica, à representação e ao treinamento das GNNs;
4. como integrar os modelos substitutos a formulações determinísticas de otimização multi-objetivo, incluindo NLP e, quando houver variáveis discretas, MINLP;
5. quanto o processo completo reduz a demanda de CPU/GPU, memória e tempo de processamento após contabilizar geração de dados, treinamento, otimização e reavaliação;
6. em que medida a fronteira de Pareto prevista preserva sua qualidade após reavaliação pelos modelos físicos de referência.

Quantificação de incerteza e aprendizado ativo poderão ser avaliados como estratégias auxiliares de seleção de novas simulações, caso acrescentem informação relevante ao processo multifidelidade.

Organização do eBook

Os capítulos são organizados em torno de:

- contexto UCAV e definição do problema aero-stealth;
- fundamentos e aplicação da Álgebra Geométrica;
- equações físicas de Maxwell/RCS e Euler/aerodinâmica;
- GNNs para *surrogate modeling*;
- modelagem multifidelidade e estratégias de geração de dados;
- otimização matemática multidisciplinar acelerada e validação.

1 Contexto e Definição do Problema

Aero-Stealth de um UCAV

Este capítulo apresenta o contexto de engenharia, a justificativa, a lacuna de pesquisa, os objetivos e a formulação inicial do problema de otimização aero-stealth de um **Unmanned Combat Aerial Vehicle (UCAV)**. A contribuição computacional central consiste no uso de **Graph Neural Networks (GNNs)** multifidelidade como modelos substitutos para reduzir a demanda de recursos computacionais e o tempo de processamento associados às avaliações eletromagnéticas e aerodinâmicas repetidas durante a otimização multidisciplinar.

A **Álgebra Geométrica (AG)** é adotada como formalismo matemático estruturante do trabalho. Ela será empregada na representação da geometria, na reformulação das relações físicas e na construção dos modelos de aprendizado e otimização. O objetivo é obter descrições algébricas mais compactas, reduzir a dependência de representações exclusivamente matriciais e explorar formulações lineares nos objetos multivetoriais sempre que a estrutura matemática do problema permitir. Não linearidades físicas intrínsecas, como os termos convectivos das equações de Euler, permanecem explicitamente representadas.

1.1 UCAV: conceito, escopo e terminologia

A expressão **Unmanned Aerial Vehicle (UAV)** designa, de forma ampla, um veículo aéreo não tripulado. A classe **Unmanned Combat Aerial Vehicle (UCAV)** particulariza esse conceito para plataformas destinadas a missões de combate. A classificação está associada à função, à missão e à integração do sistema, e não a uma configuração aerodinâmica específica (Department of the Air Force 2020; Sepulveda e Smith 2017).

Consequentemente, UCAV e *flying wing* não são termos equivalentes. Configurações sem cauda (*tailless*), *flying-wing*, *lambda-wing*, *blended-wing-body* e outras arquiteturas aparecem na literatura de baixa observabilidade porque determinadas escolhas geométricas podem favorecer integração volumétrica, desempenho aerodinâmico e controle de assinatura radar. Essas configurações representam famílias de projeto possíveis dentro da classe UCAV.

A literatura ilustra essa diversidade. O programa NATO Science and Technology Organization (NATO STO) AVT-251 desenvolveu e avaliou a configuração MULDISCON, derivada do SACCON, como um conceito UCAV multidisciplinar com ênfase em aerodinâmica, controlabilidade e baixa assinatura (Liersch et al. 2020). Aleisa et al. estudaram especificamente um UCAV

de configuração *flying-wing* com enflechamento não constante (Aleisa et al. 2023). Nikbay et al. investigaram uma configuração UCAV não planar derivada de um conceito planar de asa integrada (Nikbay et al. 2026).

O objeto desta pesquisa é, portanto, uma **família geometricamente parametrizada de configurações UCAV de baixa observabilidade**. A arquitetura aerodinâmica específica será definida pelo espaço de projeto e pelas restrições de engenharia adotadas, preservando a distinção entre a classe funcional do veículo e sua configuração geométrica.

1.2 UCAV como problema de engenharia multidisciplinar

O projeto de um UCAV integra requisitos aerodinâmicos, eletromagnéticos, estruturais, propulsores, de estabilidade e controle, além de requisitos próprios de sistemas não tripulados, como autonomia, sensores, comunicação e gerenciamento de missão (Sepulveda e Smith 2017). Essas disciplinas interagem por meio de variáveis de projeto comuns e podem produzir objetivos conflitantes.

A **Otimização Multidisciplinar de Projeto (Multidisciplinary Design Optimization, MDO)** fornece o arcabouço para formular essas interações como um problema integrado de otimização numérica (Martins e Lambe 2013). Revisões recentes continuam a destacar a MDO como elemento central do projeto de aeronaves avançadas, especialmente quando modelos disciplinares de diferentes níveis de detalhe precisam ser combinados sob restrições de desempenho e de recursos computacionais (Leng et al. 2025).

No recorte desta pesquisa, o acoplamento principal envolve **desempenho aerodinâmico, assinatura radar e geometria**. Hu e Yu formularam um problema MDO aerodinâmico-stealth-estrutural para um UCAV (Hu e Yu 2009). Nguyen et al. integraram modelos de diferentes fidelidades ao projeto multidisciplinar de UCAVs (Nguyen et al. 2013). Sepulveda, Smith e Sziroczak desenvolveram uma análise multidisciplinar de UCAVs subsônicos de baixa observabilidade (Sepulveda et al. 2019), enquanto Papageorgiou et al. incorporaram assinatura radar, sensores, aerodinâmica e trajetória em um problema integrado de projeto de aeronave não tripulada (Papageorgiou et al. 2018).

Esses antecedentes mostram que alterações na forma externa do veículo afetam simultaneamente sustentação, arrasto, estabilidade, distribuição de pressão e mecanismos de espalhamento eletromagnético. O problema de engenharia consiste, portanto, em identificar geometrias que produzam compromissos tecnicamente adequados entre respostas aerodinâmicas e eletromagnéticas sob um conjunto explícito de restrições de projeto.

1.3 Continuidade em relação à caracterização de RCS

A pesquisa parte de uma base experimental e computacional previamente desenvolvida para caracterização de **Radar Cross Section (RCS)**, ou seção reta radar. No Trabalho de Conclusão de Curso de **João Pedro Rocha Silva (2026)**, foram avaliados alvos canônicos e alvos aeroespaciais complexos por meio de diferentes técnicas de **Eletromagnetismo Computacional (Computational Electromagnetics, CEM)** e de medição experimental (Silva 2026).

Entre os métodos empregados encontram-se a **Óptica Física (Physical Optics, PO)**, a **Large Element Physical Optics (LE-PO)**, a **Ray Launching Geometrical Optics (RL-GO)** e a técnica **Shooting and Bouncing Rays Plus (SBR+)**, implementadas em ferramentas como Altair Feko e Ansys **High Frequency Structure Simulator (HFSS)**. O trabalho também implementou, para geometrias canônicas, o **Método das Diferenças Finitas no Domínio do Tempo (Finite-Difference Time-Domain, FDTD)**, o **Método dos Momentos (Method of Moments, MoM)** e o **Método dos Elementos Finitos (Finite Element Method, FEM)** (Silva 2026).

A contribuição dessa base para a presente pesquisa está na experiência acumulada com modelagem eletromagnética, comparação entre métodos e validação experimental. A nova etapa desloca a ênfase da caracterização de geometrias previamente definidas para a exploração de **famílias paramétricas de configurações UCAV** dentro de um processo de otimização.

Os resultados de Rocha Silva também evidenciam diferenças relevantes entre modelos eletromagnéticos. Em geometrias canônicas, métodos distintos reproduzem com diferentes níveis de precisão mecanismos como reflexão especular, múltiplas reflexões e difração (Silva 2026). Essa observação conduz diretamente ao conceito de fidelidade utilizado no framework.

1.4 Fidelidade e modelagem multifidelidade

Neste trabalho, **fidelidade** representa o grau de detalhamento físico e numérico com que um modelo aproxima o fenômeno e a resposta de referência relevantes ao problema. A fidelidade depende de vários elementos: equações governantes, hipóteses físicas, discretização espacial, resolução da malha, tratamento de condições de contorno, modelos constitutivos e método numérico. Portanto, a classificação de um modelo como de menor ou maior fidelidade é sempre relativa ao regime físico e à resposta de interesse.

Modelos de maior fidelidade tendem a representar mais fenômenos ou a empregar discretizações mais detalhadas, o que geralmente aumenta a demanda de **tempo de CPU/GPU, memória e armazenamento**. Modelos de menor fidelidade utilizam aproximações físicas, discretizações mais simples ou resoluções reduzidas e, por isso, permitem avaliar um número maior de configurações com a mesma infraestrutura computacional.

A **modelagem multifidelidade** combina sistematicamente informações provenientes de dois ou mais níveis de fidelidade. O objetivo é aproveitar a ampla cobertura do espaço de projeto proporcionada por modelos de menor demanda de recursos e utilizar um conjunto menor de avaliações de maior fidelidade para corrigir, calibrar ou enriquecer a aproximação (Nguyen et al. 2013; Shi et al. 2021; Black e Najafi 2022; Taghizadeh et al. 2025). A relação entre níveis pode ser aprendida, por exemplo, por uma correção de discrepância

$$y_{HF} = y_{LF} + \Delta_{\theta}(G, y_{LF}, c),$$

em que y_{LF} e y_{HF} representam respostas de menor e maior fidelidade, G representa a geometria codificada como grafo, c reúne as condições operacionais e Δ_{θ} é um modelo treinável de correção.

No domínio eletromagnético, uma hierarquia poderá combinar métodos assintóticos de alta frequência e métodos com representação mais detalhada dos mecanismos de espalhamento, sempre mediante validação para o regime de interesse. No domínio aerodinâmico, modelos de painel, equações de Euler e formulações viscosas baseadas nas equações de Navier–Stokes com médias de Reynolds podem ocupar diferentes níveis dessa hierarquia. A classificação final será definida pelas respostas que cada modelo reproduz e pelos recursos necessários para sua execução.

1.5 Radar Cross Section como resposta de projeto

A RCS quantifica a intensidade com que um alvo espalha energia eletromagnética na direção do receptor e pode ser interpretada como uma área efetiva de espalhamento sob condições especificadas (Knott et al. 1993). Na equação de alcance radar monoestática idealizada, a distância máxima de detecção varia com a quarta raiz de σ , o que estabelece uma conexão direta entre assinatura radar e detectabilidade (Knott et al. 1993; Silva 2026).

A RCS depende da frequência, da direção de incidência e observação, da polarização, das propriedades materiais e dos mecanismos de espalhamento. Em alvos eletricamente grandes, a geometria local influencia reflexão especular, difração em bordos e pontas, múltiplas reflexões e ondas de superfície (Knott et al. 1993; Silva 2026). Consequentemente, a resposta eletromagnética relevante para projeto é angular e pode apresentar picos estreitos em determinados setores.

A modelagem proposta preservará essa estrutura por meio de curvas de RCS em função de azimute, elevação, frequência e polarização. Para condições $c_{EM} = (\phi, \theta, f, p)$,

$$\sigma = \sigma(\phi, \theta, f, p; x),$$

em que x representa a geometria parametrizada. A partir da curva podem ser construídos objetivos escalares, como média setorial, valor máximo, quantis ou outras medidas de risco. Essa separação permite avaliar simultaneamente a fidelidade física da curva e sua utilização em otimização matemática.

1.6 Desempenho aerodinâmico no regime subsônico

O domínio aerodinâmico concentra-se inicialmente em escoamento externo subsônico de ar tratado como gás perfeito. A **Dinâmica dos Fluidos Computacional (Computational Fluid Dynamics, CFD)** será utilizada em níveis de fidelidade compatíveis com a fase do estudo. Modelos potenciais ou de painel podem fornecer respostas de menor demanda de recursos; as equações compressíveis e invíscidas de Euler constituem um nível intermediário relevante; e modelos viscosos baseados nas **Reynolds-Averaged Navier–Stokes (RANS)** podem servir como referência de maior fidelidade para condições selecionadas.

As respostas aerodinâmicas de interesse incluem o coeficiente de sustentação C_L , o coeficiente de arrasto C_D , o coeficiente de momento C_m , a razão L/D e, quando necessário, campos de pressão e outras grandezas locais. GNNs já foram aplicadas a malhas não estruturadas e *body-fitted* para aproximar campos de escoamento em geometrias variáveis (Chen et al. 2021; Peng et al. 2024), e operadores neurais informados pela geometria foram empregados em problemas tridimensionais de equações diferenciais parciais (Li et al. 2023). Esses resultados fornecem base metodológica para a representação aerodinâmica por grafos.

1.7 Estado da arte em otimização aero-stealth de UCAVs

A otimização aero-stealth evoluiu de formulações com modelos disciplinares simplificados para ambientes de projeto que integram CFD, CEM, modelos substitutos e técnicas de sensibilidade. Hu e Yu combinaram aerodinâmica, stealth e estruturas em um problema MDO de UCAV (Hu e Yu 2009). Nguyen et al. utilizaram uma arquitetura multifidelidade no projeto de sistemas UCAV (Nguyen et al. 2013). O programa SACCON/MULDICON consolidou uma plataforma de pesquisa multidisciplinar para aeronaves de baixa observabilidade (Liersch et al. 2020).

A otimização matemática determinística ocupa papel relevante nessa evolução. Em MDO, as funções objetivo, restrições e variáveis das diferentes disciplinas podem ser organizadas em arquiteturas monolíticas ou decompostas (Martins e Lambe 2013). Métodos baseados em gradientes reduzem o número de avaliações necessárias quando derivadas confiáveis estão disponíveis. Li et al. empregaram Programação Quadrática Sequencial (*Sequential Quadratic Programming*, SQP) em otimização aero-stealth de uma configuração *flying-wing*, combinando CFD, PO e sensitividades adjuntas (Li et al. 2019). Thoulon et al. utilizaram o algoritmo *Sequential Least Squares Programming* (SLSQP), CFD com RANS e PO para construir uma fronteira de compromisso aero-stealth em uma aeronave simplificada (Thoulon et al. 2024).

A pesquisa também considera formulações com variáveis contínuas e discretas. Problemas com variáveis contínuas e relações não lineares podem ser formulados como **Programação Não Linear (Nonlinear Programming, NLP)**. Quando decisões discretas — por exemplo, escolhas de configuração, número de elementos geométricos ou categorias de materiais — são combinadas com variáveis contínuas e relações não lineares, surge a **Programação Não Linear Inteira Mista (Mixed-Integer Nonlinear Programming, MINLP)** (Lee e Leyffer 2012; Belotti et al. 2013). Em aplicações aeroespaciais, formulações mistas já foram empregadas para integrar decisões de missão, alocação e projeto de aeronaves (Roy et al. 2017).

Esse interesse é particularmente relevante para o presente framework. Os modelos substitutos baseados em GNN podem fornecer avaliações rápidas e diferenciáveis de respostas físicas, enquanto a otimização matemática determinística pode explorar explicitamente gradientes, restrições e estrutura combinatória. A formulação final será contínua ou inteira mista de acordo com a natureza real das variáveis de projeto, preservando compatibilidade com arquiteturas MDO e com métodos determinísticos de otimização local ou global.

Trabalhos recentes mantêm ativo o problema aero-stealth. Aleisa et al. investigaram o projeto conceitual de um UCAV *flying-wing* (Aleisa et al. 2023). Thoulon et al. demonstraram uma metodologia gradiente para compromisso entre arrasto e assinatura radar (Thoulon et al. 2024). Nikbay et al. apresentaram em 2026 uma otimização multidisciplinar de um conceito UCAV não planar, combinando CFD, RCS e modelos de Kriging por **Partial Least Squares (KPLS)** para reduzir o número de avaliações das análises de maior demanda de recursos (Nikbay et al. 2026).

1.8 GNNs para análise aerodinâmica e eletromagnética

A representação de malhas por grafos estabelece uma conexão natural entre geometria discretizada e aprendizado de máquina. MeshGraphNets demonstrou a aplicação de redes de grafos à simulação sobre malhas (Pfaff et al. 2021), enquanto a literatura de *geometric deep learning* fornece o arcabouço para explorar conectividade, simetrias e transformações geométricas (Bronstein et al. 2021).

No eletromagnetismo, Shan et al. empregaram aprendizado residual informado pela física sobre grafos para equações integrais de espalhamento de alvos tridimensionais condutores perfeitos (Shan et al. 2024). Kong et al. desenvolveram um preditor de campo distante espalhado a partir de nuvens de pontos de alvos tridimensionais (Kong et al. 2024). Esses trabalhos mostram que a geometria discretizada pode ser diretamente utilizada para aproximar respostas eletromagnéticas complexas.

O antecedente mais próximo da integração aero-eletromagnética por GNN identificado na literatura recente é o trabalho de Li et al. (Li et al. 2026). Os autores desenvolveram uma GNN de difusão multitarefa definida sobre malhas superficiais não estruturadas de configurações *blended-wing-body*. O modelo prediz simultaneamente o campo de coeficiente de pressão C_p , os

coeficientes globais C_L e C_D e valores médios de RCS monoestático para polarizações horizontal e vertical. O estudo reporta aproximadamente $35\times$ de aceleração de inferência para o conjunto de saídas em relação aos solvers utilizados na geração dos dados (Li et al. 2026).

Esse resultado estabelece um benchmark diretamente relacionado ao presente problema e demonstra a viabilidade de um modelo de grafo compartilhado entre as disciplinas aerodinâmica e eletromagnética. A presente pesquisa amplia essa linha ao incorporar fidelidades distintas, preservar a dependência angular e de polarização da RCS, integrar os modelos substitutos a uma formulação de otimização matemática determinística e utilizar Álgebra Geométrica como formalismo comum de representação da geometria, da física e das operações algébricas.

1.9 Lacuna de pesquisa

A lacuna abordada nesta pesquisa concentra-se na **integração sistemática de modelagem geométrica, física, aprendizado multifidelidade e otimização matemática para configurações UCAV**. A literatura recente apresenta avanços importantes em cada um desses componentes, porém a articulação conjunta permanece limitada.

A contribuição proposta reúne cinco elementos em uma única arquitetura metodológica:

1. representação de geometrias UCAV por malhas e grafos capazes de alimentar simultaneamente modelos aerodinâmicos e eletromagnéticos;
2. aprendizado multifidelidade explícito entre níveis de análise com diferentes graus de detalhamento e diferentes demandas de recursos computacionais;
3. predição da RCS preservando sua dependência angular e de polarização, em vez de restringir a resposta a um valor médio global;
4. integração dos modelos substitutos a uma formulação de otimização matemática determinística, com suporte a NLP e, quando houver decisões discretas, MINLP;
5. adoção da Álgebra Geométrica como linguagem matemática comum para representar geometria, operadores físicos e relações empregadas no aprendizado e na otimização.

Essa integração será avaliada pelo desempenho preditivo dos modelos, pela demanda de recursos computacionais, pelo tempo total de processamento e pela qualidade das soluções obtidas após reavaliação com modelos de referência.

1.10 Justificativa

A justificativa de engenharia decorre do forte acoplamento entre geometria, aerodinâmica e assinatura radar em UCAVs de baixa observabilidade. Uma alteração geométrica capaz de reduzir retornos eletromagnéticos pode modificar distribuição de pressão, arrasto, sustentação e estabilidade. O tratamento integrado dessas respostas reduz a possibilidade de soluções ótimas

em uma disciplina produzirem desempenho inadequado em outra (Sepulveda e Smith 2017; Sepulveda et al. 2019; Liersch et al. 2020).

A justificativa computacional decorre da demanda de recursos associada às avaliações disciplinares repetidas. Modelos CEM e CFD com maior detalhamento podem requerer tempos elevados de CPU/GPU, maior uso de memória e malhas com grande número de graus de liberdade. Uma otimização que exija centenas ou milhares de avaliações multiplica essa demanda. Revisões sobre MDO baseada em metamodelos destacam esse problema como uma das principais motivações para modelos substitutos em sistemas aeroespaciais (Shi et al. 2021), e estudos recentes de eficiência em MDO de aeronaves continuam a tratar a redução de avaliações disciplinares como tema central (Leng et al. 2025).

A justificativa metodológica está na compatibilidade entre a estrutura dos dados e o modelo de aprendizado. Malhas CEM e CFD já contêm relações topológicas entre vértices, arestas, faces e células. GNNs permitem incorporar essas relações diretamente ao modelo. A multifidelidade, por sua vez, permite distribuir o orçamento de simulação entre modelos com diferentes demandas de recursos, preservando avaliações de maior fidelidade para calibração e revalidação.

A Álgebra Geométrica fornece o eixo matemático comum do framework. No eletromagnetismo, a Álgebra do Espaço-Tempo permite reunir as equações de Maxwell em uma formulação multivetorial compacta (Dressel et al. 2015). No domínio aerodinâmico, a AG será empregada para representar vetores, bivectores, orientações, operadores diferenciais e transformações geométricas, buscando formulações mais compactas e linearizações operacionais quando matematicamente admissíveis. Na otimização, a arquitetura priorizará variáveis, operadores e restrições formulados em termos geométricos e multivetoriais, recorrendo a projeções escalares quando exigidas pelos solvers numéricos (Hestenes e Sobczyk 1984; Doran e Lasenby 2003).

A justificativa científica completa-se pela continuidade com a infraestrutura de RCS já estabelecida por Rocha Silva (Silva 2026). A passagem de caracterização de alvos fixos para otimização de famílias geométricas cria uma trajetória integrada entre modelagem física, aprendizado, otimização e revalidação.

1.11 Formulação inicial do problema multidisciplinar

Seja $x \in \mathbb{R}^n$ o vetor de variáveis contínuas de projeto. Caso o espaço de decisão inclua escolhas discretas, seja $z \in \mathbb{Z}^m$ o vetor correspondente. Uma formulação multiobjetivo pode ser escrita como

$$\min_{x,z} \begin{bmatrix} J_{\text{EM}}(x, z) \\ J_{\text{aero}}(x, z) \end{bmatrix}$$

sujeita a

$$g_i(x, z) \leq 0, \quad h_j(x, z) = 0,$$

além de limites geométricos e condições operacionais.

O objetivo eletromagnético será obtido a partir da resposta angular de RCS,

$$J_{\text{EM}}(x, z) = \mathcal{R}[\sigma(\phi, \theta, f, p; x, z)],$$

em que $\mathcal{R}$ representa uma operação de agregação ou risco definida para setores angulares e condições de interesse. No domínio aerodinâmico, formulações possíveis incluem minimização de C_D com restrição de sustentação ou maximização de eficiência aerodinâmica, equivalente a

$$J_{\text{aero}}(x, z) = -\frac{L}{D}.$$

A otimização multiobjetivo poderá ser tratada por escalarização, método ε -constraint ou outras estratégias compatíveis com otimização matemática determinística. Quando todas as variáveis forem contínuas, cada subproblema poderá assumir a forma de um NLP. A presença de decisões discretas combinadas com relações não lineares conduz a uma formulação MINLP (Lee e Leyffer 2012; Belotti et al. 2013).

1.12 Papel das GNNs e da multifidelidade na otimização

O modelo substituto terá como função aproximar respostas disciplinares a partir da geometria e das condições operacionais:

$$\mathcal{G}_\theta : (G, c, y_{LF}) \longrightarrow (\hat{y}_{EM}, \hat{y}_{aero}).$$

O grafo G representa a geometria discretizada, c reúne condições de operação e y_{LF} contém respostas provenientes de modelos de menor fidelidade quando disponíveis. A arquitetura multifidelidade aprenderá a relação entre níveis de modelagem, reduzindo o número de avaliações de maior demanda de recursos necessárias para cobrir o espaço de projeto.

Durante a otimização, a maior parte das avaliações de objetivos e restrições poderá ser realizada pelas GNNs. Modelos físicos de referência permanecerão associados à geração de dados, à verificação de regiões críticas e à reavaliação das soluções selecionadas. A combinação entre inferência rápida, diferenciação automática e otimização matemática determinística é particularmente relevante para problemas com muitas variáveis e restrições.

1.13 Quantificação de incerteza e aprendizado ativo como estratégias auxiliares

A **Quantificação de Incerteza (Uncertainty Quantification, UQ)** corresponde à estimativa da incerteza associada às previsões do modelo. Em modelos substitutos, essa informação pode indicar regiões do espaço de projeto pouco representadas pelos dados e apoiar a decisão sobre quais soluções exigem nova avaliação por modelos de maior fidelidade.

O **aprendizado ativo (active learning)** é uma estratégia sequencial de geração de dados na qual o próprio estado do modelo auxilia a escolha das próximas amostras a serem avaliadas. Sua utilização é justificável quando as avaliações de maior fidelidade demandam recursos suficientes para tornar ineficiente uma amostragem uniforme ou exclusivamente predefinida. Critérios de seleção podem combinar incerteza preditiva, discrepância entre fidelidades ou relevância para a região de Pareto.

UQ e aprendizado ativo são tratados nesta pesquisa como **estratégias auxiliares a serem avaliadas**, e não como componentes obrigatórios da arquitetura. Sua adoção dependerá de evidência de que acrescentam informação útil ao processo multifidelidade em relação a um plano de experimentos previamente definido.

1.14 Questão de pesquisa

Em que medida um framework baseado em Álgebra Geométrica, Graph Neural Networks multifidelidade e otimização matemática determinística pode reduzir a demanda de recursos computacionais e o tempo total de processamento da otimização aero-stealth de configurações UCAV, preservando a precisão das respostas físicas e a qualidade das soluções reavaliadas por modelos de referência?

1.15 Objetivo geral

Desenvolver e validar um framework de otimização multidisciplinar aero-stealth para configurações UCAV, baseado em Álgebra Geométrica e modelos substitutos por Graph Neural Networks multifidelidade, de forma a reduzir a demanda de recursos computacionais das avaliações eletromagnéticas e aerodinâmicas e viabilizar sua integração com métodos determinísticos de otimização matemática.

1.16 Objetivos específicos

1. **Contextualizar e formalizar o problema de engenharia de UCAVs**, distinguindo a classe funcional do veículo das configurações aerodinâmicas empregadas no espaço de projeto.
2. **Definir uma parametrização geométrica reproduzível** para as configurações estudadas e estabelecer o fluxo CAD $\rightarrow$ malha $\rightarrow$ grafo.
3. **Formular em Álgebra Geométrica as representações geométricas e físicas relevantes**, incluindo operações associadas às equações de Maxwell, ao escoamento de Euler e às transformações empregadas no processo de otimização.
4. **Definir os níveis de fidelidade eletromagnéticos e aerodinâmicos** a partir do conteúdo físico, da discretização e da demanda de recursos de cada modelo.
5. **Construir bases de dados multifidelidade** para RCS e aerodinâmica, preservando condições operacionais, metadados de simulação e rastreabilidade entre níveis.
6. **Desenvolver GNNs baseadas em malha** para prever curvas angulares e polarizadas de RCS, coeficientes aerodinâmicos e, quando necessário, campos físicos intermediários.
7. **Desenvolver estratégias de aprendizado multifidelidade** capazes de transferir ou corrigir informação entre modelos de diferentes níveis de fidelidade.
8. **Incorporar conhecimento físico às GNNs** por meio de representações e restrições derivadas das formulações em Álgebra Geométrica de Maxwell e Euler.
9. **Integrar os modelos substitutos a uma formulação de otimização matemática determinística multiobjetivo**, utilizando NLP para variáveis contínuas e MINLP quando o espaço de decisão incorporar variáveis discretas.
10. **Validar o framework de forma end-to-end**, quantificando precisão, demanda de recursos computacionais, tempo de processamento, número de avaliações dos solvers e qualidade da fronteira de Pareto após reavaliação por modelos de referência.

1.17 Hipóteses de pesquisa

As hipóteses centrais são formuladas como relações testáveis entre desempenho preditivo, recursos empregados e qualidade das decisões de otimização.

Representação por grafos. GNNs que recebem a geometria discretizada e sua conectividade deverão apresentar melhor generalização para geometrias não vistas do que modelos baseados exclusivamente em parâmetros globais, sob condições comparáveis de treinamento.

Aprendizado multifidelidade. Para uma quantidade fixa de avaliações de maior fidelidade, a combinação de informações provenientes de diferentes fidelidades deverá produzir menor erro preditivo ou melhor qualidade das soluções de otimização do que o treinamento realizado apenas com o subconjunto de maior fidelidade.

Consistência física. A incorporação de relações físicas formuladas em Álgebra Geométrica às representações, perdas ou saídas auxiliares das GNNs deverá melhorar a consistência física e a eficiência amostral em relação a um modelo puramente supervisionado com a mesma base de dados.

Aceleração da otimização. A utilização das GNNs multifidelidade no ciclo MDO deverá reduzir o tempo total de processamento e o número de avaliações de maior demanda de recursos necessários para obter uma fronteira de Pareto reavaliada, preservando a qualidade das soluções selecionadas.

1.18 Métricas de avaliação

A avaliação deverá combinar métricas de predição, otimização e utilização de recursos. Para RCS, serão considerados erro médio da curva, erro de pico, deslocamento angular de picos e erro por setor. Para aerodinâmica, serão considerados erros em C_L , C_D , C_m , L/D e, quando aplicável, em campos físicos.

A utilização de recursos será caracterizada por **tempo de processamento**, **horas de CPU/GPU**, **pico de memória**, **armazenamento**, **número de avaliações dos modelos de referência** e **tempo de geração dos dados de treinamento**. Quando UQ for empregada, serão acrescentadas métricas de calibração e cobertura.

Duas medidas de aceleração são particularmente relevantes:

$$S_{\text{eval}} = \frac{T_{\text{solver}}}{T_{\text{GNN}}}$$

para uma avaliação individual, e

$$S_{\text{MDO}} = \frac{T_{\text{MDO, referência}}}{T_{\text{dados}} + T_{\text{treinamento}} + T_{\text{otimização}} + T_{\text{reavaliação}}}$$

para o processo completo. A segunda métrica evita atribuir aceleração ao framework sem contabilizar os recursos empregados para geração de dados e treinamento.

A qualidade da otimização será avaliada pela comparação entre a fronteira de Pareto prevista e a fronteira reavaliada, utilizando indicadores apropriados de dominância, hipervolume e erro das soluções selecionadas.

1.19 Estudos de ablação

O protocolo experimental incluirá modelos de referência capazes de separar a contribuição das principais camadas metodológicas:

- baseline baseado em parâmetros globais da geometria;
- GNN com representação geométrica convencional;
- GNN com representação e operações em Álgebra Geométrica;
- GNN com incorporação explícita de relações físicas;
- GNN multifidelidade integrada ao processo de otimização.

A Álgebra Geométrica permanece como formalismo adotado no framework final. A ablação tem a função de quantificar como cada componente modifica precisão, estabilidade, demanda de dados e comportamento da otimização, e não de decidir sua adoção.

1.20 Delimitação do estudo

O trabalho concentra-se na integração entre geometria UCAV, RCS, aerodinâmica subsônica, Álgebra Geométrica, GNNs multifidelidade e otimização matemática. Os solvers físicos de referência serão utilizados para geração de dados e reavaliação, enquanto as reformulações em AG terão profundidade suficiente para sustentar as representações, relações físicas e operações empregadas pelo modelo substituto e pela otimização.

O resultado esperado é um **framework reproduzível de otimização aero-stealth** no qual a aceleração seja demonstrada por medidas de tempo e recursos computacionais, e a validade das decisões seja sustentada por reavaliação eletromagnética e aerodinâmica em níveis de fidelidade adequados.

2 Geometric Algebra for Physical and Geometric Representation

Este capítulo apresentará a Álgebra Geométrica (AG) como linguagem de representação para geometria, campos e regularização física das GNNs. O projeto não assume a priori que AG reduz custo computacional; essa possibilidade será avaliada empiricamente.

2.1 Da álgebra linear e tensorial à Álgebra Geométrica

- vetores e covetores;
- tensores e transformações multilineares;
- métrica;
- álgebra exterior e produto exterior;
- relação entre formas diferenciais e multivetores.

2.2 Álgebra de Clifford

- produto geométrico;
- escalares, vetores, bivectores e multivetores;
- projeção por grau;
- pseudoescalar e dualidade;
- reversão, norma e inversa;
- versores e rotores.

2.3 Matrizes, tensores e sistemas de equações

O capítulo distinguirá objetos geométricos de suas representações matriciais e discutirá como operadores lineares, tensores e sistemas de equações podem ser expressos e implementados sem identificar indevidamente todo tensor com um multivetor.

2.4 Representação de malhas

Serão investigadas representações de faces, arestas, normais, áreas orientadas e transformações relativas adequadas a grafos derivados de malhas CEM/CFD.

2.5 Papel da AG no aprendizado

A contribuição da AG será testada por estudos de ablação, comparando representações cartesianas convencionais com representações geométricas estruturadas.

Status M0: estrutura editorial preparada; a fundamentação será expandida após a consolidação do corpus bibliográfico de AG.

3 Electromagnetic and Aerodynamic Governing Equations

Este capítulo reunirá os dois domínios físicos que geram os dados e as restrições usadas pelas GNNs.

3.1 Electromagnetics

3.1.1 Maxwell equations

Apresentação convencional das equações de Maxwell, condições constitutivas e condições de contorno relevantes ao espalhamento eletromagnético.

3.1.2 Differential-form representation

Ponte entre cálculo vetorial, formas diferenciais e formulações independentes de coordenadas.

3.1.3 Geometric Algebra formulation

Maxwell será investigado em Álgebra Geométrica/Álgebra do Espaço-Tempo como **unificação compacta das equações**, e não como uma suposta linearização de um sistema que já é linear nos campos em meios lineares.

3.1.4 Electromagnetic scattering and RCS

- campo incidente e espalhado;
- condições PEC e materiais;
- correntes superficiais;
- campo distante;
- RCS e polarizações;
- fidelidades CEM relevantes.

3.2 Aerodynamics

3.2.1 Perfect gas and inviscid subsonic flow

Definição do modelo físico e domínio de validade.

3.2.2 Euler equations

- conservação de massa;
- conservação de quantidade de movimento;
- conservação de energia;
- equação de estado de gás perfeito;
- condições de contorno.

3.2.3 Geometric Algebra formulation

A AG será usada para investigar uma reformulação geometricamente estruturada das equações de Euler. A não linearidade física das equações de Euler deverá ser preservada e tratada explicitamente.

3.2.4 Aerodynamic outputs

- distribuição de pressão;
- C_L ;
- C_D ;
- C_m ;
- L/D ;
- fidelidades aerodinâmicas de referência.

3.3 Uso na regularização das GNNs

O capítulo culminará na definição de resíduos físicos e condições de contorno que possam ser incorporados às funções de perda dos modelos aprendidos.

Status M0: estrutura editorial preparada; as derivações serão incluídas após revisão específica da literatura de Maxwell/GA e Euler/GA.

4 Graph Neural Networks for Physics-Based Surrogate Modeling

As Graph Neural Networks constituem a **principal contribuição computacional** do projeto: substituir grande parte das avaliações repetidas dos solvers físicos por inferências rápidas dentro do processo de otimização, mantendo revalidação de alta fidelidade para as soluções relevantes.

4.1 Why graphs?

A justificativa partirá da correspondência natural entre malhas CEM/CFD e estruturas de grafo.

4.2 Meshes as graphs

Serão avaliadas representações por nós, arestas, faces e, quando necessário, células volumétricas.

4.3 Message passing

Formalização do ciclo mensagem-agregação-atualização-readout e sua interpretação em problemas de PDEs discretizadas.

4.4 Node, edge and face features

Features geométricas, físicas, operacionais e, posteriormente, atributos derivados de Álgebra Geométrica.

4.5 Geometric representations

Comparação entre coordenadas cartesianas, invariantes geométricos, representações equivariantes e possíveis objetos multivetoriais.

4.6 Equivariance and invariance

Definição das propriedades desejáveis frente a rotações, translações, mudança de orientação e remalhamento.

4.7 Physics-informed GNNs

A física será incorporada prioritariamente como regularização, supervisão auxiliar ou informação de baixa fidelidade, evitando pressupor que uma PINN completa seja a solução adequada ao loop de otimização.

4.8 Electromagnetic surrogate

Entradas, saídas de RCS/campo e tarefas auxiliares serão especificadas durante o desenvolvimento.

4.9 Aerodynamic surrogate

Predição de coeficientes e, quando necessário, campos intermediários adequados à regularização pelas equações de Euler.

4.10 Uncertainty quantification

A incerteza epistemológica será usada tanto para validação quanto para *active learning*.

4.11 Estudos de ablação

O projeto deverá separar empiricamente os ganhos de:

1. uso de grafo;
2. representação geométrica/AG;
3. regularização física;
4. multifidelidade.

Status M0: estrutura editorial preparada; este capítulo será priorizado após a definição do problema no M1.

5 Multifidelity Learning and Adaptive Data Generation

A multifidelidade é central para tornar o treinamento das GNNs economicamente viável quando dados de alta fidelidade são caros.

5.1 Computational cost hierarchy

Caracterização explícita do custo dos diferentes níveis de solver.

5.2 Low- and high-fidelity models

Definição de baixa, média e alta fidelidade e critérios de compatibilidade entre respostas.

5.3 Electromagnetic fidelity hierarchy

Estrutura preliminar a revisar durante o projeto:

PO/LE-PO $\rightarrow$ SBR+/UTD/PTD ou equivalente HF $\rightarrow$ validação experimental, quando disponível.

5.4 Aerodynamic fidelity hierarchy

Estrutura preliminar:

painel/VSPAERO $\rightarrow$ Euler $\rightarrow$ RANS/CFD de referência.

5.5 Multi-Fidelity GNNs

Uma hipótese de referência será aprender a discrepância entre níveis:

$$y_{HF} = y_{LF} + \Delta_{\theta}(G, y_{LF}).$$

5.6 Residual correction and transfer learning

Serão comparadas estratégias de correção residual, *coarse-to-fine*, currículo e transferência entre fidelidades.

5.7 Active learning

A aquisição de novos casos deverá considerar:

- incerteza epistemológica;
- discrepância LF–HF;
- proximidade de regiões promissoras para a fronteira de Pareto;
- risco de picos de RCS ou degradação aerodinâmica.

5.8 Uncertainty-driven sampling

A incerteza será avaliada como componente explícito do ciclo de geração de dados.

Status M0: estrutura editorial preparada; o conteúdo será expandido após o capítulo de GNNs.

6 GNN-Accelerated Multidisciplinary Aero-Stealth Optimization

Este capítulo integrará os surrogates eletromagnético e aerodinâmico ao processo de otimização multidisciplinar.

6.1 Design variables

Variáveis contínuas, inteiras e categóricas serão definidas a partir da parametrização real do UCAV.

6.2 Objectives

Serão investigadas funções objetivo relacionadas a RCS, risco de picos e desempenho aerodinâmico.

6.3 Constraints

Restrições físicas, geométricas e operacionais serão explicitadas antes da escolha final do algoritmo de otimização.

6.4 NLP and MINLP

O problema será classificado como NLP ou MINLP somente após a definição das variáveis discretas. A Álgebra Geométrica estruturará representações e modelos físicos, enquanto os solvers de otimização operarão sobre objetivos e restrições escalares.

6.5 Multiobjective optimization

A análise será orientada à fronteira de Pareto aero-stealth.

6.6 Surrogate-assisted optimization

A GNN será usada para substituir avaliações caras durante grande parte da busca, com chamadas HF seletivas para calibração e validação.

6.7 High-fidelity revalidation

Soluções candidatas deverão ser reavaliadas nos solvers de referência antes de conclusões de engenharia.

6.8 Computational speed-up

Uma métrica central será o *speed-up* da otimização completa:

$$S_{\text{MDO}} = \frac{T_{\text{MDO,baseline}}}{T_{\text{MDO,GNN}}}.$$

O tempo total deverá incluir geração dos dados, treinamento, otimização e revalidação para evitar estimativas artificiais de aceleração.

6.9 Pareto quality

Serão definidas métricas para comparar a fronteira produzida pelo surrogate com soluções revalidadas em alta fidelidade.

Status M0: estrutura editorial preparada; a formulação final será desenvolvida após a consolidação das disciplinas físicas e dos surrogates.

Aleisa, Hassan, Konstantinos Kontis, Berkay Pirlepel, e Melike Nikbay. 2023. “Conceptual Design of a Nonconstant Swept Flying Wing Unmanned Combat Aerial Vehicle”. *Journal of Aircraft* 60 (6): 1872–88. <https://doi.org/10.2514/1.C037257>.

Belotti, Pietro, Christian Kirches, Sven Leyffer, Jeff Linderoth, James Luedtke, e Ashutosh Mahajan. 2013. “Mixed-Integer Nonlinear Optimization”. *Acta Numerica* 22: 1–131. <https://doi.org/10.1017/S0962492913000032>.

Black, Nolan, e Ahmad R. Najafi. 2022. “Learning Finite Element Convergence with the Multi-Fidelity Graph Neural Network”. *Computer Methods in Applied Mechanics and Engineering* 397: 115120. <https://doi.org/10.1016/j.cma.2022.115120>.

- Bronstein, Michael M., Joan Bruna, Taco Cohen, e Petar Veličković. 2021. “Geometric Deep Learning: Grids, Groups, Graphs, Geodesics, and Gauges”. *arXiv preprint arXiv:2104.13478*. <https://arxiv.org/abs/2104.13478>.
- Chen, Junfeng, Elie Hachem, e Jonathan Viquerat. 2021. “Graph Neural Networks for Laminar Flow Prediction Around Random Two-Dimensional Shapes”. *Physics of Fluids* 33 (12): 123607. <https://doi.org/10.1063/5.0064108>.
- Department of the Air Force. 2020. *Air Force Instruction 16-401: Designating and Naming Defense Military Aerospace Vehicles*. Department of the Air Force.
- Doran, Chris, e Anthony Lasenby. 2003. *Geometric Algebra for Physicists*. Cambridge University Press. <https://doi.org/10.1017/CBO9780511807497>.
- Dressel, Justin, Konstantin Y. Bliokh, e Franco Nori. 2015. “Spacetime Algebra as a Powerful Tool for Electromagnetism”. *Physics Reports* 589: 1–71. <https://doi.org/10.1016/j.physrep.2015.06.001>.
- Hestenes, David, e Garret Sobczyk. 1984. *Clifford Algebra to Geometric Calculus: A Unified Language for Mathematics and Physics*. D. Reidel Publishing Company.
- Hu, Tianyuan, e Xiongqing Yu. 2009. “Aerodynamic/Stealthy/Structural Multidisciplinary Design Optimization of Unmanned Combat Air Vehicle”. *Chinese Journal of Aeronautics* 22 (4): 380–86. [https://doi.org/10.1016/S1000-9361\(08\)60114-4](https://doi.org/10.1016/S1000-9361(08)60114-4).
- Knott, Eugene F., John F. Shaeffer, e Michael T. Tuley. 1993. *Radar Cross Section*. 2^o ed. Artech House.
- Kong, De-Hua, Jia-Ning Cao, Wen-Wei Zhang, Wen-Chi Huang, Xiaoyang He, et al. 2024. “An AI Predictor: From Point Clouds to Scattered Far Fields for 3-D PEC Targets”. *IEEE Transactions on Antennas and Propagation* 72 (6): 5179–90. <https://doi.org/10.1109/TAP.2024.3390615>.
- Lee, Jon, e Sven Leyffer, org. 2012. *Mixed Integer Nonlinear Programming*. V. 154. The IMA Volumes em Mathematics e its Applications. Springer. <https://doi.org/10.1007/978-1-4614-1927-3>.
- Leng, Jun-Xue, Zhen-Guo Wang, Wei Huang, Yang Shen, e Kai An. 2025. “Multidisciplinary Design Optimization Processes for Efficiency Improvement of Aircraft: State-of-the-Art Review”. *International Journal of Aeronautical and Space Sciences* 26 (4): 2020–42. <https://doi.org/10.1007/s42405-024-00811-8>.
- Li, Chunyun, Bowen Shu, Ke Zhao, Longzhou Yu, Yongbo Li, e Huan Zhao. 2026. “Multi-

- task Diffusion Graph Model for Aero-Electromagnetic Analysis of Blended-Wing-Body Configurations”. *Physics of Fluids* 38 (5): 057104. <https://doi.org/10.1063/5.0326519>.
- Li, Ming, Junqiang Bai, Li Li, Xiaoxuan Meng, Qing Liu, e Bai Chen. 2019. “A Gradient-Based Aero-Stealth Optimization Design Method for Flying Wing Aircraft”. *Aerospace Science and Technology* 92: 156–69. <https://doi.org/10.1016/j.ast.2019.05.067>.
- Li, Zongyi, Nikola Kovachki, Chris Choy, et al. 2023. “Geometry-Informed Neural Operator for Large-Scale 3D PDEs”. *Advances in Neural Information Processing Systems* 36. <https://doi.org/10.52202/075280-1556>.
- Liersch, Carsten M., Russell M. Cummings, Andreas Schütte, Jan Vormweg, Ryan G. Maye, e Tiger L. Jeans. 2020. “Multi-Disciplinary Design and Performance Assessment of Effective, Agile NATO Air Vehicles”. *Aerospace Science and Technology* 99: 105764. <https://doi.org/10.1016/j.ast.2020.105764>.
- Martins, Joaquim R. R. A., e Andrew B. Lambe. 2013. “Multidisciplinary Design Optimization: A Survey of Architectures”. *AIAA Journal* 51 (9): 2049–75. <https://doi.org/10.2514/1.J051895>.
- Nguyen, Nhu-Van, Seok-Min Choi, Wan-Sub Kim, et al. 2013. “Multidisciplinary Unmanned Combat Air Vehicle System Design Using Multi-Fidelity Model”. *Aerospace Science and Technology* 26 (1): 200–210. <https://doi.org/10.1016/j.ast.2012.04.004>.
- Nikbay, Melike, Sihmehmet Yildiz, Berkay Pirlepel, e Konstantinos Kontis. 2026. “Multidisciplinary Design Optimization of a Non-Planar Flying Wing UCAV Concept”. *Aerospace Science and Technology* 177: 112285. <https://doi.org/10.1016/j.ast.2026.112285>.
- Papageorgiou, Athanasios, Mehdi Tarkian, Kristian Amadori, e Johan Ölvander. 2018. “Multi-disciplinary Optimization of Unmanned Aircraft Considering Radar Signature, Sensors, and Trajectory Constraints”. *Journal of Aircraft* 55 (3). <https://doi.org/10.2514/1.C034314>.
- Peng, Jiang-Zhou, Yue Hua, Nadine Aubry, Zhi-Hua Chen, Mei Mei, e Wei-Tao Wu. 2024. “Data and Physics-Driven Modeling for Fluid Flow with a Physics-Informed Graph Convolutional Neural Network”. *Ocean Engineering* 301: 117551. <https://doi.org/10.1016/j.oceaneng.2024.117551>.
- Pfaff, Tobias, Meire Fortunato, Alvaro Sanchez-Gonzalez, e Peter W. Battaglia. 2021. “Learning Mesh-Based Simulation with Graph Networks”. *International Conference on Learning Representations*.
- Roy, Satadru, Kenneth Moore, John T. Hwang, Justin S. Gray, William A. Crossley, e Joaquim R. R. A. Martins. 2017. “A Mixed Integer Efficient Global Optimization Algorithm for the

- Simultaneous Aircraft Allocation-Mission-Design Problem”. *58th AIAA/ASCE/AHS/ASC Structures, Structural Dynamics, and Materials Conference*. <https://doi.org/10.2514/6.2017-1305>.
- Sepulveda, Eduardo, e Howard Smith. 2017. “Technology Challenges of Stealth Unmanned Combat Aerial Vehicles”. *The Aeronautical Journal* 121 (1243): 1261–95. <https://doi.org/10.1017/aer.2017.53>.
- Sepulveda, E., H. Smith, e D. Sziroczak. 2019. “Multidisciplinary Analysis of Subsonic Stealth Unmanned Combat Aerial Vehicles”. *CEAS Aeronautical Journal* 10: 431–42. <https://doi.org/10.1007/s13272-018-0325-0>.
- Shan, Tao, Maokun Li, Fan Yang, e Shenheng Xu. 2024. “Solving Combined Field Integral Equations With Physics-Informed Graph Residual Learning for EM Scattering of 3-D PEC Targets”. *IEEE Transactions on Antennas and Propagation* 72 (1): 733–44. <https://doi.org/10.1109/TAP.2023.3331262>.
- Shi, Renhe, Teng Long, Nianhui Ye, Yufei Wu, Zhao Wei, e Zhenyu Liu. 2021. “Metamodel-Based Multidisciplinary Design Optimization Methods for Aerospace System”. *Astrodynamics* 5: 185–215. <https://doi.org/10.1007/s42064-021-0109-x>.
- Silva, João Pedro Rocha. 2026. *Implementação Teórica e Prática para Caracterização de Seção Reta Radar em Laboratório*. Trabalho de Conclusão de Curso, Bacharelado em Engenharia Aeroespacial, Universidade de Brasília.
- Taghizadeh, Mohammad, Mohammad Amin Nabian, e Negin Alemazkoor. 2025. “Multifidelity Graph Neural Networks for Efficient and Accurate Mesh-Based Partial Differential Equations Surrogate Modeling”. *Computer-Aided Civil and Infrastructure Engineering* 40: 841–58. <https://doi.org/10.1111/mice.13312>.
- Thoulon, C., G. Roge, e O. Pironneau. 2024. “Gradient-Based Aero-Stealth Optimization of a Simplified Aircraft”. *Fluids* 9 (8): 174. <https://doi.org/10.3390/fluids9080174>.