

Graph Neural Networks e Álgebra Geométrica para Otimização Aero-Stealth de UCAVs

**Modelagem multifidelidade de Maxwell e Euler e aceleração da otimização
multidisciplinar**

Índice

UCAV Aero-Stealth Optimization with Multifidelity Graph Neural Networks	4
Sobre este projeto	4
Objetivo geral	4
Arquitetura da pesquisa	4
Questões metodológicas centrais	5
Organização do eBook	5
Estado atual	5
1 Aero-Stealth Optimization of a UCAV Flying-Wing	6
1.1 UCAV flying-wing e problema aero-stealth	6
1.2 Gargalo computacional	6
1.3 Formulação multidisciplinar preliminar	6
1.4 Objetivo e questão de pesquisa	7
1.5 Hipóteses e métricas	7
2 Geometric Algebra for Physical and Geometric Representation	8
2.1 Da álgebra linear e tensorial à Álgebra Geométrica	8
2.2 Álgebra de Clifford	8
2.3 Matrizes, tensores e sistemas de equações	8
2.4 Representação de malhas	9
2.5 Papel da AG no aprendizado	9
3 Electromagnetic and Aerodynamic Governing Equations	10
3.1 Electromagnetics	10
3.1.1 Maxwell equations	10
3.1.2 Differential-form representation	10
3.1.3 Geometric Algebra formulation	10
3.1.4 Electromagnetic scattering and RCS	10
3.2 Aerodynamics	11
3.2.1 Perfect gas and inviscid subsonic flow	11
3.2.2 Euler equations	11
3.2.3 Geometric Algebra formulation	11
3.2.4 Aerodynamic outputs	11
3.3 Uso na regularização das GNNs	11

4	Graph Neural Networks for Physics-Based Surrogate Modeling	12
4.1	Why graphs?	12
4.2	Meshes as graphs	12
4.3	Message passing	12
4.4	Node, edge and face features	12
4.5	Geometric representations	13
4.6	Equivariance and invariance	13
4.7	Physics-informed GNNs	13
4.8	Electromagnetic surrogate	13
4.9	Aerodynamic surrogate	13
4.10	Uncertainty quantification	13
4.11	Estudos de ablação	14
5	Multifidelity Learning and Adaptive Data Generation	15
5.1	Computational cost hierarchy	15
5.2	Low- and high-fidelity models	15
5.3	Electromagnetic fidelity hierarchy	15
5.4	Aerodynamic fidelity hierarchy	15
5.5	Multi-Fidelity GNNs	16
5.6	Residual correction and transfer learning	16
5.7	Active learning	16
5.8	Uncertainty-driven sampling	16
6	GNN-Accelerated Multidisciplinary Aero-Stealth Optimization	17
6.1	Design variables	17
6.2	Objectives	17
6.3	Constraints	17
6.4	NLP and MINLP	17
6.5	Multiobjective optimization	17
6.6	Surrogate-assisted optimization	18
6.7	High-fidelity revalidation	18
6.8	Computational speed-up	18
6.9	Pareto quality	18

UCAV Aero-Stealth Optimization with Multifidelity Graph Neural Networks

Sobre este projeto

Este eBook documenta o desenvolvimento de um framework de otimização multidisciplinar aero-stealth para configurações UCAV *flying-wing*. A contribuição computacional central é o emprego de **Graph Neural Networks (GNNs) multifidelidade** como modelos substitutos para reduzir o custo das avaliações eletromagnéticas e aerodinâmicas repetidas durante a otimização.

A Álgebra Geométrica (AG) é investigada como uma linguagem para representação geométrica e regularização física das GNNs. Seu eventual benefício computacional será tratado como hipótese de pesquisa a ser testada, e não como premissa.

Objetivo geral

Desenvolver e validar modelos substitutos baseados em Graph Neural Networks multifidelidade e *physics-informed*, com representação geométrica fundamentada em Álgebra Geométrica, para acelerar a otimização multidisciplinar da seção reta radar e do desempenho aerodinâmico de um UCAV *flying-wing*.

Arquitetura da pesquisa

A arquitetura metodológica de referência é:

CAD/OpenVSP → malha/grafos → solvers LF/HF → GNN multifidelidade → otimização aero-stealth → reval

A motivação para grafos decorre da estrutura natural de malhas triangulares e não estruturadas, amplamente explorada em *geometric deep learning* e simulação baseada em malhas (Bronstein et al. 2021; Pfaff et al. 2021). A formulação de Maxwell em Álgebra do Espaço-Tempo fornece uma referência importante para a investigação da regularização eletromagnética em AG (Dressel

et al. 2015). O problema de compromisso entre aerodinâmica e baixa observabilidade também possui antecedentes recentes em otimização aero-stealth (Thoulon et al. 2024).

Questões metodológicas centrais

O projeto investiga, entre outras questões:

1. quanto uma GNN reduz o custo de uma avaliação eletromagnética ou aerodinâmica;
2. quanto a modelagem multifidelidade reduz a necessidade de dados de alta fidelidade;
3. se regularização física melhora precisão e generalização em regimes de poucos dados;
4. se representações em Álgebra Geométrica melhoram invariância, equivariância, eficiência amostral ou robustez;
5. quanto o uso dos *surrogates* acelera a otimização completa, incluindo o custo de geração de dados e treinamento;
6. se as soluções obtidas pelo processo acelerado preservam a qualidade da fronteira de Pareto após revalidação em alta fidelidade.

Organização do eBook

Os capítulos evoluirão incrementalmente, acompanhando a pesquisa:

- definição do problema aero-stealth;
- fundamentos e papel da Álgebra Geométrica;
- equações físicas de Maxwell/RCS e Euler/aerodinâmica;
- GNNs para *surrogate modeling*;
- multifidelidade, incerteza e *active learning*;
- otimização multidisciplinar acelerada e validação.

Estado atual

Este repositório encontra-se em desenvolvimento. O **Milestone 0 (M0)** estabelece a infraestrutura reproduzível em Quarto, a bibliografia inicial, os metadados do projeto e a validação automatizada de renderização. Os capítulos científicos serão desenvolvidos de forma incremental nos marcos subsequentes.

1 Aero-Stealth Optimization of a UCAV Flying-Wing

Este capítulo definirá o problema de engenharia que motiva todo o framework. Seu propósito é estabelecer o escopo antes de introduzir Álgebra Geométrica, GNNs ou algoritmos de otimização.

1.1 UCAV flying-wing e problema aero-stealth

Conteúdo a desenvolver no M1:

- configuração UCAV *flying-wing*;
- Radar Cross Section (RCS) e baixa observabilidade;
- desempenho aerodinâmico subsônico;
- conflito e sinergias entre requisitos aerodinâmicos e eletromagnéticos;
- parametrização geométrica relevante ao problema.

1.2 Gargalo computacional

O capítulo caracterizará o custo de avaliações CEM e CFD e explicará por que a exploração direta do espaço de projeto com solvers de alta fidelidade pode se tornar proibitiva.

1.3 Formulação multidisciplinar preliminar

Serão definidos progressivamente:

- variáveis de projeto;
- condições operacionais;
- funções objetivo de RCS e aerodinâmica;
- restrições geométricas e físicas;
- níveis de fidelidade disponíveis.

1.4 Objetivo e questão de pesquisa

O objetivo central será formulado em termos da **aceleração da otimização por GNNs multifidelidade**, preservando precisão suficiente para revalidação de soluções candidatas em alta fidelidade.

1.5 Hipóteses e métricas

Serão explicitadas hipóteses sobre:

- ganho por representação em grafos;
- ganho por multifidelidade;
- ganho por regularização física;
- contribuição incremental da Álgebra Geométrica;
- *speed-up* de avaliação e da otimização completa;
- qualidade da fronteira de Pareto revalidada.

Status M0: estrutura editorial preparada. O conteúdo científico será desenvolvido no M1 a partir do TCC, do relatório sobre GNNs e das referências bibliográficas revisadas.

2 Geometric Algebra for Physical and Geometric Representation

Este capítulo apresentará a Álgebra Geométrica (AG) como linguagem de representação para geometria, campos e regularização física das GNNs. O projeto não assume a priori que AG reduz custo computacional; essa possibilidade será avaliada empiricamente.

2.1 Da álgebra linear e tensorial à Álgebra Geométrica

- vetores e covetores;
- tensores e transformações multilineares;
- métrica;
- álgebra exterior e produto exterior;
- relação entre formas diferenciais e multivetores.

2.2 Álgebra de Clifford

- produto geométrico;
- escalares, vetores, bivectores e multivetores;
- projeção por grau;
- pseudoescalar e dualidade;
- reversão, norma e inversa;
- versores e rotores.

2.3 Matrizes, tensores e sistemas de equações

O capítulo distinguirá objetos geométricos de suas representações matriciais e discutirá como operadores lineares, tensores e sistemas de equações podem ser expressos e implementados sem identificar indevidamente todo tensor com um multivetor.

2.4 Representação de malhas

Serão investigadas representações de faces, arestas, normais, áreas orientadas e transformações relativas adequadas a grafos derivados de malhas CEM/CFD.

2.5 Papel da AG no aprendizado

A contribuição da AG será testada por estudos de ablação, comparando representações cartesianas convencionais com representações geométricas estruturadas.

Status M0: estrutura editorial preparada; a fundamentação será expandida após a consolidação do corpus bibliográfico de AG.

3 Electromagnetic and Aerodynamic Governing Equations

Este capítulo reunirá os dois domínios físicos que geram os dados e as restrições usadas pelas GNNs.

3.1 Electromagnetics

3.1.1 Maxwell equations

Apresentação convencional das equações de Maxwell, condições constitutivas e condições de contorno relevantes ao espalhamento eletromagnético.

3.1.2 Differential-form representation

Ponte entre cálculo vetorial, formas diferenciais e formulações independentes de coordenadas.

3.1.3 Geometric Algebra formulation

Maxwell será investigado em Álgebra Geométrica/Álgebra do Espaço-Tempo como **unificação compacta das equações**, e não como uma suposta linearização de um sistema que já é linear nos campos em meios lineares.

3.1.4 Electromagnetic scattering and RCS

- campo incidente e espalhado;
- condições PEC e materiais;
- correntes superficiais;
- campo distante;
- RCS e polarizações;
- fidelidades CEM relevantes.

3.2 Aerodynamics

3.2.1 Perfect gas and inviscid subsonic flow

Definição do modelo físico e domínio de validade.

3.2.2 Euler equations

- conservação de massa;
- conservação de quantidade de movimento;
- conservação de energia;
- equação de estado de gás perfeito;
- condições de contorno.

3.2.3 Geometric Algebra formulation

A AG será usada para investigar uma reformulação geometricamente estruturada das equações de Euler. A não linearidade física das equações de Euler deverá ser preservada e tratada explicitamente.

3.2.4 Aerodynamic outputs

- distribuição de pressão;
- C_L ;
- C_D ;
- C_m ;
- L/D ;
- fidelidades aerodinâmicas de referência.

3.3 Uso na regularização das GNNs

O capítulo culminará na definição de resíduos físicos e condições de contorno que possam ser incorporados às funções de perda dos modelos aprendidos.

Status M0: estrutura editorial preparada; as derivações serão incluídas após revisão específica da literatura de Maxwell/GA e Euler/GA.

4 Graph Neural Networks for Physics-Based Surrogate Modeling

As Graph Neural Networks constituem a **principal contribuição computacional** do projeto: substituir grande parte das avaliações repetidas dos solvers físicos por inferências rápidas dentro do processo de otimização, mantendo revalidação de alta fidelidade para as soluções relevantes.

4.1 Why graphs?

A justificativa partirá da correspondência natural entre malhas CEM/CFD e estruturas de grafo.

4.2 Meshes as graphs

Serão avaliadas representações por nós, arestas, faces e, quando necessário, células volumétricas.

4.3 Message passing

Formalização do ciclo mensagem-agregação-atualização-readout e sua interpretação em problemas de PDEs discretizadas.

4.4 Node, edge and face features

Features geométricas, físicas, operacionais e, posteriormente, atributos derivados de Álgebra Geométrica.

4.5 Geometric representations

Comparação entre coordenadas cartesianas, invariantes geométricos, representações equivariantes e possíveis objetos multivetoriais.

4.6 Equivariance and invariance

Definição das propriedades desejáveis frente a rotações, translações, mudança de orientação e remalhamento.

4.7 Physics-informed GNNs

A física será incorporada prioritariamente como regularização, supervisão auxiliar ou informação de baixa fidelidade, evitando pressupor que uma PINN completa seja a solução adequada ao loop de otimização.

4.8 Electromagnetic surrogate

Entradas, saídas de RCS/campo e tarefas auxiliares serão especificadas durante o desenvolvimento.

4.9 Aerodynamic surrogate

Predição de coeficientes e, quando necessário, campos intermediários adequados à regularização pelas equações de Euler.

4.10 Uncertainty quantification

A incerteza epistemológica será usada tanto para validação quanto para *active learning*.

4.11 Estudos de ablação

O projeto deverá separar empiricamente os ganhos de:

1. uso de grafo;
2. representação geométrica/AG;
3. regularização física;
4. multifidelidade.

Status M0: estrutura editorial preparada; este capítulo será priorizado após a definição do problema no M1.

5 Multifidelity Learning and Adaptive Data Generation

A multifidelidade é central para tornar o treinamento das GNNs economicamente viável quando dados de alta fidelidade são caros.

5.1 Computational cost hierarchy

Caracterização explícita do custo dos diferentes níveis de solver.

5.2 Low- and high-fidelity models

Definição de baixa, média e alta fidelidade e critérios de compatibilidade entre respostas.

5.3 Electromagnetic fidelity hierarchy

Estrutura preliminar a revisar durante o projeto:

PO/LE-PO $\rightarrow$ SBR+/UTD/PTD ou equivalente HF $\rightarrow$ validação experimental, quando disponível.

5.4 Aerodynamic fidelity hierarchy

Estrutura preliminar:

painel/VSPAERO $\rightarrow$ Euler $\rightarrow$ RANS/CFD de referência.

5.5 Multi-Fidelity GNNs

Uma hipótese de referência será aprender a discrepância entre níveis:

$$y_{HF} = y_{LF} + \Delta_{\theta}(G, y_{LF}).$$

5.6 Residual correction and transfer learning

Serão comparadas estratégias de correção residual, *coarse-to-fine*, currículo e transferência entre fidelidades.

5.7 Active learning

A aquisição de novos casos deverá considerar:

- incerteza epistemológica;
- discrepância LF–HF;
- proximidade de regiões promissoras para a fronteira de Pareto;
- risco de picos de RCS ou degradação aerodinâmica.

5.8 Uncertainty-driven sampling

A incerteza será avaliada como componente explícito do ciclo de geração de dados.

Status M0: estrutura editorial preparada; o conteúdo será expandido após o capítulo de GNNs.

6 GNN-Accelerated Multidisciplinary Aero-Stealth Optimization

Este capítulo integrará os surrogates eletromagnético e aerodinâmico ao processo de otimização multidisciplinar.

6.1 Design variables

Variáveis contínuas, inteiras e categóricas serão definidas a partir da parametrização real do UCAV.

6.2 Objectives

Serão investigadas funções objetivo relacionadas a RCS, risco de picos e desempenho aerodinâmico.

6.3 Constraints

Restrições físicas, geométricas e operacionais serão explicitadas antes da escolha final do algoritmo de otimização.

6.4 NLP and MINLP

O problema será classificado como NLP ou MINLP somente após a definição das variáveis discretas. A Álgebra Geométrica estruturará representações e modelos físicos, enquanto os solvers de otimização operarão sobre objetivos e restrições escalares.

6.5 Multiobjective optimization

A análise será orientada à fronteira de Pareto aero-stealth.

6.6 Surrogate-assisted optimization

A GNN será usada para substituir avaliações caras durante grande parte da busca, com chamadas HF seletivas para calibração e validação.

6.7 High-fidelity revalidation

Soluções candidatas deverão ser reavaliadas nos solvers de referência antes de conclusões de engenharia.

6.8 Computational speed-up

Uma métrica central será o *speed-up* da otimização completa:

$$S_{\text{MDO}} = \frac{T_{\text{MDO,baseline}}}{T_{\text{MDO,GNN}}}.$$

O tempo total deverá incluir geração dos dados, treinamento, otimização e revalidação para evitar estimativas artificiais de aceleração.

6.9 Pareto quality

Serão definidas métricas para comparar a fronteira produzida pelo surrogate com soluções revalidadas em alta fidelidade.

Status M0: estrutura editorial preparada; a formulação final será desenvolvida após a consolidação das disciplinas físicas e dos surrogates.

Bronstein, Michael M., Joan Bruna, Taco Cohen, e Petar Veličković. 2021. “Geometric Deep Learning: Grids, Groups, Graphs, Geodesics, and Gauges”. *arXiv preprint arXiv:2104.13478*. <https://arxiv.org/abs/2104.13478>.

Dressel, Justin, Konstantin Y. Bliokh, e Franco Nori. 2015. “Spacetime Algebra as a Powerful Tool for Electromagnetism”. *Physics Reports* 589: 1–71. <https://doi.org/10.1016/j.physrep.2015.06.001>.

Pfaff, Tobias, Meire Fortunato, Alvaro Sanchez-Gonzalez, e Peter W. Battaglia. 2021. “Learning Mesh-Based Simulation with Graph Networks”. *International Conference on Learning Representations*.

Thoulon, C., G. Roge, e O. Pironneau. 2024. “Gradient-Based Aero-Stealth Optimization of a Simplified Aircraft”. *Fluids* 9 (8): 174. <https://doi.org/10.3390/fluids9080174>.